

INTERVIEW BANK · VERSION 1

第一版面经题库

多模态 · VLA/具身智能 · 视频理解 · 世界模型 · 训练框架 · 推理部署

收录时间 2026-06-05 至 2026-06-24

题目规模 152 道题 · 52 个来源

覆盖方向 7 个核心方向

公司/机构 Qwen、字节、字节跳动、小鹏、快手、智元、汇川、百度、美团、腾讯、蔚来、
通义 / 小红书 / Seed / 混元相关团队、阿里

生成日期 2026-06-24

使用说明：目录、题目索引和 PDF 书签均支持点击跳转。每道题保留来源、公司、方向和完整模型回答。

版本说明与覆盖范围

版本	第一版
来源起止时间	2026-06-05 至 2026-06-24
题目总数	152
来源总数	52
覆盖公司/机构	Qwen、字节、字节跳动、小鹏、快手、智元、汇川、百度、美团、腾讯、蔚来、通义 / 小红书 / Seed / 混元相关团队、阿里
覆盖范围	多模态大模型、VLA/具身智能、视频与视觉理解、世界模型与自动驾驶、训练框架、推理部署与模型压缩、强化学习与对齐、音频多模态

方向分布

方向	题目数	来源数
多模态大模型	46	20
VLA 与具身智能	30	12
视频与视觉理解	21	4
世界模型与自动驾驶	13	3
训练框架与大规模训练	23	4
推理部署与模型压缩	13	5
强化学习与模型对齐	6	4

目录

版本说明与覆盖范围	2
目录	3
题目索引	6
1. 多模态大模型	13
1.1 字节跳动·知乎：字节多模态大模型一面	13
1.2 未标明·题库：多模态大模型视觉语言对齐专项	13
1.3 字节·知乎：【清华代码熊】字节面试官：多模态大模型动态分辨率原理？	15
1.4 未标明·小红书：理想多模态大模型一面面经	17
1.5 未标明·知乎：【清华代码熊】面试官：多模态大模型视觉Token压缩方法？	17
1.6 快手·CSDN：【26届校招】快手大模型算法岗面经：从多模态模型到LoRA技术，面试官常问问题详解！	19
1.7 未标明·B站：1.5万 13 06:16 面试官：大模型中为什么不使用Dropout	19
1.8 未标明·B站：1131 0 10:52:02 【2026最新计算机视觉教程】传统CV+视觉大模型，算法原理+框架详解+源码解读+项目实战	20
1.9 未标明·Qwen-VL视觉语言题目精讲	20
1.10 Qwen·CSDN：大模型面试题85：Qwen2.5	21
1.11 字节·小红书：算法面经：字节大模型多模态	21
1.12 快手·CSDN：快手多模态算法工程师面试题精选：10道高频考题+答案解析	22
1.13 快手·小红书：算法面经：快手大模型一二面	22
1.14 未标明·CSDN：大模型最新面试题系列：微调篇之微调框架（三）	23
1.15 未标明·CSDN：大模型最新面试题系列：微调篇之微调框架（二）	23
1.16 未标明·CSDN：大模型面试题剖析：大模型多模态微调技术全解析	24
1.17 未标明·小红书：多模态面经	24
1.18 未标明·知乎：大模型的一些面试题小结	25
1.19 腾讯·小红书：算法面经：腾讯混元大模型算法	25
1.20 阿里·小红书：阿里大模型算法面经	25
2. VLA 与具身智能	26
2.1 未标明·题库：VLA 与具身智能控制专项	26
2.2 字节·小红书：字节VLA具身智能题目精讲	28
2.3 未标明·B站：1573 0 06:46 机器人中间件要学到什么程度才能和面试官对线	30
2.4 未标明·CSDN：具身智能TL常用算法面经：基础认知与 VLA 框架(一)	30
2.5 未标明·CSDN：具身智能TL常用算法面经：经典 VLA 模型与动作生成范式(二)	31

2.6 智元·掘金：CodeSheep 1月前 前端 后端 稚晖君又开始摇人了，有点猛啊！ 作为具身智能领域的新起独角兽，智元机器人这两年在资本市场可谓是备受关注。谁都没有想到，这家成立仅仅... 参与具身智能基础模型研发，覆盖 VLM/VLA/Vide	31
2.7 汇川·B站：1.0万 0 30:16 汇川C++机器人控制算法面试题	32
2.8 未标明·B站：334 0 00:20 VLA动作置信度≠任务成功率	32
2.9 小鹏·B站：2234 1 05:08 机器人强化学习算法岗位研究--以小鹏机器人为例,拼不过科班出身的了解一下!技术基础/ 开发教程/算法/训练/薪资/硕士就业分析/招聘岗位/ROS开源项目/ 机器人研究员DeepMeet·01-04	33
2.10 未标明·CSDN：Pi0具身智能Java面试题解析：核心技术考点详解	33
2.11 未标明·CSDN：中国移动具身智能算法（VLA预训练及模型架构方向）面试题精选：10道高频考题+答案解析 . 34	
2.12 腾讯·小红书：腾讯RoboticsX 具身智能算法一面（贼难）	34

3. 视频与视觉理解 35

3.1 通义 / 小红书 / Seed / 混元相关团队·脉脉：语音/音频大模型岗位要求与面试关注点	35
3.2 未标明·题库：视频理解与时序建模专项	36
3.3 未标明·CSDN：大模型，多模态大模型面试问题记录【时序，Qformer，卷积，感受野,ControlNet，IP	38
3.4 未标明·B站：2082 0 35:11 多模态大模型视频理解加速 VideoAuto-R1：GRPO 强化学习 + 置信度，实现动态推理与Early Exit 让视频推理又快又准 唐国梁Tommy·01-22	40

4. 世界模型与自动驾驶 40

4.1 蔚来·小红书：蔚来大模型算法面经	40
4.2 未标明·题库：自动驾驶数据闭环与世界模型专项	41
4.3 小鹏·小红书：小鹏汽车多模态大模型算法面经 momo 2025	43

5. 训练框架与大规模训练 44

5.1 未标明·脉脉：大模型训练框架面经讨论	44
5.2 未标明·题库：大模型训练框架与显存优化专项	44
5.3 字节·小红书：字节训练框架推理优化题目精讲	46
5.4 字节·CSDN：【26届校招】字节多模态大模型面经：一文掌握DeepSpeed、LoRA、RLHF等核心技术！	49

6. 推理部署与模型压缩 50

6.1 百度·脉脉：百度 AIDU 大模型算法面经	50
6.2 未标明·题库：大模型推理部署与模型压缩专项	50
6.3 未标明·Qwen2.5大模型题目精讲	52
6.4 美团·掘金：机器之心 2年前 人工智能 AIGC 骁龙888实时运行，美团、浙大等打造全流程移动端多模态大模型MobileVLM 多模态大模型，包含了 LLM 基座训练、SFT、VLM 全流程。也许不久的将来，每个人都能方便、快捷、低成本的拥有属	53
6.5 未标明·CSDN：大模型最新面试题系列：模型部署（一）	53

7. 强化学习与模型对齐 54

7.1 字节·知乎：2026 最新字节大模型岗面经汇总	54
---------------------------------------	----

7.2 未标明·牛客：CLIP衍生进阶模型；检索场景模型适配改造思路 3. Transformer各类Decoder结构 4. 大模型通用预训练流程；电商垂域预训练必要性及原因 5. ...GRPO公式推导；PPO四大组成模型
手撕：多头注意力MHA代码 54

7.3 字节·CSDN：字节面试题：多模态大模型的模态对齐 55

7.4 美团·小红书：美团春招大模型算法岗面经·MoE+GRPO 55

题目索引

按编号快速定位。点击题目可跳转到完整回答。

编号	方向 / 公司	题目
001	多模态大模型 字节跳动	视觉 encoder 输出如何对齐到 LLM token 空间, Linear pr...
002	多模态大模型 未标明	CLIP 预训练中的对比学习目标如何影响后续 VLM 的视觉语义对齐能力?
003	多模态大模型 未标明	Linear projector、MLP projector、Q-Former 和...
004	多模态大模型 未标明	多模态指令微调数据如何避免 OCR 泄漏、答案模板化、负样本不足和评测集污染?
005	多模态大模型 未标明	视觉 grounding 能力应该如何评估, bbox、指代表达、区域问答和 hal...
006	多模态大模型 未标明	多图理解任务中图间关系、时间顺序和跨图实体一致性如何建模?
007	多模态大模型 未标明	为什么 VLM 容易出现视觉幻觉, 如何从数据、模型结构、解码和评测四个层面缓解?
008	多模态大模型 未标明	高分辨率图像输入时, patch 数量、token 压缩、局部裁剪和动态分辨率策略如...
009	多模态大模型 未标明	VLM 线上服务中如何平衡图像预处理延迟、视觉 encoder 复用、batchi...
010	多模态大模型 字节	Vision encoder 输出如何与 LLM token 空间对齐? Linea...
011	多模态大模型 字节	多模态模型如何评估 grounding、OCR、空间关系、幻觉和多轮视觉对话能力?
012	多模态大模型 字节	图文/视频指令微调数据如何构造, 如何控制噪声、偏见和 OCR 泄漏?
013	多模态大模型 字节	多模态大模型中, vision encoder 输出如何通过 projector、Q...
014	多模态大模型 字节	VLM 训练中图文对齐、指令微调和偏好对齐分别解决什么问题?
015	多模态大模型 字节	高分辨率图片输入时, 动态分辨率、tile 切分和 token 压缩如何取舍?
016	多模态大模型 字节	OCR、grounding、计数、空间关系这四类能力分别应该如何设计评估集?
017	多模态大模型 字节	多图理解任务中, 如何保证跨图实体一致性、顺序理解和比较推理能力?
018	多模态大模型 字节	VLM 产生视觉幻觉的常见原因有哪些, 数据、模型和解码侧分别怎么缓解?
019	多模态大模型 未标明	图像 caption 数据、VQA 数据和合成指令数据在多模态训练中的作用有什么差...
020	多模态大模型 未标明	多模态模型线上服务如何优化图片预处理、vision encoder 复用和首 to...

编号	方向 / 公司	题目
021	多模态大模型 未标明	KV cache 显存如何随 batch、序列长度、层数、head 数和 hidd...
022	多模态大模型 未标明	PagedAttention 为什么能提升显存利用率，和连续 KV cache 分...
023	多模态大模型 未标明	continuous batching 如何提升吞吐，为什么可能影响单请求延迟和调...
024	多模态大模型 未标明	speculative decoding 的收益取决于哪些因素，draft mod...
025	多模态大模型 未标明	INT8、INT4、AWQ、GPTQ、SmoothQuant 分别适合哪些量化和部...
026	多模态大模型 未标明	长上下文推理中，RoPE scaling、KV eviction、prefix c...
027	多模态大模型 快手	快手大模型算法面试中，多模态模型微调为什么常用 LoRA，它和全参微调的效果、成本...
028	多模态大模型 快手	短视频业务里的多模态模型，如何同时处理封面图、视频帧、OCR、ASR 和用户文本特...
029	多模态大模型 未标明	大模型训练中为什么很多 LLM 不再依赖 Dropout，它和数据规模、归一化、残...
030	多模态大模型 未标明	为什么通用 VLM 的检测能力通常弱于 YOLO，如何增强其定位和检测能力？
031	多模态大模型 未标明	Qwen-VL 类视觉语言模型如何把图像特征接入语言模型，训练流程通常分哪几步？
032	多模态大模型 Qwen	一、先搞懂：Qwen2.5-VL到底是什么？
033	多模态大模型 字节	Vision Transformer (ViT) 和 CNN 在图像特征提取上的优...
034	多模态大模型 字节	CLIP 模型的原理是什么？它是如何实现图文对齐的？损失函数怎么设计的？
035	多模态大模型 快手	题1：请讲讲CLIP的核心原理，它是怎么做图文对齐的？正样本冲突怎么处理？
036	多模态大模型 快手	题2：CLIP和BLIP的主要区别是什么？BLIP-2的Q-Former为什么这么...
037	多模态大模型 快手	Qwen 在训练时采用的 “packing” 形式和“多轮对话”形式有何区别？各自...
038	多模态大模型 快手	训练一个 8B 参数的大模型，大概需要多少显存？如果显存不够，你会用哪些技术缓解？
039	多模态大模型 未标明	九、如何通过流水线并行（Pipeline Parallel）在多节点上扩展微调任务？
040	多模态大模型 未标明	二、如何通过vllm的采样参数（如temperature、top_p）控制生成文本...
041	多模态大模型 未标明	请举例说明“图文对齐”在实际场景中的具体体现，若图文不对齐会带来什么问题？
042	多模态大模型 未标明	你方案里KL散度、熵分别代表什么含义？

编号	方向 / 公司	题目
043	多模态大模型 未标明	强化学习部分为什么选用GRPO而不直接使用PPO?
044	多模态大模型 未标明	跟原始 Transformer 论文中的绝对位置编码相比, RoPE (旋转位置嵌入) ...
045	多模态大模型 腾讯	在推荐系统的模型适配中, 对比LoRA与全参数微调, 它们各自更适合什么样的场景?
046	多模态大模型 阿里	对比DPO和GRPO两种微调方案, 核心区别是什么? 离线训练和在线采样的优劣分别是什...
047	VLA 与具身智能 未标明	VLA 模型中 action token、连续动作回归和 diffusion po...
048	VLA 与具身智能 未标明	机器人遥操作数据采集时, 如何处理多相机、机械臂状态、力控信号和语言指令的时间同步?
049	VLA 与具身智能 未标明	轨迹数据如何切分 episode, 如何标注成功、失败、中断、重试和人为接管?
050	VLA 与具身智能 未标明	从 imitation learning 到 online RL, VLA 系统如何...
051	VLA 与具身智能 未标明	语言规划和低层控制之间如何分层, 什么时候需要 skill library 或 hi...
052	VLA 与具身智能 未标明	Sim-to-real 迁移中, 视觉域随机化、动力学随机化和真实数据少样本微调各自...
053	VLA 与具身智能 未标明	具身任务评估为什么不能只看成功率, 还需要哪些鲁棒性、安全性和泛化指标?
054	VLA 与具身智能 未标明	长程任务中, VLA 如何处理记忆、子目标分解、环境变化和动作不可逆错误?
055	VLA 与具身智能 字节	具身智能任务中, episode 如何切分, 成功、失败、中断和人为接管如何标注?
056	VLA 与具身智能 字节	VLA 系统如何从 imitation learning 过渡到在线强化学习并控制...
057	VLA 与具身智能 字节	sim-to-real 中, 视觉随机化、动力学随机化和真实少样本微调分别解决什么问...
058	VLA 与具身智能 字节	长程具身任务如何处理记忆、子目标分解、环境变化和动作不可逆错误?
059	VLA 与具身智能 字节	具身智能评估为什么不能只看成功率, 还需要哪些安全性和泛化指标?
060	VLA 与具身智能 未标明	自动驾驶世界模型如何从 BEV、occupancy、轨迹预测和仿真闭环中学习环境动...
061	VLA 与具身智能 未标明	驾驶数据闭环如何做场景挖掘、长尾样本回流、自动标注和仿真评测?
062	VLA 与具身智能 未标明	VLA 中 action token、连续动作回归和 diffusion poli...
063	VLA 与具身智能 未标明	机器人数据如何做遥操作采集、时间同步、轨迹切分和失败样本标注?
064	VLA 与具身智能 未标明	VLA 模型中 action token、连续动作回归和 diffusion po...

编号	方向 / 公司	题目
065	VLA 与具身智能 未标明	机器人遥操作数据采集时，如何同步多相机、机械臂状态、力控信号和语言指令？
066	VLA 与具身智能 智元	智元这类具身智能基础模型岗位中，VLM、VLA 和 Video 模型在机器人系统里...
067	VLA 与具身智能 智元	具身基础模型训练中，如何组织遥操作数据、仿真数据、视频数据和语言指令数据？
068	VLA 与具身智能 汇川	机器人控制算法面试中，运动规划、轨迹跟踪和底层控制分别解决什么问题？
069	VLA 与具身智能 未标明	VLA 动作置信度为什么不能等同于任务成功率，机器人控制里应如何做校准？
070	VLA 与具身智能 小鹏	VLA 模型为什么需要强化学习，和单纯模仿学习相比能解决哪些问题？
071	VLA 与具身智能 未标明	1 如何处理模型推理延迟问题？
072	VLA 与具身智能 未标明	2 如何设计高效的机器人动作队列？
073	VLA 与具身智能 未标明	如何解决Sim-to-Real（仿真到真实）鸿沟？具体有哪些技术手段？
074	VLA 与具身智能 未标明	模仿学习（IL）和强化学习（RL）在具身任务中各有什么优劣？如何结合使用？
075	VLA 与具身智能 腾讯	手术动辄几小时，Transformer 的 KV Cache 会随时间爆炸，虽然换...
076	VLA 与具身智能 腾讯	扩散模型生成的是Action Chunk，但在手术中，组织形变是实时的。如果你的 ...
077	视频与视觉理解 通义 / 小红书 / Seed / 混元相关 团队	视频模型如何建模动作、因果关系、事件边界和跨镜头一致性？
078	视频与视觉理解 通义 / 小红书 / Seed / 混元相关 团队	视频问答/视频生成如何评估时序一致性、物理合理性、身份保持和指令遵循？
079	视频与视觉理解 未标明	视频理解中均匀采样、关键帧采样、运动感知采样和自适应采样分别适合哪些场景？
080	视频与视觉理解 未标明	temporal token 压缩如何保留动作变化和事件顺序，和直接长上下文 at...
081	视频与视觉理解 未标明	视频问答如何评估动作理解、事件边界、因果关系、跨镜头一致性和细粒度属性识别？
082	视频与视觉理解 未标明	长视频理解中如何处理记忆压缩、片段检索、滑窗推理和跨片段信息融合？
083	视频与视觉理解 未标明	视频生成模型的时序一致性、身份保持、物理合理性和指令遵循分别如何设计评估？
084	视频与视觉理解 未标明	多模态视频数据清洗时，字幕、ASR、画面内容和问题答案之间如何做一致性校验？
085	视频与视觉理解 未标明	视频 grounding 和图像 grounding 的主要差异是什么，时空定位指...
086	视频与视觉理解 未标明	在线视频理解服务如何控制帧抽取成本、encoder 复用、缓存和响应延迟？

编号	方向 / 公司	题目
087	视频与视觉理解 未标明	视频理解中帧采样、temporal token 压缩和 long-context ...
088	视频与视觉理解 未标明	视频模型如何评估时序一致性、动作理解、事件边界和身份保持？
089	视频与视觉理解 未标明	视频理解中，均匀采样、关键帧采样、运动感知采样和自适应采样分别适合什么场景？
090	视频与视觉理解 未标明	temporal token 压缩如何保留动作变化和事件顺序，相比长上下文 att...
091	视频与视觉理解 未标明	视频问答如何评估动作理解、事件边界、因果关系和跨镜头一致性？
092	视频与视觉理解 未标明	长视频理解中，记忆压缩、片段检索、滑窗推理和跨片段融合如何组合？
093	视频与视觉理解 未标明	视频生成模型的时序一致性、身份保持、物理合理性和指令遵循如何评估？
094	视频与视觉理解 未标明	视频 grounding 与图像 grounding 的主要差异是什么，时空定位指...
095	视频与视觉理解 未标明	多模态视频数据清洗时，字幕、ASR、画面内容和问答之间如何做一致性校验？
096	视频与视觉理解 未标明	在线视频理解服务如何控制帧抽取成本、encoder 缓存和响应延迟？
097	视频与视觉理解 未标明	视频理解模型如何用动态推理和 Early Exit 降低延迟，同时尽量不牺牲准确率？
098	世界模型与自动驾驶 蔚来	座舱多模态大模型如何融合语音、视觉、车控状态和用户上下文，并保证安全边界？
099	世界模型与自动驾驶 未标明	自动驾驶数据闭环中，长尾场景挖掘、自动标注、训练回流和仿真评测如何形成闭环？
100	世界模型与自动驾驶 未标明	BEV、occupancy、轨迹预测和端到端规划分别在世界模型中承担什么表示角色？
101	世界模型与自动驾驶 未标明	世界模型如何学习环境动态，和传统感知预测规划模块相比优势和风险是什么？
102	世界模型与自动驾驶 未标明	多传感器数据中，相机、激光雷达、毫米波雷达、定位和车控状态如何做时间空间对齐？
103	世界模型与自动驾驶 未标明	仿真评测如何保证场景真实性、交互合理性、覆盖率和指标可解释性？
104	世界模型与自动驾驶 未标明	自动驾驶数据筛选时，如何识别 corner case、near miss、接管片段...
105	世界模型与自动驾驶 未标明	端到端自动驾驶模型如何处理可解释性、安全边界、法规约束和分布外场景？
106	世界模型与自动驾驶 未标明	座舱多模态大模型如何融合语音、视觉、车辆状态和用户上下文，同时保证安全策略？
107	世界模型与自动驾驶 小鹏	世界模型和传统感知、预测、规划模块相比，优势、风险和可解释性问题是什...
108	世界模型与自动驾驶 小鹏	驾驶数据闭环中，长尾场景挖掘、自动标注、训练回流和仿真评测如何形成闭环？

编号	方向/公司	题目
109	世界模型与自动驾驶 小鹏	多传感器数据中，相机、激光雷达、毫米波雷达、定位和车控状态如何时空对齐？
110	世界模型与自动驾驶 小鹏	端到端自动驾驶模型如何处理安全边界、法规约束、分布外场景和可解释性？
111	训练框架与大规模训练 未标明	大模型训练中显存占用如何拆解到参数、梯度、优化器状态、激活值和 KV cache？
112	训练框架与大规模训练 未标明	混合精度、gradient checkpointing、FlashAttention...
113	训练框架与大规模训练 未标明	数据并行、张量并行、流水并行、序列并行和专家并行分别解决什么瓶颈？
114	训练框架与大规模训练 未标明	DeepSpeed ZeRO-1/2/3 分别切分哪些状态，通信量、显存节省和实现...
115	训练框架与大规模训练 未标明	Megatron 中 tensor parallel 的列切分和行切分为什么要配合...
116	训练框架与大规模训练 未标明	训练显存如何拆解为参数、梯度、优化器状态、激活值、临时 buffer 和通信 bu...
117	训练框架与大规模训练 未标明	gradient checkpointing、FlashAttention、act...
118	训练框架与大规模训练 未标明	大规模训练中 loss spike、梯度溢出、数据异常和通信 hang 应该如何定...
119	训练框架与大规模训练 未标明	混合精度训练中 FP16、BF16、FP8 的数值稳定性和硬件收益如何比较？
120	训练框架与大规模训练 未标明	训练吞吐优化时，global batch、micro batch、pipeline...
121	训练框架与大规模训练 字节	DeepSpeed ZeRO、Megatron 张量并行、流水并行和数据并行分别解...
122	训练框架与大规模训练 字节	大模型训练中显存如何拆解到参数、梯度、优化器状态、激活值和 KV cache？
123	训练框架与大规模训练 字节	KV cache、PagedAttention、continuous batchi...
124	训练框架与大规模训练 字节	INT8/INT4 量化、AWQ/GPTQ、LoRA 合并和蒸馏分别适合哪些部署场...
125	训练框架与大规模训练 字节	数据并行、张量并行、流水线并行、序列并行和专家并行分别解决什么瓶颈？
126	训练框架与大规模训练 字节	DeepSpeed ZeRO-1/2/3 分别切分哪些状态，显存节省和通信开销如何...
127	训练框架与大规模训练 字节	Megatron 的 tensor parallel 为什么需要行切分、列切分和 ...
128	训练框架与大规模训练 字节	大模型训练显存如何拆成参数、梯度、优化器状态、激活值和临时 buffer？
129	训练框架与大规模训练 字节	gradient checkpointing、FlashAttention 和 a...
130	训练框架与大规模训练 字节	FP16、BF16、FP8 在数值稳定性、硬件收益和训练风险上有什么差异？

编号	方向/公司	题目
131	训练框架与大规模训练字节	global batch、micro batch、pipeline bubble ...
132	训练框架与大规模训练字节	字节多模态大模型训练中，DeepSpeed ZeRO、LoRA 和 RLHF 分别...
133	训练框架与大规模训练字节	多模态大模型训练时，视觉 encoder、LLM、LoRA 适配层和奖励/偏好数据...
134	推理部署与模型压缩 百度	线上推理如何权衡首 token 延迟、吞吐、显存、上下文长度和服务稳定性？
135	推理部署与模型压缩 未标明	KV cache 的显存占用如何随 batch size、序列长度、层数、head...
136	推理部署与模型压缩 未标明	PagedAttention 为什么能提高显存利用率，它和传统连续 KV cach...
137	推理部署与模型压缩 未标明	continuous batching 如何提高吞吐，为什么会影响单请求延迟和调度...
138	推理部署与模型压缩 未标明	speculative decoding 的收益取决于哪些因素，draft mod...
139	推理部署与模型压缩 未标明	INT8、INT4、AWQ、GPTQ、SmoothQuant 分别适合权重量化、激...
140	推理部署与模型压缩 未标明	长上下文推理中，RoPE scaling、KV eviction、prefix c...
141	推理部署与模型压缩 未标明	线上推理如何同时监控 TTFT、TPOT、吞吐、显存水位、失败率和队列等待时间？
142	推理部署与模型压缩 未标明	LoRA 多租户服务中，adapter 热切换、权重合并、缓存复用和隔离性如何设计？
143	推理部署与模型压缩 未标明	Qwen2.5 类大模型在面试中常被问到哪些结构和训练特点，和 LLaMA/Dee...
144	推理部署与模型压缩 未标明	部署 Qwen2.5 类模型时，KV cache、量化、batch 调度和长上下文...
145	推理部署与模型压缩 美团	端侧 MobileVLM 如何在算力受限设备上兼顾视觉理解能力、延迟和内存占用？
146	推理部署与模型压缩 未标明	六、如何配置vlm的服务参数（如max_model_len、n_ctx）以适应硬...
147	强化学习与模型对齐 字节	对齐训练如何评估 helpfulness、harmlessness、truthfu...
148	强化学习与模型对齐 未标明	RLHF、DPO、GRPO、PPO 的优化目标、训练数据和稳定性问题分别是什么？
149	强化学习与模型对齐 未标明	Reward model 如何构造偏好数据，如何处理 reward hacking...
150	强化学习与模型对齐 字节	多模态大模型为什么需要模态对齐，图像文本对齐通常如何训练和评估？
151	强化学习与模型对齐 美团	MoE 中专家路由如何做负载均衡和专家容量控制，为什么会出现专家塌缩？
152	强化学习与模型对齐 美团	GRPO 相比 PPO 为什么可以省去价值模型，适合哪些大模型推理训练场景？

1. 多模态大模型

本章收录 46 道题，来自 20 个来源。

1.1 字节跳动 · 知乎：字节多模态大模型一面

公司/机构：字节跳动 | 方向：多模态大模型 | 来源平台：知乎 | 来源日期：2026-06-05

来源链接：<https://zhuanlan.zhihu.com/p/1998500372969443453>

Q001 · 视觉 encoder 输出如何对齐到 LLM token 空间，Linear projector、Q-Former 和 cross-attention adapter 有什么取舍？

回答

视觉 encoder 输出是连续视觉 token，需要映射到 LLM 的隐藏维和语义空间。Linear/MLP projector 参数少、延迟低，适合保留较多视觉 token，但压缩和交互能力有限；Q-Former 用可学习 query 从视觉特征中抽取固定数量语义 token，节省上下文但可能丢局部细节；cross-attention adapter 让语言层在多层读取视觉特征，交互更强但计算和改造成本高。选择取决于分辨率、细粒度任务、token 预算和是否冻结基座。

1.2 未标明 · 题库：多模态大模型视觉语言对齐专项

公司/机构：未标明 | 方向：多模态大模型 | 来源平台：内部题库 | 来源日期：2026-06-06

Q002 · CLIP 预训练中的对比学习目标如何影响后续 VLM 的视觉语义对齐能力？

回答

CLIP 用 batch 内图文配对做双向对比学习，使真实图文对相似度高于其他组合，从而学习开放词汇视觉语义。该目标让后续 VLM 获得强检索和零样本分类基础，但偏向全局语义，对局部属性、计数和空间关系较弱。接入 VLM 时通常保留 CLIP 视觉 encoder，再通过 projector/Q-Former 对齐 LLM，并用 caption、VQA、grounding 和细粒度负样本补足。温度、负样本质量和数据噪声会直接影响对齐空间。

Q003 · Linear projector、MLP projector、Q-Former 和 cross-attention adapter 在信息保留、训练成本、推理延迟上如何取舍？

回答

视觉 encoder 输出是连续视觉 token，需要映射到 LLM 的隐藏维和语义空间。Linear/MLP projector 参数少、延迟低，适合保留较多视觉 token，但压缩和交互能力有限；Q-Former 用可学习 query 从视觉特征中抽取固定数量语义 token，节省上下文但可能丢局部细节；cross-attention adapter 让语言层在多层读取视觉特征，交互更强但计算和改造成本高。选择取决于分辨率、细粒度任务、token 预算和是否冻结基座。

Q004 · 多模态指令微调数据如何避免 OCR 泄漏、答案模板化、负样本不足和评测集污染？

回答

图文/视频指令数据应覆盖描述、问答、OCR、grounding、比较、时序和多轮任务。清洗时去重相似图片与文本，检测图文不匹配、模板化答案和低质量合成；OCR 任务要防止答案直接出现在元数据或文件名中；负样本要包含相似对象、错误区域和无法回答问题。评测集需按原始媒体哈希、文本近似和来源站点与训练数据隔离。合成数据最好由视觉验证器或人工抽样确认，不能只相信生成模型自检。

Q005 · 视觉 grounding 能力应该如何评估，bbox、指代表达、区域问答和 hallucination rate 分别看什么？

回答

Grounding 评估应同时检查定位与语言理解。BBox 用 IoU、mAP 和 Recall@K；指代表达要求模型根据属性、关系和上下文找到唯一目标；区域问答验证定位后是否正确读取区域内容；hallucination rate 统计模型定位或描述不存在对象的比例。还应覆盖小目标、遮挡、同类多实例、否定指令和复杂关系，并要求模型输出证据区域，避免答案正确但定位错误。

Q006 · 多图理解任务中图间关系、时间顺序和跨图实体一致性如何建模？

回答

多图理解首先要为每张图加入位置和顺序标识，再通过共享实体表示或跨图 attention 建立关联。跨图实体一致性可用对象重识别、属性匹配和名称绑定；时间顺序需要显式时间 token 与状态变化监督；比较推理则构造必须同时引用多图证据的问题。训练中应随机交换图片顺序、加入相似干扰图和缺失图，防止模型只看单张或依赖固定位置。评估要记录证据图选择和最终答案两个指标。

Q007 · 为什么 VLM 容易出现视觉幻觉，如何从数据、模型结构、解码和评测四个层面缓解？

回答

视觉幻觉来自训练图文弱对齐、语言先验过强、视觉 token 压缩、细粒度特征不足和解码时无证据约束。数据侧应清洗图文不匹配、加入不存在对象的负样本和区域级标注；模型侧可增强高分辨率/局部特征、跨模态交互和视觉对比损失；解码侧使用区域检索、置信度校准和证据引用；评测侧构建反事实、遮挡和对象不存在测试。仅靠扩大模型通常不能解决，因为语言能力越强也可能越会“合理编造”。

Q008 · 高分辨率图像输入时，patch 数量、token 压缩、局部裁剪和动态分辨率策略如何选择？

回答

高分辨率图像的成本主要来自 patch/token 数。动态分辨率按图像长宽和内容选择 token 数，灵活但 batch 形状复杂；tile 切分保留局部细节，适合 OCR、文档和小目标，但需处理跨 tile 关系与重复区域；token 压缩通过池化、合并或 resampler 降低 LLM 上下文成本，可能损失细节。常见方案是低分辨率全局图加若干高分辨率局部 tile，并根据任务选择压缩率。评估需分小字、计数、空间关系和普通场景。

Q009 · VLM 线上服务中如何平衡图像预处理延迟、视觉 encoder 复用、batching 和首 token 延迟？

回答

多模态服务延迟可拆为图片下载/解码、resize/tile、vision encoder、视觉 token 投影、LLM prefill 和 decode。对相同图片用内容哈希缓存 encoder 输出；批量请求按分辨率和 tile 数分桶，减少 padding；热点图片预计算视觉 token；高分辨率任务采用全局低分辨率加局部 tile。首 token 延迟主要受预处理、encoder 和 prefill 影响，可并行下载与预处理、使用更快视觉 backbone、token 压缩和 chunked prefill。

1.3 字节 · 知乎：【清华代码熊】字节面试官：多模态大模型动态分辨率原理？

公司/机构：字节 | 方向：多模态大模型 | 来源平台：知乎 | 来源日期：2026-06-14

来源链接：<https://zhuanlan.zhihu.com/p/2014314780802967473>

Q010 · Vision encoder 输出如何与 LLM token 空间对齐？Linear projector、Q-Former、cross-attention adapter 的差异是什么？

回答

视觉 encoder 输出是连续视觉 token，需要映射到 LLM 的隐藏维和语义空间。Linear/MLP projector 参数少、延迟低，适合保留较多视觉 token，但压缩和交互能力有限；Q-Former 用可学习 query 从视觉特征中抽取固定数量语义 token，节省上下文但可能丢局部细节；cross-attention adapter 让语言层在多层读取视觉特征，交互更强但计算和改造成本高。选择取决于分辨率、细粒度任务、token 预算和是否冻结基座。

Q011 · 多模态模型如何评估 grounding、OCR、空间关系、幻觉和多轮视觉对话能力？

回答

多模态评估应按能力拆分。Grounding 用 bbox/区域 IoU、指代表达准确率和区域问答；OCR 分别测试识别、版面理解和文字推理；空间关系覆盖左右、前后、遮挡、计数和相对大小；幻觉用不存在对象提及率和证据一致性；多轮视觉对话检查指代、历史一致性和纠错能力。除公开 benchmark 外，还需构建业务 hard case，并通过图像遮挡、问题改写和反事实样本验证模型是否真正使用视觉证据。

Q012 · 图文/视频指令微调数据如何构造，如何控制噪声、偏见和 OCR 泄漏？

回答

图文/视频指令数据应覆盖描述、问答、OCR、grounding、比较、时序和多轮任务。清洗时去重相似图片与文本，检测图文不匹配、模板化答案和低质量合成；OCR 任务要防止答案直接出现在元数据或文件名中；负样本要包含相似对象、错误区域和无法回答问题。评测集需按原始媒体哈希、文本近似和来源站点与训练数据隔离。合成数据最好由视觉验证器或人工抽样确认，不能只相信生成模型自检。

Q013 · 多模态大模型中，vision encoder 输出如何通过 projector、Q-Former 或 cross-attention 接入 LLM？

回答

视觉 encoder 输出是连续视觉 token，需要映射到 LLM 的隐藏维和语义空间。Linear/MLP projector 参数少、延迟低，适合保留较多视觉 token，但压缩和交互能力有限；Q-Former 用可学习 query 从视觉特征中抽取固定数量语义 token，节省上下文但可能丢局部细节；cross-attention adapter 让语言层在多层读取视觉特征，交互更强但计算和改造成本高。选择取决于分辨率、细粒度任务、token 预算和是否冻结基座。

Q014 · VLM 训练中图文对齐、指令微调和偏好对齐分别解决什么问题？

回答

图文对齐阶段让视觉特征进入语言语义空间，常用图文对比、caption 或冻结 LLM 的连接训练；指令微调让模型学会按用户要求完成 VQA、OCR、grounding、多图和视频任务；偏好对齐进一步优化回答正确性、格式、安全性和拒答行为。三阶段不能颠倒：视觉没对齐时做偏好训练，模型可能只学语言风格；指令数据过窄又会造成能力遗忘。每阶段应使用独立验证集监控视觉利用率和通用能力回退。

Q015 · 高分辨率图片输入时，动态分辨率、tile 切分和 token 压缩如何取舍？

回答

高分辨率图像的成本主要来自 patch/token 数。动态分辨率按图像长宽和内容选择 token 数，灵活但 batch 形状复杂；tile 切分保留局部细节，适合 OCR、文档和小目标，但需处理跨 tile 关系与重复区域；token 压缩通过池化、合并或 resampler 降低 LLM 上下文成本，可能损失细节。常见方案是低分辨率全局图加若干高分辨率局部 tile，并根据任务选择压缩率。评估需分小字、计数、空间关系和普通场景。

Q016 · OCR、grounding、计数、空间关系这四类能力分别应该如何设计评估集？

回答

OCR 评估集要覆盖字体、旋转、低清、表格和版面，并分别看字符准确率与问答正确率；grounding 需要对对象/区域标注，用 IoU、Recall@K 和指代表达准确率；计数要控制遮挡、密集度和类别混淆，避免答案可由语言先验猜出；空间关系覆盖绝对位置、相对位置、深度、遮挡和多对象组合。四类数据都应包含困难负样本、跨语言和分辨率分层，并检查训练集泄漏。

Q017 · 多图理解任务中，如何保证跨图实体一致性、顺序理解和比较推理能力？

回答

多图理解首先要为每张图加入位置和顺序标识，再通过共享实体表示或跨图 attention 建立关联。跨图实体一致性可用对象重识别、属性匹配和名称绑定；时间顺序需要显式时间 token 与状态变化监督；比较推理则构造必须同时引用多图证据的问题。训练中应随机交换图片顺序、加入相似干扰图和缺失图，防止模型只看单张或依赖固定位置。评估要记录证据图选择和最终答案两个指标。

Q018 · VLM 产生视觉幻觉的常见原因有哪些，数据、模型和解码侧分别怎么缓解？

回答

视觉幻觉来自训练图文弱对齐、语言先验过强、视觉 token 压缩、细粒度特征不足和解码时无证据约束。数据侧应清洗图文不匹配、加入不存在对象的负样本和区域级标注；模型侧可增强高分辨率/局部特征、跨模态交互和视觉对比损失；解码侧使用区域检索、置信度校准和证据引用；评测侧构建反事实、遮挡和对象不存在测试。仅靠扩大模型通常不能解决，因为语言能力越强也可能越会“合理编造”。

1.4 未标明 · 小红书：理想多模态大模型一面面经

公司/机构：未标明 | 方向：多模态大模型 | 来源平台：小红书 | 来源日期：2026-06-14

来源链接：https://www.xiaohongshu.com/search_result/683952c6000000002301439d?xsec_token=ABlzEXgl67LlfSvxMjioNdsA9CUcgBmOK9FtC6GDtdjC8%3D&xsec_source=pc_search

Q019 · 图像 caption 数据、VQA 数据和合成指令数据在多模态训练中的作用有什么差异？

回答

Caption 数据提供广泛视觉语义和对象属性，适合预训练对齐，但描述通常泛化且缺少精确推理；VQA 数据把视觉证据与具体问题绑定，能训练计数、空间、OCR 和推理，但任务分布较窄；合成指令数据可快速扩展任务和难度，适合多轮、拒答和长尾覆盖，但容易模板化、事实错误和自我偏见。合理配比是用大规模 caption 建基础，再用高质量 VQA/grounding 强化能力，最后用经过验证的合成数据补缺口。

Q020 · 多模态模型线上服务如何优化图片预处理、vision encoder 复用和首 token 延迟？

回答

多模态服务延迟可拆为图片下载/解码、resize/tile、vision encoder、视觉 token 投影、LLM prefill 和 decode。对相同图片用内容哈希缓存 encoder 输出；批量请求按分辨率和 tile 数分桶，减少 padding；热点图片预计算视觉 token；高分辨率任务采用全局低分辨率加局部 tile。首 token 延迟主要受预处理、encoder 和 prefill 影响，可并行下载与预处理、使用更快视觉 backbone、token 压缩和 chunked prefill。

1.5 未标明 · 知乎：【清华代码熊】面试官：多模态大模型视觉Token压缩方法？

公司/机构：未标明 | 方向：多模态大模型 | 来源平台：知乎 | 来源日期：2026-06-14

来源链接：<https://zhuanlan.zhihu.com/p/2014643829844770923>

Q021 · KV cache 显存如何随 batch、序列长度、层数、head 数和 hidden size 增长？

回答

KV Cache 显存近似为 $\text{batch} \times \text{序列长度} \times \text{层数} \times 2(K/V) \times \text{KV 头数} \times \text{head_dim} \times \text{数据类型字节数}$ 。对普通 MHA，KV 头数等于注意力头数；GQA/MQA 通过减少 KV 头显著降低缓存。显存随 batch 和上下文长度线性增长，生成过程中还会继续累积。部署时应同时考虑并发序列、最大上下文、beam 数、前缀共享和显存碎片，并用分页缓存、KV 量化或 eviction 控制水位。

Q022 · PagedAttention 为什么能提升显存利用率，和连续 KV cache 分配有什么区别？**回答**

传统 KV Cache 为每个请求预留连续最大空间，实际长度不一会造成内部浪费和外部碎片。PagedAttention 把缓存切成固定大小 block，逻辑地址连续但物理块可分散分配，请求增长时按需追加，结束后立即回收；前缀还可通过引用计数共享。这样能提高显存利用率和并发数。代价是块表查询、调度与拷贝更复杂，block 太小管理开销高，太大又增加尾部浪费。

Q023 · continuous batching 如何提升吞吐，为什么可能影响单请求延迟和调度公平性？**回答**

Continuous batching 不等待整个静态 batch 完成，而是在每个 decode step 动态加入新请求、移除已完成请求，使 GPU 长期保持高利用率。吞吐因此提高，但长请求可能占用资源更久，短请求可能排队；过大的 token batch 也会增加单步时间和 P99 延迟。调度器通常结合优先级、等待时间、剩余长度估计和 prefill/decode 分离，设置最大 batch token、抢占或 chunked prefill，在吞吐与公平性间取舍。

Q024 · speculative decoding 的收益取决于哪些因素，draft model 接受率如何影响加速比？**回答**

Speculative decoding 由小 draft model 一次提出多个 token，大模型并行验证；被接受的连续 token 可减少大模型串行 decode 次数。收益取决于 draft 速度、提议长度、接受率、大模型验证效率和额外 KV/调度开销。接受率高且 draft 足够小才有明显加速；提议太长会增加拒绝后的浪费。应在不同任务、温度和上下文长度下测平均接受 token 数、端到端延迟和吞吐，而不是只看理论步数。

Q025 · INT8、INT4、AWQ、GPTQ、SmoothQuant 分别适合哪些量化和部署场景？**回答**

GPTQ 是基于校准数据和二阶近似的离线权重量化，适合单批或低并发部署；AWQ 保护重要激活通道，常用于低比特权重量化且质量较稳；SmoothQuant 把激活离群值部分迁移到权重，适合权重与激活 INT8；INT8 通常质量风险较低，INT4 显存收益更大但对数学、代码和长上下文更敏感。部署选择还取决于硬件 kernel、是否量化 KV Cache、吞吐目标和校准集代表性。

Q026 · 长上下文推理中，RoPE scaling、KV eviction、prefix cache 分别解决什么问题？**回答**

RoPE scaling 调整位置频率以扩展模型可处理的长度，但可能损害短上下文和远距离注意力；KV eviction 在缓存不足时删除低价值历史 token，需要保留系统指令、关键实体和近期上下文；prefix cache 复用相同系统提示或文档前缀的 KV，降低重复 prefill；检索增强则把海量历史放在外部索引中，按需取回证据。它们分别解决位置外推、缓存容量、重复计算和知识规模问题，通常组合使用。

1.6 快手 · CSDN：【26届校招】快手大模型算法岗面经：从多模态模型到LoRA技术，面试官常问问题详解！

公司/机构：快手 | 方向：多模态大模型 | 来源平台：CSDN | 来源日期：2026-06-18

来源链接：https://blog.csdn.net/trb701012/article/details/152117850?ops_request_misc=elastic_search_misc&request_id=e1fdf9a1dc62ad0e6db37c5329488736&biz_id=0

Q027 · 快手大模型算法面试中，多模态模型微调为什么常用LoRA，它和全参微调的效果、成本和风险有什么差异？

回答

LoRA 的核心价值是用少量低秩增量参数适配大模型，避免更新全部权重。对多模态模型来说，全参微调效果上限更高，尤其适合大规模领域继续训练，但显存、训练成本、回滚成本都高，也更容易破坏原有通用能力。LoRA 成本低、实验快、可同时维护多个业务 adapter，适合短视频理解、内容审核、搜索推荐等垂直任务快速迭代。风险是容量有限，遇到需要重塑视觉语义空间或复杂推理能力的任务时可能不够；同时如果训练数据分布窄，LoRA 也会学到业务模板和偏见。面试回答最好落到工程指标：显存占用、训练吞吐、上线包体、adapter 切换延迟、主模型共享能力、离线评测和线上 badcase 回流。

Q028 · 短视频业务里的多模态模型，如何同时处理封面图、视频帧、OCR、ASR 和用户文本特征？

回答

短视频多模态建模的关键是把不同模态按时间和语义对齐。封面图提供强视觉摘要，但容易标题党；视频帧提供动作和场景变化，需要帧采样、temporal token 压缩或片段级编码；OCR 捕获画面文字，适合广告、字幕、商品信息理解；ASR 捕获语音语义，但要处理噪声、方言和错字；用户文本包括标题、评论、搜索 query 或标签，能补充意图。工程上通常会先分别编码各模态，再做早融合或晚融合：检索/推荐场景常用多塔或 late fusion，问答/审核场景更适合把关键视觉 token、OCR、ASR 摘要送入 LLM。评估时不能只看总体准确率，还要看长尾类别、低质视频、无字幕视频、强噪声音频和跨模态冲突样本。

1.7 未标明 · B站：1.5万 13 06:16 面试官：大模型中为什么不使用Dropout

公司/机构：未标明 | 方向：大模型训练 | 来源平台：B站 | 来源日期：2026-06-19

来源链接：<https://www.bilibili.com/video/BV1hMJ36KE2h/>

Q029 · 大模型训练中为什么很多 LLM 不再依赖

Dropout，它和数据规模、归一化、残差结构有什么关系？

回答

Dropout 的主要作用是通过随机屏蔽神经元减少过拟合，但现代 LLM 通常数据规模巨大、训练 token 很多，过拟合压力相对小，反而更关注训练稳定性和吞吐。Dropout 会引入随机噪声，可能影响大规模分布式训练的收敛效率，也会让预训练和推理行为存在额外差异。Transformer 里残差连接、RMSNorm/LayerNorm、权重衰减、数据去重、学习率调度和大规模混合数据本身已经提供了一部分正则化效果。并不是所有场景都不能用 Dropout，小数据微调、分类头训练或特定任务仍可能使用；只是主流 LLM 预训练更倾向于减少不必要随机性，把稳定性和规模效率放在前面。面试回答要避免说“Dropout 没用”，更准确是“大规模预训练阶段收益通常小于工程和收敛成本”。

1.8 未标明 · B站：1131 0 10:52:02 【2026最新计算机视觉教程】传统CV+视觉大模型，算法原理+框架详解+源码解读+项目实战

公司/机构：未标明 | 方向：多模态大模型 | 来源平台：B站 | 来源日期：2026-06-20

来源链接：<https://www.bilibili.com/video/BV1Ds7z63E2u/>

Q030 · 为什么通用 VLM 的检测能力通常弱于 YOLO，如何增强其定位和检测能力？

回答

通用 VLM 的训练目标往往偏向图文语义理解和自然语言回答，视觉 token 经过压缩后更适合表达语义概念，不一定保留像素级位置细节；YOLO 这类检测模型则直接围绕 bbox、类别和密集空间特征优化，所以定位能力更强。增强 VLM 检测能力可以从三层入手：数据层加入区域标注、grounding、检测问答和负样本；结构层保留更高分辨率视觉特征，增加区域 token 或检测 head；训练层联合 caption、VQA、grounding 和 detection loss，避免只学会说出物体但框不准。评估时要看 mAP、定位 IoU、指代表达理解、细粒度类别和复杂遮挡场景。面试里要强调，VLM 和检测器不是替代关系，很多业务会采用 VLM 做语义推理、检测器做精确定位的组合方案。

1.9 未标明 · Qwen-VL视觉语言题目精讲

公司/机构：未标明 | 方向：多模态大模型 | 来源平台：掘金 | 来源日期：2026-06-20

来源链接：<https://juejin.cn/post/7571678763782258722?searchId=202606200934123712A5056DD60BB31F76>

Q031 · Qwen-VL 类视觉语言模型如何把图像特征接入语言模型，训练流程通常分哪几步？

回答

Qwen-VL 这类模型一般不是把原始图片直接喂给大语言模型，而是先用视觉编码器把图片切成视觉特征，再通过 projector、adapter 或 cross-modal connector 映射到语言模型可以消费的 token 空间。训练通常分三步：第一步做图文对齐，让视觉 token 和文本语义落到同一个表达空间；第二步做多模态指令微调，让模型学会按照用户问题读取图片、定位信息、解释图表和进行视觉问答；第三步做偏好对齐或任务微调，提升回答格式、可靠性和安全性。面试里要强调两点：一是视觉编码器和语言模型之间的接口决定了信息瓶颈，二是评估不能只看 VQA 分数，还要看 OCR、定位、细粒度属性、幻觉率和多轮上下文稳定性。

1.10 Qwen · CSDN：大模型面试题85：Qwen2.5

公司/机构：Qwen | 方向：大模型面经 | 来源平台：CSDN | 来源日期：2026-06-24

来源链接：https://blog.csdn.net/weixin_45264425/article/details/157210711

Q032 · 一、先搞懂：Qwen2.5-VL到底是什么？

回答

Qwen2.5-VL 是面向图像和视频理解的视觉语言模型：视觉侧把图片或视频编码成视觉 token，经过连接/投影模块与文本 token 一起送入语言模型，从而完成问答、OCR、图表理解、目标定位、视频时序理解和工具调用。理解它时要关注三个层面：动态分辨率或视觉 token 压缩如何控制高分辨率成本；视觉 token 如何与语言空间对齐；训练数据如何从图文预训练过渡到多模态指令微调和偏好对齐。它不是单纯“给 Qwen 加图片输入”，而是一套视觉编码、时空建模、对齐训练和评测体系。

1.11 字节 · 小红书：算法面经：字节·大模型多模态

公司/机构：字节 | 方向：多模态大模型 | 来源平台：小红书 | 来源日期：2026-06-24

来源链接：https://www.xiaohongshu.com/explore/693c175d000000001e02f513?xsec_token=AB-GkRaO0Sq06YxsmCbi2cn_uQh1cr5GD6Ads99rpFnsM%3D&xsec_source=pc_search

Q033 · Vision Transformer (ViT) 和 CNN 在图像特征提取上的优劣对比？

回答

CNN 通过局部卷积、权重共享和平移归纳偏置，在中小数据和高分辨率密集预测中样本效率高；ViT 把图像切成 patch token，用自注意力直接建模长距离关系，规模化后表达能力和迁移性更强，但训练数据与计算需求更大。多模态大模型常选 ViT，因为 token 形式容易接入 LLM，不过对小目标和局部细节通常需要高分辨率、动态切图、多尺度特征或卷积 stem 补强。

Q034 · CLIP 模型的原理是什么？它是如何实现图文对齐的？损失函数怎么设计的？

回答

CLIP 使用图像编码器和文本编码器把配对图文映射到同一向量空间，在一个 batch 内把真实图文对作为正样本，其余组合视为负样本，双向计算图到文和文到图的对比损失。InfoNCE 本质上让正样本相似度相对所有候选更高，温度参数控制分布尖锐程度。CLIP 的优势是大规模弱监督和零样本迁移，局限是依赖 batch 内负样本、偏向全局语义，对计数、空间关系和细粒度局部属性不够敏感。

1.12 快手 ·

CSDN：快手多模态算法工程师面试题精选：10道高频考题+答案解析

公司/机构：快手 | 方向：多模态大模型 | 来源平台：CSDN | 来源日期：2026-06-24

来源链接：<https://blog.csdn.net/zhhhh15/article/details/160497336>

Q035 · 题1：请讲讲CLIP的核心原理，它是怎么做图文对齐的？正样本冲突怎么处理？

回答

CLIP 使用图像编码器和文本编码器把配对图文映射到同一向量空间，在一个 batch 内把真实图文对作为正样本，其余组合视为负样本，双向计算图到文和文到图的对比损失。InfoNCE 本质上让正样本相似度相对所有候选更高，温度参数控制分布尖锐程度。CLIP 的优势是大规模弱监督和零样本迁移，局限是依赖 batch 内负样本、偏向全局语义，对计数、空间关系和细粒度局部属性不够敏感。

Q036 · 题2：CLIP和BLIP的主要区别是什么？BLIP-2的Q-Former为什么这么设计？

回答

CLIP 是双塔对比学习模型，重点把整图和整句映射到共享向量空间，擅长检索和零样本分类；BLIP 同时结合理解与生成目标，并通过数据清洗和字幕生成改善图文训练数据；BLIP-2 使用冻结视觉编码器、冻结 LLM 和轻量 Q-Former。Q-Former 里的可学习 query 通过 cross-attention 从大量视觉 token 中提取与语言任务相关的少量表示，再接入 LLM，因此显著降低连接成本。它的取舍是压缩高效，但 query 数量过少可能损失细粒度局部信息。

1.13 快手 · 小红书：算法面经：快手大模型一二面

公司/机构：快手 | 方向：大模型面经 | 来源平台：小红书 | 来源日期：2026-06-24

来源链接：https://www.xiaohongshu.com/explore/69435d73000000000d03be65?xsec_token=ABP3C7d_SETNv5wm7Dpj0XYgZdevT7znHfB_UhzrNHxE%3D&xsec_source=pc_search

Q037 · Qwen 在训练时采用的 “packing”

形式和“多轮对话”形式有何区别？各自对训练效率和模型能力有何影响？

回答

Packing 是把多条短样本拼进同一固定长度序列，配合 attention mask 和 loss mask 避免样本间互相看到，主要目的是减少 padding、提升 token 利用率和训练吞吐。多轮对话格式则是在一条样本中保留 system、user、assistant 的真实轮次结构，并只对需要学习的 assistant token 计算损失，目标是学习上下文跟踪和角色一致性。二者可以同时使用：先构造正确的多轮样本，再把多条样本 packing；关键是处理边界位置编码、跨样本 attention 隔离和 loss mask。

Q038 · 训练一个 8B

参数的大模型，大概需要多少显存？如果显存不够，你会用哪些技术缓解？

回答

仅看权重，8B 参数模型使用 FP16/BF16 约需 16GB；但全参训练远不止权重，还包括梯度、Adam 一阶/二阶状态、主权重、激活值和通信缓冲，通常需要权重体积的数倍甚至十余倍。粗略估算时应分别列出参数、梯度、优化器状态和激活，而不是只报一个数字。显存不足可组合使用 BF16/FP16、ZeRO-2/3 或 FSDP、张量/流水线并行、gradient checkpointing、FlashAttention、CPU/NVMe offload、减小 micro-batch、序列并行，以及 LoRA/QLoRA。推理场景还要单独计算随 batch 和上下文长度增长的 KV Cache。

1.14 未标明 · CSDN：大模型最新面试题系列：微调篇之微调框架（三）

公司/机构：未标明 | 方向：大模型面经 | 来源平台：CSDN | 来源日期：2026-06-24

来源链接：<https://blog.csdn.net/zhangzhentiyas/article/details/146692681>

Q039 · 九、如何通过流水线并行（Pipeline Parallel）在多节点上扩展微调任务？

回答

数据并行复制完整模型、切分 batch，并在反向传播后同步梯度；张量并行切分单层矩阵，解决单层参数放不下；流水线并行按层切分模型，通过 micro-batch 填充流水线，但会产生 bubble；ZeRO/FSDP 则切分优化器状态、梯度和参数，降低每卡冗余。真实大模型通常组合这些策略，取舍取决于显存、网络带宽、模型宽度/深度和全局 batch。

1.15 未标明 · CSDN：大模型最新面试题系列：微调篇之微调框架（二）

公司/机构：未标明 | 方向：大模型面经 | 来源平台：CSDN | 来源日期：2026-06-24

来源链接：<https://blog.csdn.net/zhangzhentiyas/article/details/146691808>

Q040 · 二、如何通过vllm的采样参数（如temperature、top_p）控制生成文本的多样性？

回答

`temperature` 通过缩放 logits 控制概率分布尖锐程度：低温让高概率 token 更占优势，输出更稳定；高温增加随机性，但也提高事实错误和格式漂移风险。`top\_p` 只保留累计概率达到阈值的最小 token 集，再从中采样，因此会随上下文动态改变候选数量。生产中通常先按任务确定温度，再用 top_p 限制长尾：代码、抽取和结构化输出使用低温；创作和头脑风暴可适当提高。还应配合 top_k、重复惩罚、最大长度和固定随机种子做离线评测。

1.16 未标明 · CSDN：大模型面试题剖析：大模型多模态微调技术全解析

公司/机构：未标明 | 方向：多模态大模型 | 来源平台：CSDN | 来源日期：2026-06-24

来源链接：<https://blog.csdn.net/dulnode/article/details/151143684>

Q041 · 请举例说明“图文对齐”在实际场景中的具体体现，若图文不对齐会带来什么问题？

回答

图文对齐意味着视觉区域、对象属性和文本语义在共享表示或生成过程中正确对应。例如商品检索中，“红色圆领连衣裙”应匹配颜色、领型和类别都一致的图片；视觉问答中，模型提到的数量和位置应来自图中真实对象。若图文不对齐，训练会把错误属性绑定到对象，造成检索召回下降、OCR/grounding 错位和视觉幻觉。治理方法包括图文相似度过滤、对象或区域级对齐、困难负样本、人工抽检和下游任务一致性评估。

1.17 未标明 · 小红书：多模态面经

公司/机构：未标明 | 方向：多模态大模型 | 来源平台：小红书 | 来源日期：2026-06-24

来源链接：https://www.xiaohongshu.com/explore/6a3b92d90000000007027516?xsec_token=ABADIdT2-Ycpy9z77HjMhZg7IK5NSXS37J_BvXXb4hFTA%3D&xsec_source=pc_search

Q042 · 你方案里KL散度、熵分别代表什么含义？

回答

KL 散度约束新策略不要过快偏离参考策略，主要用于防止强化学习把语言能力和回答分布推坏；熵衡量策略输出的不确定性或多样性，熵过低容易过早收敛到单一模式，熵过高则动作或 token 分布过于随机。训练时常把任务奖励、KL 惩罚和熵奖励组合：提高 KL 系数会更保守，提高熵系数会鼓励探索。两者都应随训练阶段和 reward 稳定性调节，并结合通过率、长度、重复率和安全性观察是否出现模式坍塌。

Q043 · 强化学习部分为什么选用GRPO而不直接使用PPO?

回答

PPO 通常依赖 value model 估计状态价值，再用 GAE 构造 advantage；GRPO 对同一 prompt 采样一组回答，用组内奖励的相对均值和方差归一化得到 advantage，因此可省去单独的价值模型。这样能降低显存和工程复杂度，适合数学、代码、可验证问答等问题多采样场景。局限是组内样本过于相似时优势信号很弱，奖励尺度或规则漏洞也会导致 reward hacking。实践中仍需 KL 约束控制策略偏离参考模型，并监控组内奖励方差、响应长度和通过率。

1.18 未标明 · 知乎：大模型的一些面试题小结

公司/机构：未标明 | 方向：大模型面经 | 来源平台：知乎 | 来源日期：2026-06-24

来源链接：<https://zhuanlan.zhihu.com/p/1922623218738504885>

Q044 · 跟原始 Transformer

论文中的绝对位置编码相比，RoPE（旋转位置嵌入）有什么优点？

回答

RoPE 将每个位置对应为不同旋转角度，对 Query 和 Key 的二维子空间做旋转。单个向量携带的是绝对位置角度，但注意力内积中的旋转会简化为两位置角度之差，因此分数自然依赖相对距离。相比直接相加的位置向量，RoPE 不改变向量范数，且能把相对位置信息直接注入 QK 内积。长上下文扩展时，常用 NTK-aware scaling、YaRN 或位置插值调整旋转频率，但必须重新评估远距离注意力、短上下文退化和外推稳定性。

1.19 腾讯 · 小红书：算法面经：腾讯混元大模型算法

公司/机构：腾讯 | 方向：大模型面经 | 来源平台：小红书 | 来源日期：2026-06-24

来源链接：https://www.xiaohongshu.com/explore/6979ceb4000000000a032b5e?xsec_token=ABB6zZ-UgTnZrfGAiSm_oekt8Xqz4pccKCNw3YmvZz5Bo%3D&xsec_source=pc_search

Q045 · 在推荐系统的模型适配中，对比LoRA与全参数微调，它们各自更适合什么样的场景？

回答

LoRA 冻结主模型，只训练低秩增量矩阵，显著降低梯度和优化器状态显存，也便于为不同业务维护独立 adapter；全参微调容量更大，适合大规模领域迁移，但成本高且更容易造成通用能力遗忘。选择时应比较数据规模、领域差异、目标能力是否需要重塑主干表征，以及线上是否需要多租户热切换。LoRA 并非天然无损，rank、注入层、学习率和数据覆盖不足都会限制上限。

1.20 阿里 · 小红书：阿里大模型算法面经

公司/机构：阿里 | 方向：大模型面经 | 来源平台：小红书 | 来源日期：2026-06-24

来源链接：https://www.xiaohongshu.com/explore/6a3a9d210000000017008c3a?xsec_token=ABGFHX_aMmbK4mmCZT-wJheY4NN6llrEEEnziWO6I4xI0%3D&xsec_source=pc_search

Q046 ·

对比DPO和GRPO两种微调方案，核心区别是什么？离线训练和在线采样的优劣分别是什么？

回答

DPO 和“奖励模型 + GRPO”没有绝对优劣，取决于数据和目标。DPO 直接用偏好对优化策略，不需要在线采样和单独 reward model，训练稳定、成本低，适合已有高质量 chosen/rejected 数据的场景；奖励模型 + GRPO 可以对同一 prompt 在线采样多条回答，用可验证奖励或学习型奖励持续探索，适合数学、代码和复杂推理，但工程复杂、采样昂贵，并存在 reward hacking。实践中可先用 DPO 获得稳定起点，再用 GRPO 做小步强化；评估要同时看任务通过率、KL 偏移、回答长度、奖励泛化和安全性。

2. VLA 与具身智能

本章收录 30 道题，来自 12 个来源。

2.1 未标明 · 题库：VLA 与具身智能控制专项

公司/机构：未标明 | 方向：VLA / 具身智能 | 来源平台：内部题库 | 来源日期：2026-06-06

Q047 · VLA 模型中 action token、连续动作回归和 diffusion policy 分别适合哪些控制粒度和任务场景？

回答

Action token 把动作离散成词表，便于复用语言模型的自回归建模和长程规划，适合技能选择、粗粒度控制与跨机器人统一表示，但存在量化误差。连续动作回归直接输出关节、末端位姿或速度，延迟低，适合高频闭环和精细操作，但容易对多解动作取平均。Diffusion Policy 生成整段 action chunk，能表达多峰轨迹并保持平滑，适合抓取、装配等示范分布复杂的任务，代价是多步采样较慢。工程上常采用高层 token 规划、低层连续控制或 diffusion chunk 滚动执行。

Q048 ·

机器人遥操作数据采集时，如何处理多相机、机械臂状态、力控信号和语言指令的时间同步？

回答

遥操作采集应为所有传感器和控制流使用统一单调时钟，并记录高精度时间戳。相机按硬件触发或时间戳重采样对齐，机械臂关节、末端位姿和力矩以高频采集，语言指令记录开始、结束与对应任务阶段。离线构建样本时，以控制周期为主时间轴，对连续状态做插值，对图像取最近帧并限制最大时间差；同时保存时钟漂移、丢帧和网络延迟。轨迹按任务边界和关键事件切成 episode，失败样本标注失败时刻、原因、是否接管以及可否恢复。

Q049 · 轨迹数据如何切分 episode，如何标注成功、失败、中断、重试和人为接管？**回答**

Episode 应按完整任务语义和控制连续性切分：从指令下发或进入初始状态开始，到成功、失败、超时、中断或人工接管结束。除最终标签外，还要记录子目标边界、关键接触事件、重试次数、接管时刻和终止原因。成功需由可验证条件判断；失败要区分感知、规划、控制、碰撞和任务超时；中断要区分系统异常与人为暂停。保留失败前后的观测和动作，可用于训练失败检测、恢复策略和困难负样本。

Q050 · 从 imitation learning 到 online RL，VLA 系统如何设计安全探索和失败样本回流？**回答**

模仿学习直接拟合专家示范，样本效率高、训练稳定，适合先得到可用策略，但会受分布偏移和复合误差影响。强化学习能围绕长期成功率、恢复能力和效率继续优化，但真实机器人探索昂贵且危险。常见流程是先使用行为克隆或 SFT 初始化，再用离线 RL、仿真 RL 或受约束在线 RL 小步改进；在线阶段加入动作限幅、碰撞检查、不确定性门控和人工接管。失败轨迹应回流为负样本、恢复样本或 reward/critic 数据，而不是直接丢弃。

Q051 · 语言规划和低层控制之间如何分层，什么时候需要 skill library 或 hierarchical policy？**回答**

语言规划负责把长任务分解为可执行子目标，低层控制负责把子目标转成稳定的连续动作。若任务由可复用且边界清晰的技能组成，例如抓取、开门、放置，适合使用 skill library：高层选择技能并传参数，便于验证和复用。若技能组合复杂、环境动态或需要端到端优化，可用 hierarchical policy，让高层以较低频率产生 latent skill 或目标状态，低层高频执行。分层接口必须包含前置条件、终止条件、失败码和状态反馈，避免高层计划与低层真实执行脱节。

Q052 · Sim-to-real**迁移中，视觉域随机化、动力学随机化和真实数据少样本微调各自解决什么问题？****回答**

Sim-to-real 差距主要来自视觉外观、动力学、传感器噪声、控制延迟和接触模型不一致。视觉域随机化改变纹理、光照、背景、相机位姿和遮挡，提升感知鲁棒性；动力学随机化改变质量、摩擦、阻尼、执行器延迟和接触参数，提升控制稳定性；真实少样本微调少量目标机器人数据校准剩余偏差。还可结合系统辨识、仿真图像风格迁移和残差策略。随机化范围过窄无法泛化，过宽会降低可学习性，因此需用真实验证集迭代校准。

Q053 · 具身任务评估为什么不能只看成功率，还需要哪些鲁棒性、安全性和泛化指标？

回答

成功率只说明任务是否最终完成，不能反映过程是否安全、稳定和可扩展。具身评估还应包括碰撞率、力/速度越界、人工接管率、near miss、恢复成功率、轨迹平滑度、完成时间和能耗。鲁棒性要测试光照、遮挡、物体位置、传感器噪声和动力学扰动；泛化要覆盖新物体、新场景、新指令组合和不同机器人平台。长程任务还应统计子目标完成率、重规划次数和错误累积。

Q054 · 长程任务中，VLA 如何处理记忆、子目标分解、环境变化和动作不可逆错误？

回答

长程 VLA 需要分层记忆与闭环重规划。高层维护任务状态、已完成子目标、物体关系和历史失败，低层只执行短时 action chunk。每个子目标执行后重新感知并验证结果，而不是假设动作成功。对于不可逆动作，应在执行前做风险预测、可达性检查和安全确认，并提供替代方案或人工接管。记忆可由短期时序状态、结构化场景图和可检索事件日志组成，避免把全部历史都塞进上下文。

2.2 字节 · 小红书：字节VLA具身智能题目精讲

公司/机构：字节 | 方向：VLA / 具身智能 | 来源平台：小红书 | 来源日期：2026-06-14

来源链接：https://www.xiaohongshu.com/explore/6a2cd7840000000015024480?xsec_token=ABph78W1r_ZHk8bqDtoizWXOd456YhxOU55Eab6_ooDKc%3D&xsec_source=pc_search

Q055 · 具身智能任务中，episode 如何切分，成功、失败、中断和人为接管如何标注？

回答

episode 切分要围绕任务语义和控制连续性，而不是机械按固定时长切。一次 episode 通常从任务指令下发、机器人进入初始状态或人工开始遥操作时开始，到任务完成、失败、超时、中断或人为接管时结束。标注时至少记录起止时间、任务目标、关键阶段、动作轨迹、观察流、成功状态和终止原因。成功样本要标注是否完全达成目标、是否有轻微碰撞或多余动作；失败样本要标注失败发生点、失败类型、是否可恢复、是否由感知、规划、控制或环境变化导致；中断样本要区分系统异常、传感器丢失、用户暂停和安全策略触发；人为接管要记录接管时刻、接管前模型输出、人工修正动作和接管原因。这样做的价值是后续可以训练策略、失败检测、恢复策略和 reward/critic，而不是只得到一个粗糙的成功率。

Q056 · VLA 系统如何从 imitation learning 过渡到在线强化学习并控制安全风险？

回答

从 imitation learning 过渡到在线强化学习，通常不能直接把策略放到真实环境里自由探索。更稳的路径是先使用高质量遥操作或人类演示训练 BC/SFT 策略，再用离线 RL、偏好数据或仿真环境做策略改进，最后在真实环境中做受限在线探索。安全风险控制要有几层保护：动作空间限幅、速度/力矩/碰撞约束、安全区域和规则过滤器；策略侧保留不确定性估计、异常检测和可回退的保守策略；数据侧把 near miss、接管、碰撞和失败恢复样本纳入训练；评估侧先过仿真、离线 replay、影子模式和小流量灰度。面试时要强调在线 RL 的收益是优化长期目标和恢复能力，但代价是安全、样本效率和分布漂移，因此必须用 human-in-the-loop 和安全 shield 逐步放开。

Q057 · sim-to-real 中，视觉随机化、动力学随机化和真实少样本微调分别解决什么问题？

回答

视觉随机化、动力学随机化和真实少样本微调解决的是 sim-to-real gap 的不同来源。视觉随机化改变纹理、光照、背景、相机位姿、噪声和遮挡，让视觉 encoder 不依赖仿真里的固定外观，主要提升感知鲁棒性。动力学随机化改变质量、摩擦、关节阻尼、延迟、执行器噪声和接触参数，让策略适应真实物理误差，主要提升控制和接触操作稳定性。真实少样本微调用少量真实机器人数据校准仿真学到的策略或表征，弥补随机化覆盖不到的系统偏差。好的回答要补充取舍：随机化太弱会过拟合仿真，太强会让训练任务不稳定；真实微调数据少但价值高，要优先采集失败、接触、遮挡和边界工况，并用成功率、碰撞率、恢复率和跨场景泛化来评估。

Q058 · 长程具身任务如何处理记忆、子目标分解、环境变化和动作不可逆错误？

回答

长程具身任务要把高层规划和低层控制分开处理。高层用语言或视觉语言模型做任务分解，把目标拆成可执行子目标，并维护环境状态、已完成步骤、物体位置和历史失败；低层用 VLA policy、diffusion policy 或控制器执行抓取、移动、放置等短程技能。环境变化需要持续重感知和状态更新，不能只依赖初始计划；动作不可逆错误要提前做风险评估，比如倒水、碰撞、丢物体、关门后无法再观察等步骤要设置确认、回退或人工接管。记忆可以分成短期上下文、场景地图、对象状态和任务日志。评估不能只看最终成功，还要看子目标成功率、重规划次数、无效动作比例、错误恢复率、任务时长和安全事件。

Q059 · 具身智能评估为什么不能只看成功率，还需要哪些安全性和泛化指标？

回答

具身智能不能只看成功率，因为同样成功可能对应完全不同的安全性、效率和泛化能力。一个策略可能 90% 成功，但剩下 10% 是高风险碰撞或不可恢复错误，这在线上不可接受。除了成功率，还要看碰撞率、接管率、near miss、力/速度越界、任务完成时间、轨迹平滑度、能耗、恢复成功率、失败类型分布和长尾场景覆盖。泛化指标要覆盖新物体、新背景、新光照、新相机位姿、新任务组合和不同机器人平台。对于 VLA/具身系统，还要评估语言指令理解、视觉 grounding、动作可执行性、跨 episode 一致性和安全约束遵守率。面试里可以总结为：成功率回答“能不能做成”，安全和泛化指标回答“能不能稳定、低风险、可规模化地做成”。

2.3 未标明 · B站: 1573 0 06:46 机器人中间件要学到什么程度才能和面试官对线

公司/机构: 未标明 | 方向: VLA / 具身智能 | 来源平台: B站 | 来源日期: 2026-06-14

来源链接: <https://www.bilibili.com/video/BV18pYPzFEKc/>

Q060 · 自动驾驶世界模型如何从 BEV、occupancy、轨迹预测和仿真闭环中学习环境动态?

回答

自动驾驶世界模型把历史多传感器观测、车辆状态和候选动作编码为场景状态, 并预测未来。BEV 提供统一鸟瞰坐标, occupancy 描述空间占用和可见/不可见区域, 轨迹预测表示交通参与者可能运动, 规划动作作为条件影响未来演化。训练可结合重建、未来 occupancy、运动、轨迹和控制损失。真正价值需在闭环仿真中检验: 模型不仅要预测像素或特征, 还要在自车动作变化时生成合理交互结果。

Q061 · 驾驶数据闭环如何做场景挖掘、长尾样本回流、自动标注和仿真评测?

回答

驾驶数据闭环从线上日志中用接管、急刹、碰撞预警、低置信度和规则触发挖掘候选场景, 再做聚类去重和优先级排序。自动标注结合多帧融合、教师模型和地图信息生成 3D 目标、车道、occupancy 与轨迹, 并对低置信样本送入审。训练后先离线回放, 再在可交互仿真中评估安全、舒适和法规指标; 新的失败案例继续回流。关键是版本化数据、标签、模型和场景, 才能追踪每次迭代收益。

2.4 未标明 · CSDN: 具身智能TL常用算法面经: 基础认知与 VLA 框架(一)

公司/机构: 未标明 | 方向: VLA / 具身智能 | 来源平台: CSDN | 来源日期: 2026-06-17

来源链接: https://blog.csdn.net/lovely_yoshino/article/details/160694260?ops_request_misc=elastic_search_misc&request_id=c08cdbe3b7a41e30c78842ca62a9315&biz_id=0

Q062 · VLA 中 action token、连续动作回归和 diffusion policy 各自适合什么控制场景?

回答

Action token 把动作离散成词表, 便于复用语言模型的自回归建模和长程规划, 适合技能选择、粗粒度控制与跨机器人统一表示, 但存在量化误差。连续动作回归直接输出关节、末端位姿或速度, 延迟低, 适合高频闭环和精细操作, 但容易对多解动作取平均。Diffusion Policy 生成整段 action chunk, 能表达多峰轨迹并保持平滑, 适合抓取、装配等示范分布复杂的任务, 代价是多步采样较慢。工程上常采用高层 token 规划、低层连续控制或 diffusion chunk 滚动执行。

Q063 · 机器人数据如何做遥操作采集、时间同步、轨迹切分和失败样本标注？

回答

遥操作采集应为所有传感器和控制流使用统一单调时钟，并记录高精度时间戳。相机按硬件触发或时间戳重采样对齐，机械臂关节、末端位姿和力矩以高频采集，语言指令记录开始、结束与对应任务阶段。离线构建样本时，以控制周期为主时间轴，对连续状态做插值，对图像取最近帧并限制最大时间差；同时保存时钟漂移、丢帧和网络延迟。轨迹按任务边界和关键事件切成 episode，失败样本标注失败时刻、原因、是否接管以及可否恢复。

2.5 未标明 · CSDN：具身智能TL常用算法面经：经典 VLA 模型与动作生成范式(二)

公司/机构：未标明 | 方向：VLA / 具身智能 | 来源平台：CSDN | 来源日期：2026-06-17

来源链接：https://blog.csdn.net/lovely_yoshino/article/details/160722050?ops_request_misc=elastic_search_misc&request_id=c08cdbc e3b7a41e30c78842ca62a9315&biz_id=0

Q064 · VLA 模型中 action token、连续动作回归和 diffusion policy 分别适合什么控制场景？

回答

Action token 把动作离散成词表，便于复用语言模型的自回归建模和长程规划，适合技能选择、粗粒度控制与跨机器人统一表示，但存在量化误差。连续动作回归直接输出关节、末端位姿或速度，延迟低，适合高频闭环和精细操作，但容易对多解动作取平均。Diffusion Policy 生成整段 action chunk，能表达多峰轨迹并保持平滑，适合抓取、装配等示范分布复杂的任务，代价是多步采样较慢。工程上常采用高层 token 规划、低层连续控制或 diffusion chunk 滚动执行。

Q065 · 机器人遥操作数据采集时，如何同步多相机、机械臂状态、力控信号和语言指令？

回答

遥操作采集应为所有传感器和控制流使用统一单调时钟，并记录高精度时间戳。相机按硬件触发或时间戳重采样对齐，机械臂关节、末端位姿和力矩以高频采集，语言指令记录开始、结束与对应任务阶段。离线构建样本时，以控制周期为主时间轴，对连续状态做插值，对图像取最近帧并限制最大时间差；同时保存时钟漂移、丢帧和网络延迟。轨迹按任务边界和关键事件切成 episode，失败样本标注失败时刻、原因、是否接管以及可否恢复。

2.6 智元 · 掘金：CodeSheep 1月前 前端 后端 稚晖君又开始摇人了，有点猛啊！作为具身智能领域的新起独角兽，智元机器人这两年在资本市场可谓是备受关注。谁都没有想到，这家成立仅仅... 参与具身智能基础模型研发，覆盖 VLM/VLA/Vide

公司/机构：智元 | 方向：VLA / 具身智能 | 来源平台：掘金 | 来源日期：2026-06-18

来源链接：<https://juejin.cn/post/7631311804195471396?searchId=20260618093353242051243E29BC377AAC>

Q066 · 智元这类具身智能基础模型岗位中，VLM、VLA 和 Video 模型在机器人系统里分别承担什么角色？

回答

VLM、VLA 和 Video 模型在具身系统中通常对应三层能力。VLM 负责理解场景和指令，例如识别物体、读懂空间关系、把用户语言转成任务语义；Video 模型负责时序理解和预测，例如判断动作进展、物体状态变化、失败前兆和未来几步可能发生什么；VLA 则把视觉、语言和机器人状态映射到动作，输出 action token、连续控制量或一段轨迹。三者可以端到端融合，也可以分层组合：VLM 做高层规划，Video 做状态估计和预测，VLA 做底层动作生成。工程取舍是，端到端系统上限高但难调试，分层系统可解释性好但误差会层层传递。面试里要强调闭环：感知、规划、动作、执行反馈和失败样本回流缺一不可。

Q067 · 具身基础模型训练中，如何组织遥操作数据、仿真数据、视频数据和语言指令数据？

回答

这类数据要按用途分层组织。遥操作数据最接近真实控制，包含相机、机器人状态、动作、力控、任务结果和失败原因，是训练 policy 的核心；仿真数据覆盖长尾场景和安全试错，但需要视觉随机化、动力学随机化和少量真实数据校准；视频数据规模大，适合学习物体状态、动作先验和时序预测，但没有天然动作标签，需要通过伪标注、逆动力学或语言描述补齐；语言指令数据负责把用户目标映射到任务语义和子目标。训练时可以先用视频/图文数据学表征，再用遥操作数据做 imitation learning，最后通过仿真或真实环境强化学习修正失败模式。评估要看成功率、碰撞率、恢复率、跨场景泛化和安全接管次数。

2.7 汇川 · B站：1.0万 0 30:16 汇川C++机器人控制算法面试题

公司/机构：汇川 | 方向：VLA / 具身智能 | 来源平台：B站 | 来源日期：2026-06-19

来源链接：<https://www.bilibili.com/video/BV1DaxkzQECY/>

Q068 · 机器人控制算法面试中，运动规划、轨迹跟踪和底层控制分别解决什么问题？

回答

运动规划解决的是从当前状态到目标状态走哪条路径，重点考虑碰撞约束、可达性、动力学限制和任务目标；轨迹跟踪解决的是沿着规划出的路径如何在时间上平滑执行，重点关注速度、加速度、jerk 和误差收敛；底层控制解决的是如何把期望轨迹转成电机、关节或末端执行器的控制输入，常见方法包括 PID、MPC、阻抗控制和力控。三者的时间尺度不同：规划偏高层、频率较低，控制偏底层、频率更高。面试里还要说清楚误差来源：传感器噪声、模型不准、摩擦、延迟、负载变化和接触不确定性。具身智能系统里，VLA 可以生成高层动作意图或轨迹候选，但真正落地仍需要传统控制和安全约束兜住执行边界。

2.8 未标明 · B站：334 0 00:20 VLA动作置信度≠任务成功率

公司/机构：未标明 | 方向：VLA / 具身智能 | 来源平台：B站 | 来源日期：2026-06-19

来源链接：<https://www.bilibili.com/video/BV1kflv6CEno/>

Q069 · VLA 动作置信度为什么不能等同于任务成功率，机器人控制里应如何做校准？

回答

VLA 的动作置信度通常表示模型对当前动作 token、连续控制量或轨迹片段的预测把握，但任务成功率取决于长时间闭环执行结果，两者不是一回事。模型可能对单步抓取动作很自信，但因为物体滑动、遮挡、相机延迟、接触动力学误差或后续路径规划失败，最终任务仍然失败。校准时要把单步概率和 episode 级结果关联起来：记录每个时刻的观测、动作、置信度、接触状态、人工接管和最终成功/失败标签；再用 reliability diagram、ECE、Brier score 等指标看置信度是否真的对应成功概率。工程上可以训练一个独立 success predictor 或 value head，把视觉状态、动作序列和历史反馈一起输入，输出可执行性评分。上线时不要用置信度直接替代安全判断，而要结合阈值拒答、低置信度接管、失败回放和主动探索数据回流。

2.9 小鹏 · B站：2234 1 05:08 机器人强化学习算法岗位研究--以小鹏机器人为例,拼不过科班出身的了解一下!技术基础/开发教程/算法/训练/薪资/硕士就业分析/招聘岗位/ROS开源项目/ 机器人研究员DeepMeet · 01-04

公司/机构：小鹏 | 方向：VLA / 具身智能 | 来源平台：B站 | 来源日期：2026-06-20

来源链接：<https://www.bilibili.com/video/BV1nyLBNEVX/>

Q070 · VLA 模型为什么需要强化学习，和单纯模仿学习相比能解决哪些问题？

回答

模仿学习主要从专家轨迹里学习动作分布，优点是稳定、样本效率高，但容易受限于专家数据覆盖范围，遇到偏离轨迹的状态时会累积误差。VLA 引入强化学习，是为了让模型在环境反馈下优化长期任务成功率，而不是只拟合单步动作。强化学习可以处理稀疏奖励、失败恢复、探索更优策略和安全接管策略，但代价是训练不稳定、样本成本高，并且真实机器人上试错风险大。实际工程通常不会直接端到端在线 RL，而是先用遥操作或视频数据做预训练和 imitation learning，再在仿真或受控真实环境里做 RL 微调，并通过 reward shaping、离线 RL、success predictor 和安全约束降低风险。面试里要把 reward 设计、sim-to-real、失败样本回流和安全边界讲清楚。

2.10 未标明 · CSDN：Pi0具身智能Java面试题解析：核心技术考点详解

公司/机构：未标明 | 方向：VLA / 具身智能 | 来源平台：CSDN | 来源日期：2026-06-24

来源链接：https://blog.csdn.net/weixin_31315007/article/details/158247399

Q071 · 1 如何处理模型推理延迟问题？

回答

降低模型推理延迟要先拆分视觉编码、prefill、decode/动作生成、通信和控制等待。可采用视觉特征缓存、低分辨率快速路径、模型蒸馏、INT8/FP8、FlashAttention、CUDA Graph、批处理与异步流水线；机器人控制还可让低层控制器在模型计算期间继续执行短 action chunk。必须设置超时和旧结果丢弃机制，避免迟到动作污染闭环。

Q072 · 2 如何设计高效的机器人动作队列？

回答

高效动作队列需要支持时间戳、优先级、可取消和状态反馈。VLA 低频地产生 action chunk，控制线程按固定周期消费；当新观测触发重规划、碰撞风险或人工接管时，应原子地废弃未执行动作并切换到安全动作。队列还应限制最大前瞻时长，记录每个动作的计划时间与实际执行时间，用于监控延迟、丢帧和控制漂移。

2.11 未标明 · CSDN：中国移动具身智能算法（VLA预训练及模型架构方向）面试题精选：10道高频考题+答案解析

公司/机构：未标明 | 方向：VLA / 具身智能 | 来源平台：CSDN | 来源日期：2026-06-24

来源链接：<https://blog.csdn.net/zhhhh15/article/details/160808758>

Q073 · 如何解决Sim-to-Real（仿真到真实）鸿沟？具体有哪些技术手段？

回答

Sim-to-Real 的差距主要来自视觉外观、动力学参数、传感器噪声、控制延迟和接触模型不一致。常用手段包括视觉与动力学域随机化、系统辨识、噪声/延迟注入、仿真图像风格迁移、鲁棒策略训练，以及少量真实数据微调。评估不能只看平均成功率，还要看不同物体、光照、摩擦、载荷和相机位姿下的最差性能与恢复率。

Q074 · 模仿学习（IL）和强化学习（RL）在具身任务中各有什么优劣？如何结合使用？

回答

模仿学习直接拟合专家演示，训练稳定、样本利用率高，适合快速获得可用策略，但容易受到分布偏移和复合误差影响；强化学习能基于长期奖励探索超越演示的策略，但真实机器人采样昂贵且有安全风险。常见组合是先行为克隆/SFT 初始化，再用离线 RL、仿真 RL 或受约束在线 RL 优化成功率和恢复能力，同时保留专家数据做正则，防止策略漂移。

2.12 腾讯 · 小红书：腾讯RoboticsX 具身智能算法一面（贼难）

公司/机构：腾讯 | 方向：VLA / 具身智能 | 来源平台：小红书 | 来源日期：2026-06-24

来源链接：https://www.xiaohongshu.com/explore/69e37080000000020039d78?xsec_token=ABHXIJUG94jDyqOCDzJzB4zp2bIDfU1_FEwualMezweJM%3D&xsec_source=pc_search

Q075 · 手术动辄几小时，Transformer 的 KV Cache 会随时间爆炸，虽然换了 Mamba。但 Mamba 的线性压缩本质上是 Lossy，怎么保证它在记录了前一个小时的操作后，还能精准记得现在对应的逻辑，而不是产生幻觉？

回答

Transformer 的自注意力需要计算序列中 token 两两交互，标准实现的注意力矩阵大小为 $n \times n$ ，因此时间和显存复杂度通常随序列长度呈 $O(n^2)$ 增长；Mamba 使用选择性状态空间模型，把历史压缩进固定维度状态并递推更新，序列计算近似 $O(n)$ 。代价是 Mamba 的状态压缩不是无损记忆，长时细节可能被覆盖。机器人长任务中不应只依赖单一隐状态，而应结合分层记忆：短期连续状态交给 Mamba，关键事件、目标和操作结果写入结构化外部记忆，需要时检索回模型；同时用阶段边界监督、记忆一致性损失和长序列回放评估遗忘。

Q076 · 扩散模型生成的是 Action Chunk，但在手术中，组织形变是实时的。如果你的 Chunk 还没跑完，组织已经发生了非线性位移，你的系统怎么做闭环修正？

回答

Action Chunk 不能作为开环轨迹一次执行到底。更稳妥的做法是采用滚动时域控制：策略每次预测一段动作，但控制器只执行前几个动作，随后重新采集视觉、力觉和机器人本体状态，再用最新观测重规划剩余轨迹。对组织形变这类强非刚性场景，还应加入目标跟踪与形变估计、动作置信度或不确定性检测、力/速度安全约束以及异常触发的快速停止。训练时可通过扰动轨迹、失败恢复数据和延迟随机化，让策略学会在状态偏离时回到可恢复区域。核心是“短执行、频重规划、低层安全控制兜底”，而不是追求一次生成很长的动作序列。

3. 视频与视觉理解

本章收录 21 道题，来自 4 个来源。

3.1 通义 / 小红书 / Seed / 混元相关团队 · 脉脉：语音/音频大模型岗位要求与面试关注点

公司/机构：通义 / 小红书 / Seed / 混元相关团队 | 方向：音频大模型 | 来源平台：脉脉 | 来源日期：2026-06-05

来源链接：<https://maimai.cn/community/home/recommended>

Q077 · 视频模型如何建模动作、因果关系、事件边界和跨镜头一致性？

回答

视频问答评估应按能力拆分。动作理解测试主体、动作和对象是否正确；事件边界用 temporal IoU、mAP 或边界误差衡量起止时间；因果关系需设计仅看单帧无法回答的前因后果题；跨镜头一致性检查同一实体、状态和事件在镜头切换后是否保持；细粒度属性再评估颜色、数量和局部动作。除自动准确率外，还需人工判断答案是否真正依赖视频证据，并用反事实或打乱帧顺序检测模型是否只靠语言先验。

Q078 · 视频问答/视频生成如何评估时序一致性、物理合理性、身份保持和指令遵循？

回答

视频问答评估应按能力拆分。动作理解测试主体、动作和对象是否正确；事件边界用 temporal IoU、mAP 或边界误差衡量起止时间；因果关系需设计仅看单帧无法回答的前因后果题；跨镜头一致性检查同一实体、状态和事件在镜头切换后是否保持；细粒度属性再评估颜色、数量和局部动作。除自动准确率外，还需人工判断答案是否真正依赖视频证据，并用反事实或打乱帧顺序检测模型是否只靠语言先验。

3.2 未标明 · 题库：视频理解与时序建模专项

公司/机构：未标明 | 方向：视频 / 视觉理解 | 来源平台：内部题库 | 来源日期：2026-06-06

Q079 · 视频理解中均匀采样、关键帧采样、运动感知采样和自适应采样分别适合哪些场景？

回答

均匀采样覆盖全局时间轴，适合视频分类和整体摘要，但可能漏掉短暂事件；关键帧采样依据镜头切换、语义变化或显著性，适合事件定位和摘要；运动感知采样根据光流或帧差增加快速动作区域的采样密度；自适应采样由轻量模型根据问题和内容动态决定取帧，效果最好但增加系统复杂度。实际系统常先低成本均匀扫描，再对高变化或与问题相关的片段加密采样。

Q080 · temporal token 压缩如何保留动作变化和事件顺序，和直接长上下文 attention 相比有什么取舍？

回答

Temporal token 压缩通过池化、聚类、token merging、事件边界聚合或可学习 query，把相邻帧的冗余表示合并。为保留动作变化，应对高运动、状态转折和关键对象交互降低压缩率，并加入时间位置编码和顺序监督。直接长上下文 attention 保留细节更完整，但计算与 KV Cache 随 token 数快速增长；压缩显著降低成本，却可能丢失短暂事件和精确顺序。常见方案是多尺度表示：低频全局 token 加高频关键片段 token。

Q081 · 视频问答如何评估动作理解、事件边界、因果关系、跨镜头一致性和细粒度属性识别？

回答

视频问答评估应按能力拆分。动作理解测试主体、动作和对象是否正确；事件边界用 temporal IoU、mAP 或边界误差衡量起止时间；因果关系需设计仅看单帧无法回答的前因后果题；跨镜头一致性检查同一实体、状态和事件在镜头切换后是否保持；细粒度属性再评估颜色、数量和局部动作。除自动准确率外，还需人工判断答案是否真正依赖视频证据，并用反事实或打乱帧顺序检测模型是否只靠语言先验。

Q082 · 长视频理解中如何处理记忆压缩、片段检索、滑窗推理和跨片段信息融合？

回答

长视频可采用“分段编码、索引检索、局部推理、全局融合”。先把视频切成语义片段并生成视觉 token、字幕和事件摘要；用向量索引根据问题检索候选片段；对候选片段做高分辨率滑窗推理；最后通过时间图、层次 Transformer 或外部记忆融合跨片段证据。记忆压缩保存实体状态和关键事件，避免重复编码；滑窗保留局部细节，但窗口重叠和跨窗实体对齐必须处理。

Q083 · 视频生成模型的时序一致性、身份保持、物理合理性和指令遵循分别如何设计评估？

回答

视频生成评估应覆盖四类指标。时序一致性看帧间结构、运动连续性和闪烁，可结合光流误差、temporal LPIPS 和人评；身份保持检查人物或物体跨帧特征一致性；物理合理性评估重力、碰撞、遮挡、物体恒常性和因果关系；指令遵循检查主体、动作、场景、镜头和时间顺序是否符合文本。FVD 等总体分数不能单独使用，应配合分项 benchmark、人工偏好和真实失败案例。

Q084 · 多模态视频数据清洗时，字幕、ASR、画面内容和问题答案之间如何做一致性校验？

回答

多模态视频清洗需先做时间对齐：字幕和 ASR 绑定到精确时间段，画面按镜头或事件切片。随后检查 ASR 置信度、字幕重复和语言一致性，并用视觉文本相似度验证语音描述是否对应画面。问答数据要确认答案能从指定时间段获得，排除只依赖常识、标题或泄漏字幕的样本。还应检测静态视频、黑屏、重复片段、音画错位和敏感内容，并通过抽样人审校准自动阈值。

Q085 · 视频 grounding 和图像 grounding 的主要差异是什么，时空定位指标应该怎么看？

回答

图像 grounding 只需在单帧定位区域，视频 grounding 还需确定时间范围并保持目标跨帧身份，因此同时包含空间框和时间片段。常见指标包括 temporal IoU、spatial IoU、时空 tube IoU、Recall@IoU、mAP，以及起止边界误差。对移动目标还应评估轨迹连续性和身份切换。数据集要覆盖短事件、长事件、遮挡、镜头切换和多个相似实例，防止模型只靠字幕或单帧线索。

Q086 · 在线视频理解服务如何控制帧抽取成本、encoder 复用、缓存和响应延迟？

回答

在线视频理解应将解码、取帧、视觉编码和语言推理解耦。先用低成本镜头切分或运动检测减少无效帧，再按问题自适应加密关键片段；相同视频的视觉特征按视频哈希和时间段缓存，避免重复跑 encoder；长视频采用分段批处理和异步预取。延迟监控要拆成视频下载、解码、encoder、检索和 LLM 阶段，并限制最大帧数、分辨率和上下文 token。热点视频可预计算特征，实时流则使用滑窗增量编码。

3.3 未标明 · CSDN：大模型，多模态大模型面试问题记录【时序，Qformer，卷积，感受野，ControlNet，IP

公司/机构：未标明 | 方向：多模态大模型 | 来源平台：CSDN | 来源日期：2026-06-14

来源链接：https://blog.csdn.net/qq_45934285/article/details/143261317?ops_request_misc=elastic_search_misc&request_id=c8807a7ab28dbb2c805a1ada07358a16&biz_id=0

Q087 · 视频理解中帧采样、temporal token 压缩和 long-context attention 如何取舍？

回答

均匀采样覆盖全局时间轴，适合视频分类和整体摘要，但可能漏掉短暂事件；关键帧采样依据镜头切换、语义变化或显著性，适合事件定位和摘要；运动感知采样根据光流或帧差增加快速动作区域的采样密度；自适应采样由轻量模型根据问题和内容动态决定取帧，效果最好但增加系统复杂度。实际系统常先低成本均匀扫描，再对高变化或与问题相关的片段加密采样。

Q088 · 视频模型如何评估时序一致性、动作理解、事件边界和身份保持？

回答

视频模型评估应拆成四个独立维度。时序一致性检查状态变化是否连续，可用帧间特征距离、光流一致性和人工闪烁评分；动作理解用动作类别、主体-动作-对象三元组和顺序问答；事件边界用 temporal IoU、边界误差和 mAP；身份保持用跨帧人脸/物体特征相似度、ID switch 和属性稳定性。还应加入帧顺序打乱、遮挡和镜头切换测试，判断模型是否真正利用时间信息。

Q089 ·

视频理解中，均匀采样、关键帧采样、运动感知采样和自适应采样分别适合什么场景？

回答

均匀采样覆盖全局时间轴，适合视频分类和整体摘要，但可能漏掉短暂事件；关键帧采样依据镜头切换、语义变化或显著性，适合事件定位和摘要；运动感知采样根据光流或帧差增加快速动作区域的采样密度；自适应采样由轻量模型根据问题和内容动态决定取帧，效果最好但增加系统复杂度。实际系统常先低成本均匀扫描，再对高变化或与问题相关的片段加密采样。

Q090 · temporal token 压缩如何保留动作变化和事件顺序，相比长上下文 attention 有什么取舍？

回答

Temporal token 压缩通过池化、聚类、token merging、事件边界聚合或可学习 query，把相邻帧的冗余表示合并。为保留动作变化，应对高运动、状态转折和关键对象交互降低压缩率，并加入时间位置编码和顺序监督。直接长上下文 attention 保留细节更完整，但计算与 KV Cache 随 token 数快速增长；压缩显著降低成本，却可能丢失短暂事件和精确顺序。常见方案是多尺度表示：低频全局 token 加高频关键片段 token。

Q091 · 视频问答如何评估动作理解、事件边界、因果关系和跨镜头一致性？

回答

视频问答评估应按能力拆分。动作理解测试主体、动作和对象是否正确；事件边界用 temporal IoU、mAP 或边界误差衡量起止时间；因果关系需设计仅看单帧无法回答的前因后果题；跨镜头一致性检查同一实体、状态和事件在镜头切换后是否保持；细粒度属性再评估颜色、数量和局部动作。除自动准确率外，还需人工判断答案是否真正依赖视频证据，并用反事实或打乱帧顺序检测模型是否只靠语言先验。

Q092 · 长视频理解中，记忆压缩、片段检索、滑窗推理和跨片段融合如何组合？

回答

长视频可采用“分段编码、索引检索、局部推理、全局融合”。先把视频切成语义片段并生成视觉 token、字幕和事件摘要；用向量索引根据问题检索候选片段；对候选片段做高分辨率滑窗推理；最后通过时间图、层次 Transformer 或外部记忆融合跨片段证据。记忆压缩保存实体状态和关键事件，避免重复编码；滑窗保留局部细节，但窗口重叠和跨窗实体对齐必须处理。

Q093 · 视频生成模型的时序一致性、身份保持、物理合理性和指令遵循如何评估？

回答

视频生成评估应覆盖四类指标。时序一致性看帧间结构、运动连续性和闪烁，可结合光流误差、temporal LPIPS 和人评；身份保持检查人物或物体跨帧特征一致性；物理合理性评估重力、碰撞、遮挡、物体恒常性和因果关系；指令遵循检查主体、动作、场景、镜头和时间顺序是否符合文本。FVD 等总体分数不能单独使用，应配合分项 benchmark、人工偏好和真实失败案例。

Q094 · 视频 grounding 与图像 grounding 的主要差异是什么，时空定位指标怎么设计？

回答

图像 grounding 只需在单帧定位区域，视频 grounding 还需确定时间范围并保持目标跨帧身份，因此同时包含空间框和时间片段。常见指标包括 temporal IoU、spatial IoU、时空 tube IoU、Recall@IoU、mAP，以及起止边界误差。对移动目标还应评估轨迹连续性和身份切换。数据集要覆盖短事件、长事件、遮挡、镜头切换和多个相似实例，防止模型只靠字幕或单帧线索。

Q095 · 多模态视频数据清洗时，字幕、ASR、画面内容和问答之间如何做一致性校验？

回答

多模态视频清洗需先做时间对齐：字幕和 ASR 绑定到精确时间段，画面按镜头或事件切片。随后检查 ASR 置信度、字幕重复和语言一致性，并用视觉文本相似度验证语音描述是否对应画面。问答数据要确认答案能从指定时间段获得，排除只依赖常识、标题或泄漏字幕的样本。还应检测静态视频、黑屏、重复片段、音画错位和敏感内容，并通过抽样人审校准自动阈值。

Q096 · 在线视频理解服务如何控制帧抽取成本、encoder 缓存和响应延迟？

回答

在线视频理解应将解码、取帧、视觉编码和语言推理解耦。先用低成本镜头切分或运动检测减少无效帧，再按问题自适应加密关键片段；相同视频的视觉特征按视频哈希和时间段缓存，避免重复跑 encoder；长视频采用分段批处理和异步预取。延迟监控要拆成视频下载、解码、encoder、检索和 LLM 阶段，并限制最大帧数、分辨率和上下文 token。热点视频可预计算特征，实时流则使用滑窗增量编码。

3.4 未标明 · B站：2082 0 35:11

多模态大模型视频理解加速 | VideoAuto-R1: GRPO 强化学习 + 置信度，实现动态推理与Early Exit | 让视频推理又快又准 唐国梁Tommy · 01-22

公司/机构：未标明 | 方向：视频 / 视觉理解 | 来源平台：B站 | 来源日期：2026-06-20

来源链接：<https://www.bilibili.com/video/BV1h7zFBEEFA/>

Q097 · 视频理解模型如何用动态推理和 Early Exit 降低延迟，同时尽量不牺牲准确率？

回答

视频理解的计算量主要来自帧数、分辨率和时序 attention。动态推理的思路是让模型根据样本难度自适应决定看多少帧、走多少层或生成多长推理链。简单样本可以早退出，复杂样本继续计算。Early Exit 通常会在中间层加分类头、置信度估计或价值判断，当置信度足够高且跨帧一致性稳定时提前输出。关键风险是过早退出会漏掉后续关键事件，因此要结合时间覆盖约束、置信度校准和困难样本回退策略。训练上可以用蒸馏、强化学习或代价敏感目标，把准确率和计算成本一起优化。评估时不能只看平均延迟，还要看 P95/P99、长视频事件召回、动作边界、身份保持和低置信度样本的失败率。

4. 世界模型与自动驾驶

本章收录 13 道题，来自 3 个来源。

4.1 蔚来 · 小红书：蔚来大模型算法面经

公司/机构：蔚来 | 方向：自动驾驶 / 世界模型 | 来源平台：小红书 | 来源日期：2026-06-05

来源链接：https://www.xiaohongshu.com/search_result/68b7ef74000000001b030950?xsec_token=ABmNiAbZMsocld6zx5LpZoLGkaSkO3HkDKM_ppMt2vISE=&xsec_source=pc_search

Q098 · 座舱多模态大模型如何融合语音、视觉、车控状态和用户上下文，并保证安全边界？

回答

座舱模型应把语音 ASR、摄像头视觉、车辆 CAN 状态、导航和用户历史按时间对齐，并通过模态专用编码器接入统一语言模型。用户请求先做意图与权限判断，再生成可执行车控计划；涉及驾驶安全的功能必须经过白名单、状态机和二次确认，禁止模型直接发送任意控制指令。隐私上要最小化采集、区分本地与云端处理并隔离用户记忆。评估既看交互成功率，也看误触发、越权、分心风险和不同噪声场景鲁棒性。

4.2 未标明 · 题库：自动驾驶数据闭环与世界模型专项

公司/机构：未标明 | 方向：自动驾驶 / 世界模型 | 来源平台：内部题库 | 来源日期：2026-06-06

Q099 ·

自动驾驶数据闭环中，长尾场景挖掘、自动标注、训练回流和仿真评测如何形成闭环？

回答

驾驶数据闭环从线上日志中用接管、急刹、碰撞预警、低置信度和规则触发挖掘候选场景，再做聚类去重和优先级排序。自动标注结合多帧融合、教师模型和地图信息生成 3D 目标、车道、occupancy 与轨迹，并对低置信样本送入审。训练后先离线回放，再在可交互仿真中评估安全、舒适和法规指标；新的失败案例继续回流。关键是版本化数据、标签、模型和场景，才能追踪每次迭代收益。

Q100 · BEV、occupancy、轨迹预测和端到端规划分别在世界模型中承担什么表示角色？

回答

BEV 将多摄像头和雷达信息映射到统一鸟瞰空间，便于几何推理；occupancy 进一步表达每个空间单元是否被占用、类别和运动状态，能覆盖非规则物体；轨迹预测描述其他参与者未来的多模态行为；端到端规划根据这些状态和导航目标直接输出自车轨迹或控制。世界模型可把它们组织成从当前状态到未来状态的层次表示，但应避免中间表示与最终规划目标割裂。

Q101 · 世界模型如何学习环境动态，和传统感知预测规划模块相比优势和风险是什么？

回答

自动驾驶世界模型把历史多传感器观测、车辆状态和候选动作编码为场景状态，并预测未来。BEV 提供统一鸟瞰坐标，occupancy 描述空间占用和可见/不可见区域，轨迹预测表示交通参与者可能运动，规划动作作为条件影响未来演化。训练可结合重建、未来 occupancy、运动、轨迹和控制损失。真正价值需在闭环仿真中检验：模型不仅要预测像素或特征，还要在自车动作变化时生成合理交互结果。

Q102 ·**多传感器数据中，相机、激光雷达、毫米波雷达、定位和车控状态如何做时间空间对齐？****回答**

时间对齐需使用硬件同步、PTP/GPS 时钟或统一高精度时间戳，并估计传感器固定延迟和时钟漂移；对不同频率数据按目标时间插值或取最近帧。空间对齐先做相机内参，再求各传感器到车体坐标系的外参，并在线监控震动导致的漂移。车辆运动期间还需用 IMU/里程计做运动补偿，将点云、图像和雷达测量变换到同一参考时刻。校准质量可用重投影误差、地图对齐和跨传感器目标一致性评估。

Q103 · 仿真评测如何保证场景真实性、交互合理性、覆盖率和指标可解释性？**回答**

端到端模型不应独自承担全部安全责任。训练中加入法规、碰撞、可行驶区域和舒适性损失；推理时由独立安全层检查速度、间距、交通规则和轨迹可达性，必要时覆盖模型输出。分布外检测可结合特征距离、模型集成和不确定性，触发降级或人工接管。可解释性通过输出关键对象、占用、候选轨迹及风险评分实现。验证必须覆盖闭环仿真、故障注入、长尾场景和形式化安全约束。

Q104 · 自动驾驶数据筛选时，如何识别 corner case、near miss、接管片段和标注不确定样本？**回答**

Corner case 可由规则触发、模型低置信、预测分歧和异常检测共同挖掘；near miss 可用 TTC、急刹、横向距离和风险模型识别；接管片段需向前回溯若干秒捕获诱因，并区分安全接管与舒适性接管。标注不确定样本可根据多标注者分歧、教师模型方差和时序不一致筛选。候选场景还需聚类去重、按风险和新颖度排序，避免数据闭环被大量相似普通样本淹没。

Q105 · 端到端自动驾驶模型如何处理可解释性、安全边界、法规约束和分布外场景？**回答**

端到端模型不应独自承担全部安全责任。训练中加入法规、碰撞、可行驶区域和舒适性损失；推理时由独立安全层检查速度、间距、交通规则和轨迹可达性，必要时覆盖模型输出。分布外检测可结合特征距离、模型集成和不确定性，触发降级或人工接管。可解释性通过输出关键对象、占用、候选轨迹及风险评分实现。验证必须覆盖闭环仿真、故障注入、长尾场景和形式化安全约束。

Q106 ·

座舱多模态大模型如何融合语音、视觉、车辆状态和用户上下文，同时保证安全策略？

回答

座舱模型应把语音 ASR、摄像头视觉、车辆 CAN 状态、导航和用户历史按时间对齐，并通过模态专用编码器接入统一语言模型。用户请求先做意图与权限判断，再生成可执行车控计划；涉及驾驶安全的功能必须经过白名单、状态机和二次确认，禁止模型直接发送任意控制指令。隐私上要最小化采集、区分本地与云端处理并隔离用户记忆。评估既看交互成功率，也看误触发、越权、分心风险和不同噪声场景鲁棒性。

4.3 小鹏·小红书：小鹏汽车多模态大模型算法面经 momo 2025

公司/机构：小鹏 | 方向：自动驾驶 / 世界模型 | 来源平台：小红书 | 来源日期：2026-06-14

来源链接：https://www.xiaohongshu.com/search_result/?keyword=%E5%A4%9A%E6%A8%A1%E6%80%81%E5%A4%A7%E6%A8%A1%E5%9E%8B+%E9%9D%A2%E8%AF%95%E9%A2%98&type=51&xsec_source=pc_search

Q107 · 世界模型和传统感知、预测、规划模块相比，优势、风险和可解释性问题是什么？

回答

传统栈将感知、预测和规划模块化，接口清晰、易定位问题，但误差会逐级传播且难以联合优化。世界模型学习环境状态转移，可利用海量无标签视频、做反事实 rollout，并让规划直接考虑动作对未来的影响。风险包括生成未来不真实、长时误差累积、闭环分布漂移和难以给出安全保证。可解释性可通过显式 BEV/occupancy、对象轨迹、因果探针和反事实场景提升，同时保留规则安全层和模块化诊断指标。

Q108 · 驾驶数据闭环中，长尾场景挖掘、自动标注、训练回流和仿真评测如何形成闭环？

回答

驾驶数据闭环从线上日志中用接管、急刹、碰撞预警、低置信度和规则触发挖掘候选场景，再做聚类去重和优先级排序。自动标注结合多帧融合、教师模型和地图信息生成 3D 目标、车道、occupancy 与轨迹，并对低置信样本送入审。训练后先离线回放，再在可交互仿真中评估安全、舒适和法规指标；新的失败案例继续回流。关键是版本化数据、标签、模型和场景，才能追踪每次迭代收益。

Q109 · 多传感器数据中，相机、激光雷达、毫米波雷达、定位和车控状态如何时空对齐？

回答

时间对齐需使用硬件同步、PTP/GPS 时钟或统一高精度时间戳，并估计传感器固定延迟和时钟漂移；对不同频率数据按目标时间插值或取最近帧。空间对齐先做相机内参，再求各传感器到车体坐标系的外参，并在线监控震动导致的漂移。车辆运动期间还需用 IMU/里程计做运动补偿，将点云、图像和雷达测量变换到同一参考时刻。校准质量可用重投影误差、地图对齐和跨传感器目标一致性评估。

Q110 · 端到端自动驾驶模型如何处理安全边界、法规约束、分布外场景和可解释性？

回答

端到端模型不应独自承担全部安全责任。训练中加入法规、碰撞、可行驶区域和舒适性损失；推理时由独立安全层检查速度、间距、交通规则和轨迹可达性，必要时覆盖模型输出。分布外检测可结合特征距离、模型集成和不确定性，触发降级或人工接管。可解释性通过输出关键对象、占用、候选轨迹及风险评分实现。验证必须覆盖闭环仿真、故障注入、长尾场景和形式化安全约束。

5. 训练框架与大规模训练

本章收录 23 道题，来自 4 个来源。

5.1 未标明 · 脉脉：大模型训练框架面经讨论

公司/机构：未标明 | 方向：训练框架 | 来源平台：脉脉 | 来源日期：2026-06-05

来源链接：<https://maimai.cn/community/home/recommended>

Q111 · 大模型训练中显存占用如何拆解到参数、梯度、优化器状态、激活值和 KV cache？

回答

训练显存由模型参数、梯度、优化器状态、激活值和临时/通信缓冲组成。BF16 参数约 2 字节，梯度通常再 2 字节；Adam 的一阶、二阶矩及可能的 FP32 主权重会带来每参数约 8–12 字节额外开销。激活随 micro-batch、序列长度、隐藏维和层数增长，长序列时常成为主项。临时 buffer 来自 attention、算子 workspace 和通信桶。优化可用 ZeRO/FSDP、混合精度、checkpointing、FlashAttention、序列并行和 offload。KV Cache 主要属于推理显存，不应和训练激活混为一谈。

Q112 · 混合精度、gradient checkpointing、FlashAttention 和通信重叠如何影响吞吐与稳定性？

回答

Gradient checkpointing 不保存部分前向激活，反向时重算，显著省显存但增加计算；FlashAttention 通过分块和在线 softmax 减少注意力矩阵的显存读写，通常同时提升速度和降低显存；activation offload 把激活移到 CPU/NVMe，显存收益大但受 PCIe 带宽和同步影响。三者可组合，但需避免重算与 offload 造成过多等待。稳定性方面 FlashAttention 应验证数值误差，checkpointing 要保证随机算子状态一致，offload 要监控传输超时。

5.2 未标明 · 题库：大模型训练框架与显存优化专项

公司/机构：未标明 | 方向：训练框架 | 来源平台：内部题库 | 来源日期：2026-06-06

Q113 · 数据并行、张量并行、流水并行、序列并行和专家并行分别解决什么瓶颈？

回答

数据并行复制模型并切分 batch，适合模型能放入单卡但需要扩吞吐；张量并行切分单层矩阵，解决单层过宽；流水线并行按层切分，解决模型过深但有 bubble；序列并行沿 token 维切分 LayerNorm、激活等，降低长序列显存；专家并行把 MoE 专家分布到不同设备，通过 all-to-all 路由 token。ZeRO/FSDP 则切分优化器状态、梯度和参数。实际系统通常组合使用，瓶颈在显存、通信、负载均衡和调度复杂度。

Q114 · DeepSpeed ZeRO-1/2/3

分别切分哪些状态，通信量、显存节省和实现复杂度如何变化？

回答

ZeRO-1 只切分优化器状态，通信变化较小；ZeRO-2 再切分梯度，进一步省显存；ZeRO-3 连参数也切分，每层计算前按需 all-gather 参数，显存节省最大但通信和调度最复杂。以 Adam 为例，优化器状态通常是显存大头，因此 ZeRO-1 已有明显收益；ZeRO-3 适合单卡无法容纳模型参数的情况。选择时要考虑网络带宽、micro-batch、参数重用、通信重叠和 CPU/NVMe offload，不能只看理论显存。

Q115 · Megatron 中 tensor parallel 的列切分和行切分为什么要配合 collective 通信？

回答

Megatron 张量并行通过列切分和行切分让相邻线性层的通信最小化。第一层按输出维列切分，每卡产生部分隐藏特征，后续可直接并行计算；第二层按输入维行切分，每卡计算部分结果，最后用 all-reduce 合并。注意力头和 FFN 中间维也按类似方式切分。Collective 通信保证不同卡上的部分张量在需要时聚合；切分顺序若设计不当，会在每层之间产生额外 all-gather，吞吐显著下降。

Q116 · 训练显存如何拆解为参数、梯度、优化器状态、激活值、临时 buffer 和通信 buffer？

回答

训练显存由模型参数、梯度、优化器状态、激活值和临时/通信缓冲组成。BF16 参数约 2 字节，梯度通常再 2 字节；Adam 的一阶、二阶矩及可能的 FP32 主权重会带来每参数约 8–12 字节额外开销。激活随 micro-batch、序列长度、隐藏维和层数增长，长序列时常成为主项。临时 buffer 来自 attention、算子 workspace 和通信桶。优化可用 ZeRO/FSDP、混合精度、checkpointing、FlashAttention、序列并行和 offload。KV Cache 主要属于推理显存，不应和训练激活混为一谈。

Q117 · gradient checkpointing、FlashAttention、activation offload 分别如何影响显存、吞吐和稳定性？

回答

Gradient checkpointing 不保存部分前向激活，反向时重算，显著省显存但增加计算；FlashAttention 通过分块和在线 softmax 减少注意力矩阵的显存读写，通常同时提升速度和降低显存；activation offload 把激活移到 CPU/NVMe，显存收益大但受 PCIe 带宽和同步影响。三者可组合，但需避免重算与 offload 造成过多等待。稳定性方面 FlashAttention 应验证数值误差，checkpointing 要保证随机算子状态一致，offload 要监控传输超时。

Q118 · 大规模训练中 loss spike、梯度溢出、数据异常和通信 hang 应该如何定位？

回答

定位大规模训练异常要保存 step 级 loss、梯度范数、学习率、数据批次 ID 和通信事件。Loss spike 先排查异常样本、长度突变和学习率，再检查数值溢出；梯度溢出可查看各层 amax、loss scale 和 NaN 首发层；数据异常通过固定批次复现和数据哈希定位；通信 hang 则检查各 rank 是否走到同一 collective、张量形状是否一致、超时日志和网络错误。应支持自动跳过坏批次、保存故障 checkpoint 和最小规模复现。

Q119 · 混合精度训练中 FP16、BF16、FP8 的数值稳定性和硬件收益如何比较？

回答

FP16 尾数精度较高但指数范围小，容易梯度溢出，通常需要 loss scaling；BF16 与 FP32 指数范围相同，训练更稳定，现代大模型常优先使用，但细粒度精度略低；FP8 显存和算力收益更大，需要硬件支持、逐张量/通道缩放、amax 历史和高精度累积。选择时看硬件、模型规模和稳定性：BF16 常作默认，FP16 用于旧硬件，FP8 适合成熟训练栈的大规模加速，并需监控 loss spike 和层级溢出。

Q120 · 训练吞吐优化时，global batch、micro batch、pipeline bubble 和通信重叠如何联动调参？

回答

$\text{Global batch} = \text{micro-batch} \times \text{数据并行度} \times \text{梯度累积步数}$ 。增大 micro-batch 可提高算子利用率，但会增加激活显存；减小 micro-batch 并增加累积能省显存，却可能降低吞吐。流水线并行需要足够多 micro-batch 填满各 stage，减少 bubble；通信重叠则把梯度 all-reduce、参数 all-gather 放到相邻计算后面。调参时先满足显存，再通过 profile 找算子、流水线空闲和通信占比，并同步调整学习率与 global batch。

5.3 字节 · 小红书：字节训练框架推理优化题目精讲

公司/机构：字节 | 方向：训练框架 / 推理优化 | 来源平台：小红书 | 来源日期：2026-06-14

来源链接：https://www.xiaohongshu.com/search_result/6a2cd39c000000001503c862?xsec_token=ABph78W1r_ZHk8bqDtoizWXIM5-ErHrykT5k6uiUMg5Y%3D&xsec_source=pc_search

Q121 · DeepSpeed ZeRO、Megatron 张量并行、流水并行和数据并行分别解决什么瓶颈？

回答

数据并行复制模型并切分 batch，适合模型能放入单卡但需要扩吞吐；张量并行切分单层矩阵，解决单层过宽；流水线并行按层切分，解决模型过深但有 bubble；序列并行沿 token 维切分 LayerNorm、激活等，降低长序列显存；专家并行把 MoE 专家分布到不同设备，通过 all-to-all 路由 token。ZeRO/FSDP 则切分优化器状态、梯度和参数。实际系统通常组合使用，瓶颈在显存、通信、负载均衡和调度复杂度。

Q122 · 大模型训练中显存如何拆解到参数、梯度、优化器状态、激活值和 KV cache？

回答

训练显存由模型参数、梯度、优化器状态、激活值和临时/通信缓冲组成。BF16 参数约 2 字节，梯度通常再 2 字节；Adam 的一阶、二阶矩及可能的 FP32 主权重会带来每参数约 8–12 字节额外开销。激活随 micro-batch、序列长度、隐藏维和层数增长，长序列时常成为主项。临时 buffer 来自 attention、算子 workspace 和通信桶。优化可用 ZeRO/FSDP、混合精度、checkpointing、FlashAttention、序列并行和 offload。KV Cache 主要属于推理显存，不应和训练激活混为一谈。

Q123 · KV cache、PagedAttention、continuous batching 和 speculative decoding 如何提升推理吞吐？

回答

Continuous batching 不等待整个静态 batch 完成，而是在每个 decode step 动态加入新请求、移除已完成请求，使 GPU 长期保持高利用率。吞吐因此提高，但长请求可能占用资源更久，短请求可能排队；过大的 token batch 也会增加单步时间和 P99 延迟。调度器通常结合优先级、等待时间、剩余长度估计和 prefill/decode 分离，设置最大 batch token、抢占或 chunked prefill，在吞吐与公平性间取舍。

Q124 · INT8/INT4 量化、AWQ/GPTQ、LoRA 合并和蒸馏分别适合哪些部署场景？

回答

GPTQ 是基于校准数据和二阶近似的离线权重量化，适合单批或低并发部署；AWQ 保护重要激活通道，常用于低比特权重量化且质量较稳；SmoothQuant 把激活离群值部分迁移到权重，适合权重与激活 INT8；INT8 通常质量风险较低，INT4 显存收益更大但对数学、代码和长上下文更敏感。部署选择还取决于硬件 kernel、是否量化 KV Cache、吞吐目标和校准集代表性。

Q125 · 数据并行、张量并行、流水线并行、序列并行和专家并行分别解决什么瓶颈？

回答

数据并行复制模型并切分 batch，适合模型能放入单卡但需要扩吞吐；张量并行切分单层矩阵，解决单层过宽；流水线并行按层切分，解决模型过深但有 bubble；序列并行沿 token 维切分 LayerNorm、激活等，降低长序列显存；专家并行把 MoE 专家分布到不同设备，通过 all-to-all 路由 token。ZeRO/FSDP 则切分优化器状态、梯度和参数。实际系统通常组合使用，瓶颈在显存、通信、负载均衡和调度复杂度。

Q126 · DeepSpeed ZeRO-1/2/3 分别切分哪些状态，显存节省和通信开销如何变化？

回答

ZeRO-1 只切分优化器状态，通信变化较小；ZeRO-2 再切分梯度，进一步省显存；ZeRO-3 连参数也切分，每层计算前按需 all-gather 参数，显存节省最大但通信和调度最复杂。以 Adam 为例，优化器状态通常是显存大头，因此 ZeRO-1 已有明显收益；ZeRO-3 适合单卡无法容纳模型参数的情况。选择时要考虑网络带宽、micro-batch、参数重用、通信重叠和 CPU/NVMe offload，不能只看理论显存。

Q127 · Megatron 的 tensor parallel 为什么需要行切分、列切分和 collective 通信配合？

回答

Megatron 张量并行通过列切分和行切分让相邻线性层的通信最小化。第一层按输出维列切分，每卡产生部分隐藏特征，后续可直接并行计算；第二层按输入维行切分，每卡计算部分结果，最后用 all-reduce 合并。注意力头和 FFN 中间维也按类似方式切分。Collective 通信保证不同卡上的部分张量在需要时聚合；切分顺序若设计不当，会在每层之间产生额外 all-gather，吞吐显著下降。

Q128 · 大模型训练显存如何拆成参数、梯度、优化器状态、激活值和临时 buffer？

回答

训练显存由模型参数、梯度、优化器状态、激活值和临时/通信缓冲组成。BF16 参数约 2 字节，梯度通常再 2 字节；Adam 的一阶、二阶矩及可能的 FP32 主权重会带来每参数约 8–12 字节额外开销。激活随 micro-batch、序列长度、隐藏维和层数增长，长序列时常成为主项。临时 buffer 来自 attention、算子 workspace 和通信桶。优化可用 ZeRO/FSDP、混合精度、checkpointing、FlashAttention、序列并行和 offload。KV Cache 主要属于推理显存，不应和训练激活混为一谈。

Q129 · gradient checkpointing、FlashAttention 和 activation offload 分别如何影响显存和吞吐？

回答

Gradient checkpointing 不保存部分前向激活，反向时重算，显著省显存但增加计算；FlashAttention 通过分块和在线 softmax 减少注意力矩阵的显存读写，通常同时提升速度和降低显存；activation offload 把激活移到 CPU/NVMe，显存收益大但受 PCIe 带宽和同步影响。三者可组合，但需避免重算与 offload 造成过多等待。稳定性方面 FlashAttention 应验证数值误差，checkpointing 要保证随机算子状态一致，offload 要监控传输超时。

Q130 · FP16、BF16、FP8 在数值稳定性、硬件收益和训练风险上有什么差异？

回答

FP16 尾数精度较高但指数范围小，容易梯度溢出，通常需要 loss scaling；BF16 与 FP32 指数范围相同，训练更稳定，现代大模型常优先使用，但细粒度精度略低；FP8 显存和算力收益更大，需要硬件支持、逐张量/通道缩放、amax 历史和高精度累积。选择时看硬件、模型规模和稳定性：BF16 常作默认，FP16 用于旧硬件，FP8 适合成熟训练栈的大规模加速，并需监控 loss spike 和层级溢出。

Q131 · global batch、micro batch、pipeline bubble 和通信重叠如何联动调参？

回答

Global batch = micro-batch × 数据并行度 × 梯度累积步数。增大 micro-batch 可提高算子利用率，但会增加激活显存；减小 micro-batch 并增加累积能省显存，却可能降低吞吐。流水线并行需要足够多 micro-batch 填满各 stage，减少 bubble；通信重叠则把梯度 all-reduce、参数 all-gather 放到相邻计算后面。调参时先满足显存，再通过 profile 找算子、流水线空闲和通信占比，并同步调整学习率与 global batch。

5.4 字节 · CSDN：【26届校招】字节多模态大模型面经：一文掌握DeepSpeed、LoRA、RLHF等核心技术！

公司/机构：字节 | 方向：训练框架 / 对齐训练 | 来源平台：CSDN | 来源日期：2026-06-18

来源链接：https://blog.csdn.net/libaiup/article/details/152087779?ops_request_misc=elastic_search_misc&request_id=e1fdf9a1dc62ad0e6db37c5329488736&biz_id=0

Q132 · 字节多模态大模型训练中，DeepSpeed ZeRO、LoRA 和 RLHF 分别解决什么问题，如何取舍？

回答

这题要把训练链路拆开讲。DeepSpeed ZeRO 解决的是大模型训练时参数、梯度和优化器状态的显存压力，适合全参训练或大规模继续预训练；LoRA 解决的是低成本任务适配，通过低秩增量参数减少训练显存和存储成本，适合垂直任务微调和多租户部署；RLHF 解决的是模型输出偏好与人类期望不一致的问题，通常放在 SFT 之后，用偏好数据、reward model 或 DPO/GRPO 类方法做对齐。取舍上，如果目标是扩展模型能力，优先考虑全参训练和 ZeRO；如果目标是快速适配业务，优先 LoRA；如果基础能力已经够但回答风格、安全性、指令遵循不稳定，再做 RLHF 或偏好优化。面试里还要补一句：三者不是互斥关系，真实大厂训练常常是 ZeRO 支撑训练底座，LoRA 做快速实验，RLHF/DPO 做最后对齐。

Q133 · 多模态大模型训练时，视觉 encoder、LLM、LoRA 适配层和奖励/偏好数据应如何分阶段训练？

回答

比较稳的训练路径通常分四段。第一段做图文对齐，让视觉 encoder 或 connector 把视觉 token 对齐到 LLM 能理解的语义空间，核心指标看 caption、OCR、grounding 和图文检索。第二段做多模态指令微调，让模型学会按照文本指令理解图片、视频或多图上下文，此时要混合 VQA、OCR、定位、推理、多轮对话数据。第三段用 LoRA 或部分参数微调做业务适配，重点控制过拟合和灾难性遗忘，可以只调 connector、LLM 部分层或 adapter。第四段才是偏好对齐，利用人工偏好、拒答样本、安全样本和线上 badcase 做 DPO/RLHF。风险点是：如果视觉对齐没做好就直接偏好优化，reward 可能只学会语言风格；如果 LoRA 数据太窄，会牺牲通用视觉理解；如果偏好数据带长度偏置，模型会变得啰嗦但不一定更正确。

6. 推理部署与模型压缩

本章收录 13 道题，来自 5 个来源。

6.1 百度·脉脉：百度 AIDU 大模型算法面经

公司/机构：百度 | 方向：推理优化 / 模型压缩 | 来源平台：脉脉 | 来源日期：2026-06-05

来源链接：<https://maimai.cn/community/home/recommended>

Q134·线上推理如何权衡首 token 延迟、吞吐、显存、上下文长度和服务稳定性？

回答

首 token 延迟主要由排队、输入预处理和 prefill 决定，吞吐则依赖 batching 和 GPU 利用率；增大 batch 能提吞吐，却可能拉高 TTFT。长上下文增加 attention 计算和 KV Cache，压缩并发空间。工程上通过 chunked prefill、continuous batching、PagedAttention、prefix cache、量化和请求分级控制取舍。稳定性要求设置输入长度上限、显存水位保护、超时、降级模型和 admission control，并分别监控 TTFT、TPOT、吞吐、P99、OOM 和队列长度。

6.2 未标明·题库：大模型推理部署与模型压缩专项

公司/机构：未标明 | 方向：推理优化 / 模型压缩 | 来源平台：内部题库 | 来源日期：2026-06-06

Q135·KV cache 的显存占用如何随 batch size、序列长度、层数、head 数和 hidden size 增长？

回答

KV Cache 显存近似为 $\text{batch} \times \text{序列长度} \times \text{层数} \times 2(K/V) \times \text{KV 头数} \times \text{head_dim} \times \text{数据类型字节数}$ 。对普通 MHA，KV 头数等于注意力头数；GQA/MQA 通过减少 KV 头显著降低缓存。显存随 batch 和上下文长度线性增长，生成过程中还会继续累积。部署时应同时考虑并发序列、最大上下文、beam 数、前缀共享和显存碎片，并用分页缓存、KV 量化或 eviction 控制水位。

Q136·PagedAttention 为什么能提高显存利用率，它和传统连续 KV cache 分配有什么区别？

回答

传统 KV Cache 为每个请求预留连续最大空间，实际长度不一会造成内部浪费和外部碎片。PagedAttention 把缓存切成固定大小 block，逻辑地址连续但物理块可分散分配，请求增长时按需追加，结束后立即回收；前缀还可通过引用计数共享。这样能提高显存利用率和并发数。代价是块表查询、调度与拷贝更复杂，block 太小管理开销高，太大又增加尾部浪费。

Q137 · continuous batching 如何提高吞吐，为什么会影响单请求延迟和调度公平性？**回答**

Continuous batching 不等待整个静态 batch 完成，而是在每个 decode step 动态加入新请求、移除已完成请求，使 GPU 长期保持高利用率。吞吐因此提高，但长请求可能占用资源更久，短请求可能排队；过大的 token batch 也会增加单步时间和 P99 延迟。调度器通常结合优先级、等待时间、剩余长度估计和 prefill/decode 分离，设置最大 batch token、抢占或 chunked prefill，在吞吐与公平性间取舍。

Q138 · speculative decoding 的收益取决于哪些因素，draft model 接受率和额外计算如何权衡？**回答**

Speculative decoding 由小 draft model 一次提出多个 token，大模型并行验证；被接受的连续 token 可减少大模型串行 decode 次数。收益取决于 draft 速度、提议长度、接受率、大模型验证效率和额外 KV/调度开销。接受率高且 draft 足够小才有明显加速；提议太长会增加拒绝后的浪费。应在不同任务、温度和上下文长度下测平均接受 token 数、端到端延迟和吞吐，而不是只看理论步数。

Q139 · INT8、INT4、AWQ、GPTQ、SmoothQuant 分别适合权重量化、激活量化还是离线压缩？**回答**

GPTQ 是基于校准数据和二阶近似的离线权重量化，适合单批或低并发部署；AWQ 保护重要激活通道，常用于低比特权重量化且质量较稳；SmoothQuant 把激活离群值部分迁移到权重，适合权重与激活 INT8；INT8 通常质量风险较低，INT4 显存收益更大但对数学、代码和长上下文更敏感。部署选择还取决于硬件 kernel、是否量化 KV Cache、吞吐目标和校准集代表性。

Q140 · 长上下文推理中，RoPE scaling、KV eviction、prefix cache 和检索增强分别解决什么问题？**回答**

RoPE scaling 调整位置频率以扩展模型可处理的长度，但可能损害短上下文和远距离注意力；KV eviction 在缓存不足时删除低价值历史 token，需要保留系统指令、关键实体和近期上下文；prefix cache 复用相同系统提示或文档前缀的 KV，降低重复 prefill；检索增强则把海量历史放在外部索引中，按需取回证据。它们分别解决位置外推、缓存容量、重复计算和知识规模问题，通常组合使用。

Q141 · 线上推理如何同时监控 TTFT、TPOT、吞吐、显存水位、失败率和队列等待时间？

回答

线上推理应同时监控请求级和系统级指标。TTFT 反映排队、prefill 和调度，TPOT 反映 decode 速度；吞吐统计 token/s 和 requests/s；显存看权重、KV Cache、水位峰值和碎片；稳定性看错误率、OOM、超时和重试；队列等待按优先级与输入长度分桶。还应记录 batch token、活跃序列数、cache 命中和抢占次数。告警需关联这些指标，例如 TTFT 上升但 TPOT 正常，多半是排队或 prefill 拥塞。

Q142 · LoRA 多租户服务中，adapter 热切换、权重合并、缓存复用和隔离性如何设计？

回答

多租户 LoRA 服务通常共享基座权重，把 adapter 独立存储并按请求加载。热门 adapter 常驻 GPU，冷门 adapter 放 CPU 并异步预取；批处理时尽量聚合同一 adapter，或使用支持多 adapter 的 fused kernel。永久合并适合单一固定业务，动态服务不宜频繁合并。缓存需按模型版本、adapter ID 和精度隔离，租户权限控制防止越权加载；还要限制 adapter 大小、校验权重来源，并监控切换延迟和显存抖动。

6.3 未标明 · Qwen2.5大模型题目精讲

公司/机构：未标明 | 方向：大模型架构 / 推理部署 | 来源平台：CSDN | 来源日期：2026-06-18

来源链接：https://blog.csdn.net/weixin_45264425/article/details/157210711?ops_request_misc=elastic_search_misc&request_id=999875e57e23e759c8bfa4ce6e10a1f6&biz_id=0

Q143 · Qwen2.5 类大模型在面试中常被问到哪些结构和训练特点，和 LLaMA/DeepSeek 的回答重点有什么不同？

回答

回答 Qwen2.5 时不要只背模型名，要围绕结构、数据、上下文和生态讲。结构上可以从 decoder-only Transformer、RoPE/长上下文扩展、GQA/MQA 类 attention 优化、SwiGLU、RMSNorm 这些通用组件展开；训练上强调中英文、多语言、代码、数学和指令数据混合；生态上 Qwen 的多尺寸模型、VL/Audio/Code 等变体和工具调用能力是常见亮点。和 LLaMA 对比时，可以强调开源生态、数据配比和中文能力；和 DeepSeek 对比时，可以讨论 MoE、推理成本、强化学习推理能力和工程部署取舍。面试官真正想看的是你能否把架构差异转成能力、成本和部署影响，而不是罗列参数。

Q144 · 部署 Qwen2.5 类模型时，KV cache、量化、batch 调度和长上下文分别会带来哪些瓶颈？

回答

部署瓶颈可以按 prefill 和 decode 两阶段拆。prefill 阶段主要受输入长度和矩阵计算影响，长上下文会增加首 token 延迟；decode 阶段每生成一个 token 都要读写 KV cache，显存带宽和 cache 管理变成瓶颈。量化能降低权重显存和部分计算成本，但要验证数学、代码、长上下文和安全拒答是否退化；continuous batching 提升吞吐，但可能让单请求延迟和公平性变差；PagedAttention 能减少 KV 碎片，提高多请求场景的显存利用率。长上下文还会带来 RoPE scaling、attention 稀疏化、prefix cache 命中率和上下文截断策略问题。好的面试回答要同时给出指标：TTFT、TPOT、吞吐、显存水位、P99 延迟和失败率。

6.4 美团 · 掘金：机器之心 2 年前 人工智能 AIGC

骁龙888实时运行，美团、浙大等打造全流程移动端多模态大模型MobileVLM
多模态大模型，包含了 LLM 基座训练、SFT、VLM
全流程。也许不久的将来，每个人都能方便、快捷、低成本的拥有属

公司/机构：美团 | 方向：多模态大模型 | 来源平台：掘金 | 来源日期：2026-06-20

来源链接：<https://juejin.cn/post/7319663384097275942?searchId=20260620093344D895E8525CC128AE9B31>

Q145 · 端侧 MobileVLM 如何在算力受限设备上兼顾视觉理解能力、延迟和内存占用？

回答

端侧 MobileVLM 的核心矛盾是视觉 token 多、语言模型重，而移动设备的算力、内存和功耗都有限。常见优化路线是视觉侧用轻量 encoder 或降低输入分辨率，连接层压缩视觉 token，语言侧选择小参数模型并配合 INT8/INT4 量化、算子融合和 KV cache 管理。训练时要用蒸馏把大模型的视觉问答、OCR 和推理能力迁移到小模型，同时用端侧真实场景数据做微调，避免只在公开数据集上好看。部署评估要同时看首 token 延迟、端到端响应时间、峰值内存、功耗、温升和离线准确率。面试里可以强调端侧模型不是简单缩小参数，而是模型结构、数据蒸馏、推理引擎和业务场景共同取舍。

6.5 未标明 · CSDN：大模型最新面试题系列：模型部署（一）

公司/机构：未标明 | 方向：大模型面经 | 来源平台：CSDN | 来源日期：2026-06-24

来源链接：<https://blog.csdn.net/zhangzhentiyes/article/details/146966643>

Q146 · 六、如何配置vllm的服务参数（如max_model_len、n_ctx）以适应硬件限制？

回答

配置 `max\_model\_len` 或 `n\_ctx` 时要先按 KV Cache 显存预算倒推，而不是直接设成模型理论上限。可用近似关系估算 KV Cache：层数 $\times 2(K/V) \times$ KV 头数 $\times$ head_dim $\times$ 序列长度 $\times$ 并发序列数 $\times$ 数据类型字节数。预留模型权重、CUDA workspace 和碎片后，再确定最大上下文与 `gpu\_memory\_utilization`。上下文越长，可同时服务的请求越少；如果频繁 OOM，应降低最大长度、并发序列数或 batch token 上限，采用 GQA/MQA、KV Cache FP8、张量并行或前缀缓存。上线前需压测 TTFT、吞吐、P99 和抢占次数。

7. 强化学习与模型对齐

本章收录 6 道题，来自 4 个来源。

7.1 字节 · 知乎：2026 最新字节大模型岗面经汇总

公司/机构：字节 | 方向：强化学习 / 对齐训练 | 来源平台：知乎 | 来源日期：2026-06-05

来源链接：<https://www.zhihu.com/search?type=content&q=%E5%A4%A7%E6%A8%A1%E5%9E%8B%20%E9%9D%A2%E7%BB%8F>

Q147 · 对齐训练如何评估 helpfulness、harmlessness、truthfulness 和复杂任务通过率？

回答

对齐评估应拆成帮助性、安全性、真实性和任务能力。Helpfulness 看指令完成度、相关性和可执行性；harmlessness 用红队集测试违法、伤害、隐私和越权请求；truthfulness 检查事实准确、引用可靠和不确定性表达；复杂任务通过率则用代码测试、数学验证器、工具调用成功率和多步任务完成率。还需监控过度拒答、回答长度偏置、能力回退和不同语言/群体上的公平性。

7.2 未标明 · 牛客：CLIP衍生进阶模型；检索场景模型适配改造思路 3. Transformer各类Decoder结构 4. 大模型通用预训练流程；电商垂域预训练必要性及原因 5. ...GRPO公式推导；PPO四大组成模型 手撕：多头注意力MHA代码

公司/机构：未标明 | 方向：强化学习 / 对齐训练 | 来源平台：牛客 | 来源日期：2026-06-14

来源链接：<https://www.nowcoder.com/feed/main/detail/d9b2ff6d748c4827aba3a0227a733d0f>

Q148 · RLHF、DPO、GRPO、PPO 的优化目标、训练数据和稳定性问题分别是什么？

回答

PPO 和 GRPO 属于在线策略优化：PPO 用 value model/GAE 估计优势并限制更新幅度，灵活但模型多、显存高；GRPO 用同一 prompt 的组内相对奖励构造优势，可省去 value model，适合可验证推理。DPO 直接用 chosen/rejected 偏好对优化策略与参考模型的相对概率，训练简单稳定，但依赖离线偏好数据覆盖。RLHF 是更宽泛流程，通常包含 SFT、奖励模型和策略优化。共同风险包括 reward hacking、长度偏置、KL 失控和分布外泛化差。

Q149 · Reward model 如何构造偏好数据，如何处理 reward hacking、长度偏置和分布外回答？

回答

奖励模型通常用同一 prompt 下的回答对训练，使 preferred 回答得分高于 rejected 回答。数据应覆盖正确性、帮助性、安全性、格式和不同长度，并保留标注分歧。为降低长度偏置，可做长度配对、分桶采样和残差校准；为防 reward hacking，要加入对抗样本、规则审计和独立测试集；分布外回答可通过不确定性估计、拒绝评分和周期性在线人审处理。奖励模型不能只看训练准确率，还要验证与真实任务通过率和人工偏好的一致性。

7.3 字节 · CSDN：字节面试题：多模态大模型的模态对齐

公司/机构：字节 | 方向：多模态大模型 | 来源平台：CSDN | 来源日期：2026-06-20

来源链接：https://blog.csdn.net/qq_54708219/article/details/154648350?ops_request_misc=elastic_search_misc&request_id=7c49c03fddd2e3ebf778f7759577b47e&biz_id=0

Q150 · 多模态大模型为什么需要模态对齐，图像文本对齐通常如何训练和评估？

回答

模态对齐的目标是让图像、视频和文本在语义空间里能互相解释。没有对齐时，语言模型即使很强，也不知道某个视觉 token 对应的是物体、位置、文字还是动作，容易出现看图说话不准、OCR 错误和视觉幻觉。训练上常见做法包括图文对比学习、图文匹配、caption 生成、区域级 grounding、多图问答和指令微调。对齐粒度也很重要：全局图文对齐适合检索和分类，区域级对齐适合定位和细节问答，时序对齐适合视频理解。评估时不能只看一个综合 benchmark，要拆成检索召回、VQA 准确率、OCR 准确率、定位 IoU、幻觉率、多轮一致性和长尾场景表现。面试回答最好补一句：对齐不是一次性预训练结束，线上 badcase、业务数据和人工偏好会持续修正模型对视觉证据的使用方式。

7.4 美团 · 小红书：美团春招大模型算法岗面经·MoE+GRPO

公司/机构：美团 | 方向：MoE / GRPO / 大模型训练 | 来源平台：小红书 | 来源日期：2026-06-23

来源链接：<https://www.xiaohongshu.com/explore/6a0033fc000000003601d12a>

Q151 · MoE 中专家路由如何做负载均衡和专家容量控制，为什么会出现专家塌缩？

回答

MoE 的核心是用 router/gate 为每个 token 选择少量专家计算，从而用较低计算量扩展参数规模。负载均衡要解决的是“所有 token 都挤到少数专家”的问题，常见做法包括 top-k 路由、router auxiliary loss、专家容量因子 capacity factor、token dropping 或 rerouting、router z-loss、噪声路由和分组路由。容量控制本质是在吞吐、显存和质量之间取舍：容量太小会丢 token 或把 token 分给次优专家，质量下降；容量太大会增加 padding、通信和显存浪费。专家塌缩通常来自三类原因：第一，router 初期偏置导致马太效应，热门专家越训练越强；第二，训练数据分布不均，让某些专家长期收到更容易优化的样本；第三，辅助损失权重、学习率或 top-k 设置不合理，使路由器只追求主损失而忽略均衡。面试回答时要强调 MoE 不只是模型结构问题，也是分布式系统问题，因为跨卡专家并行会引入 all-to-all 通信，负载不均会直接拖慢训练吞吐。

Q152 · GRPO 相比 PPO 为什么可以省去价值模型，适合哪些大模型推理训练场景？

回答

PPO 通常需要 policy model、reference model、reward model 和 value model。value model 用来估计状态价值，帮助计算 advantage，但这会带来额外显存、训练不稳定和价值估计误差。GRPO 的思路是对同一个 prompt 采样一组回答，用组内 reward 的相对均值或标准差来构造 advantage，因此不再单独训练 value model。它的优势是工程更轻、显存压力更小，尤其适合数学推理、代码生成、复杂问答这类“同一问题可以采样多条候选并做相对比较”的场景。局限也要说清楚：GRPO 依赖 reward 质量和组采样多样性，如果 reward 稀疏、候选高度相似或规则奖励有漏洞，模型仍可能 reward hacking；同时它更适合可验证或可比较的推理任务，不一定适合开放式创作和主观偏好很强的场景。回答这题最好把 PPO 的 value baseline 和 GRPO 的 group-relative baseline 对比清楚，再落到显存、稳定性、采样成本和适用任务上。