

Interview Hub / Version 1

大模型与具身智能 完整面经题库

聚焦多模态大模型、VLA/具身智能、世界模型、视频理解、训练框架、推理部署与自动驾驶数据闭环。所有题目按归一化题面去重，并保留来源信息与模型参考回答。

281

唯一题目

2717

来源记录

32

方向分组

19

来源平台

起止时间 2026-01-06 至 2026-08-24

生成时间 2026/08/24 19:15 Asia/Shanghai

覆盖范围 多模态、VLA/具身智能、视频理解、世界模型、训练框架、推理部署、自动驾驶与数据闭环。

目录

按题目方向分组，点击目录项可跳转到对应章节。PDF 内每题包含题目、方向、岗位、来源和参考回答。

多模态大模型	100 题	VLA / 具身智能	54 题
推理优化 / 模型压缩	47 题	自动驾驶 / 数据闭环	21 题
视频 / 视觉理解	15 题	强化学习 / 对齐训练	7 题
训练框架	7 题	世界模型	4 题
大模型训练 / 强化学习	2 题	具身基础模型	2 题
机器人操作	1 题	机器人导航 / 具身智能	1 题
机器人导航 / 运动规划	1 题	机器人控制	1 题
机器人控制 / 强化学习	1 题	机器人数据	1 题
机器人系统	1 题	具身智能 / 强化学习	1 题
具身智能 / Sim-to-Real	1 题	世界模型 / 具身智能	1 题
视频理解 / 多模态大模型	1 题	推理部署	1 题
推理部署 / 多模态大模型	1 题	推理优化 / 大模型基础	1 题
训练框架 / 推理优化	1 题	自动驾驶 / 世界模型	1 题
VLA / 动作生成	1 题	VLA / 机器人基础模型	1 题
VLA / 机器人控制	1 题	VLA / 机器人数据	1 题
VLA / 人形机器人	1 题	VLA / 系统工程	1 题

来源平台统计

CSDN 1177	掘金 460	小红书 435	B站 308	知乎 142	牛客 98	51CTO 64	GitHub 12	内部题库 6	脉脉 4	博客园 2
微信公众号搜狗 2	GitHub Pages 1	公开资料 1	Robotics Center 1	古月居 1	与非网 1	OfferShow 1	力扣中文 1			

Q1 Qwen2.5-VL 这类 VLM 面试中，回答模型结构时应该拆成哪些模块？

方向 多模态大模型

岗位 LLM / 多模态算法岗位

难度 中等

来源 博客园 2026-08-24

参考回答

回答 VLM 结构可以按五块拆：视觉输入处理，包括动态分辨率、patch/tile 和位置编码；vision encoder，把图像或视频转成视觉特征；连接层，如 projector、Q-Former 或 cross-attention，把视觉特征映射到 LLM token 空间；LLM 主干，负责语言理解、推理和生成；训练与评估，包括图文预训练、指令微调、OCR/grounding/多图评测。这样回答比只背模型名字更稳，也方便继续追问高分辨率、长视频、多图和推理成本。

来源链接 cnblogs.com/moonout/p/19733786

- Qwen2.5-VL
- ViT
- SAM
- CLIP
- 视觉文本对齐

Q2 ViT、CLIP 和 SAM 在多模态大模型体系里分别提供什么能力，不能混为一谈的点是什么？

方向 多模态大模型

岗位 LLM / 多模态算法岗位

难度 中等

来源 博客园 2026-08-24

参考回答

ViT 是视觉编码器骨架，把图像切成 patch 并用 Transformer 提取视觉特征；CLIP 是图文对比学习框架，学习图像和文本的语义对齐，擅长检索和开放类别识别；SAM 是分割基础模型，擅长 promptable segmentation，提供区域级掩码能力。它们在 VLM 中角色不同：ViT 提供特征，CLIP 提供语义对齐预训练，SAM 可用于精细区域或标注辅助。不能把 CLIP 当成完整对话式 VLM，也不能认为 SAM 直接具备语言推理能力；真正的 VLM 还需要连接层、LLM 和指令微调。

来源链接 cnblogs.com/moonout/p/19733786

- Qwen2.5-VL
- ViT
- SAM
- CLIP
- 视觉文本对齐

Q3 Connector 桥接式多模态和原生 Any-to-Any 多模态模型的核心差异是什么？

方向 多模态大模型

岗位 多模态大模型 / Omni 模型岗位

难度 困难

来源 GitHub 2026-08-24

参考回答

Connector 路线通常保留预训练 vision encoder 和 LLM，通过 MLP、Q-Former 或 adapter 把视觉特征投到语言 token 空间，优点是复用成熟模型、训练成本低、工程落地快；缺点是模态交互多发生在后接层，生成图像/音频/视频等能力往往需要额外模块。原生 Any-to-Any 模型则尝试把文本、图像、音频、视频统一成可建模 token 或 latent，在同一生成框架中处理多模态输入输出，能力边界更宽，但训练数据、tokenizer、损失权重、上下文长度和推理成本都更复杂。面试回答要避免只说“更强”，要讲清成本和数据门槛。

来源链接 [github.com/laoshan-song/Awesome-LLM-](https://github.com/laoshan-song/Awesome-LLM-Interview/blob/main/notes/05_%E5%89%8D%E6%B2%BF%E4%B8%93%E9%A2%98/19_%E5%A4%9A%E6%A8%A1%E6%80%81%E5%A4%A7%E6%A8%A1%E5%9E%8B.md)

[Interview/blob/main/notes/05_%E5%89%8D%E6%B2%BF%E4%B8%93%E9%A2%98/19_%E5%A4%9A%E6%A8%A1%E6%80%81%E5%A4%A7%E6%A8%A1%E5%9E%8B.md](https://github.com/laoshan-song/Awesome-LLM-Interview/blob/main/notes/05_%E5%89%8D%E6%B2%BF%E4%B8%93%E9%A2%98/19_%E5%A4%9A%E6%A8%A1%E6%80%81%E5%A4%A7%E6%A8%A1%E5%9E%8B.md)

多模态大模型

Any-to-Any

原生多模态

Omni

视觉 Tokenizer

Q4 原生多模态模型训练时，文本、图像、音频、视频 token 混合会带来哪些数据和优化难点？

方向 多模态大模型

岗位 多模态大模型 / Omni 模型岗位

难度 困难

来源 GitHub 2026-08-24

参考回答

难点首先是 token 预算：视频和音频 token 远多于文本，如果不压缩会挤占上下文并抬高训练成本。其次是数据配比：文本数据多、质量高，多模态数据噪声大，比例不当会造成语言能力退化或视觉能力不足。第三是目标函数冲突：理解任务、生成任务、对齐任务和重建任务的损失尺度不同，需要课程学习和权重调度。第四是时间同步与语义对齐，尤其视频-音频-文本字幕常常错位。最后是评估困难，必须同时看文本能力、多模态理解、跨模态生成、幻觉、安全和延迟成本。

来源链接 [github.com/laoshan-song/Awesome-LLM-](https://github.com/laoshan-song/Awesome-LLM-Interview/blob/main/notes/05_%E5%89%8D%E6%B2%BF%E4%B8%93%E9%A2%98/19_%E5%A4%9A%E6%A8%A1%E6%80%81%E5%A4%A7%E6%A8%A1%E5%9E%8B.md)

[Interview/blob/main/notes/05_%E5%89%8D%E6%B2%BF%E4%B8%93%E9%A2%98/19_%E5%A4%9A%E6%A8%A1%E6%80%81%E5%A4%A7%E6%A8%A1%E5%9E%8B.md](https://github.com/laoshan-song/Awesome-LLM-Interview/blob/main/notes/05_%E5%89%8D%E6%B2%BF%E4%B8%93%E9%A2%98/19_%E5%A4%9A%E6%A8%A1%E6%80%81%E5%A4%A7%E6%A8%A1%E5%9E%8B.md)

多模态大模型

Any-to-Any

原生多模态

Omni

视觉 Tokenizer

Q5 视觉指令微调为什么是 VLM 从图文对齐走向可对话、可遵循指令的关键阶段？

方向 多模态大模型

岗位 VLM / 多模态算法岗位

难度 中等

来源 GitHub 2026-08-24

参考回答

图文对齐阶段主要让模型知道图像和文本在语义上如何匹配，但不一定会按人类指令回答，也不一定能进行多轮解释、拒答或结构化输出。视觉指令微调用图像-问题-答案、多轮对话、定位描述、OCR 问答和复杂推理数据，把视觉表示接入 LLM 的指令遵循能力中。它解决的是任务格式和交互方式问题：用户问什么、模型如何组织答案、何时引用视觉证据、何时承认不确定。面试要强调数据质量比数量更关键，尤其要过滤 OCR 泄漏、模板化问答、错误 caption 和训练/评测集重叠。

来源链接 github.com/datawhalechina/hello-agents/blob/main/Extra-Chapter/Extra01-%E9%9D%A2%E8%AF%95%E9%97%AE%E9%A2%98%E6%80%BB%E7%BB%93.md

VLM

Vision Encoder

Q-Former

视觉指令微调

Grounding

Q6 Grounding 能力和普通 VQA 能力有什么差别？评估时应该关注哪些指标？

方向 多模态大模型

岗位 VLM / 多模态算法岗位

难度 中等

来源 GitHub 2026-08-24

参考回答

普通 VQA 只要求回答问题，模型可能凭语言先验猜对；Grounding 要求把文本、答案或指令准确对应到图像区域、物体、坐标或时空片段，更关注视觉证据绑定。评估指标包括框/掩码 IoU、pointing accuracy、referring expression comprehension、文本答案正确率与定位一致性、负样本拒答率，以及多目标关系的准确性。对于视频 grounding 还要加时间边界 tIoU 和跨帧一致性。面试里可以指出：没有 grounding 约束的 VLM 容易产生视觉幻觉，实际业务中应把答案正确性和证据定位一起评估。

来源链接 github.com/datawhalechina/hello-agents/blob/main/Extra-Chapter/Extra01-%E9%9D%A2%E8%AF%95%E9%97%AE%E9%A2%98%E6%80%BB%E7%BB%93.md

VLM

Vision Encoder

Q-Former

视觉指令微调

Grounding

Q7

阿里多模态大模型面试中，视觉编码器到 LLM 的连接层如何选型，MLP projector、Q-Former 和 cross-attention adapter 各有什么取舍？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 B站 2026-08-02

参考回答

这题核心是视觉 token 如何变成语言模型可消费的语义表示。MLP projector 最简单，把 vision encoder 输出线性或非线形映射到 LLM hidden size，延迟低、实现稳，适合 LLaVA 类图文问答和通用多模态 SFT，但它对视觉 token 的筛选能力弱，高分辨率和细粒度任务会把上下文撑得很大。Q-Former 用一组可学习 query 从视觉特征中抽取固定数量的语义 token，能显著压缩视觉输入，适合成本敏感的服务化模型，但容易丢 OCR、小目标和空间细节。Cross-attention adapter 在语言层多次读取视觉特征，交互能力最强，适合复杂推理、grounding 和视频理解，但改造深、推理成本高、训练稳定性要求更高。工程回答要补一句：选型取决于任务粒度、视觉 token 预算、是否冻结 LLM、延迟约束和评测集是否包含 OCR/grounding/空间关系 hard case。

来源链接 [bilibili.com/video/BV1r83t61EiT/](https://www.bilibili.com/video/BV1r83t61EiT/)

B站

阿里

大模型

多模态

面试

多模态大模型

VLM

Projector

Q8

快手短视频多模态理解中，如何把视频帧、ASR、OCR、封面和用户反馈构造成训练样本？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-08-02

参考回答

短视频样本构造要先把不同模态按时间对齐。视频侧抽关键帧或短 clip，保留时间戳、镜头边界和运动强度；ASR 按句子或词级时间戳切分；OCR 记录文字框、出现时间和置信度；封面作为强视觉摘要但要注意它可能是诱导图；用户反馈包括点击、完播、点赞、评论、负反馈和搜索转化。训练样本可以分成内容理解、标签预测、视频问答、检索排序和安全审核几类。关键是避免把用户反馈直接当真值，因为反馈受推荐位置、标题党和人群偏差影响，需要去偏、分桶和延迟窗口处理。多模态融合时可用视频 encoder 表示画面，文本 encoder 表示 ASR/OCR/标题，再用 cross-attention 或 late fusion 融合。评估不能只看离线 AUC，还要看长尾类别、冷启动、误杀率、线上指标和人工质检一致性。

来源链接 blog.csdn.net/trb701012/article/details/152117850

CSDN

快手

大模型

多模态

面试

视频理解

多模态数据

Q9 移动端多模态大模型如何在视觉理解效果、端侧延迟和显存/内存占用之间取舍？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 掘金 2026-08-02

参考回答

移动端多模态模型的核心约束是算力、内存、功耗和实时性。视觉侧通常要选择轻量 vision encoder，减少输入分辨率、patch 数和视觉 token；连接层可用 MLP projector 或 resampler 压缩视觉特征；语言侧使用小参数 LLM，并配合 INT8/INT4 量化、KV cache 管理和算子融合。效果和成本的主要矛盾在于：高分辨率有利于 OCR、小目标和细粒度识别，但会显著增加视觉 token 和首 token 延迟；更强 LLM 推理好，但内存和功耗更高。工程上常做动态分辨率、局部 tile、视觉特征缓存、端云协同和任务分级。评估要同时报告准确率、TTFT、TPOT、峰值内存、功耗、发热和弱网场景下的可用性。

来源链接 juejin.cn/post/7319663384097275942

掘金

美团

大模型

LLM

多模态

MobileVLM

端侧部署

多模态大模型

Q10 多模态大模型面试中，如何系统回答“常见模态融合方式有哪些”？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 B站 2026-08-02

参考回答

可以按融合发生的位置来回答。早期融合是在输入或浅层把图像、文本、音频等 token 放到一起建模，跨模态交互充分，但成本高、需要大量对齐数据。中期融合通常通过 cross-attention、adapter 或 Q-Former 让一种模态读取另一种模态特征，兼顾效果和效率，是很多 VLM 的主流选择。晚期融合先分别用单模态模型编码，再在分类、检索或排序层融合，工程简单、延迟可控，但复杂推理能力弱。还可以按结构讲 projector、resampler、Perceiver、MoE 和 retrieval-augmented fusion。回答时最好结合任务：OCR/grounding 需要保留局部视觉 token，视频理解需要时序融合，推荐/检索可以更多用 late fusion。最后补充评估指标和部署成本，体现工程意识。

来源链接 bilibili.com/video/BV1mR3c6yEKE/

B站

大模型

多模态

面试

多模态融合

VLM

面试题

Cross Attention

Q11 多模态大模型为什么常用 ViT 作为视觉编码器，而不是传统 CNN？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 B站 2026-08-02

参考回答

ViT 更适合作为多模态大模型视觉编码器，主要因为它天然输出 patch token 序列，和 LLM 的 token 化接口更匹配，也更容易用 attention 建模全局关系。CNN 擅长局部纹理和层级特征，但输出通常是特征图，需要额外 flatten 或 pooling，长程空间关系和可变分辨率处理不如 Transformer 直观。ViT 还能更方便地接入 CLIP 预训练、多尺度 tile、动态分辨率和 cross-attention。对于 OCR、图表、文档和空间推理任务，保留 patch token 比单个全局向量更有价值。当然 CNN 在低算力、边缘部署和小数据场景仍有优势。面试中不要简单说 ViT 一定更好，而要讲清：选择取决于预训练资源、token 接口、全局建模、分辨率需求和部署成本。

来源链接 bilibili.com/video/BV1hDGF6HE3a/

B站

大模型

多模态

面试

VLM

ViT

CNN

视觉编码器

Q12 高德地图类多模态任务中，如何把街景图像、路网拓扑、POI 文本和用户轨迹统一到一个模型输入？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-08-02

参考回答

地图多模态的关键是空间对齐。街景图像可以绑定到道路点、朝向和时间；路网拓扑提供节点、边、转向关系和通行限制；POI 文本包含名称、类别、地址和评论；用户轨迹表示真实移动意图和时段偏好。统一输入时可先把数据投影到 geohash、路段或 POI 节点，再构造多模态图：节点存 POI/路段/图像特征，边存距离、方向、连通性和时间转移概率。模型上可以用图神经网络融合拓扑，用 Transformer 融合文本和视觉，用轨迹序列模型学习行为。任务包括位置理解、路线推荐、街景问答、POI 纠错和异常检测。评估要按城市、区域、新 POI、冷启动和长尾类别拆开看，避免模型只记热门地标。

来源链接 blog.csdn.net/zhhhh15/article/details/159165484

CSDN

大模型

多模态

面试

高德

地图多模态

街景

POI

Q13 多模态大模型常见建模方式有哪些，early fusion、late fusion 和 cross-attention fusion 有什么区别？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-08-02

参考回答

Early fusion 在较早阶段把不同模态 token 拼接或映射到统一空间，让模型从底层开始学习跨模态交互，表达能力强，但计算量大、对数据规模和对齐质量要求高。Late fusion 先分别编码图像、文本、音频或视频，再在决策层融合，系统简单、可复用单模态模型，适合检索、分类和低延迟任务，但深层跨模态推理能力较弱。Cross-attention fusion 让一种模态作为 query 去读取另一种模态的 key/value，能在多层建立可控交互，常用于 VLM、视频问答和图文生成，代价是结构复杂。还有 adapter/projector、Q-Former、Perceiver resampler、Mixture-of-Experts 等变体。工程选型要看任务是否需要细粒度 grounding、实时性、模态缺失鲁棒性和训练数据规模。

来源链接 blog.csdn.net/m0_59164520/article/details/145123109

CSDN

大模型

多模态

面试

多模态融合

Early Fusion

Late Fusion

Cross Attention

Q14 DeepSeek 类推理模型面试中，如何解释推理数据、长链路 CoT 和蒸馏之间的关系？

方向 大模型面经

岗位 AI / 算法候选人

难度 中等

来源 B站 2026-08-02

参考回答

推理模型能力通常来自三部分：高质量推理数据、能够表达中间步骤的训练目标，以及把强模型能力迁移到小模型的蒸馏。推理数据需要覆盖数学、代码、逻辑、多步规划和可验证任务，重点不是答案数量，而是步骤是否可靠、是否能被验证。长链路 CoT 让模型学习分解问题、检查假设和逐步求解，但训练时要防止错误链路被模型模仿，也要避免泄露不必要的冗长思维。蒸馏可以蒸馏最终答案、简化推理过程、偏好排序或 verifier 信号。最终答案蒸馏稳定但提升有限，过程蒸馏能提升可解释和复杂推理，但质量要求高，偏好蒸馏更适合改善选择和风格。面试中要补充评估：pass@k、严格验证准确率、长度成本、幻觉率和小模型迁移收益。

来源链接 bilibili.com/video/BV17yMn6GEjK/

B站

大模型

面试

DeepSeek

推理模型

CoT

蒸馏

大模型面试

Q15 大模型部署时，如何从吞吐、首 token 延迟、显存和稳定性四个角度设计优化方案？

方向 大模型面经

岗位 AI / 算法候选人

难度 中等

来源 CSDN 2026-08-02

参考回答

吞吐优化主要靠 continuous batching、请求合并、算子融合和高效调度，让 GPU 尽量保持高利用率。首 token 延迟主要受排队、prompt 预处理和 prefill 影响，可用 prefix cache、chunked prefill、较小 batch 上限和冷热模型分级降低。显存优化包括权重量化、KV cache 分页、GQA/MQA、上下文长度限制、adapter 管理和显存水位保护。稳定性则需要 admission control、超时降级、OOM 保护、模型健康检查和请求隔离。不同指标会互相牵制：大 batch 提升吞吐但可能拉高 P99；长上下文增强能力但 KV cache 暴涨。完整答案应给出监控指标：TTFT、TPOT、tokens/s、GPU 利用率、显存峰值、OOM、超时率和队列等待时间。

来源链接 blog.csdn.net/zhangzhentiyes/article/details/146966952

CSDN

大模型

面试

模型部署

推理优化

TTFT

KV Cache

稳定性

Q16 原生多模态预训练和在 LLM 上接视觉模块相比，训练目标、数据和成本有什么差异？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 B站 2026-08-02

参考回答

在 LLM 上接视觉模块通常复用已有语言模型，只训练 projector、视觉适配层和少量指令数据，成本低、收敛快，适合快速获得 VLM 能力，但视觉和语言的深层融合有限，容易受语言先验影响。原生多模态预训练从更早阶段让图像、文本、视频、音频等 token 共同训练，模型内部能形成更统一的跨模态表示，理论上更适合复杂视觉推理、生成和多模态交互，但数据清洗、训练稳定性、算力和评估成本都高很多。训练目标也更复杂，可能包括图文对比、caption、masked modeling、next token、多模态指令和跨模态生成。工程取舍是：如果业务需要快速落地，接视觉模块更现实；如果追求长期基础模型能力，原生多模态更有潜力。

来源链接 bilibili.com/video/BV1NY3p6uEZk/

B站

大模型

多模态

原生多模态

预训练

VLM

训练目标

模型架构

Q17

长文本与多模态模型结合时，如何处理上下文长度、视觉 token 和检索证据之间的预算冲突？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-08-02

参考回答

长文本多模态任务的核心矛盾是上下文预算有限，但文本证据、图片 token、历史对话和输出空间都想占 token。解决思路是先做证据选择：文本用检索、摘要和段落重排筛出相关片段；图像用动态分辨率、tile 选择和视觉 token 压缩保留关键区域；历史对话做状态摘要而不是全量保留。模型输入中要区分系统指令、用户问题、文本证据、视觉证据和引用位置，避免证据混淆。对于文档图片或图表，OCR 文本和视觉区域要绑定坐标；对于多图任务，要保留图片编号和来源。评估要看答案准确率、引用命中率、视觉证据使用率、长上下文鲁棒性和幻觉率。工程上还要监控 TTFT、KV cache 显存和检索延迟。

来源链接 blog.csdn.net/weixin_29053067/article/details/163284639

CSDN

大模型

多模态

长文本

Kimi

Token预算

检索证据

Q18

CLIP、BLIP 和 Qwen-VL 的训练目标与能力边界分别有什么不同？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-07-07

参考回答

CLIP 是双塔对比学习模型，核心目标是让匹配的图文向量接近、不匹配的远离，擅长检索和零样本分类，但生成和细粒度推理弱。BLIP 在图文理解和生成之间做了更多桥接，既能做 caption/VQA，也关注数据过滤和生成式目标；BLIP-2 用 Q-Former 把视觉特征压缩成少量 query token 接入 LLM，参数效率更高。Qwen-VL 类模型直接围绕强 LLM 构建视觉语言能力，重点是图像/视频输入、OCR、grounding、多轮对话和工具式任务。能力边界上，CLIP 更像通用视觉语义表征，BLIP 更像视觉语言桥接方案，Qwen-VL 更像可交互的多模态助手。面试回答要把训练目标、模型结构、数据类型和适用任务一起讲清楚。

来源链接 zhuanlan.zhihu.com/p/713494385

百度

CLIP

BLIP

Qwen-VL

VLM

Q19 多模态模型上线前，如何把离线能力评测和业务指标关联起来？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-07-07

参考回答

离线评测要先按业务任务拆能力，例如图文检索、OCR、商品属性、视频分类、风险识别、问答正确率和幻觉率。每个能力都要有代表性测试集，并按场景、类目、长尾、低质图片和高风险样本分桶。业务指标则可能是点击率、转化率、审核召回、误杀率、客服解决率或用户停留。关联二者的方式是建立任务链路：模型能力提升应该影响哪个中间指标，再影响哪个业务结果。例如 OCR 提升可能先提升商品属性覆盖率，再提升搜索相关性。上线前做 shadow test、人工抽检和 A/B 实验，记录失败样本回流。不能只用一个综合分，因为综合分可能掩盖某个关键业务场景下降；也不能只看线上指标，否则难以定位模型具体能力短板。

来源链接 zhuanlan.zhihu.com/p/2000170723654779295

美团

评测

业务指标

误差分析

多模态

Q20 地图类多模态模型如何融合道路图像、POI 文本、轨迹和地理空间关系？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

地图场景的多模态建模不能只看单张图片，还要把地理位置和拓扑关系纳入表示。道路图像提供车道线、路牌、建筑和环境线索；POI 文本提供名称、品类和营业信息；轨迹反映真实通行模式；路网拓扑提供连接关系、转向限制和距离。模型可以把视觉特征、文本特征和地理网格或道路节点 embedding 对齐到统一空间，再通过图神经网络或 cross-attention 融合邻近区域信息。训练任务包括 POI 匹配、路牌识别、地点问答、轨迹目的地预测和异常道路发现。评估时要按城市、道路等级、昼夜天气和新开道路分桶，重点检查空间关系和时效性。隐私上要避免暴露个人轨迹，通常使用聚合特征和脱敏采样。

来源链接 blog.csdn.net/zhhhhh15/article/details/159165484

高德

地图

多模态

空间关系

POI

Q21 Qwen-VL 类模型把图像接入 LLM 时，为什么需要控制视觉 token 数量和位置编码？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

图像经过视觉 encoder 后会产生大量 patch token，如果直接全部送入 LLM，prefill 成本、显存和注意力计算都会快速上升。因此 Qwen-VL 类模型需要通过 resize、动态分辨率、tile、pooling、resampler 或 projector 控制视觉 token 数量。位置编码同样重要，因为模型不仅要知道“有什么”，还要知道“在哪里”；高分辨率切图后更要保留 tile 的全局位置，否则局部 token 会失去空间参照。token 太少会损失 OCR、小目标和空间关系，token 太多会拖慢推理并挤占文本上下文。工程上通常使用全局图加局部 tile、多尺度位置编码和任务相关压缩。训练时要让模型见过不同分辨率、不同 tile 数和不同图文排列，否则部署时动态输入会造成分布偏移。

来源链接 blog.csdn.net/weixin_31588979/article/details/160087360

Qwen

Qwen-VL

视觉token

projector

VLM

Q22 VLM 从图文预训练到指令微调再到偏好对齐，各阶段分别解决什么问题？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

图文预训练主要解决视觉表征和语言语义的基础对齐，让模型知道图像内容如何映射到文本空间，常用 caption、图文对比、图文匹配或生成式目标。指令微调让模型学会按用户问题完成任务，例如 OCR、VQA、grounding、多图比较、视频问答和拒答；它强调任务格式、证据使用和多轮交互。偏好对齐进一步优化回答风格、安全边界、幻觉控制和人类偏好，例如回答更简洁、引用证据、不确定时不乱猜。三个阶段的数据质量侧重点不同：预训练看规模和覆盖，指令微调看任务多样性和答案可靠性，偏好对齐看偏好对是否能真实反映好坏。不能跳过前两阶段直接做偏好，否则模型可能只是语言风格更像答案，但视觉证据利用不足。

来源链接 blog.csdn.net/2401_85592132/article/details/151260542

阿里云

VLM

预训练

指令微调

偏好对齐

Q23 电商场景的多模态指令数据如何构造，才能覆盖商品属性、图文一致性和用户意图？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

电商多模态指令数据要围绕真实业务任务构造，而不是只做通用看图说话。样本可以分为商品属性抽取、图文一致性判断、卖点生成、相似商品比较、搭配推荐、违规内容识别和用户问题回答。每条数据最好绑定图片区域、标题、类目、属性表、OCR、评论或问答上下文，避免答案只来自文本泄漏。质量分层很关键：高质量人工标注和专家规则样本用于核心能力，弱标注和合成样本用于覆盖长尾，但要经过图文匹配、属性一致性和敏感内容过滤。用户意图侧要覆盖搜索、购买决策、售后咨询和风格偏好。评估时按类目、价格段、图像质量和长尾属性分桶，检查模型是否能在图像证据不足时表达不确定，而不是编造属性。

来源链接 blog.csdn.net/2201_75499313/article/details/146128971

阿里

淘天

电商

多模态数据

SFT

Q24 电商多模态模型如何同时建模商品图片、标题、属性和用户行为，避免只学到热门偏置？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 牛客 2026-07-07

参考回答

电商多模态建模通常分两层：先用图片、标题、类目、属性、OCR 和详情文本学习商品表征，再把点击、收藏、加购、成交、停留时长等用户行为作为监督信号用于召回或排序。为了避免热门偏置，训练时不能只把点击当正样本，因为曝光越多的商品天然点击多；需要加入曝光日志做反事实校正，按位置、流量入口、价格段和类目分桶采样。图片侧要保留款式、颜色、材质、logo、场景等细粒度属性，文本侧要清洗营销噪声和属性缺失。负样本应包含同类相似商品、相同标题不同图片、相同图片不同属性等 hard negative。评估要分整体指标和长尾指标，看 NDCG、Recall、属性一致性、跨模态检索准确率，以及新品和低曝光商品的泛化效果。

来源链接 nowcoder.com/feed/main/detail/824e9694564848f7a56bc9131ff2ceec

字节

电商

多模态

商品理解

检索

Q25 动态分辨率 VLM 如何在 OCR、细粒度识别和推理成本之间分配视觉 token?

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-07-07

参考回答

动态分辨率的核心是按任务和图像内容决定视觉 token 预算，而不是所有图片统一 resize 到固定尺寸。对普通场景理解，低分辨率全图 token 足够保留主体和布局；对 OCR、表格、小目标、遥感或界面截图，需要局部高分辨率 tile 保留细节。常见做法是全局低分辨率图提供上下文，再对高信息密度区域切 tile，并给 tile 加位置编码，避免模型不知道局部来自哪里。成本上，tile 数越多，LLM prefill 越长，显存和首 token 延迟都会上升，所以要限制最大 tile 数、合并低价值 patch，或用 resampler 压缩。训练时要混合不同分辨率和任务，防止模型只适应某种 token 布局。评估时不能只看通用 VQA，要单独看 OCR 准确率、局部属性、空间关系和延迟曲线。

来源链接 zhuanlan.zhihu.com/p/2014314780802967473

字节

动态分辨率

tile

VLM

OCR

Q26 图文对齐训练后检索效果提升但视觉问答仍出错，应该如何从数据、连接层和评估集定位问题?

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 牛客 2026-07-07

参考回答

这类问题要先区分“全局语义对齐好”和“局部视觉证据可用”不是一回事。图文对比学习通常让整图和整句靠近，能提升检索，但未必学会计数、空间关系、OCR 和局部属性。数据侧先检查图文是否弱相关、caption 是否只描述主体而忽略细节、负样本是否太简单；可以加入 hard negative，例如同类物体、相似颜色、相似布局但答案不同的样本。连接层侧看视觉 token 是否被过度压缩，projector 或 Q-Former 是否丢掉小目标和文本区域，必要时保留高分辨率 tile 或区域 token。评估侧要拆成检索、VQA、OCR、grounding、计数、空间关系几套集，避免只用检索指标掩盖问答短板。工程上还应抽样可视化 attention 或证据区域，确认模型回答时真的看到了相关区域，而不是靠语言先验猜答案。

来源链接 nowcoder.com/discuss/878600528970735616

百度

多模态

图文对齐

负样本

评估

Q27 复杂图文任务中，如何把文字识别、空间关系、计数和推理能力拆开评估？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-07-03

参考回答

复杂图文评估要按能力拆开，而不是只给一个总分。文字识别看字符级准确率、表格字段抽取和长文本阅读；空间关系看左右、包含、遮挡、相对位置和区域指代；计数要覆盖密集小目标、遮挡目标和相似目标；推理能力则要让答案依赖多个视觉证据，而不是只靠常识。数据集设计上应加入反事实样本，例如改动数量、位置或文字，让模型不能靠语言先验猜。上线前还要看错误类型分布，区分是看不清、定位错、读错字，还是推理链断了。

来源链接 zhuanlan.zhihu.com/p/1947724271746024823

阿里云

多模态大模型

面经

大模型

Q28 图文指令数据如何做质量分层，避免低质描述和错配样本拖累模型？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-07-03

参考回答

图文数据质量可以从清晰度、图文一致性、信息密度、任务价值和合规安全五层筛选。低清、广告、水印、重复图和无关描述应先过滤；再用图文相似度、文字区域检查和人工抽检排除错配。高质量样本应描述具体对象、属性、数量、位置和关系，而不是只有“这是一张好看的图片”。指令数据还要覆盖问答、定位、比较、解释和拒答，避免模型只学会生成泛化描述。训练时可以对高质量样本加权，对噪声来源限额采样，并用验证集持续监控幻觉和细粒度能力。

来源链接 zhuanlan.zhihu.com/p/1996677583337698496

百度

多模态大模型

面经

大模型

Q29 移动端多模态模型为什么要做视觉特征压缩，如何避免压缩后丢失关键细节？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 掘金 2026-07-03

参考回答

移动端算力和内存有限，视觉 token 如果过多，会直接拉高编码耗时、上下文长度和功耗，所以必须压缩。压缩可以用池化、区域筛选、特征聚合、低分辨率全局图加局部高分辨率块等方式。避免丢细节的关键是不要盲目平均所有区域，而是保留文字、小目标、主体区域和用户问题相关区域。可以先用轻量检测或注意力分数找关键区域，再把这些区域送入高精度编码。评估要按任务分开看：普通场景描述可以强压缩，文字识别、商品属性和图表理解则需要保留更多局部信息。

来源链接 juejin.cn/post/7319663384097275942

美团

多模态大模型

面经

大模型

Q30

动态图像分辨率与局部切图如何在细粒度识别和推理成本之间取舍？

方向 多模态大模型

岗位 多模态大模型算法工程师

难度 中等

来源 知乎 2026-07-02

参考回答

动态分辨率和局部切图的本质，是用更多视觉细节换取更高计算成本。固定低分辨率输入适合普通场景理解，但会丢掉小字、小目标、图表细节和密集区域；局部切图会把原图按比例切成多个区域，让模型同时看到全局缩略图和局部高分辨率细节，因此更适合 OCR、图表、文档、多目标计数和细粒度属性识别。代价是视觉 token 数增加，视觉编码耗时、显存占用、上下文长度和首 token 延迟都会上升。工程上通常不应所有图片都开最高切图数，而是先用轻量规则或小模型判断任务是否需要细节：普通问答用低分辨率；涉及文字、表格、小目标和坐标关系时提高切图数；超大图再配合区域检索。面试回答可以强调三点：第一，必须保留全局图，避免局部切图丢上下文；第二，切图数量要受最大 token 和延迟预算约束；第三，评估要分开看普通问答、文字识别、细粒度定位和线上延迟，而不是只看一个综合准确率。

来源链接 zhuanlan.zhihu.com/p/2014314780802967473

字节

多模态大模型

动态图像分辨率

局部切图

细粒度理解

Q31

快手短视频多模态理解中，如何把封面、视频帧、字幕、ASR 和互动行为构造成训练样本？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-01

参考回答

短视频样本要同时包含内容侧和用户反馈侧。内容侧先抽封面、关键帧或 clip，提取 OCR 字幕、ASR 文本、背景音乐、标题、话题和作者信息；用户侧记录曝光、点击、完播、停留、点赞、收藏、评论、转发和负反馈。构造时用统一 video id 和时间戳对齐多模态信息，并区分强弱监督：完播、长停留和收藏通常比点击更强，负反馈和快速划走可作为负样本。难点是曝光偏置和热门偏置，所以要位置校正、负采样、时间切分和去重，避免模型只学到流量分布。训练上可以把内容理解任务和推荐排序任务结合，既做 caption/OCR/VQA 辅助目标，也做 CTR、完播率或互动率预测。评估要看离线 AUC/NDCG、线上 A/B、冷启动、长尾覆盖和内容安全。

来源链接 blog.csdn.net/trb701012/article/details/152117850

CSDN

快手

大模型

多模态

面经

面试

Q32 短视频 VLM 为什么需要时序建模，单帧图文模型在推荐和审核场景会漏掉哪些信息？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-01

参考回答

单帧图文模型只能看到局部静态证据，容易漏掉动作过程、情绪变化、剧情反转、危险行为和违规上下文。短视频推荐关心的是用户为什么停留：可能是前几秒铺垫、中间动作、结尾反转或音乐节奏；审核场景也常常需要连续帧才能判断打斗、危险操作、擦边或误导。时序建模可以通过 clip-level encoder、temporal attention、事件边界检测、关键片段检索和长视频记忆来实现。工程上通常先低成本均匀采样，再对高运动或高语义变化片段加密采样。面试里可以指出：单帧模型适合封面理解和粗分类；时序模型适合动作、因果、事件边界和跨镜头一致性。真正上线时两者会分层组合，以控制成本和延迟。

来源链接 blog.csdn.net/trb701012/article/details/152117850

CSDN

快手

大模型

多模态

面经

面试

Q33 小红书内容理解场景中，如何同时优化图文相关性、审美质量和安全风险识别？

方向 大模型面经

岗位 AI / 算法候选人

难度 中等

来源 CSDN 2026-07-01

参考回答

这类场景不能只做一个多分类模型，而应拆成多任务内容理解。图文相关性关注标题、正文、图片和视频是否一致，可用图文匹配、OCR/ASR 对齐和语义检索；审美质量关注清晰度、构图、主体突出、滤镜和风格，可以训练质量评分或偏好模型；安全风险识别关注违规、广告、诱导、隐私和敏感内容，需要规则、分类器和人工审核闭环。多任务训练时共享视觉/文本编码器，但不同任务用独立 head 或 adapter，避免安全任务被推荐目标稀释。数据上要注意负样本构造：图文错配、标题党、低质图、擦边和误导内容都要覆盖。上线后用召回率、误杀率、申诉率、人工复核一致性和推荐效果综合权衡。

来源链接 blog.csdn.net/2401_83173765/article/details/148292651

CSDN

小红书

大模型

面经

面试

Q34 文档多模态大模型中，版面结构、OCR 文本和视觉区域如何联合建模？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-07-01

参考回答

文档理解不能把 OCR 文本当普通纯文本，因为表格、标题、段落、脚注和图像区域的空间位置很关键。常见做法是同时输入 OCR token、bbox 坐标、页面图像特征和版面结构标签，用 Layout-aware Transformer、视觉 token 加文本 token 或区域级 cross-attention 建模。bbox 提供阅读顺序和二维空间关系，视觉特征补充字体、表格线、图标和扫描噪声，文本特征负责语义。对于多页文档，还需要页面级索引和跨页检索。训练任务可以包括字段抽取、表格解析、文档 VQA、阅读顺序恢复和版面分类。面试中要强调：文档多模态的核心不是 OCR 后喂给 LLM，而是保留“文字在哪里”和“版面如何组织”。

来源链接 xiaohongshu.com/explore/68df41c7000000004016ed7

小红书

大模型

多模态

面试

Q35 InternVL 这类 VLM 为什么常用高分辨率切图和动态 tile，代价是什么？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-07-01

参考回答

高分辨率切图是为了保留小目标、文字、图表和局部属性。若直接把整图缩到固定分辨率，OCR、计数和细粒度识别会损失严重；动态 tile 会根据图像长宽比和分辨率把图片切成多个局部块，再加全局缩略图，让模型同时看到整体和细节。代价是视觉 token 数量增加，导致 encoder 计算、LLM 上下文、显存和首 token 延迟上升。工程上需要限制最大 tile 数、做 token 压缩、缓存视觉特征，并按任务动态选择分辨率：普通问答低 tile，OCR/图表/小目标高 tile。面试里可以把它归纳为“用计算换细节”，关键是按任务自适应，而不是所有图片都开最高分辨率。

来源链接 xiaohongshu.com/explore/6922fb9c000000001e03509a

小红书

大模型

多模态

面试

Q36 模型部署时，vLLM 的 PagedAttention、prefix cache 和 continuous batching 分别解决什么问题？

方向 大模型面经

岗位 AI / 算法候选人

难度 中等

来源 CSDN 2026-07-01

参考回答

PagedAttention 解决 KV cache 显存碎片和预留浪费，把不同请求的 KV 切成块管理，逻辑连续但物理可离散分配；prefix cache 解决重复前缀的重复计算问题，比如系统提示词、长文档前缀或多轮对话公共上下文可以复用已算好的 KV；continuous batching 解决静态 batch 等待和 GPU 利用率低的问题，让新请求在生成过程中动态加入批次，完成的请求及时释放资源。三者都提升吞吐，但影响点不同：PagedAttention 偏显存管理，prefix cache 偏复用计算，continuous batching 偏调度效率。上线评估要同时看 TTFT、TPOT、吞吐、显存水位、P99 延迟和公平性，不能只看平均 tokens/s。

来源链接 blog.csdn.net/zhangzhentiyes/article/details/146966952

CSDN

大模型

面试

Q37 SFT 微调中，packing、多轮对话 mask 和 loss 只算 assistant token 分别有什么作用？

方向 大模型面经

岗位 AI / 算法候选人

难度 中等

来源 CSDN 2026-07-01

参考回答

Packing 是把多条短样本拼到同一固定长度序列里，提高 token 利用率，减少 padding；但必须用 attention mask 或 sample boundary 防止不同样本互相看见。多轮对话 mask 用来保留 system、user、assistant 的角色结构，让模型理解上下文轮次。loss 只算 assistant token 是因为训练目标是让模型学会回答，而不是预测用户问题或系统提示词；如果把 user token 也计入 loss，模型可能学习复述输入，降低指令跟随质量。实践中还要处理 EOS、模板一致性、超长截断和多样本拼接后的 position id。面试里可以强调：SFT 数据格式错误会直接表现为模型啰嗦、角色混乱、重复用户问题或无法正确停止。

来源链接 blog.csdn.net/zhangzhentiyes/article/details/146692681

CSDN

大模型

面试

Q38 大模型训练出现 loss spike 时，应该如何区分是数据异常、数值不稳定还是通信/并行问题？

方向 大模型面经

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-01

参考回答

先看 spike 是否可复现。如果固定随机种子和同一 batch 可复现，优先检查数据：异常长样本、乱码、错误标签、重复模板或损坏图片。如果不可复现且伴随 NaN/Inf，重点查数值稳定性：学习率过高、梯度裁剪缺失、FP16 溢出、归一化异常或 attention mask 错误。如果 spike 只在多机多卡出现，单卡或少卡正常，就要查通信和并行：梯度同步、参数分片恢复、pipeline micro-batch 边界、MoE 路由负载和 checkpoint 恢复。排查手段包括记录样本 id、梯度范数、激活统计、loss scale、每层参数范数和通信 trace。处理上可以数据隔离、降低学习率、启用 BF16、梯度裁剪、跳过坏 batch 或修复并行配置。

来源链接 blog.csdn.net/zhangzhentiyes/article/details/145909886

CSDN

大模型

面试

Q39 训练稳定性里，学习率 warmup、梯度裁剪、weight decay 和 EMA 分别解决什么问题？

方向 大模型面经

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-01

参考回答

Warmup 让训练初期从较小学习率逐步升高，避免随机初始化或新任务微调阶段梯度剧烈震荡；梯度裁剪限制梯度范数，防止偶发异常 batch 或长序列导致参数一步更新过大；weight decay 抑制权重过大，提高泛化，AdamW 中通常与梯度更新解耦；EMA 对参数做滑动平均，能降低训练噪声，常用于视觉或扩散模型，LLM 中使用要看成本和收益。它们解决的问题不同：warmup 管启动，裁剪管极端梯度，weight decay 管复杂度，EMA 管评估稳定。面试里要补一句：这些手段不能替代数据清洗和数值监控，如果 mask、标签或混合精度配置错了，再多稳定技巧也只是掩盖问题。

来源链接 blog.csdn.net/zhangzhentiyes/article/details/145885374

CSDN

大模型

面试

Q40

多模态大模型通常由视觉编码器、连接层和语言模型组成，各部分训练目标如何分阶段设计？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 掘金 2026-07-01

参考回答

第一阶段通常做视觉-语言对齐，冻结或半冻结视觉编码器和 LLM，训练 projector/Q-Former，让视觉 token 映射到语言模型可理解的空间，目标可以是 caption 或图文匹配。第二阶段做多模态指令微调，混合 VQA、OCR、grounding、图表、多图和视频任务，让模型学会按指令使用视觉证据。第三阶段可做偏好对齐或安全对齐，降低幻觉、格式错误和不当回答。若领域差异大，可以在视觉侧或 LLM 高层加入 LoRA 继续适配。面试里要说明分阶段的原因：直接端到端全量训练成本高且不稳定，先对齐再指令微调能降低训练难度，同时保留语言模型原有能力。

来源链接 juejin.cn/post/7545697626613563442

掘金

大模型

多模态

面试

Q41

Qwen 在训练时采用的“packing”形式和“多轮对话”形式有何区别？各自对训练效率和模型能力有何影响？

方向 大模型面经

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-24

参考回答

Packing 是把多条短样本拼进同一固定长度序列，配合 attention mask 和 loss mask 避免样本间互相看到，主要目的是减少 padding、提升 token 利用率和训练吞吐。多轮对话格式则是在一条样本中保留 system、user、assistant 的真实轮次结构，并只对需要学习的 assistant token 计算损失，目标是学习上下文跟踪和角色一致性。二者可以同时使用：先构造正确的多轮样本，再把多条样本 packing；关键是处理边界位置编码、跨样本 attention 隔离和 loss mask。

来源链接 xiaohongshu.com/explore/69435d73000000000d03be65

小红书

快手

大模型

面经

Q42 训练一个 8B 参数的大模型，大概需要多少显存？如果显存不够，你会用哪些技术缓解？

方向 大模型面经

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-24

参考回答

仅看权重，8B 参数模型使用 FP16/BF16 约需 16GB；但全参训练远不止权重，还包括梯度、Adam 一阶/二阶状态、主权重、激活值和通信缓冲，通常需要权重体积的数倍甚至十余倍。粗略估算时应分别列出参数、梯度、优化器状态和激活，而不是只报一个数字。显存不足可组合使用 BF16/FP16、ZeRO-2/3 或 FSDP、张量/流水线并行、gradient checkpointing、FlashAttention、CPU/NVMe offload、减小 micro-batch、序列并行，以及 LoRA/QLoRA。推理场景还要单独计算随 batch 和上下文长度增长的 KV Cache。

来源链接 xiaohongshu.com/explore/69435d73000000000d03be65

小红书

快手

大模型

面经

Q43 你方案里KL散度、熵分别代表什么含义？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-24

参考回答

KL 散度约束新策略不要过快偏离参考策略，主要用于防止强化学习把语言能力和回答分布推坏；熵衡量策略输出的不确定性或多样性，熵过低容易过早收敛到单一模式，熵过高则动作或 token 分布过于随机。训练时常把任务奖励、KL 惩罚和熵奖励组合：提高 KL 系数会更保守，提高熵系数会鼓励探索。两者都应随训练阶段和 reward 稳定性调节，并结合通过率、长度、重复率和安全性观察是否出现模式坍塌。

来源链接 xiaohongshu.com/explore/6a3b92d90000000007027516

小红书

多模态

面经

Q44 强化学习部分为什么选用GRPO而不直接使用PPO？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-24

参考回答

PPO 通常依赖 value model 估计状态价值，再用 GAE 构造 advantage；GRPO 对同一 prompt 采样一组回答，用组内奖励的相对均值和方差归一化得到 advantage，因此可省去单独的价值模型。这样能降低显存和工程复杂度，适合数学、代码、可验证问答等问题多采样场景。局限是组内样本过于相似时优势信号很弱，奖励尺度或规则漏洞也会导致 reward hacking。实践中仍需 KL 约束控制策略偏离参考模型，并监控组内奖励方差、响应长度和通过率。

来源链接 xiaohongshu.com/explore/6a3b92d90000000007027516

小红书

多模态

面经

Q45

Vision Transformer (ViT) 和 CNN 在图像特征提取上的优劣对比？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-24

参考回答

CNN 通过局部卷积、权重共享和平移归纳偏置，在中小数据和高分辨率密集预测中样本效率高；ViT 把图像切成 patch token，用自注意力直接建模长距离关系，规模化后表达能力和迁移性更强，但训练数据与计算需求更大。多模态大模型常选 ViT，因为 token 形式容易接入 LLM，不过对小目标和局部细节通常需要高分辨率、动态切图、多尺度特征或卷积 stem 补强。

来源链接 xiaohongshu.com/explore/693c175d000000001e02f513

小红书

字节

大模型

多模态

面经

Q46

CLIP 模型的原理是什么？它是如何实现图文对齐的？损失函数怎么设计的？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-24

参考回答

CLIP 使用图像编码器和文本编码器把配对图文映射到同一向量空间，在一个 batch 内把真实图文对作为正样本，其余组合视为负样本，双向计算图到文和文到图的对比损失。InfoNCE 本质上让正样本相似度相对所有候选更高，温度参数控制分布尖锐程度。CLIP 的优势是大规模弱监督和零样本迁移，局限是依赖 batch 内负样本、偏向全局语义，对计数、空间关系和细粒度局部属性不够敏感。

来源链接 xiaohongshu.com/explore/693c175d000000001e02f513

小红书

字节

大模型

多模态

面经

Q47

跟原始 Transformer 论文中的绝对位置编码相比，RoPE（旋转位置嵌入）有什么优点？

方向 大模型面经

岗位 AI / 算法候选人

难度 中等

来源 知乎 2026-06-24

参考回答

RoPE 将每个位置对应为不同旋转角度，对 Query 和 Key 的二维子空间做旋转。单个向量携带的是绝对位置角度，但注意力内积中的旋转会化简为两位置角度之差，因此分数自然依赖相对距离。相比直接相加的位置向量，RoPE 不改变向量范数，且能把相对位置信息直接注入 QK 内积。长上下文扩展时，常用 NTK-aware scaling、YaRN 或位置插值调整旋转频率，但必须重新评估远距离注意力、短上下文退化和外推稳定性。

来源链接 zhuatlan.zhihu.com/p/1922623218738504885

知乎

大模型

面试

Q48 对比DPO和GRPO两种微调方案，核心区别是什么？离线训练和在线采样的优劣分别是什么？

方向 大模型面经

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-24

参考回答

DPO 和“奖励模型 + GRPO”没有绝对优劣，取决于数据和目标。DPO 直接用偏好对优化策略，不需要在线采样和单独 reward model，训练稳定、成本低，适合已有高质量 chosen/rejected 数据的场景；奖励模型 + GRPO 可以对同一 prompt 在线采样多条回答，用可验证奖励或学习型奖励持续探索，适合数学、代码和复杂推理，但工程复杂、采样昂贵，并存在 reward hacking。实践中可先用 DPO 获得稳定起点，再用 GRPO 做小步强化；评估要同时看任务通过率、KL 偏移、回答长度、奖励泛化和安全性。

来源链接 xiaohongshu.com/explore/6a3a9d210000000017008c3a

小红书

阿里

大模型

面经

Q49 在推荐系统的模型适配中，对比LoRA与全参数微调，它们各自更适合什么样的场景？

方向 大模型面经

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-24

参考回答

LoRA 冻结主模型，只训练低秩增量矩阵，显著降低梯度和优化器状态显存，也便于为不同业务维护独立 adapter；全参微调容量更大，适合大规模领域迁移，但成本高且更容易造成通用能力遗忘。选择时应比较数据规模、领域差异、目标能力是否需要重塑主干表征，以及线上是否需要多租户热切换。LoRA 并非天然无损，rank、注入层、学习率和数据覆盖不足都会限制上限。

来源链接 xiaohongshu.com/explore/6979ceb4000000000a032b5e

小红书

腾讯

大模型

面经

Q50 题1：请讲讲CLIP的核心原理，它是如何做图文对齐的？正样本冲突怎么处理？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-24

参考回答

CLIP 使用图像编码器和文本编码器把配对图文映射到同一向量空间，在一个 batch 内把真实图文对作为正样本，其余组合视为负样本，双向计算图到文和文到图的对比损失。InfoNCE 本质上让正样本相似度相对所有候选更高，温度参数控制分布尖锐程度。CLIP 的优势是大规模弱监督和零样本迁移，局限是依赖 batch 内负样本、偏向全局语义，对计数、空间关系和细粒度局部属性不够敏感。

来源链接 blog.csdn.net/zhhhh15/article/details/160497336

CSDN

快手

多模态

面试

Q51 题2：CLIP和BLIP的主要区别是什么？BLIP-2的Q-Former为什么这么设计？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-24

参考回答

CLIP 是双塔对比学习模型，重点把整图和整句映射到共享向量空间，擅长检索和零样本分类；BLIP 同时结合理解与生成目标，并通过数据清洗和字幕生成改善图文训练数据；BLIP-2 使用冻结视觉编码器、冻结 LLM 和轻量 Q-Former。Q-Former 里的可学习 query 通过 cross-attention 从大量视觉 token 中提取与语言任务相关的少量表示，再接入 LLM，因此显著降低连接成本。它的取舍是压缩高效，但 query 数量过少可能损失细粒度局部信息。

来源链接 blog.csdn.net/zhhhh15/article/details/160497336

CSDN

快手

多模态

面试

Q52 一、先搞懂：Qwen2.5-VL到底是什么？

方向 大模型面经

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-24

参考回答

Qwen2.5-VL 是面向图像和视频理解的视觉语言模型：视觉侧把图片或视频编码成视觉 token，经过连接/投影模块与文本 token 一起送入语言模型，从而完成问答、OCR、图表理解、目标定位、视频时序理解和工具调用。理解它时要关注三个层面：动态分辨率或视觉 token 压缩如何控制高分辨率成本；视觉 token 如何与语言空间对齐；训练数据如何从图文预训练过渡到多模态指令微调 and 偏好对齐。它不是单纯“给 Qwen 加图片输入”，而是一套视觉编码、时空建模、对齐训练和评测体系。

来源链接 blog.csdn.net/weixin_45264425/article/details/157210711

CSDN

Qwen

大模型

面试

Q53 请举例说明“图文对齐”在实际场景中的具体体现，若图文不对齐会带来什么问题？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-24

参考回答

图文对齐意味着视觉区域、对象属性和文本语义在共享表示或生成过程中正确对应。例如商品检索中，“红色圆领连衣裙”应匹配颜色、领型和类别都一致的图片；视觉问答中，模型提到的数量和位置应来自图中真实对象。若图文不对齐，训练会把错误属性绑定到对象，造成检索召回下降、OCR/grounding 错位和视觉幻觉。治理方法包括图文相似度过滤、对象或区域级对齐、困难负样本、人工抽检和下游任务一致性评估。

来源链接 blog.csdn.net/dulnode/article/details/151143684

CSDN

大模型

多模态

面试

Q54 六、如何配置vllm的服务参数（如max_model_len、n_ctx）以适应硬件限制？

方向 大模型面经

岗位 AI / 算法候选人

难度 中等

来源 CSDN 2026-06-24

参考回答

配置 `max\_model\_len` 或 `n\_ctx` 时要先按 KV Cache 显存预算倒推，而不是直接设成模型理论上限。可用近似关系估算 KV Cache：层数 $\times 2(K/V) \times$ KV 头数 $\times$ head_dim $\times$ 序列长度 $\times$ 并发序列数 $\times$ 数据类型字节数。预留模型权重、CUDA workspace 和碎片后，再确定最大上下文与 `gpu\_memory\_utilization`。上下文越长，可同时服务的请求越少；如果频繁 OOM，应降低最大长度、并发序列数或 batch token 上限，采用 GQA/MQA、KV Cache FP8、张量并行或前缀缓存。上线前需压测 TTFT、吞吐、P99 和抢占次数。

来源链接 blog.csdn.net/zhangzhentiyas/article/details/146966643

CSDN

大模型

面试

Q55 九、如何通过流水线并行（Pipeline Parallel）在多节点上扩展微调任务？

方向 大模型面经

岗位 AI / 算法候选人

难度 中等

来源 CSDN 2026-06-24

参考回答

数据并行复制完整模型、切分 batch，并在反向传播后同步梯度；张量并行切分单层矩阵，解决单层参数放不下；流水线并行按层切分模型，通过 micro-batch 填充流水线，但会产生 bubble；ZeRO/FSDP 则切分优化器状态、梯度和参数，降低每卡冗余。真实大模型通常组合这些策略，取舍取决于显存、网络带宽、模型宽度/深度和全局 batch。

来源链接 blog.csdn.net/zhangzhentiyas/article/details/146692681

CSDN

大模型

面试

Q56 二、如何通过vllm的采样参数（如temperature、top_p）控制生成文本的多样性？

方向 大模型面经

岗位 AI / 算法候选人

难度 中等

来源 CSDN 2026-06-24

参考回答

`temperature` 通过缩放 logits 控制概率分布尖锐程度：低温让高概率 token 更占优势，输出更稳定；高温增加随机性，但也提高事实错误和格式漂移风险。`top\_p` 只保留累计概率达到阈值的最小 token 集，再从中采样，因此会随上下文动态改变候选数量。生产中通常先按任务确定温度，再用 top_p 限制长尾：代码、抽取和结构化输出使用低温；创作和头脑风暴可适当提高。还应配合 top_k、重复惩罚、最大长度和固定随机种子做离线评测。

来源链接 blog.csdn.net/zhangzhentiyas/article/details/146691808

CSDN

大模型

面试

Q57 Qwen-VL 类视觉语言模型如何把图像特征接入语言模型，训练流程通常分哪几步？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 掘金 2026-06-20

参考回答

Qwen-VL 这类模型一般不是把原始图片直接喂给大语言模型，而是先用视觉编码器把图片切成视觉特征，再通过 projector、adapter 或 cross-modal connector 映射到语言模型可以消费的 token 空间。训练通常分三步：第一步做图文对齐，让视觉 token 和文本语义落到同一个表达空间；第二步做多模态指令微调，让模型学会按照用户问题读取图片、定位信息、解释图表和进行视觉问答；第三步做偏好对齐或任务微调，提升回答格式、可靠性和安全性。面试里要强调两点：一是视觉编码器和语言模型之间的接口决定了信息瓶颈，二是评估不能只看 VQA 分数，还要看 OCR、定位、细粒度属性、幻觉率和多轮上下文稳定性。

来源链接 juejin.cn/post/7571678763782258722

掘金

Qwen

大模型

多模态

Q58 端侧 MobileVLM 如何在算力受限设备上兼顾视觉理解能力、延迟和内存占用？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 掘金 2026-06-20

参考回答

端侧 MobileVLM 的核心矛盾是视觉 token 多、语言模型重，而移动设备的算力、内存和功耗都有限。常见优化路线是视觉侧用轻量 encoder 或降低输入分辨率，连接层压缩视觉 token，语言侧选择小参数模型并配合 INT8/INT4 量化、算子融合和 KV cache 管理。训练时要用蒸馏把大模型的视觉问答、OCR 和推理能力迁移到小模型，同时用端侧真实场景数据做微调，避免只在公开数据集上好看。部署评估要同时看首 token 延迟、端到端响应时间、峰值内存、功耗、温升和离线准确率。面试里可以强调端侧模型不是简单缩小参数，而是模型结构、数据蒸馏、推理引擎和业务场景共同取舍。

来源链接 juejin.cn/post/7319663384097275942

掘金

美团

大模型

LLM

多模态

Q59

为什么通用 VLM 的检测能力通常弱于 YOLO，如何增强其定位和检测能力？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 B站 2026-06-20

参考回答

通用 VLM 的训练目标往往偏向图文语义理解和自然语言回答，视觉 token 经过压缩后更适合表达语义概念，不一定保留像素级位置细节；YOLO 这类检测模型则直接围绕 bbox、类别和密集空间特征优化，所以定位能力更强。增强 VLM 检测能力可以从三层入手：数据层加入区域标注、grounding、检测问答和负样本；结构层保留更高分辨率视觉特征，增加区域 token 或检测 head；训练层联合 caption、VQA、grounding 和 detection loss，避免只学会说出物体但框不准。评估时要看 mAP、定位 IoU、指代表达理解、细粒度类别和复杂遮挡场景。面试里要强调，VLM 和检测器不是替代关系，很多业务会采用 VLM 做语义推理、检测器做精确定位的组合方案。

来源链接 bilibili.com/video/BV1Ds7z63E2u/

B站

大模型

Q60

大模型训练中为什么很多 LLM 不再依赖 Dropout，它和数据规模、归一化、残差结构有什么关系？

方向 大模型训练

岗位 AI / 算法候选人

难度 中等

来源 B站 2026-06-19

参考回答

Dropout 的主要作用是通过随机屏蔽神经元减少过拟合，但现代 LLM 通常数据规模巨大、训练 token 很多，过拟合压力相对小，反而更关注训练稳定性和吞吐。Dropout 会引入随机噪声，可能影响大规模分布式训练的收敛效率，也会让预训练和推理行为存在额外差异。Transformer 里残差连接、RMSNorm/LayerNorm、权重衰减、数据去重、学习率调度和大规模混合数据本身已经提供了一部分正则化效果。并不是所有场景都不能用 Dropout，小数据微调、分类头训练或特定任务仍可能使用；只是主流 LLM 预训练更倾向于减少不必要随机性，把稳定性和规模效率放在前面。面试回答要避免说“Dropout 没用”，更准确是“大规模预训练阶段收益通常小于工程和收敛成本”。

来源链接 bilibili.com/video/BV1hMJ36KE2h/

B站

大模型

面试

Q61**快手大模型算法面试中，多模态模型微调为什么常用 LoRA，它和全参微调的效果、成本和风险有什么差异？**

方向 多模态大模型

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-18

参考回答

LoRA 的核心价值是用少量低秩增量参数适配大模型，避免更新全部权重。对多模态模型来说，全参微调效果上限更高，尤其适合大规模领域继续训练，但显存、训练成本、回滚成本都高，也更容易破坏原有通用能力。LoRA 成本低、实验快、可同时维护多个业务 adapter，适合短视频理解、内容审核、搜索推荐等垂直任务快速迭代。风险是容量有限，遇到需要重塑视觉语义空间或复杂推理能力的任务时可能不够；同时如果训练数据分布窄，LoRA 也会学到业务模板和偏见。面试回答最好落到工程指标：显存占用、训练吞吐、上线包体、adapter 切换延迟、主模型共享能力、离线评测和线上 badcase 回流。

来源链接 blog.csdn.net/trb701012/article/details/152117850

CSDN

快手

大模型

多模态

面经

面试

Q62**短视频业务里的多模态模型，如何同时处理封面图、视频帧、OCR、ASR 和用户文本特征？**

方向 多模态大模型

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-18

参考回答

短视频多模态建模的关键是把不同模态按时间和语义对齐。封面图提供强视觉摘要，但容易标题党；视频帧提供动作和场景变化，需要帧采样、temporal token 压缩或片段级编码；OCR 捕获画面文字，适合广告、字幕、商品信息理解；ASR 捕获语音语义，但要处理噪声、方言和错字；用户文本包括标题、评论、搜索 query 或标签，能补充意图。工程上通常会先分别编码各模态，再做早融合或晚融合：检索/推荐场景常用多塔或 late fusion，问答/审核场景更适合把关键视觉 token、OCR、ASR 摘要送入 LLM。评估时不能只看总体准确率，还要看长尾类别、低质视频、无字幕视频、强噪声音频和跨模态冲突样本。

来源链接 blog.csdn.net/trb701012/article/details/152117850

CSDN

快手

大模型

多模态

面经

面试

Q63

Qwen2.5 类大模型在面试中常被问到哪些结构和训练特点，和 LLaMA/DeepSeek 的回答重点有什么不同？

方向 大模型架构 / 推理部署

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-18

参考回答

回答 Qwen2.5 时不要只背模型名，要围绕结构、数据、上下文和生态讲。结构上可以从 decoder-only Transformer、RoPE/长上下文扩展、GQA/MQA 类 attention 优化、SwiGLU、RMSNorm 这些通用组件展开；训练上强调中英文、多语言、代码、数学和指令数据混合；生态上 Qwen 的多尺寸模型、VL/Audio/Code 等变体和工具调用能力是常见亮点。和 LLaMA 对比时，可以强调开源生态、数据配比和中文能力；和 DeepSeek 对比时，可以讨论 MoE、推理成本、强化学习推理能力和工程部署取舍。面试官真正想看的是你能否把架构差异转成能力、成本和部署影响，而不是罗列参数。

来源链接 blog.csdn.net/weixin_45264425/article/details/157210711

CSDN

Qwen

大模型

面试

Q64

部署 Qwen2.5 类模型时，KV cache、量化、batch 调度和长上下文分别会带来哪些瓶颈？

方向 大模型架构 / 推理部署

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-18

参考回答

部署瓶颈可以按 prefill 和 decode 两阶段拆。prefill 阶段主要受输入长度和矩阵计算影响，长上下文会增加首 token 延迟；decode 阶段每生成一个 token 都要读写 KV cache，显存带宽和 cache 管理变成瓶颈。量化能降低权重显存和部分计算成本，但要验证数学、代码、长上下文和安全拒答是否退化；continuous batching 提升吞吐，但可能让单请求延迟和公平性变差；PagedAttention 能减少 KV 碎片，提高多请求场景的显存利用率。长上下文还会带来 RoPE scaling、attention 稀疏化、prefix cache 命中率和上下文截断策略问题。好的面试回答要同时给出指标：TTFT、TPOT、吞吐、显存水位、P99 延迟和失败率。

来源链接 blog.csdn.net/weixin_45264425/article/details/157210711

CSDN

Qwen

大模型

面试

Q65 视频理解中帧采样、temporal token 压缩和 long-context attention 如何取舍？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-14

参考回答

均匀采样覆盖全局时间轴，适合视频分类和整体摘要，但可能漏掉短暂事件；关键帧采样依据镜头切换、语义变化或显著性，适合事件定位和摘要；运动感知采样根据光流或帧差增加快速动作区域的采样密度；自适应采样由轻量模型根据问题和内容动态决定取帧，效果最好但增加系统复杂度。实际系统常先低成本均匀扫描，再对高变化或与问题相关的片段加密采样。

来源链接 blog.csdn.net/qq_45934285/article/details/143261317

CSDN

大模型

多模态

面试

Q66 视频模型如何评估时序一致性、动作理解、事件边界和身份保持？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-14

参考回答

视频模型评估应拆成四个独立维度。时序一致性检查状态变化是否连续，可用帧间特征距离、光流一致性和人工闪烁评分；动作理解用动作类别、主体-动作-对象三元组和顺序问答；事件边界用 temporal IoU、边界误差和 mAP；身份保持用跨帧人脸/物体特征相似度、ID switch 和属性稳定性。还应加入帧顺序打乱、遮挡和镜头切换测试，判断模型是否真正利用时间信息。

来源链接 blog.csdn.net/qq_45934285/article/details/143261317

CSDN

大模型

多模态

面试

Q67 视频理解中，均匀采样、关键帧采样、运动感知采样和自适应采样分别适合什么场景？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-14

参考回答

均匀采样覆盖全局时间轴，适合视频分类和整体摘要，但可能漏掉短暂事件；关键帧采样依据镜头切换、语义变化或显著性，适合事件定位和摘要；运动感知采样根据光流或帧差增加快速动作区域的采样密度；自适应采样由轻量模型根据问题和内容动态决定取帧，效果最好但增加系统复杂度。实际系统常先低成本均匀扫描，再对高变化或与问题相关的片段加密采样。

来源链接 blog.csdn.net/qq_45934285/article/details/143261317

CSDN

大模型

多模态

面试

Q68 temporal token 压缩如何保留动作变化和事件顺序，相比长上下文 attention 有什么取舍？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-14

参考回答

Temporal token 压缩通过池化、聚类、token merging、事件边界聚合或可学习 query，把相邻帧的冗余表示合并。为保留动作变化，应对高运动、状态转折和关键对象交互降低压缩率，并加入时间位置编码和顺序监督。直接长上下文 attention 保留细节更完整，但计算与 KV Cache 随 token 数快速增长；压缩显著降低成本，却可能丢失短暂事件和精确顺序。常见方案是多尺度表示：低频全局 token 加高频关键片段 token。

来源链接 blog.csdn.net/qq_45934285/article/details/143261317

CSDN

大模型

多模态

面试

Q69 视频问答如何评估动作理解、事件边界、因果关系和跨镜头一致性？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-14

参考回答

视频问答评估应按能力拆分。动作理解测试主体、动作和对象是否正确；事件边界用 temporal IoU、mAP 或边界误差衡量起止时间；因果关系需设计仅看单帧无法回答的前因后果题；跨镜头一致性检查同一实体、状态和事件在镜头切换后是否保持；细粒度属性再评估颜色、数量和局部动作。除自动准确率外，还需人工判断答案是否真正依赖视频证据，并用反事实或打乱帧顺序检测模型是否只靠语言先验。

来源链接 blog.csdn.net/qq_45934285/article/details/143261317

CSDN

大模型

多模态

面试

Q70 长视频理解中，记忆压缩、片段检索、滑窗推理和跨片段融合如何组合？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-14

参考回答

长视频可采用“分段编码、索引检索、局部推理、全局融合”。先把视频切成语义片段并生成视觉 token、字幕和事件摘要；用向量索引根据问题检索候选片段；对候选片段做高分辨率滑窗推理；最后通过时间图、层次 Transformer 或外部记忆融合跨片段证据。记忆压缩保存实体状态和关键事件，避免重复编码；滑窗保留局部细节，但窗口重叠和跨窗实体对齐必须处理。

来源链接 blog.csdn.net/qq_45934285/article/details/143261317

CSDN

大模型

多模态

面试

Q71 视频生成模型的时序一致性、身份保持、物理合理性和指令遵循如何评估?

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-14

参考回答

视频生成评估应覆盖四类指标。时序一致性看帧间结构、运动连续性和闪烁，可结合光流误差、temporal LPIPS 和人评；身份保持检查人物或物体跨帧特征一致性；物理合理性评估重力、碰撞、遮挡、物体恒常性和因果关系；指令遵循检查主体、动作、场景、镜头和时间顺序是否符合文本。FVD 等总体分数不能单独使用，应配合分项 benchmark、人工偏好和真实失败案例。

来源链接 blog.csdn.net/qq_45934285/article/details/143261317

CSDN

大模型

多模态

面试

Q72 视频 grounding 与图像 grounding 的主要差异是什么，时空定位指标怎么设计?

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-14

参考回答

图像 grounding 只需在单帧定位区域，视频 grounding 还需确定时间范围并保持目标跨帧身份，因此同时包含空间框和时间片段。常见指标包括 temporal IoU、spatial IoU、时空 tube IoU、Recall@IoU、mAP，以及起止边界误差。对移动目标还应评估轨迹连续性和身份切换。数据集要覆盖短事件、长事件、遮挡、镜头切换和多个相似实例，防止模型只靠字幕或单帧线索。

来源链接 blog.csdn.net/qq_45934285/article/details/143261317

CSDN

大模型

多模态

面试

Q73 多模态视频数据清洗时，字幕、ASR、画面内容和问答之间如何做一致性校验?

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-14

参考回答

多模态视频清洗需先做时间对齐：字幕和 ASR 绑定到精确时间段，画面按镜头或事件切片。随后检查 ASR 置信度、字幕重复和语言一致性，并用视觉文本相似度验证语音描述是否对应画面。问答数据要确认答案能从指定时间段获得，排除只依赖常识、标题或泄漏字幕的样本。还应检测静态视频、黑屏、重复片段、音画错位和敏感内容，并通过抽样人审校准自动阈值。

来源链接 blog.csdn.net/qq_45934285/article/details/143261317

CSDN

大模型

多模态

面试

Q74 在线视频理解服务如何控制帧抽取成本、encoder 缓存和响应延迟？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-14

参考回答

在线视频理解应将解码、取帧、视觉编码和语言推理解耦。先用低成本镜头切分或运动检测减少无效帧，再按问题自适应加密关键片段；相同视频的视觉特征按视频哈希和时间段缓存，避免重复跑 encoder；长视频采用分段批处理和异步预取。延迟监控要拆成视频下载、解码、encoder、检索和 LLM 阶段，并限制最大帧数、分辨率和上下文 token。热点视频可预计算特征，实时流则使用滑窗增量编码。

来源链接 blog.csdn.net/qq_45934285/article/details/143261317

CSDN

大模型

多模态

面试

Q75 Vision encoder 输出如何与 LLM token 空间对齐？Linear projector、Q-Former、cross-attention adapter 的差异是什么？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

视觉 encoder 输出是连续视觉 token，需要映射到 LLM 的隐藏维和语义空间。Linear/MLP projector 参数少、延迟低，适合保留较多视觉 token，但压缩和交互能力有限；Q-Former 用可学习 query 从视觉特征中抽取固定数量语义 token，节省上下文但可能丢局部细节；cross-attention adapter 让语言层在多层读取视觉特征，交互更强但计算和改造成本高。选择取决于分辨率、细粒度任务、token 预算和是否冻结基座。

来源链接 zhuanlan.zhihu.com/p/2014314780802967473

知乎

字节

大模型

多模态

面试

Q76 多模态模型如何评估 grounding、OCR、空间关系、幻觉和多轮视觉对话能力？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

多模态评估应按能力拆分。Grounding 用 bbox/区域 IoU、指代表达准确率和区域问答；OCR 分别测试识别、版面理解和文字推理；空间关系覆盖左右、前后、遮挡、计数和相对大小；幻觉用不存在对象提及率和证据一致性；多轮视觉对话检查指代、历史一致性和纠错能力。除公开 benchmark 外，还需构建业务 hard case，并通过图像遮挡、问题改写和反事实样本验证模型是否真正使用视觉证据。

来源链接 zhuanlan.zhihu.com/p/2014314780802967473

知乎

字节

大模型

多模态

面试

Q77 图文/视频指令微调数据如何构造，如何控制噪声、偏见和 OCR 泄漏？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

图文/视频指令数据应覆盖描述、问答、OCR、grounding、比较、时序和多轮任务。清洗时去重相似图片与文本，检测图文不匹配、模板化答案和低质量合成；OCR 任务要防止答案直接出现在元数据或文件名中；负样本要包含相似对象、错误区域和无法回答问题。评测集需按原始媒体哈希、文本近似和来源站点与训练数据隔离。合成数据最好由视觉验证器或人工抽样确认，不能只相信生成模型自检。

来源链接 zhuanlan.zhihu.com/p/2014314780802967473

知乎

字节

大模型

多模态

面试

Q78 多模态大模型中，vision encoder 输出如何通过 projector、Q-Former 或 cross-attention 接入 LLM？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

视觉 encoder 输出是连续视觉 token，需要映射到 LLM 的隐藏维和语义空间。Linear/MLP projector 参数少、延迟低，适合保留较多视觉 token，但压缩和交互能力有限；Q-Former 用可学习 query 从视觉特征中抽取固定数量语义 token，节省上下文但可能丢局部细节；cross-attention adapter 让语言层在多层读取视觉特征，交互更强但计算和改造成本高。选择取决于分辨率、细粒度任务、token 预算和是否冻结基座。

来源链接 zhuanlan.zhihu.com/p/2014314780802967473

知乎

字节

大模型

多模态

面试

Q79 VLM 训练中图文对齐、指令微调 and 偏好对齐分别解决什么问题？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

图文对齐阶段让视觉特征进入语言语义空间，常用图文对比、caption 或冻结 LLM 的连接器训练；指令微调让模型学会按用户要求完成 VQA、OCR、grounding、多图和视频任务；偏好对齐进一步优化回答正确性、格式、安全性和拒答行为。三阶段不能颠倒：视觉没对齐时做偏好训练，模型可能只学语言风格；指令数据过窄又会造成能力遗忘。每阶段应使用独立验证集监控视觉利用率和通用能力回退。

来源链接 zhuanlan.zhihu.com/p/2014314780802967473

知乎

字节

大模型

多模态

面试

Q80 高分辨率图片输入时，动态分辨率、tile 切分和 token 压缩如何取舍？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

高分辨率图像的成本主要来自 patch/token 数。动态分辨率按图像长宽和内容选择 token 数，灵活但 batch 形状复杂；tile 切分保留局部细节，适合 OCR、文档和小目标，但需处理跨 tile 关系与重复区域；token 压缩通过池化、合并或 resampler 降低 LLM 上下文成本，可能损失细节。常见方案是低分辨率全局图加若干高分辨率局部 tile，并根据任务选择压缩率。评估需分小字、计数、空间关系和普通场景。

来源链接 zhuanlan.zhihu.com/p/2014314780802967473

知乎

字节

大模型

多模态

面试

Q81 OCR、grounding、计数、空间关系这四类能力分别应该如何设计评估集？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

OCR 评估集要覆盖字体、旋转、低清、表格和版面，并分别看字符准确率与问答正确率；grounding 需要对象/区域标注，用 IoU、Recall@K 和指代表达准确率；计数要控制遮挡、密集度和类别混淆，避免答案可由语言先验猜出；空间关系覆盖绝对位置、相对位置、深度、遮挡和多对象组合。四类数据都应包含困难负样本、跨语言和分辨率分层，并检查训练集泄漏。

来源链接 zhuanlan.zhihu.com/p/2014314780802967473

知乎

字节

大模型

多模态

面试

Q82 多图理解任务中，如何保证跨图实体一致性、顺序理解和比较推理能力？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

多图理解首先要为每张图加入位置和顺序标识，再通过共享实体表示或跨图 attention 建立关联。跨图实体一致性可用对象重识别、属性匹配和名称绑定；时间顺序需要显式时间 token 与状态变化监督；比较推理则构造必须同时引用多图证据的问题。训练中应随机交换图片顺序、加入相似干扰图和缺失图，防止模型只看单张或依赖固定位置。评估要记录证据图选择和最终答案两个指标。

来源链接 zhuanlan.zhihu.com/p/2014314780802967473

知乎

字节

大模型

多模态

面试

Q83 VLM 产生视觉幻觉的常见原因有哪些，数据、模型和解码侧分别怎么缓解？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

视觉幻觉来自训练图文弱对齐、语言先验过强、视觉 token 压缩、细粒度特征不足和解码时无证据约束。数据侧应清洗图文不匹配、加入不存在对象的负样本和区域级标注；模型侧可增强高分辨率/局部特征、跨模态交互和视觉对比损失；解码侧使用区域检索、置信度校准和证据引用；评测侧构建反事实、遮挡和对象不存在测试。仅靠扩大模型通常不能解决，因为语言能力越强也可能越会“合理编造”。

来源链接 zhuanlan.zhihu.com/p/2014314780802967473

知乎

字节

大模型

多模态

面试

Q84 图像 caption 数据、VQA 数据和合成指令数据在多模态训练中的作用有什么差异？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-14

参考回答

Caption 数据提供广泛视觉语义和对象属性，适合预训练对齐，但描述通常泛化且缺少精确推理；VQA 数据把视觉证据与具体问题绑定，能训练计数、空间、OCR 和推理，但任务分布较窄；合成指令数据可快速扩展任务和难度，适合多轮、拒答和长尾覆盖，但容易模板化、事实错误和自我偏见。合理配比是用大规模 caption 建基础，再用高质量 VQA/grounding 强化能力，最后用经过验证的合成数据补缺口。

来源链接 xiaohongshu.com/search_result/683952c6000000002301439d

小红书

大模型

多模态

面经

Q85 多模态模型线上服务如何优化图片预处理、vision encoder 复用和首 token 延迟？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-14

参考回答

多模态服务延迟可拆为图片下载/解码、resize/tile、vision encoder、视觉 token 投影、LLM prefill 和 decode。对相同图片用内容哈希缓存 encoder 输出；批量请求按分辨率和 tile 数分桶，减少 padding；热点图片预计算视觉 token；高分辨率任务采用全局低分辨率加局部 tile。首 token 延迟主要受预处理、encoder 和 prefill 影响，可并行下载与预处理、使用更快视觉 backbone、token 压缩和 chunked prefill。

来源链接 xiaohongshu.com/search_result/683952c6000000002301439d

小红书

大模型

多模态

面经

Q86 KV cache 显存如何随 batch、序列长度、层数、head 数和 hidden size 增长？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

KV Cache 显存近似为 $\text{batch} \times \text{序列长度} \times \text{层数} \times 2(K/V) \times \text{KV 头数} \times \text{head_dim} \times \text{数据类型字节数}$ 。对普通 MHA，KV 头数等于注意力头数；GQA/MQA 通过减少 KV 头显著降低缓存。显存随 batch 和上下文长度线性增长，生成过程中还会继续累积。部署时应同时考虑并发序列、最大上下文、beam 数、前缀共享和显存碎片，并用分页缓存、KV 量化或 eviction 控制水位。

来源链接 zhuanlan.zhihu.com/p/2014643829844770923

知乎

大模型

多模态

面试

Q87 PagedAttention 为什么能提升显存利用率，和连续 KV cache 分配有什么区别？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

传统 KV Cache 为每个请求预留连续最大空间，实际长度不一会造成内部浪费和外部碎片。PagedAttention 把缓存切成固定大小 block，逻辑地址连续但物理块可分散分配，请求增长时按需追加，结束后立即回收；前缀还可通过引用计数共享。这样能提高显存利用率和并发数。代价是块表查询、调度与拷贝更复杂，block 太小管理开销高，太大又增加尾部浪费。

来源链接 zhuanlan.zhihu.com/p/2014643829844770923

知乎

大模型

多模态

面试

Q88 continuous batching 如何提升吞吐，为什么可能影响单请求延迟和调度公平性？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

Continuous batching 不等待整个静态 batch 完成，而是在每个 decode step 动态加入新请求、移除已完成请求，使 GPU 长期保持高利用率。吞吐因此提高，但长请求可能占用资源更久，短请求可能排队；过大的 token batch 也会增加单步时间和 P99 延迟。调度器通常结合优先级、等待时间、剩余长度估计和 prefill/decode 分离，设置最大 batch token、抢占或 chunked prefill，在吞吐与公平性间取舍。

来源链接 zhuanlan.zhihu.com/p/2014643829844770923

知乎

大模型

多模态

面试

Q89 speculative decoding 的收益取决于哪些因素，draft model 接受率如何影响加速比？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

Speculative decoding 由小 draft model 一次提出多个 token，大模型并行验证；被接受的连续 token 可减少大模型串行 decode 次数。收益取决于 draft 速度、提议长度、接受率、大模型验证效率和额外 KV/调度开销。接受率高且 draft 足够小才有明显加速；提议太长会增加拒绝后的浪费。应在不同任务、温度和上下文长度下测平均接受 token 数、端到端延迟和吞吐，而不是只看理论步数。

来源链接 zhuanlan.zhihu.com/p/2014643829844770923

知乎

大模型

多模态

面试

Q90 INT8、INT4、AWQ、GPTQ、SmoothQuant 分别适合哪些量化和部署场景？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

GPTQ 是基于校准数据和二阶近似的离线权重量化，适合单批或低并发部署；AWQ 保护重要激活通道，常用于低比特权重量化且质量较稳；SmoothQuant 把激活离群值部分迁移到权重，适合权重与激活 INT8；INT8 通常质量风险较低，INT4 显存收益更大但对数学、代码和长上下文更敏感。部署选择还取决于硬件 kernel、是否量化 KV Cache、吞吐目标和校准集代表性。

来源链接 zhuanlan.zhihu.com/p/2014643829844770923

知乎

大模型

多模态

面试

Q91 长上下文推理中，RoPE scaling、KV eviction、prefix cache 分别解决什么问题？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-14

参考回答

RoPE scaling 调整位置频率以扩展模型可处理的长度，但可能损害短上下文和远距离注意力；KV eviction 在缓存不足时删除低价值历史 token，需要保留系统指令、关键实体和近期上下文；prefix cache 复用相同系统提示或文档前缀的 KV，降低重复 prefill；检索增强则把海量历史放在外部索引中，按需取回证据。它们分别解决位置外推、缓存容量、重复计算和知识规模问题，通常组合使用。

来源链接 zhuanlan.zhihu.com/p/2014643829844770923

知乎

大模型

多模态

面试

Q92 CLIP 预训练中的对比学习目标如何影响后续 VLM 的视觉语义对齐能力？

方向 多模态大模型

岗位 多模态算法 / VLM 工程

难度 困难

来源 内部题库 2026-06-06

参考回答

CLIP 用 batch 内图文配对做双向对比学习，使真实图文对相似度高于其他组合，从而学习开放词汇视觉语义。该目标让后续 VLM 获得强检索和零样本分类基础，但偏向全局语义，对局部属性、计数和空间关系较弱。接入 VLM 时通常保留 CLIP 视觉 encoder，再通过 projector/Q-Former 对齐 LLM，并用 caption、VQA、grounding 和细粒度负样本补足。温度、负样本质量和数据噪声会直接影响对齐空间。

来源链接 无

题库

多模态

VLM

视觉语言对齐

Grounding

OCR

CLIP

Q-Former

Q93 Linear projector、MLP projector、Q-Former 和 cross-attention adapter 在信息保留、训练成本、推理延迟上如何取舍？

方向 多模态大模型

岗位 多模态算法 / VLM 工程

难度 困难

来源 内部题库 2026-06-06

参考回答

视觉 encoder 输出是连续视觉 token，需要映射到 LLM 的隐藏维和语义空间。Linear/MLP projector 参数少、延迟低，适合保留较多视觉 token，但压缩和交互能力有限；Q-Former 用可学习 query 从视觉特征中抽取固定数量语义 token，节省上下文但可能丢局部细节；cross-attention adapter 让语言层在多层读取视觉特征，交互更强但计算和改造成本高。选择取决于分辨率、细粒度任务、token 预算和是否冻结基座。

来源链接 无

题库

多模态

VLM

视觉语言对齐

Grounding

OCR

CLIP

Q-Former

Q94 多模态指令微调数据如何避免 OCR 泄漏、答案模板化、负样本不足和评测集污染？

方向 多模态大模型

岗位 多模态算法 / VLM 工程

难度 困难

来源 内部题库 2026-06-06

参考回答

图文/视频指令数据应覆盖描述、问答、OCR、grounding、比较、时序和多轮任务。清洗时去重相似图片与文本，检测图文不匹配、模板化答案和低质量合成；OCR 任务要防止答案直接出现在元数据或文件名中；负样本要包含相似对象、错误区域和无法回答问题。评测集需按原始媒体哈希、文本近似和来源站点与训练数据隔离。合成数据最好由视觉验证器或人工抽样确认，不能只相信生成模型自检。

来源链接 无

题库

多模态

VLM

视觉语言对齐

Grounding

OCR

CLIP

Q-Former

Q95

视觉 grounding 能力应该如何评估，bbox、指代表达、区域问答和 hallucination rate 分别看什么？

方向 多模态大模型

岗位 多模态算法 / VLM 工程

难度 困难

来源 内部题库 2026-06-06

参考回答

Grounding 评估应同时检查定位与语言理解。BBox 用 IoU、mAP 和 Recall@K；指代表达要求模型根据属性、关系和上下文找到唯一目标；区域问答验证定位后是否正确读取区域内容；hallucination rate 统计模型定位或描述不存在对象的比例。还应覆盖小目标、遮挡、同类多实例、否定指令和复杂关系，并要求模型输出证据区域，避免答案正确但定位错误。

来源链接 无

题库

多模态

VLM

视觉语言对齐

Grounding

OCR

CLIP

Q-Former

Q96

多图理解任务中图间关系、时间顺序和跨图实体一致性如何建模？

方向 多模态大模型

岗位 多模态算法 / VLM 工程

难度 困难

来源 内部题库 2026-06-06

参考回答

多图理解首先要为每张图加入位置和顺序标识，再通过共享实体表示或跨图 attention 建立关联。跨图实体一致性可用对象重识别、属性匹配和名称绑定；时间顺序需要显式时间 token 与状态变化监督；比较推理则构造必须同时引用多图证据的问题。训练中应随机交换图片顺序、加入相似干扰图和缺失图，防止模型只看单张或依赖固定位置。评估要记录证据图选择和最终答案两个指标。

来源链接 无

题库

多模态

VLM

视觉语言对齐

Grounding

OCR

CLIP

Q-Former

Q97

为什么 VLM 容易出现视觉幻觉，如何从数据、模型结构、解码和评测四个层面缓解？

方向 多模态大模型

岗位 多模态算法 / VLM 工程

难度 困难

来源 内部题库 2026-06-06

参考回答

视觉幻觉来自训练图文弱对齐、语言先验过强、视觉 token 压缩、细粒度特征不足和解码时无证据约束。数据侧应清洗图文不匹配、加入不存在对象的负样本和区域级标注；模型侧可增强高分辨率/局部特征、跨模态交互和视觉对比损失；解码侧使用区域检索、置信度校准和证据引用；评测侧构建反事实、遮挡和对象不存在测试。仅靠扩大模型通常不能解决，因为语言能力越强也可能越会“合理编造”。

来源链接 无

题库

多模态

VLM

视觉语言对齐

Grounding

OCR

CLIP

Q-Former

Q98 高分辨率图像输入时，patch 数量、token 压缩、局部裁剪和动态分辨率策略如何选择？

方向 多模态大模型

岗位 多模态算法 / VLM 工程

难度 困难

来源 内部题库 2026-06-06

参考回答

高分辨率图像的成本主要来自 patch/token 数。动态分辨率按图像长宽和内容选择 token 数，灵活但 batch 形状复杂；tile 切分保留局部细节，适合 OCR、文档和小目标，但需处理跨 tile 关系与重复区域；token 压缩通过池化、合并或 resampler 降低 LLM 上下文成本，可能损失细节。常见方案是低分辨率全局图加若干高分辨率局部 tile，并根据任务选择压缩率。评估需分小字、计数、空间关系和普通场景。

来源链接 无

题库

多模态

VLM

视觉语言对齐

Grounding

OCR

CLIP

Q-Former

Q99 VLM 线上服务中如何平衡图像预处理延迟、视觉 encoder 复用、batching 和首 token 延迟？

方向 多模态大模型

岗位 多模态算法 / VLM 工程

难度 困难

来源 内部题库 2026-06-06

参考回答

多模态服务延迟可拆为图片下载/解码、resize/tile、vision encoder、视觉 token 投影、LLM prefill 和 decode。对相同图片用内容哈希缓存 encoder 输出；批量请求按分辨率和 tile 数分桶，减少 padding；热点图片预计算视觉 token；高分辨率任务采用全局低分辨率加局部 tile。首 token 延迟主要受预处理、encoder 和 prefill 影响，可并行下载与预处理、使用更快视觉 backbone、token 压缩和 chunked prefill。

来源链接 无

题库

多模态

VLM

视觉语言对齐

Grounding

OCR

CLIP

Q-Former

Q100 视觉 encoder 输出如何对齐到 LLM token 空间，Linear projector、Q-Former 和 cross-attention adapter 有什么取舍？

方向 多模态大模型

岗位 多模态算法实习生

难度 困难

来源 知乎 2026-06-05

参考回答

视觉 encoder 输出是连续视觉 token，需要映射到 LLM 的隐藏维和语义空间。Linear/MLP projector 参数少、延迟低，适合保留较多视觉 token，但压缩和交互能力有限；Q-Former 用可学习 query 从视觉特征中抽取固定数量语义 token，节省上下文但可能丢局部细节；cross-attention adapter 让语言层在多层读取视觉特征，交互更强但计算和改造成本高。选择取决于分辨率、细粒度任务、token 预算和是否冻结基座。

来源链接 zhuanlan.zhihu.com/p/1998500372969443453

知乎

字节跳动

多模态

VLM

视觉语言对齐

Q101 从零搭建一个具身智能项目，为什么要同时考虑感知、策略、控制、仿真和数据飞轮？

方向 VLA / 具身智能

岗位 具身智能算法 / 机器人基础模型岗位

难度 中等

来源 GitHub 2026-08-24

参考回答

具身智能不是单一模型问题。感知负责识别物体、空间、状态和 affordance；策略负责把语言目标转成子目标和动作意图；控制负责把高层动作变成稳定、安全、实时的机器人执行；仿真用于低成本覆盖长尾、验证安全和预训练；数据飞轮负责从真实失败中持续改进。只做大模型会卡在真实控制和安全边界，只做控制又缺少开放任务泛化。面试里可以用闭环链路回答：数据采集、标注、训练、仿真评估、真机部署、失败回流，每一环都有指标和质量门槛。

来源链接 github.com/Mbot-lab/Mbot-llm-wiki-EAI

具身智能

VLA

世界模型

Sim2Real

数据飞轮

Q102 Sim2Real 在具身智能项目中主要解决什么问题，哪些问题不能只靠域随机化解决？

方向 VLA / 具身智能

岗位 具身智能算法 / 机器人基础模型岗位

难度 中等

来源 GitHub 2026-08-24

参考回答

Sim2Real 主要缓解真实机器人数据昂贵、危险场景难采、长尾覆盖不足的问题。域随机化可以让模型适应纹理、光照、相机姿态和部分动力学变化，但不能完全解决接触物理不准、传感器延迟、执行器背隙、软物体形变、人类环境不可控和任务语义差异。更可靠的方案是仿真预训练 + 真实少样本微调 + 在线校正 + 真机评测闭环。面试时要强调：仿真是加速器，不是真实评估替代品，最终指标仍然要落到真机成功率、安全触发和失败恢复。

来源链接 github.com/Mbot-lab/Mbot-llm-wiki-EAI

具身智能

VLA

世界模型

Sim2Real

数据飞轮

Q103

本体遥操作、VR 遥操作、互联网视频学习和仿真数据各自适合补充机器人数据的哪一部分？

方向 VLA / 具身智能

岗位 具身智能数据 / 机器人算法岗位

难度 中等

来源 公开资料 2026-08-24

参考回答

本体遥操作数据质量最高，动作、传感器和真实动力学一致，适合精细操作和接触任务，但成本高、规模有限。VR 遥操作能降低采集门槛、提升速度，适合大规模示范，但存在控制映射和人体动作到机器人 embodiment 的差异。互联网视频覆盖物体和场景丰富，适合学习视觉先验、任务语义和 affordance，但缺少精确动作和机器人状态。仿真数据便宜、可控、可生成长尾场景，适合预训练、失败恢复和安全测试，但有 sim-to-real gap。面试回答要强调组合：真实遥操作做高质量锚点，视频和仿真扩覆盖，最终用真机闭环评估校正。

来源链接 aibangbots.com/a/11605

机器人数据

本体遥操作

VR遥操作

仿真数据

数据飞轮

Q104

具身智能数据飞轮中，如何把线上失败样本变成下一轮训练收益？

方向 VLA / 具身智能

岗位 具身智能数据 / 机器人算法岗位

难度 中等

来源 公开资料 2026-08-24

参考回答

数据飞轮链路是：线上执行记录全量日志，触发器挖掘失败或不确定片段，人工/自动标注失败原因和目标状态，筛掉传感器异常，加入训练或评测集，再用离线与真机指标验证收益。关键是不要把所有失败样本都混进训练，而是分成感知失败、规划失败、控制失败、安全接管、标注错误等类别。对可学习失败，可以生成恢复动作、负样本或偏好数据；对不可学习的硬件/同步问题，应进入数据质量治理。每轮回流都要记录版本、样本来源、覆盖场景和指标变化，否则数据量变大但模型不一定变强。

来源链接 aibangbots.com/a/11605

机器人数据

本体遥操作

VR遥操作

仿真数据

数据飞轮

Q105 机器人遥操作数据采集时，多相机、关节状态、力控信号和夹爪状态如何做时间同步？

方向 VLA / 具身智能

岗位 机器人数据 / 具身智能算法岗位

难度 困难

来源 Robotics Center 2026-08-24

参考回答

最理想方案是硬件同步：用主时钟或触发脉冲同时驱动相机帧、关节状态采样和力/扭矩传感器记录，所有数据写入统一时间基准。若只能软件同步，要记录每路数据的原始时间戳、采样频率和系统时钟漂移，训练前按控制周期重采样，并对相机帧、关节状态、夹爪开合、F/T 信号做插值或最近邻对齐。接触敏感任务不能容忍几十毫秒偏差，因为视觉接触点和力峰值错位会让模型学到错误因果。工程上还应保留同步质量指标，例如最大时间偏移、丢帧率、时钟漂移和接触事件对齐误差，用于过滤低质量 episode。

来源链接 roboticscenter.ai/zh/blog/robot-data-annotation-challenges

机器人数据

遥操作

时间同步

轨迹标注

失败样本

Q106 机器人轨迹数据进入训练前，如何切分 episode 并标注成功、失败、中断和人为接管？

方向 VLA / 具身智能

岗位 机器人数据 / 具身智能算法岗位

难度 困难

来源 Robotics Center 2026-08-24

参考回答

Episode 切分不能只按固定时间窗，应该以任务语义和机器人状态共同决定：开始点通常是语言指令下发、机器人进入可控状态或夹爪接近目标；结束点可以是成功完成、超时、人工接管、碰撞、安全停机或目标状态变化。标注至少包含 success、failure、abort、intervention、reset 等状态，并记录失败原因，例如感知错误、抓取失败、路径碰撞、目标滑落、控制饱和。失败样本不要简单删除，应该区分可学习失败和脏数据：可学习失败可用于恢复策略、安全判别或负样本训练；传感器错位、严重丢帧和错误标注才应剔除。这样才能让数据闭环真正提升鲁棒性。

来源链接 roboticscenter.ai/zh/blog/robot-data-annotation-challenges

机器人数据

遥操作

时间同步

轨迹标注

失败样本

Q107 评估 VLA/机器人策略时，为什么不能只看离线 loss 或单一成功率？应该设计哪些指标？

方向 VLA / 具身智能

岗位 机器人基础模型 / VLA 算法岗位

难度 困难

来源 CSDN 2026-08-24

参考回答

离线 loss 只能说明模型拟合了数据分布，不代表闭环执行稳定；单一成功率也会掩盖安全风险、长尾失败和任务难度差异。更完整的指标应分四层：离线指标看动作误差、语言条件匹配和轨迹相似度；仿真指标看 LIBERO、Meta-World、ManiSkill 等任务成功率和泛化；真机指标看闭环成功率、恢复次数、碰撞/安全触发、接触稳定性；部署指标看 E2E latency、控制频率、显存、GPU 占用和失败恢复耗时。面试里要强调指标必须和任务目标绑定，例如装配任务要看接触时刻和插入成功，家居长程任务要看子目标完成与错误恢复。

来源链接 xingyun3d.csdn.net/69fb0cbf54b52172bc720972.html

VLA

Benchmark

LIBERO

Open X-Embodiment

真机评测

Q108 如果一个 VLA 方法声称提升了泛化能力，面试中应如何设计公平 baseline 和消融实验？

方向 VLA / 具身智能

岗位 机器人基础模型 / VLA 算法岗位

难度 困难

来源 CSDN 2026-08-24

参考回答

公平 baseline 首先要固定数据量、任务划分、视觉 backbone、控制频率和评测环境，否则改进来源不清楚。基础 baseline 至少包含行为克隆、ACT/Diffusion Policy 这类强模仿学习方法，以及同等数据上的开源 VLA 或任务内 finetune 版本。消融实验要围绕你的创新点拆：如果创新是动作表示，就固定数据和视觉特征，对比 action token、连续回归、action chunk、diffusion；如果创新是数据策略，就固定模型结构，对比数据清洗、失败样本、跨 embodiment 混合和语言标注。最后用仿真与真机双评测验证，避免只在离线 replay 上得出泛化结论。

来源链接 xingyun3d.csdn.net/69fb0cbf54b52172bc720972.html

VLA

Benchmark

LIBERO

Open X-Embodiment

真机评测

Q109 RT-2、OpenVLA、ACT 和 Diffusion Policy 在动作表示、推理延迟和适用任务上有什么核心差异？

方向 VLA / 具身智能

岗位 具身智能 / VLA 算法岗位

难度 困难

来源 CSDN 2026-08-24

参考回答

RT-2 和 OpenVLA 更接近把动作离散化成 token，优势是能复用 VLM/LLM 的语言-视觉知识和自回归建模框架，适合语言条件、多任务和开放词汇泛化，但离散化会带来量化误差，且大模型自回归推理延迟较高。ACT 通常用 CVAE 和 action chunk，一次预测一段连续动作，工程闭环快、小数据友好，适合固定任务或少量任务的模仿学习，但语言泛化弱。Diffusion Policy 把动作序列看成从噪声逐步去噪的生成过程，能表达多峰轨迹和复杂接触操作，代价是采样步数、部署延迟和稳定性调参更重。面试回答要落到任务：语言泛化选 VLA 路线，低延迟固定操作可先用 ACT，复杂多峰操作可考虑 Diffusion Policy。

来源链接 xingyun3d.csdn.net/69fb0c350a2f6a37c5a812f8.html

VLA

具身智能

action token

Diffusion Policy

OpenVLA

ACT

Q110 如果机器人任务存在多峰动作分布，为什么 diffusion policy 往往比单步连续回归更稳？

方向 VLA / 具身智能

岗位 具身智能 / VLA 算法岗位

难度 困难

来源 CSDN 2026-08-24

参考回答

多峰动作分布意味着同一个观察下可能存在多种合理动作，例如绕左/绕右抓取、先推再抓或直接抓。单步连续回归通常用均值回归，会把多个模式平均成一个不可执行动作，表现为轨迹发软、接触点漂移或中间姿态不合理。Diffusion Policy 通过条件生成整个动作序列，可以在采样过程中保留多个模式，再由条件观测和训练分布收敛到其中一个一致轨迹，因此对接触丰富、遮挡、工具使用和灵巧操作更友好。工程上仍要控制采样步数、动作平滑、安全边界和控制频率，否则优势会被延迟和闭环误差抵消。

来源链接 xingyun3d.csdn.net/69fb0c350a2f6a37c5a812f8.html

VLA

具身智能

action token

Diffusion Policy

OpenVLA

ACT

Q111 大模型进入具身智能后，和纯数字世界任务相比，感知、决策和执行链路会新增哪些工程难点？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 中等

来源 51CTO 2026-08-02

参考回答

具身智能把大模型从文本或图像理解扩展到真实物理世界，最大的变化是输出会改变环境并产生安全后果。感知侧需要处理多相机、深度、点云、遮挡、光照和传感器噪声，还要把 2D 语义 grounding 转成 3D 可操作目标。决策侧不仅要理解指令，还要拆解子任务、维护环境状态、处理失败恢复和不确定性。执行侧要面对动力学、接触、摩擦、延迟、关节限制和碰撞风险。和纯文本任务不同，具身系统必须有低层控制器、安全过滤、急停、碰撞检测和人工接管机制。数据也更复杂，需要同步图像、本体状态、动作、力反馈、语言指令和任务结果。评估不能只看回答正确率，要看真机成功率、碰撞率、接管率、恢复率和跨场景泛化。

来源链接 blog.51cto.com/u_15916160/14781263

51CTO

大模型

具身

具身智能

机器人

VLA

安全控制

工程落地

Q112 端到端 VLA 上机械臂时，为什么不能只训练一个大模型直接输出动作，还需要低层控制和安全约束？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 B站 2026-08-02

参考回答

端到端 VLA 可以把视觉、语言和动作统一建模，但真实机械臂执行需要满足实时性、动力学和安全约束。大模型推理频率通常低于控制频率，直接输出每个控制周期动作会有延迟和抖动；接触任务中小误差会导致滑落、碰撞或卡死；分布外场景下模型置信度也不可靠。因此系统通常让 VLA 输出高层意图、目标位姿、技能 token 或短 action chunk，低层控制器负责轨迹跟踪、力控、速度限制、碰撞检测和急停。还需要 IK 可行性、工作空间约束、夹爪状态检查和失败恢复策略。训练上要有遥操作数据、失败样本、时间同步和本体状态。评估不能只看离线动作误差，要看真机成功率、碰撞率、恢复率和 P99 延迟。

来源链接 bilibili.com/video/BV15Bgb6KEsG/

B站

VLA

具身

机器人

具身智能

机械臂

低层控制

安全约束

Q113 Google RT 系列具身智能工作给 VLA 面试带来哪些核心考点？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 掘金 2026-08-02

参考回答

RT 系列的核心考点是如何把互联网级视觉语言知识迁移到机器人控制。RT-1 证明了多任务机器人数据可以用 Transformer 建模，把图像、语言指令和动作统一成序列；RT-2 进一步把 VLM 的语义知识转成动作 token，让模型能理解未见过的语义概念并做简单操作。面试中常问数据规模、动作 token 化、跨任务泛化、语言指令理解、真实机器人评估和失败模式。要指出 RT 类模型的优势是语义泛化和统一建模，局限是高频精细控制、接触任务、长程规划和安全约束仍需要低层控制与系统兜底。工程落地时通常会结合技能库、规划器、视觉 grounding、动作过滤和人工接管，而不是让大模型单独控制全部动作。

来源链接 juejin.cn/post/7344970197130674215

掘金

VLA

具身

机器人

Google

RT-1

RT-2

具身智能

Q114 从零做具身智能项目时，最小可行系统应该包含哪些模块，如何避免一开始就陷入大而全？

方向 VLA / 具身智能

岗位 AI / 算法候选人

难度 中等

来源 知乎 2026-08-02

参考回答

最小可行具身系统应先选一个边界清楚的任务，例如桌面目标抓取、语音指令搬运或按钮按压。模块上需要相机/深度输入、目标检测或 VLM grounding、坐标转换、运动规划、夹爪控制、任务状态机和安全急停。不要一开始就训练端到端 VLA，可以先用 VLM 做语义目标选择，传统规划器做可达性和轨迹，低层控制器执行动作。数据侧记录每次任务的图像、目标、动作、结果和失败原因，为后续学习策略做准备。评估先看少量固定物体和固定场景的成功率，再逐步加入遮挡、光照变化、新物体和语言变化。这样能快速闭环，也能清楚定位失败来自感知、标定、规划还是控制。

来源链接 zhuanlan.zhihu.com/p/2059963418312957972

知乎

具身

具身智能项目

MVP

机器人系统

VLM

工程落地

Q115 VLA 模型的输入和输出分别是什么，为什么动作空间设计会直接影响模型能否落地？

方向 VLA / 具身智能

岗位 VLA预训练及模型架构算法工程师

难度 困难

来源 CSDN 2026-07-23

参考回答

VLA 的输入通常包括视觉观测、语言指令、机器人本体状态和历史动作。视觉可以是 RGB、深度、点云或多相机图像；语言描述任务目标；本体状态包括关节角、末端位姿、夹爪状态、速度和力矩；历史动作帮助模型理解当前执行阶段。输出可以是离散 action token、末端位姿增量、关节增量、轨迹关键点或未来 K 步 action chunk。动作空间决定模型输出是否容易学习、是否能被低层控制器稳定执行。离散 token 方便接入自回归 LLM，但精度受离散化影响；连续动作适合精细控制，但对数据质量和稳定性要求高；action chunk 能降低推理频率，但过长会降低闭环反应速度。落地时要根据机器人平台、控制频率、任务粒度和安全要求选择动作表示。评估不能只看离线 loss，要看真机成功率、动作平滑度、碰撞率、急停次数和跨场景泛化。

来源链接 blog.csdn.net/ZHHHHH15/article/details/160808758

中国移动

VLA

预训练

动作空间

具身智能

Q116

UniVLA 中 late action model / 潜在动作模型通常怎么搭建，为什么不直接让 VLM 输出关节动作？

方向 VLA / 具身智能

岗位 具身智能算法工程师

难度 困难

来源 牛客 2026-07-22

参考回答

这题的核心是把语义理解和低层连续控制解耦。VLM 擅长理解图像、语言和任务语义，但直接输出高频关节动作会遇到动作维度高、控制频率不匹配、训练噪声大和安全边界难约束的问题。late action model 的思路是先让前面的视觉语言主干形成任务相关表征，再在后端接一个动作专家或潜在动作解码器，把语义状态转成可执行的末端位姿、关节增量或 action chunk。潜在动作模型可以用 VQ、VAE、diffusion/flow matching 或 transformer decoder 学习动作分布，优点是能表达多峰动作，比如同一个抓取任务可以从不同方向接近。训练上通常先对齐视觉语言表征，再用遥操作轨迹做行为克隆或生成式动作学习，最后用真机失败样本微调。工程上还要让低层控制器做轨迹跟踪、碰撞检测、速度/力限制和急停。回答时强调：VLA 不是让大模型替代伺服控制，而是让大模型给出具备语义条件的动作意图，低层系统保证实时性和安全性。

来源链接 nowcoder.com/feed/main/detail/37af3ac1986b438c81cd26ab90a792a8

傅利叶智能

UniVLA

VLA

latent action

具身智能

Q117

机器人长程任务中如何把语言子目标、视觉状态和低层控制连接起来，避免一步错全局崩？

方向 VLA / 具身智能

岗位 具身智能算法工程师

难度 中等

来源 掘金 2026-07-03

参考回答

机器人长程任务要把“想做什么”和“怎么动”分开建模。高层语言模块负责把指令拆成可验证的子目标，例如找到杯子、移动到可抓取位置、抓起、放到指定区域；视觉状态模块负责判断每个子目标是否已经满足，例如目标是否可见、手爪是否接触、物体是否稳定；低层控制器负责执行短时动作，并处理限幅、碰撞、速度和力控约束。为了避免一步错导致全局崩溃，每个子目标执行后都要重新感知和校验，而不是默认动作成功；如果状态不符合预期，要触发重试、重新规划或人工接管。训练数据也要包含失败、恢复和中断样本，让模型学会从偏离状态回到任务轨道。面试里可以用一句话概括：高层做任务分解和状态机，低层做连续控制和安全兜底，中间用可验证状态连接；真正可靠的系统依赖频繁闭环，而不是一次性生成完整动作序列。

来源链接 juejin.cn/post/7631311804195471396

智元

具身智能

机器人

长程任务

分层控制

Q118 机器人执行失败后，系统如何识别失败原因并选择重试、重规划或人工接管？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-03

参考回答

失败处理要先做状态诊断，而不是盲目重试。系统可以根据视觉状态、力觉异常、目标是否移动、轨迹偏差、碰撞检测和超时信息判断失败类型：感知失败、规划失败、控制失败、环境变化或安全风险。轻微偏差可以低层控制重试；目标位置变化需要重新感知和规划；连续失败或安全风险升高时应人工接管。训练数据中要保留失败前后的完整片段和接管原因，用于学习恢复策略。评估时除了成功率，还要看失败检测准确率、恢复成功率、平均重试次数和危险动作拦截率。

来源链接 blog.csdn.net/lovely_yoshino/article/details/160694260

综合

VLA / 具身智能

面经

大模型

Q119 VLA 框架中，视觉、语言和动作三部分的接口应该如何设计，才能支持跨机器人泛化？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-07-01

参考回答

跨机器人泛化的关键是把任务语义、环境观测和具体控制接口解耦。视觉侧输出对象、空间关系、状态变化或视觉 token；语言侧提供目标、约束和阶段性指令；动作侧不能只绑定某个机械臂的关节维度，而应尽量使用末端位姿、技能 token、归一化动作或机器人无关的 action chunk。不同机器人再通过低层控制器或 embodiment adapter 映射到具体关节。训练数据中要显式记录相机外参、机器人本体状态、控制频率和动作坐标系，否则模型会把平台差异误当成任务规律。回答时可以强调分层：高层 VLA 学任务和语义动作，低层控制器处理动力学和安全约束。这样既利于跨平台迁移，也方便在真实机器人上做限幅、碰撞检查和急停。

来源链接 blog.csdn.net/lovely_yoshino/article/details/160694260

CSDN

VLA

面经

具身

Q120

经典 VLA 模型里，RT-1/RT-2、OpenVLA 和 Diffusion Policy 的动作生成范式有什么差异？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-07-01

参考回答

RT-1 更偏机器人多任务策略学习，把视觉和语言条件映射到离散化动作 token，适合统一多个任务但受动作量化影响。

RT-2 把互联网视觉语言知识迁移到机器人动作，把动作也表示成语言模型可生成的 token，优势是语义泛化更强。

OpenVLA 延续视觉语言动作统一建模思路，强调开源数据和跨任务泛化。Diffusion Policy 则不是自回归 token 生成，而是对一段连续动作轨迹做去噪生成，能表达多峰、平滑的 action chunk，适合抓取、装配等连续控制任务，但推理步数和延迟更高。面试里要把“离散 token 便于复用 LLM”和“连续扩散轨迹更适合精细控制”讲清楚，并说明实际系统常用高层 token 规划加低层连续控制。

来源链接 blog.csdn.net/lovely_yoshino/article/details/160722050

CSDN

VLA

面经

具身

Q121

VLA 预训练数据应该包含哪些字段，为什么只保存图像和动作不够？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-07-01

参考回答

VLA 预训练样本至少要包含多视角图像或视频、语言指令、机器人本体状态、末端位姿、动作命令、时间戳、相机外参、任务阶段、成功/失败标签和必要的力觉或触觉信息。只保存图像和动作会丢掉意图、坐标系和状态上下文，模型不知道这个动作是为了完成什么目标，也难以区分同一视觉状态下的不同任务。时间戳用于同步多相机和控制信号，外参用于空间对齐，本体状态用于判断可达性，成功失败标签用于学习恢复和风险。对于真实机器人数据，还要记录人工接管、异常、碰撞、超时和重试。一个成熟的数据 schema 能支持 imitation learning、失败样本挖掘、离线 RL 和仿真回放，而不是只能做简单行为克隆。

来源链接 blog.csdn.net/zhhhhh15/article/details/160808758

CSDN

VLA

面试

具身

Q122 VLA 模型如何处理语言指令中的歧义，比如“把它放到旁边”这种缺少明确目标的命令？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-07-01

参考回答

这类指令的难点在于代词、参照物和空间关系都不完整。系统应先做语义解析和上下文补全：结合历史对话、当前视觉场景、用户注视或最近操作，推断“它”指哪个对象，“旁边”相对哪个参照物。若存在多个高概率解释，不能强行动作，应触发澄清问题或给出候选确认。模型侧可以输出不确定性、候选目标和理由，再由安全策略决定是否执行。训练数据中要加入歧义指令、澄清对话和错误执行负例，让模型学会“看不确定时先问”。面试回答可以总结为：语言理解不是直接映射动作，而是先把指令落到可验证的场景符号和目标状态，再规划动作。

来源链接 blog.csdn.net/zhhhh15/article/details/160808758

CSDN

VLA

面试

具身

Q123 VLA 框架为什么需要把任务理解、场景 grounding 和低层控制解耦？端到端方案和分层方案如何取舍？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-29

参考回答

VLA 系统面对的是“看懂环境、理解指令、落到物理执行”三个不同难度的问题。如果完全端到端，模型可以减少人工模块边界，理论上能从数据中学到更统一的表示，适合数据规模足够大、任务分布相对稳定、允许离线充分验证的场景。但端到端的问题是调试困难：失败时很难判断是视觉 grounding 错了、语言目标理解错了，还是低层执行不稳。分层方案会把任务理解、场景 grounding、技能选择和低层控制拆开，优点是可解释、可替换、可插入安全约束，适合真实机器人落地；缺点是模块误差会逐层传递，接口设计不好会限制上限。面试回答可以这样收束：实验探索可以偏端到端，产品落地通常更偏分层闭环；高层负责语义和目标，低层负责稳定控制，中间用状态估计、约束检查和失败恢复把两者连接起来。

来源链接 blog.csdn.net/lovely_yoshino/article/details/160694260

CSDN

VLA

面经

具身

Q124

具身智能基础认知中，VLA 与传统感知-规划-控制管线相比，优势、风险和可解释性问题是什

么？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-29

参考回答

传统感知-规划-控制管线通常先做检测、分割、定位和状态估计，再由规划器生成轨迹，最后控制器执行。它的优点是模块清晰、可解释、工程边界明确，适合安全要求高的工业场景；缺点是依赖人工建模和规则，遇到开放词汇物体、复杂语言指令和长尾场景时扩展成本高。VLA 的优势是把视觉、语言和行为放进统一模型里，可以直接利用大规模图文、视频和机器人数据获得更强的语义泛化能力，能处理“把桌上红色杯子放到电脑左边”这类开放指令。风险在于：模型可能产生视觉幻觉，动作决策缺乏可解释性，训练分布外场景不稳定，且错误可能直接进入物理世界。工程上不能把 VLA 当成黑盒控制器裸奔，通常要加安全边界、动作可行性检查、低层控制兜底、异常停止、日志回放和离线仿真评估。好的回答要同时承认 VLA 的泛化潜力和落地风险。

来源链接 blog.csdn.net/lovely_yoshino/article/details/160694260

CSDN

VLA

面经

具身

Q125

手术动辄几小时，Transformer 的 KV Cache 会随时间爆炸，虽然换了 Mamba。但 Mamba 的线性压缩本质上是 Lossy，怎么保证它在记录了前一个小时的

操作后，还能精准记得现在对应的逻辑，而不是产生幻觉？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-24

参考回答

Transformer 的自注意力需要计算序列中 token 两两交互，标准实现的注意力矩阵大小为 $n \times n$ ，因此时间和显存复杂度通常随序列长度呈 $O(n^2)$ 增长；Mamba 使用选择性状态空间模型，把历史压缩进固定维度状态并递推更新，序列计算近似 $O(n)$ 。代价是 Mamba 的状态压缩不是无损记忆，长时细节可能被覆盖。机器人长任务中不应只依赖单一隐状态，而应结合分层记忆：短期连续状态交给 Mamba，关键事件、目标和操作结果写入结构化外部记忆，需要时检索回模型；同时用阶段边界监督、记忆一致性损失和长序列回放评估遗忘。

来源链接 xiaohongshu.com/explore/69e370800000000020039d78

小红书

腾讯

面试

具身

Q126 扩散模型生成的是Action Chunk，但在手术中，组织形变是实时的。如果你的 Chunk 还没跑完，组织已经发生了非线性位移，你的系统怎么做闭环修正？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-24

参考回答

Action Chunk 不能作为开环轨迹一次执行到底。更稳妥的做法是采用滚动时域控制：策略每次预测一段动作，但控制器只执行前几个动作，随后重新采集视觉、力觉和机器人本体状态，再用最新观测重规划剩余轨迹。对组织形变这类强非刚性场景，还应加入目标跟踪与形变估计、动作置信度或不确定性检测、力/速度安全约束以及异常触发的快速停止。训练时可通过扰动轨迹、失败恢复数据和延迟随机化，让策略学会在状态偏离时回到可恢复区域。核心是“短执行、频重规划、低层安全控制兜底”，而不是追求一次生成很长的动作序列。

来源链接 xiaohongshu.com/explore/69e370800000000020039d78

小红书

腾讯

面试

具身

Q127 如何解决Sim-to-Real（仿真到真实）鸿沟？具体有哪些技术手段？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-24

参考回答

Sim-to-Real 的差距主要来自视觉外观、动力学参数、传感器噪声、控制延迟和接触模型不一致。常用手段包括视觉与动力学域随机化、系统辨识、噪声/延迟注入、仿真图像风格迁移、鲁棒策略训练，以及少量真实数据微调。评估不能只看平均成功率，还要看不同物体、光照、摩擦、载荷和相机位姿下的最差性能与恢复率。

来源链接 blog.csdn.net/zhhhhh15/article/details/160808758

CSDN

VLA

面试

具身

Q128 模仿学习（IL）和强化学习（RL）在具身任务中各有什么优劣？如何结合使用？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-24

参考回答

模仿学习直接拟合专家演示，训练稳定、样本利用率高，适合快速获得可用策略，但容易受到分布偏移和复合误差影响；强化学习能基于长期奖励探索超越演示的策略，但真实机器人采样昂贵且有安全风险。常见组合是先用行为克隆/SFT 初始化，再用离线 RL、仿真 RL 或受约束在线 RL 优化成功率和恢复能力，同时保留专家数据做正则，防止策略漂移。

来源链接 blog.csdn.net/zhhhhh15/article/details/160808758

CSDN

VLA

面试

具身

Q129 1 如何处理模型推理延迟问题？

方向 VLA / 具身智能

岗位 AI / 算法候选人

难度 中等

来源 CSDN 2026-06-24

参考回答

降低模型推理延迟要先拆分视觉编码、prefill、decode/动作生成、通信和控制等待。可采用视觉特征缓存、低分辨率快速路径、模型蒸馏、INT8/FP8、FlashAttention、CUDA Graph、批处理与异步流水线；机器人控制还可让低层控制器在模型计算期间继续执行短 action chunk。必须设置超时和旧结果丢弃机制，避免迟到动作污染闭环。

来源链接 blog.csdn.net/weixin_31315007/article/details/158247399

CSDN

面试

具身

Q130 2 如何设计高效的机器人动作队列？

方向 VLA / 具身智能

岗位 AI / 算法候选人

难度 中等

来源 CSDN 2026-06-24

参考回答

高效动作队列需要支持时间戳、优先级、可取消和状态反馈。VLA 低频地产生 action chunk，控制线程按固定周期消费；当新观测触发重规划、碰撞风险或人工接管时，应原子地废弃未执行动作并切换到安全动作。队列还应限制最大前瞻时长，记录每个动作的计划时间与实际执行时间，用于监控延迟、丢帧和控制漂移。

来源链接 blog.csdn.net/weixin_31315007/article/details/158247399

CSDN

面试

具身

Q131 VLA 模型为什么需要强化学习，和单纯模仿学习相比能解决哪些问题？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 B站 2026-06-20

参考回答

模仿学习主要从专家轨迹里学习动作分布，优点是稳定、样本效率高，但容易受限于专家数据覆盖范围，遇到偏离轨迹的状态时会累积误差。VLA 引入强化学习，是为了让模型在环境反馈下优化长期任务成功率，而不是只拟合单步动作。强化学习可以处理稀疏奖励、失败恢复、探索更优策略和安全接管策略，但代价是训练不稳定、样本成本高，并且真实机器人上试错风险大。实际工程通常不会直接端到端在线 RL，而是先用遥操作或视频数据做预训练和 imitation learning，再在仿真或受控真实环境里做 RL 微调，并通过 reward shaping、离线 RL、success predictor 和安全约束降低风险。面试里要把 reward 设计、sim-to-real、失败样本回流和安全边界讲清楚。

来源链接 bilibili.com/video/BV1nyILBNEVX/

B站

小鹏

机器人

Q132 VLA 动作置信度为什么不能等同于任务成功率，机器人控制里应如何做校准？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 B站 2026-06-19

参考回答

VLA 的动作置信度通常表示模型对当前动作 token、连续控制量或轨迹片段的预测把握，但任务成功率取决于长时间闭环执行结果，两者不是一回事。模型可能对单步抓取动作很自信，但因为物体滑动、遮挡、相机延迟、接触动力学误差或后续路径规划失败，最终任务仍然失败。校准时要把单步概率和 episode 级结果关联起来：记录每个时刻的观测、动作、置信度、接触状态、人工接管和最终成功/失败标签；再用 reliability diagram、ECE、Brier score 等指标看置信度是否真的对应成功概率。工程上可以训练一个独立 success predictor 或 value head，把视觉状态、动作序列和历史反馈一起输入，输出可执行性评分。上线时不要用置信度直接替代安全判断，而要结合阈值拒答、低置信度接管、失败回放和主动探索数据回流。

来源链接 [bilibili.com/video/BV1kflv6CEno/](https://www.bilibili.com/video/BV1kflv6CEno/)

B站

VLA

机器人

Q133 机器人控制算法面试中，运动规划、轨迹跟踪和底层控制分别解决什么问题？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 中等

来源 B站 2026-06-19

参考回答

运动规划解决的是从当前状态到目标状态走哪条路径，重点考虑碰撞约束、可达性、动力学限制和任务目标；轨迹跟踪解决的是沿着规划出的路径如何在时间上平滑执行，重点关注速度、加速度、jerk 和误差收敛；底层控制解决的是如何把期望轨迹转成电机、关节或末端执行器的控制输入，常见方法包括 PID、MPC、阻抗控制和力控。三者的时间尺度不同：规划偏高层、频率较低，控制偏底层、频率更高。面试里还要说清楚误差来源：传感器噪声、模型不准、摩擦、延迟、负载变化和接触不确定性。具身智能系统里，VLA 可以生成高层动作意图或轨迹候选，但真正落地仍需要传统控制和安全约束兜住执行边界。

来源链接 [bilibili.com/video/BV1DaxkzQECY/](https://www.bilibili.com/video/BV1DaxkzQECY/)

B站

面试

机器人

Q134**智元这类具身智能基础模型岗位中，VLM、VLA 和 Video 模型在机器人系统里分别承担什么角色？****方向** VLA / 具身智能**岗位** 大模型相关岗位**难度** 困难**来源** 掘金 2026-06-18**参考回答**

VLM、VLA 和 Video 模型在具身系统中通常对应三层能力。VLM 负责理解场景和指令，例如识别物体、读懂空间关系、把用户语言转成任务语义；Video 模型负责时序理解和预测，例如判断动作进展、物体状态变化、失败前兆和未来几步可能发生什么；VLA 则把视觉、语言和机器人状态映射到动作，输出 action token、连续控制量或一段轨迹。三者可以端到端融合，也可以分层组合：VLM 做高层规划，Video 做状态估计和预测，VLA 做低层动作生成。工程取舍是，端到端系统上限高但难调试，分层系统可解释性好但误差会层层传递。面试里要强调闭环：感知、规划、动作、执行反馈和失败样本回流缺一不可。

来源链接 juejin.cn/post/7631311804195471396

掘金

智元

VLA

具身

机器人

Q135**具身基础模型训练中，如何组织遥操作数据、仿真数据、视频数据和语言指令数据？****方向** VLA / 具身智能**岗位** 大模型相关岗位**难度** 困难**来源** 掘金 2026-06-18**参考回答**

这类数据要按用途分层组织。遥操作数据最接近真实控制，包含相机、机器人状态、动作、力控、任务结果和失败原因，是训练 policy 的核心；仿真数据覆盖长尾场景和安全试错，但需要视觉随机化、动力学随机化和少量真实数据校准；视频数据规模大，适合学习物体状态、动作先验和时序预测，但没有天然动作标签，需要通过伪标注、逆动力学或语言描述补齐；语言指令数据负责把用户目标映射到任务语义和子目标。训练时可以先用视频/图文数据学表征，再用遥操作数据做 imitation learning，最后通过仿真或真实环境强化学习修正失败模式。评估要看成功率、碰撞率、恢复率、跨场景泛化和安全接管次数。

来源链接 juejin.cn/post/7631311804195471396

掘金

智元

VLA

具身

机器人

Q136 VLA 中 action token、连续动作回归和 diffusion policy 各自适合什么控制场景？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-17

参考回答

Action token 把动作离散成词表，便于复用语言模型的自回归建模和长程规划，适合技能选择、粗粒度控制与跨机器人统一表示，但存在量化误差。连续动作回归直接输出关节、末端位姿或速度，延迟低，适合高频闭环和精细操作，但容易对多解动作取平均。Diffusion Policy 生成整段 action chunk，能表达多峰轨迹并保持平滑，适合抓取、装配等示范分布复杂的任务，代价是多步采样较慢。工程上常采用高层 token 规划、低层连续控制或 diffusion chunk 滚动执行。

来源链接 blog.csdn.net/lovely_yoshino/article/details/160694260

CSDN

VLA

面经

具身

Q137 机器人数据如何做遥操作采集、时间同步、轨迹切分和失败样本标注？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-17

参考回答

遥操作采集应为所有传感器和控制流使用统一单调时钟，并记录高精度时间戳。相机按硬件触发或时间戳重采样对齐，机械臂关节、末端位姿和力矩以高频采集，语言指令记录开始、结束与对应任务阶段。离线构建样本时，以控制周期为主时间轴，对连续状态做插值，对图像取最近帧并限制最大时间差；同时保存时钟漂移、丢帧和网络延迟。轨迹按任务边界和关键事件切成 episode，失败样本标注失败时刻、原因、是否接管以及可否恢复。

来源链接 blog.csdn.net/lovely_yoshino/article/details/160694260

CSDN

VLA

面经

具身

Q138 VLA 模型中 action token、连续动作回归和 diffusion policy 分别适合什么控制场景？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-17

参考回答

Action token 把动作离散成词表，便于复用语言模型的自回归建模和长程规划，适合技能选择、粗粒度控制与跨机器人统一表示，但存在量化误差。连续动作回归直接输出关节、末端位姿或速度，延迟低，适合高频闭环和精细操作，但容易对多解动作取平均。Diffusion Policy 生成整段 action chunk，能表达多峰轨迹并保持平滑，适合抓取、装配等示范分布复杂的任务，代价是多步采样较慢。工程上常采用高层 token 规划、低层连续控制或 diffusion chunk 滚动执行。

来源链接 blog.csdn.net/lovely_yoshino/article/details/160722050

CSDN

VLA

面经

具身

Q139 机器人遥操作数据采集时，如何同步多相机、机械臂状态、力控信号和语言指令？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-17

参考回答

遥操作采集应为所有传感器和控制流使用统一单调时钟，并记录高精度时间戳。相机按硬件触发或时间戳重采样对齐，机械臂关节、末端位姿和力矩以高频采集，语言指令记录开始、结束与对应任务阶段。离线构建样本时，以控制周期为主时间轴，对连续状态做插值，对图像取最近帧并限制最大时间差；同时保存时钟漂移、丢帧和网络延迟。轨迹按任务边界和关键事件切成 episode，失败样本标注失败时刻、原因、是否接管以及可否恢复。

来源链接 blog.csdn.net/lovely_yoshino/article/details/160722050

CSDN

VLA

面经

具身

Q140 自动驾驶世界模型如何从 BEV、occupancy、轨迹预测和仿真闭环中学习环境动态？

方向 VLA / 具身智能

岗位 AI / 算法候选人

难度 中等

来源 B站 2026-06-14

参考回答

自动驾驶世界模型把历史多传感器观测、车辆状态和候选动作编码为场景状态，并预测未来。BEV 提供统一鸟瞰坐标，occupancy 描述空间占用和可见/不可见区域，轨迹预测表示交通参与者可能运动，规划动作作为条件影响未来演化。训练可结合重建、未来 occupancy、运动、轨迹和控制损失。真正价值需在闭环仿真中检验：模型不仅要预测像素或特征，还要在自车动作变化时生成合理交互结果。

来源链接 bilibili.com/video/BV18pYPzfEKc/

B站

面试

机器人

自动驾驶

Q141 驾驶数据闭环如何做场景挖掘、长尾样本回流、自动标注和仿真评测？

方向 VLA / 具身智能

岗位 AI / 算法候选人

难度 中等

来源 B站 2026-06-14

参考回答

驾驶数据闭环从线上日志中用接管、急刹、碰撞预警、低置信度和规则触发挖掘候选场景，再做聚类去重和优先级排序。自动标注结合多帧融合、教师模型和地图信息生成 3D 目标、车道、occupancy 与轨迹，并对低置信样本送人审。训练后先离线回放，再在可交互仿真中评估安全、舒适和法规指标；新的失败案例继续回流。关键是版本化数据、标签、模型和场景，才能追踪每次迭代收益。

来源链接 bilibili.com/video/BV18pYPzfEKc/

B站

面试

机器人

自动驾驶

Q142 具身智能任务中，episode 如何切分，成功、失败、中断和人为接管如何标注？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

episode 切分要围绕任务语义和控制连续性，而不是机械按固定时长切。一次 episode 通常从任务指令下发、机器人进入初始状态或人工开始遥操作时开始，到任务完成、失败、超时、中断或人为接管时结束。标注时至少记录起止时间、任务目标、关键阶段、动作轨迹、观察流、成功状态和终止原因。成功样本要标注是否完全达成目标、是否有轻微碰撞或多余动作；失败样本要标注失败发生点、失败类型、是否可恢复、是否由感知、规划、控制或环境变化导致；中断样本要区分系统异常、传感器丢失、用户暂停和安全策略触发；人为接管要记录接管时刻、接管前模型输出、人工修正动作和接管原因。这样做的价值是后续可以训练策略、失败检测、恢复策略和 reward/critic，而不是只得到一个粗糙的成功率。

来源链接 xiaohongshu.com/explore/6a2cd7840000000015024480

小红书

字节

VLA

具身

Q143 VLA 系统如何从 imitation learning 过渡到在线强化学习并控制安全风险？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

从 imitation learning 过渡到在线强化学习，通常不能直接把策略放到真实环境里自由探索。更稳的路径是先用高质量遥操作或人类演示训练 BC/SFT 策略，再用离线 RL、偏好数据或仿真环境做策略改进，最后在真实环境中做受限在线探索。安全风险控制要有几层保护：动作空间限幅、速度/力矩/碰撞约束、安全区域和规则过滤器；策略侧保留不确定性估计、异常检测和可回退的保守策略；数据侧把 near miss、接管、碰撞和失败恢复样本纳入训练；评估侧先过仿真、离线 replay、影子模式和小流量灰度。面试时要强调在线 RL 的收益是优化长期目标和恢复能力，但代价是安全、样本效率和分布漂移，因此必须用 human-in-the-loop 和安全 shield 逐步放开。

来源链接 xiaohongshu.com/explore/6a2cd7840000000015024480

小红书

字节

VLA

具身

Q144 sim-to-real 中，视觉随机化、动力学随机化和真实少样本微调分别解决什么问题？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

视觉随机化、动力学随机化和真实少样本微调解决的是 sim-to-real gap 的不同来源。视觉随机化改变纹理、光照、背景、相机位姿、噪声和遮挡，让视觉 encoder 不依赖仿真里的固定外观，主要提升感知鲁棒性。动力学随机化改变质量、摩擦、关节阻尼、延迟、执行器噪声和接触参数，让策略适应真实物理误差，主要提升控制和接触操作稳定性。真实少样本微调用少量真实机器人数据校准仿真学到的策略或表征，弥补随机化覆盖不到的系统偏差。好的回答要补充取舍：随机化太弱会过拟合仿真，太强会让训练任务不稳定；真实微调数据少但价值高，要优先采集失败、接触、遮挡和边界工况，并用成功率、碰撞率、恢复率和跨场景泛化来评估。

来源链接 xiaohongshu.com/explore/6a2cd7840000000015024480

小红书

字节

VLA

具身

Q145 长程具身任务如何处理记忆、子目标分解、环境变化和动作不可逆错误？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

长程具身任务要把高层规划和低层控制分开处理。高层用语言或视觉语言模型做任务分解，把目标拆成可执行子目标，并维护环境状态、已完成步骤、物体位置和历史失败；低层用 VLA policy、diffusion policy 或控制器执行抓取、移动、放置等短程技能。环境变化需要持续重感知和状态更新，不能只依赖初始计划；动作不可逆错误要提前做风险评估，比如倒水、碰撞、丢物体、关门后无法再观察等步骤要设置确认、回退或人工接管。记忆可以分成短期上下文、场景地图、对象状态和任务日志。评估不能只看最终成功，还要看子目标成功率、重规划次数、无效动作比例、错误恢复率、任务时长和安全事件。

来源链接 xiaohongshu.com/explore/6a2cd7840000000015024480

小红书

字节

VLA

具身

Q146 具身智能评估为什么不能只看成功率，还需要哪些安全性和泛化指标？

方向 VLA / 具身智能

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

具身智能不能只看成功率，因为同样成功可能对应完全不同的安全性、效率和泛化能力。一个策略可能 90% 成功，但剩下 10% 是高风险碰撞或不可恢复错误，这在线上不可接受。除了成功率，还要看碰撞率、接管率、near miss、力/速度越界、任务完成时间、轨迹平滑度、能耗、恢复成功率、失败类型分布和长尾场景覆盖。泛化指标要覆盖新物体、新背景、新光照、新相机位姿、新任务组合和不同机器人平台。对于 VLA/具身系统，还要评估语言指令理解、视觉 grounding、动作可执行性、跨 episode 一致性和安全约束遵守率。面试里可以总结为：成功率回答“能不能做成”，安全和泛化指标回答“能不能稳定、低风险、可规模化地做成”。

来源链接 xiaohongshu.com/explore/6a2cd7840000000015024480

小红书

字节

VLA

具身

Q147 VLA 模型中 action token、连续动作回归和 diffusion policy 分别适合哪些控制粒度和任务场景？

方向 VLA / 具身智能

岗位 具身智能 / 机器人算法

难度 困难

来源 内部题库 2026-06-06

参考回答

Action token 把动作离散成词表，便于复用语言模型的自回归建模和长程规划，适合技能选择、粗粒度控制与跨机器人统一表示，但存在量化误差。连续动作回归直接输出关节、末端位姿或速度，延迟低，适合高频闭环和精细操作，但容易对多解动作取平均。Diffusion Policy 生成整段 action chunk，能表达多峰轨迹并保持平滑，适合抓取、装配等示范分布复杂的任务，代价是多步采样较慢。工程上常采用高层 token 规划、低层连续控制或 diffusion chunk 滚动执行。

来源链接 无

题库

VLA

具身智能

机器人

Action Token

Diffusion Policy

遥操作

Sim-to-real

Q148 机器人遥操作数据采集时，如何处理多相机、机械臂状态、力控信号和语言指令的时间同步？

方向 VLA / 具身智能

岗位 具身智能 / 机器人算法

难度 困难

来源 内部题库 2026-06-06

参考回答

遥操作采集应为所有传感器和控制流使用统一单调时钟，并记录高精度时间戳。相机按硬件触发或时间戳重采样对齐，机械臂关节、末端位姿和力矩以高频采集，语言指令记录开始、结束与对应任务阶段。离线构建样本时，以控制周期为主时间轴，对连续状态做插值，对图像取最近帧并限制最大时间差；同时保存时钟漂移、丢帧和网络延迟。轨迹按任务边界和关键事件切成 episode，失败样本标注失败时刻、原因、是否接管以及可否恢复。

来源链接 无

题库

VLA

具身智能

机器人

Action Token

Diffusion Policy

遥操作

Sim-to-real

Q149 轨迹数据如何切分 episode，如何标注成功、失败、中断、重试和人为接管？

方向 VLA / 具身智能

岗位 具身智能 / 机器人算法

难度 困难

来源 内部题库 2026-06-06

参考回答

Episode 应按完整任务语义和控制连续性切分：从指令下发或进入初始状态开始，到成功、失败、超时、中断或人工接管结束。除最终标签外，还要记录子目标边界、关键接触事件、重试次数、接管时刻和终止原因。成功需由可验证条件判断；失败要区分感知、规划、控制、碰撞和任务超时；中断要区分系统异常与人为暂停。保留失败前后的观测和动作，可用于训练失败检测、恢复策略和困难负样本。

来源链接 无

题库

VLA

具身智能

机器人

Action Token

Diffusion Policy

遥操作

Sim-to-real

Q150 从 imitation learning 到 online RL，VLA 系统如何设计安全探索和失败样本回流？

方向 VLA / 具身智能

岗位 具身智能 / 机器人算法

难度 困难

来源 内部题库 2026-06-06

参考回答

模仿学习直接拟合专家示范，样本效率高、训练稳定，适合先得到可用策略，但会受分布偏移和复合误差影响。强化学习能围绕长期成功率、恢复能力和效率继续优化，但真实机器人探索昂贵且危险。常见流程是先用行为克隆或 SFT 初始化，再用离线 RL、仿真 RL 或受约束在线 RL 小步改进；在线阶段加入动作限幅、碰撞检查、不确定性门控和人工接管。失败轨迹应回流为负样本、恢复样本或 reward/critic 数据，而不是直接丢弃。

来源链接 无

题库

VLA

具身智能

机器人

Action Token

Diffusion Policy

遥操作

Sim-to-real

Q151 语言规划和低层控制之间如何分层，什么时候需要 skill library 或 hierarchical policy?

方向 VLA / 具身智能

岗位 具身智能 / 机器人算法

难度 困难

来源 内部题库 2026-06-06

参考回答

语言规划负责把长任务分解为可执行子目标，低层控制负责把子目标转成稳定的连续动作。若任务由可复用且边界清晰的技能组成，例如抓取、开门、放置，适合使用 skill library：高层选择技能并传参数，便于验证和复用。若技能组合复杂、环境动态或需要端到端优化，可用 hierarchical policy，让高层以较低频率产生 latent skill 或目标状态，低层高频执行。分层接口必须包含前置条件、终止条件、失败码和状态反馈，避免高层计划与低层真实执行脱节。

来源链接 无

题库

VLA

具身智能

机器人

Action Token

Diffusion Policy

遥操作

Sim-to-real

Q152 Sim-to-real 迁移中，视觉域随机化、动力学随机化和真实数据少样本微调各自解决什么问题？

方向 VLA / 具身智能

岗位 具身智能 / 机器人算法

难度 困难

来源 内部题库 2026-06-06

参考回答

Sim-to-real 差距主要来自视觉外观、动力学、传感器噪声、控制延迟和接触模型不一致。视觉域随机化改变纹理、光照、背景、相机位姿和遮挡，提升感知鲁棒性；动力学随机化改变质量、摩擦、阻尼、执行器延迟和接触参数，提升控制稳定性；真实少样本微调用少量目标机器人数据校准剩余偏差。还可结合系统辨识、仿真图像风格迁移和残差策略。随机化范围过窄无法泛化，过宽会降低可学习性，因此需用真实验证集迭代校准。

来源链接 无

题库

VLA

具身智能

机器人

Action Token

Diffusion Policy

遥操作

Sim-to-real

Q153 具身任务评估为什么不能只看成功率，还需要哪些鲁棒性、安全性和泛化指标？

方向 VLA / 具身智能

岗位 具身智能 / 机器人算法

难度 困难

来源 内部题库 2026-06-06

参考回答

成功率只说明任务是否最终完成，不能反映过程是否安全、稳定和可扩展。具身评估还应包括碰撞率、力/速度越界、人工接管率、near miss、恢复成功率、轨迹平滑度、完成时间和能耗。鲁棒性要测试光照、遮挡、物体位置、传感器噪声和动力学扰动；泛化要覆盖新物体、新场景、新指令组合和不同机器人平台。长程任务还应统计子目标完成率、重规划次数和错误累积。

来源链接 无

题库

VLA

具身智能

机器人

Action Token

Diffusion Policy

遥操作

Sim-to-real

Q154

长程任务中，VLA 如何处理记忆、子目标分解、环境变化和动作不可逆错误？

方向 VLA / 具身智能

岗位 具身智能 / 机器人算法

难度 困难

来源 内部题库 2026-06-06

参考回答

长程 VLA 需要分层记忆与闭环重规划。高层维护任务状态、已完成子目标、物体关系和历史失败，低层只执行短时 action chunk。每个子目标执行后重新感知并验证结果，而不是假设动作成功。对于不可逆动作，应在执行前做风险预测、可达性检查和安全确认，并提供替代方案或人工接管。记忆可由短期时序状态、结构化场景图和可检索事件日志组成，避免把全部历史都塞进上下文。

来源链接 无

题库

VLA

具身智能

机器人

Action Token

Diffusion Policy

遥操作

Sim-to-real

Q155 MQA、GQA 和 MLA 为什么能降低 KV Cache 压力？它们的代价分别是什么？

方向 推理优化 / 模型压缩

岗位 LLM 推理优化 / 模型部署岗位

难度 困难

来源 GitHub Pages 2026-08-24

参考回答

标准 MHA 每个 attention head 都有独立 K/V，KV Cache 随层数、batch、序列长度和 head 数线性增长。MQA 让多个 query head 共享一组 K/V，显著降低 KV 显存和带宽，但可能牺牲表达能力；GQA 把 head 分组共享 K/V，在性能和显存之间折中；MLA 进一步把 K/V 表示压到低秩 latent，再恢复注意力所需信息，适合长上下文和大模型推理，但实现复杂，尤其要处理位置编码和 attention 计算兼容性。面试要讲清楚：它们本质是在减少解码阶段最昂贵的 KV 读写，而不是减少所有计算。

来源链接 wanshuiyin.github.io/ARIS-in-AI-Offer/tutorials/kv_cache_speculative_decoding_tutorial.html

KV Cache

MQA

GQA

MLA

KV 量化

投机解码

Q156 KV Cache 量化和权重量化的目标有什么不同，线上部署时应该如何评估风险？

方向 推理优化 / 模型压缩

岗位 LLM 推理优化 / 模型部署岗位

难度 困难

来源 GitHub Pages 2026-08-24

参考回答

权重量化主要降低模型参数显存和矩阵乘带宽，影响所有阶段；KV Cache 量化主要降低长上下文和大 batch 解码阶段的缓存显存与访存压力，随请求长度越长收益越明显。KV 量化风险在于注意力分布对 K/V 精度敏感，可能造成长上下文遗忘、事实错误或多轮一致性下降。线上评估不能只看 perplexity，要看长文 QA、多轮对话、代码/数学、检索片段引用、首 token/每 token 延迟、显存水位和异常率。高风险业务可采用分层策略：短上下文不量化，长上下文低比特，关键层保留高精度。

来源链接 wanshuiyin.github.io/ARIS-in-AI-Offer/tutorials/kv_cache_speculative_decoding_tutorial.html

KV Cache

MQA

GQA

MLA

KV 量化

投机解码

Q157 KV Cache、PagedAttention、Continuous Batching 和 Speculative Decoding 分别解决推理链路的什么瓶颈？

方向 推理优化 / 模型压缩

岗位 大模型推理部署 / 系统优化岗位

难度 困难

来源 知乎 2026-08-24

参考回答

KV Cache 解决自回归解码重复计算历史 token 的问题，用显存换计算；PagedAttention 解决 KV Cache 变长请求造成的显存碎片和连续分配浪费，把 KV 切成页块管理；Continuous Batching 解决 GPU 空转问题，让已完成/新进入的请求动态加入 batch，提高吞吐；Speculative Decoding 解决单步解码串行瓶颈，用小 draft model 先生成候选 token，再由大模型并行验证。四者分别对应计算复用、内存管理、调度利用率和解码并行化，工程上通常组合使用，但要同时监控 TTFT、TPOT、吞吐、显存水位和失败率。

来源链接 zhuanlan.zhihu.com/p/2057144249490077467

KV Cache

PagedAttention

Continuous Batching

Speculative Decoding

vLLM

Q158 为什么 Continuous Batching 会提升吞吐，但仍可能让部分请求的尾延迟变差？

方向 推理优化 / 模型压缩

岗位 大模型推理部署 / 系统优化岗位

难度 困难

来源 知乎 2026-08-24

参考回答

Continuous Batching 的核心是动态合批，GPU 不再等一个固定 batch 全部结束，而是不断插入新请求，整体利用率更高。但调度器为了吞吐可能让长请求、低优先级请求或 prefill 较重的请求等待更久；如果 prefill/decode 混排不合理，还会让 decode 请求被大 prompt 阻塞，导致 TPOT 或尾延迟变差。解决方法包括 prefill/decode 分离、chunked prefill、优先级队列、最大等待时间约束、按租户限流、长短请求分池，以及同时用 P50/P95/P99 而不是平均延迟评估。

来源链接 zhuanlan.zhihu.com/p/2057144249490077467

KV Cache

PagedAttention

Continuous Batching

Speculative Decoding

vLLM

Q159**字节多模态训练中，DeepSpeed ZeRO、LoRA 和 RLHF 分别解决什么问题，为什么不能放在同一层面比较？****方向** 训练框架 / 推理优化**岗位** 大模型相关岗位**难度** 困难**来源** CSDN 2026-08-02**参考回答**

DeepSpeed ZeRO、LoRA 和 RLHF 属于训练链路的不同层。ZeRO 解决的是大模型训练的系统资源瓶颈，把优化器状态、梯度、参数切分到多卡，核心指标是显存占用、吞吐、通信开销和可训练模型规模。LoRA 解决的是参数高效微调问题，用低秩增量更新少量参数，适合多业务快速适配、降低显存和保存多个 adapter，但它不直接解决分布式训练通信，也不保证偏好对齐。RLHF 解决的是模型行为对齐问题，通常包括 SFT、奖励模型和策略优化，让输出更符合人类偏好、安全规范或任务目标。面试中不要把它们简单说成三种训练方法，而要讲清：ZeRO 是训练基础设施，LoRA 是微调参数化方式，RLHF 是对齐目标和优化流程。实际项目里三者可以组合，比如 ZeRO 承载大规模训练，LoRA 做业务适配，再用 DPO/RLHF 做偏好对齐。

来源链接 blog.csdn.net/libaiup/article/details/152087779

CSDN

字节

大模型

多模态

面经

DeepSpeed

训练框架

LoRA

Q160**大模型训练中的 3D 并行是什么，数据并行、张量并行和流水线并行分别解决什么瓶颈？****方向** 训练框架 / 推理优化**岗位** 大模型相关岗位**难度** 中等**来源** 牛客 2026-08-02**参考回答**

3D 并行通常指数据并行、张量并行和流水线并行组合使用。数据并行把同一模型复制到多卡，每张卡处理不同 batch，再同步梯度，主要提升吞吐，但每卡仍需放下完整模型参数。张量并行把单层内部矩阵按列或行切到多卡，解决单层参数或激活太大放不下的问题，但会引入频繁 collective 通信。流水线并行把不同层放到不同设备，解决模型层数太多导致单卡无法容纳的问题，但会产生 pipeline bubble，需要 micro-batch 填充。实际训练还会配合 ZeRO/FSDP 切分优化器、梯度和参数。面试回答要强调没有一种并行万能，选择取决于模型规模、层宽、层数、网络带宽、global batch、显存和吞吐目标。

来源链接 nowcoder.com/discuss/911748651754487808

牛客

大模型

面试

训练框架

3D并行

张量并行

流水线并行

数据并行

Q161 多模态模型推理为什么比纯文本 LLM 更复杂，视觉 encoder 缓存和图像预处理如何优化？

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 中等

来源 掘金 2026-08-02

参考回答

多模态推理比纯文本多了图像/视频解码、resize/crop、归一化、vision encoder、视觉 token 压缩和跨模态拼接等阶段。首 token 延迟不仅来自 LLM prefill，还来自视觉预处理和 encoder。优化上，静态图片或重复视频片段可以按媒体哈希缓存视觉特征；多轮对话中同一图片的视觉 token 可复用；图像预处理要批处理并放到 GPU 或高效 CPU pipeline；动态分辨率根据任务选择全局低分辨率加局部 tile，避免所有图片都高分辨率。视频任务可先低帧率粗筛，再对关键片段加密采样。监控要拆分图像下载、预处理、视觉 encoder、projector、LLM prefill 和 decode，否则无法定位瓶颈。

来源链接 juejin.cn/post/7373573927211565091

掘金

大模型

LLM

多模态

多模态推理

Vision Encoder

缓存

图像预处理

Q162 多模态 CoT 在视觉推理中有什么价值，为什么不能简单照搬纯文本 CoT？

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 中等

来源 B站 2026-08-02

参考回答

多模态 CoT 的价值是把视觉证据、空间关系和语言推理显式串起来，适合图表理解、数学题、空间推理、视频事件因果和医学影像等任务。但它不能简单照搬纯文本 CoT，因为视觉证据可能不完整、区域定位可能错误，模型容易编造看似合理的中间步骤。更可靠的做法是让推理链绑定可验证证据，例如引用图像区域、OCR 片段、检测框或关键帧；对于视频任务还要绑定时间戳。训练数据要区分“视觉观察”“中间推理”和“最终答案”，防止语言先验覆盖视觉输入。评估不能只看最终答案，还要看证据定位准确率、推理步骤一致性、幻觉率和反事实扰动下的鲁棒性。

来源链接 bilibili.com/video/BV11JoLYeEH3/

B站

多模态

多模态推理

CoT

视觉推理

VLM

证据定位

Q163

线上推理出现 P99 延迟升高但平均延迟正常时，应该如何从队列、prefill、decode 和 KV cache 四个层面排查？

方向 推理部署

岗位 大模型推理部署工程师

难度 困难

来源 CSDN 2026-07-12

参考回答

P99 升高但平均延迟正常，通常说明少量请求被长尾拖慢，而不是整体算力完全不足。第一层先看队列：是否有长上下文或高优先级请求占用 batch，是否存在 head-of-line blocking，队列等待时间是否在 P99 上放大。第二层看 prefill：长输入、prefix cache 未命中、chunked prefill 设置不合理，都会让首 token 延迟抬高；要按输入长度分桶看 TTFT。第三层看 decode：输出很长、continuous batching 调度不公平、单步 batch token 过大，会导致部分请求 TPOT 变差。第四层看 KV cache：显存水位高、碎片多、PagedAttention block 回收慢或 KV 量化/eviction 策略异常，都可能让少数请求等待资源。排查时不要只看平均 tokens/s，要同时记录队列等待、TTFT、TPOT、active sequence 数、batch token、KV cache 使用率、OOM/重试和不同长度分桶的 P95/P99。解决上可以做请求分级、长短请求隔离、限制最大上下文、开启 prefix cache、优化 chunked prefill、调整 batch token 上限和显存水位保护。

来源链接 blog.csdn.net/zhangzhentiyes/article/details/146966952

推理部署

P99

prefill

decode

KV cache

Q164

大模型推理服务如何在高并发下同时保证吞吐、延迟和稳定性？

方向 推理部署

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-07-08

参考回答

高并发推理服务要把请求准入、队列调度、显存管理和降级策略一起设计。吞吐依赖 batching、continuous batching、PagedAttention 和高 GPU 利用率；延迟依赖输入长度控制、prefill/decode 分离、优先级队列和超时机制；稳定性依赖显存水位保护、OOM 前拒绝新请求、异常重试、模型副本隔离和灰度发布。调度时要避免长上下文请求拖垮短请求，可以按输入长度、业务优先级和输出预算分队列。KV cache 是显存核心变量，需要监控每个请求的 token 数和剩余生成长度。线上还要有降级路径，例如切小模型、缩短上下文、关闭复杂工具、限制最大输出。指标上同时看 TTFT、TPOT、P95/P99、tokens/s、失败率和队列等待。

来源链接 zhuanlan.zhihu.com/p/1997087164006155782

腾讯

推理部署

稳定性

调度

降级

Q165 大模型线上推理为什么要把 prefill 和 decode 分开优化，二者瓶颈分别是什么？

方向 推理部署

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

Prefill 阶段处理整段输入上下文，主要瓶颈是大矩阵计算、注意力计算和输入 token 长度，因此影响首 token 延迟 TTFT。Decode 阶段每次生成一个或少量 token，主要瓶颈是 KV cache 读写、batch 调度和小矩阵计算效率，因此影响 TPOT 和吞吐。二者优化策略不同：prefill 适合 chunked prefill、prefix cache、输入长度控制和高效 attention；decode 适合 continuous batching、PagedAttention、KV cache 压缩、speculative decoding 和更好的调度。线上系统还要区分长输入短输出、短输入长输出、多轮对话和批量离线任务。只看总延迟容易误判瓶颈，必须分别监控 TTFT、TPOT、tokens/s、显存水位和队列等待。

来源链接 blog.csdn.net/zhangzhentiyes/article/details/146966643

部署

prefill

decode

TTFT

TPOT

Q166 字节多模态训练中，DeepSpeed ZeRO-3、张量并行和 LoRA 微调应该如何组合，分别解决什么瓶颈？

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-07-01

参考回答

可以先把问题拆成参数放置、单层计算和训练成本三层。ZeRO-3/FSDP 负责把参数、梯度和优化器状态分片，解决单卡显存装不下完整模型的问题；张量并行切分 attention 或 FFN 的矩阵计算，解决单层太宽、单卡算不动的问题；LoRA 则只训练低秩增量，减少可训练参数、优化器状态和通信量。多模态场景里，常见做法是冻结或半冻结视觉编码器，语言模型主体用 ZeRO/FSDP 管理，projector、adapter 或部分 LLM 层用 LoRA 训练。如果模型很大且单层矩阵也放不下，再叠加张量并行。面试里要强调组合顺序：先估算权重、梯度、优化器状态和激活值，再决定是否需要 ZeRO-3；再看单层矩阵和 batch token 是否需要张量并行；最后用 LoRA 控制微调成本和灾难性遗忘。风险是并行策略叠太多会让通信、checkpoint、恢复和性能调优复杂化。

来源链接 blog.csdn.net/libaiup/article/details/152087779

CSDN

字节

大模型

多模态

面经

DeepSpeed

Q167

多模态 LoRA 微调时，视觉编码器、projector 和 LLM 哪些层更适合训练，如何避免语言能力退化？

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-07-01

参考回答

多模态 LoRA 的核心是让视觉特征进入语言空间，同时尽量少破坏原有语言能力。视觉编码器如果已经很强，通常先冻结，只训练 projector 或 cross-modal adapter；如果目标领域视觉分布差异很大，比如医学、遥感、车载或机器人视角，再考虑解冻高层视觉 block 或加视觉侧 LoRA。LLM 侧可以在 attention 的 q/v/o 或 FFN 上加 LoRA，但 rank 不宜过大，且要混入通用指令数据维持语言能力。避免退化的关键包括：保留一定比例纯文本/通用多模态数据；控制学习率和 LoRA rank；对 projector 先 warmup；监控语言 benchmark、OCR、grounding 和幻觉率；必要时用 KL 或 reference loss 约束输出分布。回答时不要只说“冻结视觉、训练 LoRA”，要说明训练哪些层取决于领域差异、数据规模和目标任务。

来源链接 blog.csdn.net/libaiup/article/details/152087779

CSDN

字节

大模型

多模态

面经

DeepSpeed

Q168

分布式训练中，如何判断瓶颈是在计算、显存、通信还是数据加载？

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-01

参考回答

判断瓶颈要看 profiler 和系统指标，而不是凭感觉。计算瓶颈表现为 GPU SM 利用率高但 step time 长，算子占比集中在 matmul/attention；显存瓶颈表现为 OOM、频繁重算或 batch 上不去；通信瓶颈表现为 all-reduce/all-gather/all-to-all 时间占比高，GPU 等通信，跨节点扩展效率差；数据加载瓶颈表现为 GPU 利用率周期性掉到低位，CPU、磁盘或网络读取成为等待点。排查顺序通常是先固定 batch 和序列长度，记录 step time 分解，再分别开启/关闭 checkpointing、调整并行度、换数据缓存、看通信 trace。优化手段包括 FlashAttention、算子融合、ZeRO/FSDP、张量并行、通信重叠、数据预取和样本 packing。面试里最好能给出“指标-现象-手段”的闭环。

来源链接 blog.csdn.net/zhangzhentiyes/article/details/145909490

CSDN

大模型

面试

Q169 视频理解模型如何用动态推理和 Early Exit 降低延迟，同时尽量不牺牲准确率？

方向 视频 / 视觉理解

岗位 大模型相关岗位

难度 困难

来源 B站 2026-06-20

参考回答

视频理解的计算量主要来自帧数、分辨率和时序 attention。动态推理的思路是让模型根据样本难度自适应决定看多少帧、走多少层或生成多长推理链。简单样本可以早退出，复杂样本继续计算。Early Exit 通常会在中间层加分类头、置信度估计或价值判断，当置信度足够高且跨帧一致性稳定时提前输出。关键风险是过早退出会漏掉后续关键事件，因此要结合时间覆盖约束、置信度校准和困难样本回退策略。训练上可以用蒸馏、强化学习或代价敏感目标，把准确率和计算成本一起优化。评估时不能只看平均延迟，还要看 P95/P99、长视频事件召回、动作边界、身份保持和低置信度样本的失败率。

来源链接 bilibili.com/video/BV1h7zFBEEFA/

B站

大模型

多模态

Q170 字节多模态大模型训练中，DeepSpeed ZeRO、LoRA 和 RLHF 分别解决什么问题，如何取舍？

方向 训练框架 / 对齐训练

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-18

参考回答

这题要把训练链路拆开讲。DeepSpeed ZeRO 解决的是大模型训练时参数、梯度和优化器状态的显存压力，适合全参训练或大规模继续预训练；LoRA 解决的是低成本任务适配，通过低秩增量参数减少训练显存和存储成本，适合垂直任务微调和多租户部署；RLHF 解决的是模型输出偏好与人类期望不一致的问题，通常放在 SFT 之后，用偏好数据、reward model 或 DPO/GRPO 类方法做对齐。取舍上，如果目标是扩展模型能力，优先考虑全参训练和 ZeRO；如果目标是快速适配业务，优先 LoRA；如果基础能力已经够但回答风格、安全性、指令遵循不稳定，再做 RLHF 或偏好优化。面试里还要补一句：三者不是互斥关系，真实大厂训练常常是 ZeRO 支撑训练底座，LoRA 做快速实验，RLHF/DPO 做最后对齐。

来源链接 blog.csdn.net/libaiup/article/details/152087779

CSDN

字节

大模型

多模态

面经

DeepSpeed

Q171 多模态大模型训练时，视觉 encoder、LLM、LoRA 适配层和奖励/偏好数据应如何分阶段训练？

方向 训练框架 / 对齐训练

岗位 大模型相关岗位

难度 困难

来源 CSDN 2026-06-18

参考回答

比较稳的训练路径通常分四段。第一段做图文对齐，让视觉 encoder 或 connector 把视觉 token 对齐到 LLM 能理解的语义空间，核心指标看 caption、OCR、grounding 和图文检索。第二段做多模态指令微调，让模型学会按照文本指令理解图片、视频或多图上下文，此时要混合 VQA、OCR、定位、推理、多轮对话数据。第三段用 LoRA 或部分参数微调做业务适配，重点控制过拟合和灾难性遗忘，可以只调 connector、LLM 部分层或 adapter。第四段才是偏好对齐，利用人工偏好、拒答样本、安全样本和线上 badcase 做 DPO/RLHF。风险点是：如果视觉对齐没做好就直接偏好优化，reward 可能只学会语言风格；如果 LoRA 数据太窄，会牺牲通用视觉理解；如果偏好数据带长度偏置，模型会变得啰嗦但不一定更正确。

来源链接 blog.csdn.net/libaiup/article/details/152087779

CSDN

字节

大模型

多模态

面经

DeepSpeed

Q172 DeepSpeed ZeRO、Megatron 张量并行、流水并行和数据并行分别解决什么瓶颈？

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

数据并行复制模型并切分 batch，适合模型能放入单卡但需要扩吞吐；张量并行切分单层矩阵，解决单层过宽；流水线并行按层切分，解决模型过深但有 bubble；序列并行沿 token 维切分 LayerNorm、激活等，降低长序列显存；专家并行把 MoE 专家分布到不同设备，通过 all-to-all 路由 token。ZeRO/FSDP 则切分优化器状态、梯度和参数。实际系统通常组合使用，瓶颈在显存、通信、负载均衡和调度复杂度。

来源链接 xiaohongshu.com/search_result/6a2cd39c000000001503c862

小红书

字节

训练框架

Q173 大模型训练中显存如何拆解到参数、梯度、优化器状态、激活值和 KV cache?

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

训练显存由模型参数、梯度、优化器状态、激活值和临时/通信缓冲组成。BF16 参数约 2 字节，梯度通常再 2 字节；Adam 的一阶、二阶矩及可能的 FP32 主权重会带来每参数约 8-12 字节额外开销。激活随 micro-batch、序列长度、隐藏维和层数增长，长序列时常成为主项。临时 buffer 来自 attention、算子 workspace 和通信桶。优化可用 ZeRO/FSDP、混合精度、checkpointing、FlashAttention、序列并行和 offload。KV Cache 主要属于推理显存，不应和训练激活混为一谈。

来源链接 xiaohongshu.com/search_result/6a2cd39c000000001503c862

小红书

字节

训练框架

Q174 KV cache、PagedAttention、continuous batching 和 speculative decoding 如何提升推理吞吐?

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

Continuous batching 不等待整个静态 batch 完成，而是在每个 decode step 动态加入新请求、移除已完成请求，使 GPU 长期保持高利用率。吞吐因此提高，但长请求可能占用资源更久，短请求可能排队；过大的 token batch 也会增加单步时间和 P99 延迟。调度器通常结合优先级、等待时间、剩余长度估计和 prefill/decode 分离，设置最大 batch token、抢占或 chunked prefill，在吞吐与公平性间取舍。

来源链接 xiaohongshu.com/search_result/6a2cd39c000000001503c862

小红书

字节

训练框架

Q175 INT8/INT4 量化、AWQ/GPTQ、LoRA 合并和蒸馏分别适合哪些部署场景?

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

GPTQ 是基于校准数据和二阶近似的离线权重量化，适合单批或低并发部署；AWQ 保护重要激活通道，常用于低比特权重量化且质量较稳；SmoothQuant 把激活离群值部分迁移到权重，适合权重与激活 INT8；INT8 通常质量风险较低，INT4 显存收益更大但对数学、代码和长上下文更敏感。部署选择还取决于硬件 kernel、是否量化 KV Cache、吞吐目标和校准集代表性。

来源链接 xiaohongshu.com/search_result/6a2cd39c000000001503c862

小红书

字节

训练框架

Q176 数据并行、张量并行、流水线并行、序列并行和专家并行分别解决什么瓶颈？

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

数据并行复制模型并切分 batch，适合模型能放入单卡但需要扩吞吐；张量并行切分单层矩阵，解决单层过宽；流水线并行按层切分，解决模型过深但有 bubble；序列并行沿 token 维切分 LayerNorm、激活等，降低长序列显存；专家并行把 MoE 专家分布到不同设备，通过 all-to-all 路由 token。ZeRO/FSDP 则切分优化器状态、梯度和参数。实际系统通常组合使用，瓶颈在显存、通信、负载均衡和调度复杂度。

来源链接 xiaohongshu.com/search_result/6a2cd39c000000001503c862

小红书

字节

训练框架

Q177 DeepSpeed ZeRO-1/2/3 分别切分哪些状态，显存节省和通信开销如何变化？

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

ZeRO-1 只切分优化器状态，通信变化较小；ZeRO-2 再切分梯度，进一步省显存；ZeRO-3 连参数也切分，每层计算前按需 all-gather 参数，显存节省最大但通信和调度最复杂。以 Adam 为例，优化器状态通常是显存大头，因此 ZeRO-1 已有明显收益；ZeRO-3 适合单卡无法容纳模型参数的情况。选择时要考虑网络带宽、micro-batch、参数重用、通信重叠和 CPU/NVMe offload，不能只看理论显存。

来源链接 xiaohongshu.com/search_result/6a2cd39c000000001503c862

小红书

字节

训练框架

Q178 Megatron 的 tensor parallel 为什么需要行切分、列切分和 collective 通信配合？

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

Megatron 张量并行通过列切分和行切分让相邻线性层的通信最小化。第一层按输出维列切分，每卡产生部分隐藏特征，后续可直接并行计算；第二层按输入维行切分，每卡计算部分结果，最后用 all-reduce 合并。注意力头和 FFN 中间维也按类似方式切分。Collective 通信保证不同卡上的部分张量在需要时聚合；切分顺序若设计不当，会在每层之间产生额外 all-gather，吞吐显著下降。

来源链接 xiaohongshu.com/search_result/6a2cd39c000000001503c862

小红书

字节

训练框架

Q179 大模型训练显存如何拆成参数、梯度、优化器状态、激活值和临时 buffer?

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

训练显存由模型参数、梯度、优化器状态、激活值和临时/通信缓冲组成。BF16 参数约 2 字节，梯度通常再 2 字节；Adam 的一阶、二阶矩及可能的 FP32 主权重会带来每参数约 8-12 字节额外开销。激活随 micro-batch、序列长度、隐藏维和层数增长，长序列时常成为主项。临时 buffer 来自 attention、算子 workspace 和通信桶。优化可用 ZeRO/FSDP、混合精度、checkpointing、FlashAttention、序列并行和 offload。KV Cache 主要属于推理显存，不应和训练激活混为一谈。

来源链接 xiaohongshu.com/search_result/6a2cd39c000000001503c862

小红书

字节

训练框架

Q180 gradient checkpointing、FlashAttention 和 activation offload 分别如何影响显存和吞吐?

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

Gradient checkpointing 不保存部分前向激活，反向时重算，显著省显存但增加计算；FlashAttention 通过分块和在线 softmax 减少注意力矩阵的显存读写，通常同时提升速度和降低显存；activation offload 把激活移到 CPU/NVMe，显存收益大但受 PCIe 带宽和同步影响。三者可组合，但需避免重算与 offload 造成过多等待。稳定性方面 FlashAttention 应验证数值误差，checkpointing 要保证随机算子状态一致，offload 要监控传输超时。

来源链接 xiaohongshu.com/search_result/6a2cd39c000000001503c862

小红书

字节

训练框架

Q181 FP16、BF16、FP8 在数值稳定性、硬件收益和训练风险上有什么差异?

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

FP16 尾数精度较高但指数范围小，容易梯度溢出，通常需要 loss scaling；BF16 与 FP32 指数范围相同，训练更稳定，现代大模型常优先使用，但细粒度精度略低；FP8 显存和算力收益更大，需要硬件支持、逐张量/通道缩放、amax 历史和高精度累积。选择时看硬件、模型规模和稳定性：BF16 常作默认，FP16 用于旧硬件，FP8 适合成熟训练栈的大规模加速，并需监控 loss spike 和层级溢出。

来源链接 xiaohongshu.com/search_result/6a2cd39c000000001503c862

小红书

字节

训练框架

Q182 global batch、micro batch、pipeline bubble 和通信重叠如何联动调参？

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 困难

来源 小红书 2026-06-14

参考回答

Global batch = micro-batch × 数据并行度 × 梯度累积步数。增大 micro-batch 可提高算子利用率，但会增加激活显存；减小 micro-batch 并增加累积能省显存，却可能降低吞吐。流水线并行需要足够多 micro-batch 填满各 stage，减少 bubble；通信重叠则把梯度 all-reduce、参数 all-gather 放到相邻计算后面。调参时先满足显存，再通过 profile 找算子、流水线空闲和通信占比，并同步调整学习率与 global batch。

来源链接 xiaohongshu.com/search_result/6a2cd39c000000001503c862

小红书

字节

训练框架

Q183 KV cache 的显存占用如何随 batch size、序列长度、层数、head 数和 hidden size 增长？

方向 推理优化 / 模型压缩

岗位 推理部署 / 模型压缩工程

难度 困难

来源 内部题库 2026-06-06

参考回答

KV Cache 显存近似为 $\text{batch} \times \text{序列长度} \times \text{层数} \times 2(K/V) \times \text{KV 头数} \times \text{head_dim} \times \text{数据类型字节数}$ 。对普通 MHA，KV 头数等于注意力头数；GQA/MQA 通过减少 KV 头显著降低缓存。显存随 batch 和上下文长度线性增长，生成过程中还会继续累积。部署时应同时考虑并发序列、最大上下文、beam 数、前缀共享和显存碎片，并用分页缓存、KV 量化或 eviction 控制水位。

来源链接 无

题库

推理部署

KV Cache

PagedAttention

vLLM

量化

Speculative Decoding

模型压缩

Q184 PagedAttention 为什么能提高显存利用率，它和传统连续 KV cache 分配有什么区别？

方向 推理优化 / 模型压缩

岗位 推理部署 / 模型压缩工程

难度 困难

来源 内部题库 2026-06-06

参考回答

传统 KV Cache 为每个请求预留连续最大空间，实际长度不一会造成内部浪费和外部碎片。PagedAttention 把缓存切成固定大小 block，逻辑地址连续但物理块可分散分配，请求增长时按需追加，结束后立即回收；前缀还可通过引用计数共享。这样能提高显存利用率和并发数。代价是块表查询、调度与拷贝更复杂，block 太小管理开销高，太大又增加尾部浪费。

来源链接 无

题库

推理部署

KV Cache

PagedAttention

vLLM

量化

Speculative Decoding

模型压缩

Q185 continuous batching 如何提高吞吐，为什么会影响单请求延迟和调度公平性？

方向 推理优化 / 模型压缩

岗位 推理部署 / 模型压缩工程

难度 困难

来源 内部题库 2026-06-06

参考回答

Continuous batching 不等待整个静态 batch 完成，而是在每个 decode step 动态加入新请求、移除已完成请求，使 GPU 长期保持高利用率。吞吐因此提高，但长请求可能占用资源更久，短请求可能排队；过大的 token batch 也会增加单步时间和 P99 延迟。调度器通常结合优先级、等待时间、剩余长度估计和 prefill/decode 分离，设置最大 batch token、抢占或 chunked prefill，在吞吐与公平性间取舍。

来源链接 无

题库

推理部署

KV Cache

PagedAttention

vLLM

量化

Speculative Decoding

模型压缩

Q186 speculative decoding 的收益取决于哪些因素，draft model 接受率和额外计算如何权衡？

方向 推理优化 / 模型压缩

岗位 推理部署 / 模型压缩工程

难度 困难

来源 内部题库 2026-06-06

参考回答

Speculative decoding 由小 draft model 一次提出多个 token，大模型并行验证；被接受的连续 token 可减少大模型串行 decode 次数。收益取决于 draft 速度、提议长度、接受率、大模型验证效率和额外 KV/调度开销。接受率高且 draft 足够小才有明显加速；提议太长会增加拒绝后的浪费。应在不同任务、温度和上下文长度下测平均接受 token 数、端到端延迟和吞吐，而不是只看理论步数。

来源链接 无

题库

推理部署

KV Cache

PagedAttention

vLLM

量化

Speculative Decoding

模型压缩

Q187 INT8、INT4、AWQ、GPTQ、SmoothQuant 分别适合权重量化、激活量化还是离线压缩？

方向 推理优化 / 模型压缩

岗位 推理部署 / 模型压缩工程

难度 困难

来源 内部题库 2026-06-06

参考回答

GPTQ 是基于校准数据和二阶近似的离线权重量化，适合单批或低并发部署；AWQ 保护重要激活通道，常用于低比特权重量化且质量较稳；SmoothQuant 把激活离群值部分迁移到权重，适合权重与激活 INT8；INT8 通常质量风险较低，INT4 显存收益更大但对数学、代码和长上下文更敏感。部署选择还取决于硬件 kernel、是否量化 KV Cache、吞吐目标和校准集代表性。

来源链接 无

题库

推理部署

KV Cache

PagedAttention

vLLM

量化

Speculative Decoding

模型压缩

Q188 长上下文推理中，RoPE scaling、KV eviction、prefix cache 和检索增强分别解决什么问题？

方向 推理优化 / 模型压缩

岗位 推理部署 / 模型压缩工程

难度 困难

来源 内部题库 2026-06-06

参考回答

RoPE scaling 调整位置频率以扩展模型可处理的长度，但可能损害短上下文和远距离注意力；KV eviction 在缓存不足时删除低价值历史 token，需要保留系统指令、关键实体和近期上下文；prefix cache 复用相同系统提示或文档前缀的 KV，降低重复 prefill；检索增强则把海量历史放在外部索引中，按需取回证据。它们分别解决位置外推、缓存容量、重复计算和知识规模问题，通常组合使用。

来源链接 无

题库

推理部署

KV Cache

PagedAttention

vLLM

量化

Speculative Decoding

模型压缩

Q189 线上推理如何同时监控 TTFT、TPOT、吞吐、显存水位、失败率和队列等待时间？

方向 推理优化 / 模型压缩

岗位 推理部署 / 模型压缩工程

难度 困难

来源 内部题库 2026-06-06

参考回答

线上推理应同时监控请求级和系统级指标。TTFT 反映排队、prefill 和调度，TPOT 反映 decode 速度；吞吐统计 token/s 和 requests/s；显存看权重、KV Cache、水位峰值和碎片；稳定性看错误率、OOM、超时和重试；队列等待按优先级与输入长度分桶。还应记录 batch token、活跃序列数、cache 命中和抢占次数。告警需关联这些指标，例如 TTFT 上升但 TPOT 正常，多半是排队或 prefill 拥塞。

来源链接 无

题库

推理部署

KV Cache

PagedAttention

vLLM

量化

Speculative Decoding

模型压缩

Q190 LoRA 多租户服务中，adapter 热切换、权重合并、缓存复用和隔离性如何设计？

方向 推理优化 / 模型压缩

岗位 推理部署 / 模型压缩工程

难度 困难

来源 内部题库 2026-06-06

参考回答

多租户 LoRA 服务通常共享基座权重，把 adapter 独立存储并按请求加载。热门 adapter 常驻 GPU，冷门 adapter 放 CPU 并异步预取；批处理时尽量聚合同一 adapter，或使用支持多 adapter 的 fused kernel。永久合并适合单一固定业务，动态服务不宜频繁合并。缓存需按模型版本、adapter ID 和精度隔离，租户权限控制防止越权加载；还要限制 adapter 大小、校验权重来源，并监控切换延迟和显存抖动。

来源链接 无

题库

推理部署

KV Cache

PagedAttention

vLLM

量化

Speculative Decoding

模型压缩

Q191 数据并行、张量并行、流水并行、序列并行和专家并行分别解决什么瓶颈？

方向 训练框架

岗位 大模型训练工程 / 系统优化

难度 困难

来源 内部题库 2026-06-06

参考回答

数据并行复制模型并切分 batch，适合模型能放入单卡但需要扩吞吐；张量并行切分单层矩阵，解决单层过宽；流水线并行按层切分，解决模型过深但有 bubble；序列并行沿 token 维切分 LayerNorm、激活等，降低长序列显存；专家并行把 MoE 专家分布到不同设备，通过 all-to-all 路由 token。ZeRO/FSDP 则切分优化器状态、梯度和参数。实际系统通常组合使用，瓶颈在显存、通信、负载均衡和调度复杂度。

来源链接 无

题库

训练框架

DeepSpeed

Megatron

ZeRO

FlashAttention

显存优化

分布式训练

Q192 DeepSpeed ZeRO-1/2/3 分别切分哪些状态，通信量、显存节省和实现复杂度如何变化？

方向 训练框架

岗位 大模型训练工程 / 系统优化

难度 困难

来源 内部题库 2026-06-06

参考回答

ZeRO-1 只切分优化器状态，通信变化较小；ZeRO-2 再切分梯度，进一步省显存；ZeRO-3 连参数也切分，每层计算前按需 all-gather 参数，显存节省最大但通信和调度最复杂。以 Adam 为例，优化器状态通常是显存大头，因此 ZeRO-1 已有明显收益；ZeRO-3 适合单卡无法容纳模型参数的情况。选择时要考虑网络带宽、micro-batch、参数重用、通信重叠和 CPU/NVMe offload，不能只看理论显存。

来源链接 无

题库

训练框架

DeepSpeed

Megatron

ZeRO

FlashAttention

显存优化

分布式训练

Q193 Megatron 中 tensor parallel 的列切分和行切分为什么要配合 collective 通信？

方向 训练框架

岗位 大模型训练工程 / 系统优化

难度 困难

来源 内部题库 2026-06-06

参考回答

Megatron 张量并行通过列切分和行切分让相邻线性层的通信最小化。第一层按输出维列切分，每卡产生部分隐藏特征，后续可直接并行计算；第二层按输入维行切分，每卡计算部分结果，最后用 all-reduce 合并。注意力头和 FFN 中间维也按类似方式切分。Collective 通信保证不同卡上的部分张量在需要时聚合；切分顺序若设计不当，会在每层之间产生额外 all-gather，吞吐显著下降。

来源链接 无

题库

训练框架

DeepSpeed

Megatron

ZeRO

FlashAttention

显存优化

分布式训练

Q194 训练显存如何拆解为参数、梯度、优化器状态、激活值、临时 buffer 和通信 buffer?

方向 训练框架

岗位 大模型训练工程 / 系统优化

难度 困难

来源 内部题库 2026-06-06

参考回答

训练显存由模型参数、梯度、优化器状态、激活值和临时/通信缓冲组成。BF16 参数约 2 字节，梯度通常再 2 字节；Adam 的一阶、二阶矩及可能的 FP32 主权重会带来每参数约 8-12 字节额外开销。激活随 micro-batch、序列长度、隐藏维和层数增长，长序列时常成为主项。临时 buffer 来自 attention、算子 workspace 和通信桶。优化可用 ZeRO/FSDP、混合精度、checkpointing、FlashAttention、序列并行和 offload。KV Cache 主要属于推理显存，不应和训练激活混为一谈。

来源链接 无

题库

训练框架

DeepSpeed

Megatron

ZeRO

FlashAttention

显存优化

分布式训练

Q195 gradient checkpointing、FlashAttention、activation offload 分别如何影响显存、吞吐和稳定性?

方向 训练框架

岗位 大模型训练工程 / 系统优化

难度 困难

来源 内部题库 2026-06-06

参考回答

Gradient checkpointing 不保存部分前向激活，反向时重算，显著省显存但增加计算；FlashAttention 通过分块和在线 softmax 减少注意力矩阵的显存读写，通常同时提升速度和降低显存；activation offload 把激活移到 CPU/NVMe，显存收益大但受 PCIe 带宽和同步影响。三者可组合，但需避免重算与 offload 造成过多等待。稳定性方面 FlashAttention 应验证数值误差，checkpointing 要保证随机算子状态一致，offload 要监控传输超时。

来源链接 无

题库

训练框架

DeepSpeed

Megatron

ZeRO

FlashAttention

显存优化

分布式训练

Q196 大规模训练中 loss spike、梯度溢出、数据异常和通信 hang 应该如何定位?

方向 训练框架

岗位 大模型训练工程 / 系统优化

难度 困难

来源 内部题库 2026-06-06

参考回答

定位大规模训练异常要保存 step 级 loss、梯度范数、学习率、数据批次 ID 和通信事件。Loss spike 先排查异常样本、长度突变和学习率，再检查数值溢出；梯度溢出可查看各层 amax、loss scale 和 NaN 首发层；数据异常通过固定批次复现和数据哈希定位；通信 hang 则检查各 rank 是否走到同一 collective、张量形状是否一致、超时日志和网络错误。应支持自动跳过坏批次、保存故障 checkpoint 和最小规模复现。

来源链接 无

题库

训练框架

DeepSpeed

Megatron

ZeRO

FlashAttention

显存优化

分布式训练

Q197 混合精度训练中 FP16、BF16、FP8 的数值稳定性和硬件收益如何比较？

方向 训练框架

岗位 大模型训练工程 / 系统优化

难度 困难

来源 内部题库 2026-06-06

参考回答

FP16 尾数精度较高但指数范围小，容易梯度溢出，通常需要 loss scaling；BF16 与 FP32 指数范围相同，训练更稳定，现代大模型常优先使用，但细粒度精度略低；FP8 显存和算力收益更大，需要硬件支持、逐张量/通道缩放、amax 历史和高精度累积。选择时看硬件、模型规模和稳定性：BF16 常作默认，FP16 用于旧硬件，FP8 适合成熟训练栈的大规模加速，并需监控 loss spike 和层级溢出。

来源链接 无

题库

训练框架

DeepSpeed

Megatron

ZeRO

FlashAttention

显存优化

分布式训练

Q198 训练吞吐优化时，global batch、micro batch、pipeline bubble 和通信重叠如何联动调参？

方向 训练框架

岗位 大模型训练工程 / 系统优化

难度 困难

来源 内部题库 2026-06-06

参考回答

$\text{Global batch} = \text{micro-batch} \times \text{数据并行度} \times \text{梯度累积步数}$ 。增大 micro-batch 可提高算子利用率，但会增加激活显存；减小 micro-batch 并增加累积能省显存，却可能降低吞吐。流水线并行需要足够多 micro-batch 填满各 stage，减少 bubble；通信重叠则把梯度 all-reduce、参数 all-gather 放到相邻计算后面。调参时先满足显存，再通过 profile 找算子、流水线空闲和通信占比，并同步调整学习率与 global batch。

来源链接 无

题库

训练框架

DeepSpeed

Megatron

ZeRO

FlashAttention

显存优化

分布式训练

Q199 线上推理如何权衡首 token 延迟、吞吐、显存、上下文长度和服务稳定性？

方向 推理优化 / 模型压缩

岗位 大模型算法

难度 困难

来源 脉脉 2026-06-05

参考回答

首 token 延迟主要由排队、输入预处理和 prefill 决定，吞吐则依赖 batching 和 GPU 利用率；增大 batch 能提吞吐，却可能拉高 TTFT。长上下文增加 attention 计算和 KV Cache，压缩并发空间。工程上通过 chunked prefill、continuous batching、PagedAttention、prefix cache、量化和请求分级控制取舍。稳定性要求设置输入长度上限、显存水位保护、超时、降级模型和 admission control，并分别监控 TTFT、TPOT、吞吐、P99、OOM 和队列长度。

来源链接 maimai.cn/community/home/recommended

脉脉

百度

AIDU

大模型算法

论文追问

Q200 大模型训练中显存占用如何拆解到参数、梯度、优化器状态、激活值和 KV cache?

方向 训练框架

岗位 大模型训练工程候选人

难度 中等

来源 脉脉 2026-06-05

参考回答

训练显存由模型参数、梯度、优化器状态、激活值和临时/通信缓冲组成。BF16 参数约 2 字节，梯度通常再 2 字节；Adam 的一阶、二阶矩及可能的 FP32 主权重会带来每参数约 8-12 字节额外开销。激活随 micro-batch、序列长度、隐藏维和层数增长，长序列时常成为主项。临时 buffer 来自 attention、算子 workspace 和通信桶。优化可用 ZeRO/FSDP、混合精度、checkpointing、FlashAttention、序列并行和 offload。KV Cache 主要属于推理显存，不应和训练激活混为一谈。

来源链接 maimai.cn/community/home/recommended

脉脉

训练框架

DeepSpeed

Megatron

分布式训练

Q201 混合精度、gradient checkpointing、FlashAttention 和通信重叠如何影响吞吐与稳定性?

方向 训练框架

岗位 大模型训练工程候选人

难度 中等

来源 脉脉 2026-06-05

参考回答

Gradient checkpointing 不保存部分前向激活，反向时重算，显著省显存但增加计算；FlashAttention 通过分块和在线 softmax 减少注意力矩阵的显存读写，通常同时提升速度和降低显存；activation offload 把激活移到 CPU/NVMe，显存收益大但受 PCIe 带宽和同步影响。三者可组合，但需避免重算与 offload 造成过多等待。稳定性方面 FlashAttention 应验证数值误差，checkpointing 要保证随机算子状态一致，offload 要监控传输超时。

来源链接 maimai.cn/community/home/recommended

脉脉

训练框架

DeepSpeed

Megatron

分布式训练

Q202 自动驾驶世界模型如何把 BEV、occupancy、轨迹预测和闭环仿真统一到规划可用的环境动态建模中？

方向 自动驾驶数据 / 世界模型

岗位 自动驾驶 / 世界模型算法岗位

难度 困难

来源 博客园 2026-08-24

参考回答

BEV 提供统一鸟瞰空间坐标，方便融合多相机、激光雷达和地图；occupancy 表示空间占用和可通行区域，能描述静态/动态障碍；轨迹预测建模其他交通参与者未来行为；闭环仿真则把自车动作对环境反馈的影响纳入评估。世界模型的目标是学习状态转移：当前感知、历史动作、交通上下文输入后，预测未来场景和风险，让规划器能比较候选动作的后果。面试要强调规划可用性：预测不只是生成好看的 BEV，而是要服务碰撞风险、舒适性、法规约束、可解释性和长尾场景覆盖。

来源链接 cnblogs.com/clnchanpin/p/19502504

世界模型

自动驾驶

BEV

Occupancy

闭环仿真

Q203 闭环仿真评估自动驾驶策略时，为什么需要关注交互真实性而不只是轨迹误差？

方向 自动驾驶数据 / 世界模型

岗位 自动驾驶 / 世界模型算法岗位

难度 困难

来源 博客园 2026-08-24

参考回答

轨迹误差是开环指标，只比较模型预测和记录轨迹是否接近，但真实驾驶是交互系统：自车换道、减速或避让会改变其他车辆反应。一个开环误差小的模型，闭环中可能产生不合理让行、碰撞或僵持。交互真实性要求仿真中的车辆、行人、信号和道路约束对自车动作有合理反馈，并覆盖 cut-in、急刹、遮挡、无保护左转等长尾场景。评估时应看碰撞率、违规率、舒适性、到达率、接管率、场景覆盖和反事实一致性，而不是只看 ADE/FDE。

来源链接 cnblogs.com/clnchanpin/p/19502504

世界模型

自动驾驶

BEV

Occupancy

闭环仿真

Q204

世界模型训练中如何把真实驾驶数据、仿真数据和闭环评测连接起来，避免只学到离线预测指标？

方向 自动驾驶数据 / 世界模型

岗位 自动驾驶 / 世界模型算法工程师

难度 困难

来源 CSDN 2026-07-11

参考回答

这题的核心是区分“离线预测准确”和“闭环驾驶可用”。真实驾驶数据提供长尾场景、传感器噪声、交通参与者真实反应和人类接管片段，是世界模型学习环境动态的基础；仿真数据提供可控扰动、危险场景扩增和反事实评测能力，但容易有 sim-to-real gap；闭环评测负责把模型预测放回规划控制链路，看自车动作改变后环境是否合理演化。训练时可以用真实日志学习 BEV、occupancy、轨迹和交通规则，再用仿真生成稀有交互与碰撞边界样本，最后用闭环指标筛选失败场景回流训练。不能只优化 ADE、FDE 或未来 occupancy IoU，因为这些离线指标不一定对应安全规划。更可靠的指标包括碰撞率、接管率、规则违反、舒适性、near miss、长尾场景通过率和不确定性校准。工程上还要保留可解释中间量，例如风险热力图、候选动作代价和参与者反应假设，便于排查世界模型是否学错了因果关系。

来源链接 blog.csdn.net/kaka0722ww/article/details/160022527

世界模型

自动驾驶

仿真

闭环评测

数据闭环

Q205

世界模型用于自动驾驶规划时，如何处理可解释性、安全边界和分布外场景？

方向 自动驾驶数据 / 世界模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

世界模型能把感知、预测和规划放到统一动态建模中，但这也会降低模块边界的可解释性。工程上需要让模型输出中间状态，例如 BEV、occupancy、轨迹分布、风险热力图和候选动作代价，而不是只输出最终控制。安全边界不能完全交给神经网络，需要规则约束、碰撞检查、可达集、速度/加速度限制和冗余安全控制器兜底。分布外场景要通过不确定性估计、低置信触发降级、长尾场景挖掘和仿真回归处理。评估时要看模型在罕见天气、施工、异形障碍、交通参与者异常行为下是否会给出高置信错误。上线策略通常是影子模式、限定场景、逐步放量，并保留可审计日志用于失败归因。

来源链接 blog.csdn.net/youmaob/article/details/159420071

世界模型

自动驾驶

安全边界

OOD

可解释性

Q206 自动驾驶数据闭环中，如何识别并回流 corner case、near miss 和接管片段？

方向 自动驾驶数据 / 世界模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

数据闭环先要定义触发信号：接管、急刹、碰撞风险、规划不连续、感知低置信、规则冲突、预测误差大、用户投诉和仿真失败都可以作为候选。corner case 强调罕见或分布外，near miss 强调差点出事故但未发生，接管片段则有人类安全员介入。回流流程通常是自动挖掘候选、去重聚类、自动预标注、人工复核、质量验收、训练重采样和仿真回归。关键是避免只回流“看起来吓人”的片段，而忽略模型真正失败的原因；需要把失败归因到感知、预测、规划、控制或地图。评估时要看新数据是否提升目标场景通过率，同时不降低普通场景表现。隐私和合规上要做车牌、人脸和位置脱敏。

来源链接 blog.csdn.net/weixin_59191169/article/details/159648229

自动驾驶

数据闭环

长尾场景

自动标注

仿真评测

Q207 自动驾驶世界模型如何把 BEV、occupancy、轨迹预测和闭环仿真连接起来？

方向 自动驾驶数据 / 世界模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

自动驾驶世界模型的目标不是只做感知，而是学习“当前状态加候选动作会导致什么未来”。BEV 提供统一鸟瞰坐标，把相机、雷达、地图和历史轨迹对齐到可规划空间；occupancy 描述静态和动态空间占用，尤其适合表达可见和不可见区域；轨迹预测建模其他交通参与者未来运动；闭环仿真则把自车规划动作放回环境中，评估交互结果。训练时可以联合未来 occupancy、轨迹、碰撞风险、交通规则和规划代价，让模型理解动态演化。难点在于闭环误差会累积，仿真参与者反应要合理，长尾场景要覆盖。评估不能只看离线 mAP 或 ADE/FDE，还要看闭环碰撞率、接管率、规则违反、舒适性和场景覆盖。

来源链接 blog.csdn.net/kaka0722ww/article/details/160022527

自动驾驶

世界模型

BEV

occupancy

闭环仿真

Q208 小鹏 VLM/VLA 场景中，自动驾驶感知输出如何转成可被语言模型使用的场景 token?

方向 自动驾驶 / 世界模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-07-01

参考回答

自动驾驶里的原始图像、点云和 BEV 特征不能直接丢给语言模型，需要先转成结构化或半结构化场景 token。常见做法是先利用感知模型得到车道线、交通灯、动态目标、occupancy、可行驶区域、轨迹候选和自车状态，再通过 projector、query token 或序列化模板把这些信息编码成 LLM 可消费的 token。关键是保留时空关系：目标相对自车的位置、速度、意图，车道拓扑和交通规则约束，不能只给静态类别标签。对于 VLA，还要把候选动作或规划轨迹作为条件，让模型理解“如果我这样开，未来会发生什么”。面试里可以强调两条路线：端到端视觉 token 路线表达力强但解释性弱；结构化场景 token 路线更可控、更适合安全审计，实际系统往往混合使用。

来源链接 xiaohongshu.com/explore/6a4486d500000000170285f1

小红书

小鹏

面经

Q209 自动驾驶 VLA 如何评估闭环能力，为什么离线感知准确率不足以说明模型可用?

方向 自动驾驶 / 世界模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-07-01

参考回答

离线感知准确率只说明单帧或短片段识别得准，不代表模型在自己的动作影响下仍然安全。闭环评估要让模型输出规划或控制，再把动作反馈到仿真或真实系统中，观察后续状态是否变好。关键指标包括碰撞率、接管率、交通规则违规率、舒适性、最小 TTC、路线完成率、长尾场景恢复能力和 near miss。还要做反事实评估：同一场景下不同自车动作会导致不同未来，世界模型或 VLA 必须能预测这种动作条件下的变化。离线模型可能在专家轨迹附近表现好，但一旦偏离训练分布就会误差累积。面试回答应指出：自动驾驶模型最终优化的是安全、合法、舒适和可恢复的闭环行为，而不是单独的检测 mAP 或轨迹 ADE。

来源链接 xiaohongshu.com/explore/6a4486d500000000170285f1

小红书

小鹏

面经

Q210 世界模型和传统感知、预测、规划模块相比，优势、风险和可解释性问题是什么？

方向 自动驾驶 / 世界模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-14

参考回答

传统栈将感知、预测和规划模块化，接口清晰、易定位问题，但误差会逐级传播且难以联合优化。世界模型学习环境状态转移，可利用海量无标签视频、做反事实 rollout，并让规划直接考虑动作对未来的影响。风险包括生成未来不真实、长时误差累积、闭环分布漂移和难以给出安全保证。可解释性可通过显式 BEV/occupancy、对象轨迹、因果探针和反事实场景提升，同时保留规则安全层和模块化诊断指标。

来源链接 xiaohongshu.com/search_result/

小红书

小鹏

大模型

多模态

面经

Q211 驾驶数据闭环中，长尾场景挖掘、自动标注、训练回流和仿真评测如何形成闭环？

方向 自动驾驶 / 世界模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-14

参考回答

驾驶数据闭环从线上日志中用接管、急刹、碰撞预警、低置信度和规则触发挖掘候选场景，再做聚类去重和优先级排序。自动标注结合多帧融合、教师模型和地图信息生成 3D 目标、车道、occupancy 与轨迹，并对低置信样本送人审。训练后先离线回放，再在可交互仿真中评估安全、舒适和法规指标；新的失败案例继续回流。关键是版本化数据、标签、模型和场景，才能追踪每次迭代收益。

来源链接 xiaohongshu.com/search_result/

小红书

小鹏

大模型

多模态

面经

Q212 多传感器数据中，相机、激光雷达、毫米波雷达、定位和车控状态如何时空对齐？

方向 自动驾驶 / 世界模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-14

参考回答

时间对齐需使用硬件同步、PTP/GPS 时钟或统一高精度时间戳，并估计传感器固定延迟和时钟漂移；对不同频率数据按目标时间插值或取最近帧。空间对齐先做相机内参，再求各传感器到车体坐标系的外参，并在线监控震动导致的漂移。车辆运动期间还需用 IMU/里程计做运动补偿，将点云、图像和雷达测量变换到同一参考时刻。校准质量可用重投影误差、地图对齐和跨传感器目标一致性评估。

来源链接 xiaohongshu.com/search_result/

小红书

小鹏

大模型

多模态

面经

Q213 端到端自动驾驶模型如何处理安全边界、法规约束、分布外场景和可解释性？

方向 自动驾驶 / 世界模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-14

参考回答

端到端模型不应独自承担全部安全责任。训练中加入法规、碰撞、可行驶区域和舒适性损失；推理时由独立安全层检查速度、间距、交通规则和轨迹可达性，必要时覆盖模型输出。分布外检测可结合特征距离、模型集成和不确定性，触发降级或人工接管。可解释性通过输出关键对象、占用、候选轨迹及风险评分实现。验证必须覆盖闭环仿真、故障注入、长尾场景和形式化安全约束。

来源链接 xiaohongshu.com/search_result/

小红书

小鹏

大模型

多模态

面经

Q214 自动驾驶数据闭环中，长尾场景挖掘、自动标注、训练回流和仿真评测如何形成闭环？

方向 自动驾驶 / 世界模型

岗位 自动驾驶算法 / 世界模型

难度 困难

来源 内部题库 2026-06-06

参考回答

驾驶数据闭环从线上日志中用接管、急刹、碰撞预警、低置信度和规则触发挖掘候选场景，再做聚类去重和优先级排序。自动标注结合多帧融合、教师模型和地图信息生成 3D 目标、车道、occupancy 与轨迹，并对低置信样本送人审。训练后先离线回放，再在可交互仿真中评估安全、舒适和法规指标；新的失败案例继续回流。关键是版本化数据、标签、模型和场景，才能追踪每次迭代收益。

来源链接 无

题库

自动驾驶

数据闭环

世界模型

BEV

Occupancy

仿真

长尾场景

Q215 BEV、occupancy、轨迹预测和端到端规划分别在世界模型中承担什么表示角色？

方向 自动驾驶 / 世界模型

岗位 自动驾驶算法 / 世界模型

难度 困难

来源 内部题库 2026-06-06

参考回答

BEV 将多摄像头和雷达信息映射到统一鸟瞰空间，便于几何推理；occupancy 进一步表达每个空间单元是否被占用、类别和运动状态，能覆盖非规则物体；轨迹预测描述其他参与者未来的多模态行为；端到端规划根据这些状态和导航目标直接输出自车轨迹或控制。世界模型可把它们组织成从当前状态到未来状态的层次表示，但应避免中间表示与最终规划目标割裂。

来源链接 无

题库

自动驾驶

数据闭环

世界模型

BEV

Occupancy

仿真

长尾场景

Q216 世界模型如何学习环境动态，和传统感知预测规划模块相比优势和风险是什么？

方向 自动驾驶 / 世界模型

岗位 自动驾驶算法 / 世界模型

难度 困难

来源 内部题库 2026-06-06

参考回答

自动驾驶世界模型把历史多传感器观测、车辆状态和候选动作编码为场景状态，并预测未来。BEV 提供统一鸟瞰坐标，occupancy 描述空间占用和可见/不可见区域，轨迹预测表示交通参与者可能运动，规划动作作为条件影响未来演化。训练可结合重建、未来 occupancy、运动、轨迹和控制损失。真正价值需在闭环仿真中检验：模型不仅要预测像素或特征，还要在自车动作变化时生成合理交互结果。

来源链接 无

题库

自动驾驶

数据闭环

世界模型

BEV

Occupancy

仿真

长尾场景

Q217 多传感器数据中，相机、激光雷达、毫米波雷达、定位和车控状态如何做时间空间对齐？

方向 自动驾驶 / 世界模型

岗位 自动驾驶算法 / 世界模型

难度 困难

来源 内部题库 2026-06-06

参考回答

时间对齐需使用硬件同步、PTP/GPS 时钟或统一高精度时间戳，并估计传感器固定延迟和时钟漂移；对不同频率数据按目标时间插值或取最近帧。空间对齐先做相机内参，再求各传感器到车体坐标系的外参，并在线监控震动导致的漂移。车辆运动期间还需用 IMU/里程计做运动补偿，将点云、图像和雷达测量变换到同一参考时刻。校准质量可用重投影误差、地图对齐和跨传感器目标一致性评估。

来源链接 无

题库

自动驾驶

数据闭环

世界模型

BEV

Occupancy

仿真

长尾场景

Q218 仿真评测如何保证场景真实性、交互合理性、覆盖率和指标可解释性？

方向 自动驾驶 / 世界模型

岗位 自动驾驶算法 / 世界模型

难度 困难

来源 内部题库 2026-06-06

参考回答

端到端模型不应独自承担全部安全责任。训练中加入法规、碰撞、可行驶区域和舒适性损失；推理时由独立安全层检查速度、间距、交通规则和轨迹可达性，必要时覆盖模型输出。分布外检测可结合特征距离、模型集成和不确定性，触发降级或人工接管。可解释性通过输出关键对象、占用、候选轨迹及风险评分实现。验证必须覆盖闭环仿真、故障注入、长尾场景和形式化安全约束。

来源链接 无

题库

自动驾驶

数据闭环

世界模型

BEV

Occupancy

仿真

长尾场景

Q219 自动驾驶数据筛选时，如何识别 corner case、near miss、接管片段和标注不确定样本？

方向 自动驾驶 / 世界模型

岗位 自动驾驶算法 / 世界模型

难度 困难

来源 内部题库 2026-06-06

参考回答

Corner case 可由规则触发、模型低置信、预测分歧和异常检测共同挖掘；near miss 可用 TTC、急刹、横向距离和风险模型识别；接管片段需向前回溯若干秒捕获诱因，并区分安全接管与舒适性接管。标注不确定样本可根据多标注者分歧、教师模型方差和时序不一致筛选。候选场景还需聚类去重、按风险和新颖度排序，避免数据闭环被大量相似普通样本淹没。

来源链接 无

题库

自动驾驶

数据闭环

世界模型

BEV

Occupancy

仿真

长尾场景

Q220 端到端自动驾驶模型如何处理可解释性、安全边界、法规约束和分布外场景？

方向 自动驾驶 / 世界模型

岗位 自动驾驶算法 / 世界模型

难度 困难

来源 内部题库 2026-06-06

参考回答

端到端模型不应独自承担全部安全责任。训练中加入法规、碰撞、可行驶区域和舒适性损失；推理时由独立安全层检查速度、间距、交通规则和轨迹可达性，必要时覆盖模型输出。分布外检测可结合特征距离、模型集成和不确定性，触发降级或人工接管。可解释性通过输出关键对象、占用、候选轨迹及风险评分实现。验证必须覆盖闭环仿真、故障注入、长尾场景和形式化安全约束。

来源链接 无

题库

自动驾驶

数据闭环

世界模型

BEV

Occupancy

仿真

长尾场景

Q221 座舱多模态大模型如何融合语音、视觉、车辆状态和用户上下文，同时保证安全策略？

方向 自动驾驶 / 世界模型

岗位 自动驾驶算法 / 世界模型

难度 困难

来源 内部题库 2026-06-06

参考回答

座舱模型应把语音 ASR、摄像头视觉、车辆 CAN 状态、导航和用户历史按时间对齐，并通过模态专用编码器接入统一语言模型。用户请求先做意图与权限判断，再生成可执行车控计划；涉及驾驶安全的功能必须经过白名单、状态机和二次确认，禁止模型直接发送任意控制指令。隐私上要最小化采集、区分本地与云端处理并隔离用户记忆。评估既看交互成功率，也看误触发、越权、分心风险和不同噪声场景鲁棒性。

来源链接 无

题库

自动驾驶

数据闭环

世界模型

BEV

Occupancy

仿真

长尾场景

Q222 座舱多模态大模型如何融合语音、视觉、车控状态和用户上下文，并保证安全边界？

方向 自动驾驶 / 世界模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-06-05

参考回答

座舱模型应把语音 ASR、摄像头视觉、车辆 CAN 状态、导航和用户历史按时间对齐，并通过模态专用编码器接入统一语言模型。用户请求先做意图与权限判断，再生成可执行车控计划；涉及驾驶安全的功能必须经过白名单、状态机和二次确认，禁止模型直接发送任意控制指令。隐私上要最小化采集、区分本地与云端处理并隔离用户记忆。评估既看交互成功率，也看误触发、越权、分心风险和不同噪声场景鲁棒性。

来源链接 xiaohongshu.com/search_result/68b7ef74000000001b030950

小红书

蔚来

大模型

面经

Q223 短视频理解模型如何把封面、视频帧、OCR、ASR 和用户反馈构造成训练样本？

方向 视频理解

难度 中等

岗位 大模型相关岗位

来源 牛客 2026-07-07

参考回答

短视频样本要同时保留内容证据和行为反馈。封面提供静态主题，视频帧提供动作和场景变化，OCR 捕捉画面文字，ASR/字幕提供语音语义，用户点击、完播、点赞、评论和负反馈提供偏好监督。构造时先按镜头或时间窗口抽帧，并把 OCR/ASR 对齐到时间段；再生成视频级摘要、事件标签、实体标签和风险标签。用户行为不能直接当内容标签，因为受曝光位置和人群偏好影响，需要做去偏采样或作为排序目标而非纯语义目标。训练上可以先做内容理解预训练，再做多任务学习：分类、检索、问答、审核和推荐预估。评估要分内容准确性、时序理解、冷启动视频、长尾类目和线上指标，避免模型只学热门模板。

来源链接 nowcoder.com/feed/main/detail/b8573c3fe8e14f63aab2ff63c5359924

快手 短视频 视频理解 ASR OCR

Q224 长视频理解中如何用片段检索和层级摘要回答跨时间问题？

方向 视频理解 / 多模态大模型

难度 中等

岗位 视频理解算法工程师

来源 CSDN 2026-07-03

参考回答

长视频不能把所有帧一次性塞进模型，否则成本高、上下文长，而且容易被无关片段稀释。更稳的做法是分层处理：第一层把视频按镜头、时间窗口或事件边界切成片段，为每个片段生成短摘要、关键实体、动作和时间范围；第二层建立可检索索引，用户问题来了以后先召回相关片段；第三层对召回片段做高分辨率或更密集的时序推理；最后再把多个片段的证据合并成答案。跨时间问题的难点是顺序和状态变化，例如“他先做了什么，后来为什么失败”。这时摘要不能只写静态物体，还要记录主体、动作、对象、开始结束、状态变化和因果线索。工程上可以保留全局时间线，避免片段之间互相孤立；对高置信片段用细粒度模型复核，对低相关片段只保留摘要。评估时要看片段召回率、答案正确率、时间定位误差和跨片段一致性。

来源链接 gitcode.csdn.net/69f8558e54b52172bc71bf4c.html

快手 视频理解 长视频 片段检索 层级摘要

Q225 视频理解中均匀采样、关键帧采样、运动感知采样和自适应采样分别适合哪些场景？

方向 视频 / 视觉理解

岗位 视频理解 / 多模态算法

难度 困难

来源 内部题库 2026-06-06

参考回答

均匀采样覆盖全局时间轴，适合视频分类和整体摘要，但可能漏掉短暂事件；关键帧采样依据镜头切换、语义变化或显著性，适合事件定位和摘要；运动感知采样根据光流或帧差增加快速动作区域的采样密度；自适应采样由轻量模型根据问题和内容动态决定取帧，效果最好但增加系统复杂度。实际系统常先低成本均匀扫描，再对高变化或与问题相关的片段加密采样。

来源链接 无

题库

视频理解

长视频

Temporal Token

Video QA

事件边界

时序一致性

Q226 temporal token 压缩如何保留动作变化和事件顺序，和直接长上下文 attention 相比有什么取舍？

方向 视频 / 视觉理解

岗位 视频理解 / 多模态算法

难度 困难

来源 内部题库 2026-06-06

参考回答

Temporal token 压缩通过池化、聚类、token merging、事件边界聚合或可学习 query，把相邻帧的冗余表示合并。为保留动作变化，应对高运动、状态转折和关键对象交互降低压缩率，并加入时间位置编码和顺序监督。直接长上下文 attention 保留细节更完整，但计算与 KV Cache 随 token 数快速增长；压缩显著降低成本，却可能丢失短暂事件和精确顺序。常见方案是多尺度表示：低频全局 token 加高频关键片段 token。

来源链接 无

题库

视频理解

长视频

Temporal Token

Video QA

事件边界

时序一致性

Q227 视频问答如何评估动作理解、事件边界、因果关系、跨镜头一致性和细粒度属性识别？

方向 视频 / 视觉理解

岗位 视频理解 / 多模态算法

难度 困难

来源 内部题库 2026-06-06

参考回答

视频问答评估应按能力拆分。动作理解测试主体、动作和对象是否正确；事件边界用 temporal IoU、mAP 或边界误差衡量起止时间；因果关系需设计仅看单帧无法回答的前因后果题；跨镜头一致性检查同一实体、状态和事件在镜头切换后是否保持；细粒度属性再评估颜色、数量和局部动作。除自动准确率外，还需人工判断答案是否真正依赖视频证据，并用反事实或打乱帧顺序检测模型是否只靠语言先验。

来源链接 无

题库

视频理解

长视频

Temporal Token

Video QA

事件边界

时序一致性

Q228 长视频理解中如何处理记忆压缩、片段检索、滑窗推理和跨片段信息融合？

方向 视频 / 视觉理解

岗位 视频理解 / 多模态算法

难度 困难

来源 内部题库 2026-06-06

参考回答

长视频可采用“分段编码、索引检索、局部推理、全局融合”。先把视频切成语义片段并生成视觉 token、字幕和事件摘要；用向量索引根据问题检索候选片段；对候选片段做高分辨率滑窗推理；最后通过时间图、层次 Transformer 或外部记忆融合跨片段证据。记忆压缩保存实体状态和关键事件，避免重复编码；滑窗保留局部细节，但窗口重叠和跨窗实体对齐必须处理。

来源链接 无

题库

视频理解

长视频

Temporal Token

Video QA

事件边界

时序一致性

Q229 视频生成模型的时序一致性、身份保持、物理合理性和指令遵循分别如何设计评估？

方向 视频 / 视觉理解

岗位 视频理解 / 多模态算法

难度 困难

来源 内部题库 2026-06-06

参考回答

视频生成评估应覆盖四类指标。时序一致性看帧间结构、运动连续性和闪烁，可结合光流误差、temporal LPIPS 和人评；身份保持检查人物或物体跨帧特征一致性；物理合理性评估重力、碰撞、遮挡、物体恒常性和因果关系；指令遵循检查主体、动作、场景、镜头和时间顺序是否符合文本。FVD 等总体分数不能单独使用，应配合分项 benchmark、人工偏好和真实失败案例。

来源链接 无

题库

视频理解

长视频

Temporal Token

Video QA

事件边界

时序一致性

Q230 多模态视频数据清洗时，字幕、ASR、画面内容和问题答案之间如何做一致性校验？

方向 视频 / 视觉理解

岗位 视频理解 / 多模态算法

难度 困难

来源 内部题库 2026-06-06

参考回答

多模态视频清洗需先做时间对齐：字幕和 ASR 绑定到精确时间段，画面按镜头或事件切片。随后检查 ASR 置信度、字幕重复和语言一致性，并用视觉文本相似度验证语音描述是否对应画面。问答数据要确认答案能从指定时间段获得，排除只依赖常识、标题或泄漏字幕的样本。还应检测静态视频、黑屏、重复片段、音画错位和敏感内容，并通过抽样人审校准自动阈值。

来源链接 无

题库

视频理解

长视频

Temporal Token

Video QA

事件边界

时序一致性

Q231 视频 grounding 和图像 grounding 的主要差异是什么，时空定位指标应该怎么看？

方向 视频 / 视觉理解

岗位 视频理解 / 多模态算法

难度 困难

来源 内部题库 2026-06-06

参考回答

图像 grounding 只需在单帧定位区域，视频 grounding 还需确定时间范围并保持目标跨帧身份，因此同时包含空间框和时间片段。常见指标包括 temporal IoU、spatial IoU、时空 tube IoU、Recall@IoU、mAP，以及起止边界误差。对移动目标还应评估轨迹连续性和身份切换。数据集要覆盖短事件、长事件、遮挡、镜头切换和多个相似实例，防止模型只靠字幕或单帧线索。

来源链接 无

题库

视频理解

长视频

Temporal Token

Video QA

事件边界

时序一致性

Q232 在线视频理解服务如何控制帧抽取成本、encoder 复用、缓存和响应延迟？

方向 视频 / 视觉理解

岗位 视频理解 / 多模态算法

难度 困难

来源 内部题库 2026-06-06

参考回答

在线视频理解应将解码、取帧、视觉编码和语言推理解耦。先用低成本镜头切分或运动检测减少无效帧，再按问题自适应加密关键片段；相同视频的视觉特征按视频哈希和时间段缓存，避免重复跑 encoder；长视频采用分段批处理和异步预取。延迟监控要拆成视频下载、解码、encoder、检索和 LLM 阶段，并限制最大帧数、分辨率和上下文 token。热点视频可预计算特征，实时流则使用滑动增量编码。

来源链接 无

题库

视频理解

长视频

Temporal Token

Video QA

事件边界

时序一致性

Q233 视频模型如何建模动作、因果关系、事件边界和跨镜头一致性？

方向 音频大模型

岗位 语音音频大模型算法

难度 中等

来源 脉脉 2026-06-05

参考回答

视频问答评估应按能力拆分。动作理解测试主体、动作和对象是否正确；事件边界用 temporal IoU、mAP 或边界误差衡量起止时间；因果关系需设计仅看单帧无法回答的前因后果题；跨镜头一致性检查同一实体、状态和事件在镜头切换后是否保持；细粒度属性再评估颜色、数量和局部动作。除自动准确率外，还需人工判断答案是否真正依赖视频证据，并用反事实或打乱帧顺序检测模型是否只靠语言先验。

来源链接 maimai.cn/community/home/recommended

脉脉

语音大模型

音频理解

ASR

TTS

多模态

Q234 视频问答/视频生成如何评估时序一致性、物理合理性、身份保持和指令遵循？

方向 音频大模型

岗位 语音音频大模型算法

难度 中等

来源 脉脉 2026-06-05

参考回答

视频问答评估应按能力拆分。动作理解测试主体、动作和对象是否正确；事件边界用 temporal IoU、mAP 或边界误差衡量起止时间；因果关系需设计仅看单帧无法回答的前因后果题；跨镜头一致性检查同一实体、状态和事件在镜头切换后是否保持；细粒度属性再评估颜色、数量和局部动作。除自动准确率外，还需人工判断答案是否真正依赖视频证据，并用反事实或打乱帧顺序检测模型是否只靠语言先验。

来源链接 maimai.cn/community/home/recommended

脉脉

语音大模型

音频理解

ASR

TTS

多模态

Q235 视频理解里如何做长视频分段、层级表征和摘要，避免只看关键帧丢失动作过程？

方向 视频理解 / 多模态大模型

岗位 多模态算法工程师

难度 中等

来源 CSDN 2026-05-04

参考回答

长视频不能只抽几张关键帧后交给图文模型，因为动作、因果和状态变化都藏在帧间。工程上通常先做分段：可以按镜头切换、时间窗口或事件边界把视频切成 clip，每个 clip 保留连续帧或稀疏帧序列；再做层级表征：底层用视觉编码器或视频 Transformer 提取局部时序特征，中层聚合作片段和对象状态变化，高层再生成事件摘要或供 LLM 推理。为了避免丢动作过程，采样要覆盖开始、过程、结束三个阶段，不能只取最高置信关键帧；对快速动作可以提高局部帧率，对长静态片段可以降低采样。面试里可以强调三点：一是分段要服务任务，例如问答重视事件边界，推荐重视用户停留片段；二是摘要要保留主体、动作、对象、时间顺序和状态变化；三是评估不能只看文本相似度，还要用时序一致性、动作识别准确率、事件定位误差和人工核验检查模型是否真的理解了视频。

来源链接 gitcode.csdn.net/69f8558e54b52172bc71bf4c.html

快手

多模态大模型

视频理解

短视频推荐

VLM

数据构造

Q236 短视频推荐场景中如何把画面、字幕、音频和用户反馈统一构造成多模态训练样本？

方向 视频理解 / 多模态大模型

岗位 多模态算法工程师

难度 中等

来源 CSDN 2026-05-04

参考回答

短视频推荐的数据构造要把内容侧多模态信号和用户侧反馈对齐到同一个样本里。内容侧通常包括视频帧或 clip、封面、OCR 字幕、ASR 文本、背景音乐、声音事件、标题标签和作者信息；用户侧包括曝光、点击、完播、停留时长、点赞、收藏、评论、转发、不感兴趣等行为。构造样本时，先用统一的视频 id 和时间戳把多模态特征对齐，再把用户行为转成监督信号：点击和完播可以做排序目标，长停留和收藏更接近强兴趣，跳出或负反馈可以做负样本。难点在噪声和偏差：字幕可能错、ASR 可能漏，热门视频有曝光偏置，用户点击不一定代表满意。因此需要做去重、质量过滤、曝光校正、负采样和时间切分，避免训练集泄漏到未来。一个成熟回答还要提到多任务训练：用 CTR、完播率、互动率、内容理解辅助任务一起训练，让模型既学会语义对齐，也学会推荐目标。最后用离线 AUC/NDCG、线上 A/B、冷启动效果和长尾内容覆盖率综合评估。

来源链接 gitcode.csdn.net/69f8558e54b52172bc71bf4c.html

快手

多模态大模型

视频理解

短视频推荐

VLM

数据构造

Q237 视频理解模型如何区分“动作发生过”和“动作正在发生”，数据标注和模型结构上分别要注意什么？

方向 视频理解 / 多模态大模型

岗位 多模态算法工程师

难度 中等

来源 CSDN 2026-05-04

参考回答

这需要显式建模时间边界和状态。数据标注上不能只给视频级标签，而要标出动作开始、持续、结束以及动作后的状态，例如“拿起杯子”发生过后杯子位置会变化，“正在拿起”则处于运动过程。模型结构上要保留帧序和局部运动特征，可以用 clip-level encoder、temporal attention、光流或轨迹特征，并在输出中区分事件检测、动作分类和状态判断。训练时可以加入正负时间片段：动作前、动作中、动作后都要有样本，避免模型只靠物体共现判断。评估上看 temporal IoU、边界误差和状态问答准确率。面试中要强调，视频理解的关键不是“看见物体”，而是理解状态随时间如何变化。

来源链接 gitcode.csdn.net/69f8558e54b52172bc71bf4c.html

快手

多模态大模型

视频理解

短视频推荐

VLM

数据构造

Q238 多模态大模型中的模态对齐到底在对齐什么，图文对比学习、指令微调 and 偏好对齐各自解决哪类问题？

方向 强化学习 / 对齐训练

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-08-02

参考回答

模态对齐不是只让图片和文字向量相似，而是让视觉证据、语言语义和任务输出在同一个推理链路里可互相约束。图文对比学习主要做粗粒度语义对齐，让图片表示接近对应文本，适合检索和初始化，但不保证能按指令回答。图文 caption 或 image-text 生成让模型学会把视觉内容转成语言描述，但容易学成描述器。多模态指令微调让模型理解用户问题，覆盖 VQA、OCR、grounding、多图比较和视觉推理，是从“看懂”到“会答”的关键。偏好对齐进一步修正回答风格、安全性、拒答和幻觉，解决“答得是否可靠、是否符合人类偏好”。工程上要分阶段评估：对比学习看检索/分类，指令微调看任务准确率，偏好对齐看幻觉率、安全率和人工胜率，不能只用一个总分判断模态对齐好坏。

来源链接 blog.csdn.net/qq_54708219/article/details/154648350

CSDN

字节

大模型

多模态

面试

多模态对齐

VLM

指令微调

Q239 多模态大模型的模态对齐为什么不能只靠图文对比学习，指令微调阶段还需要对齐什么？

方向 强化学习 / 对齐训练

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-01

参考回答

图文对比学习主要把整图和整句拉到同一语义空间，适合检索和粗粒度语义对齐，但它不能保证模型会按指令回答、能定位局部区域、能处理多轮上下文，也不能解决视觉幻觉。指令微调阶段要进一步对齐三类东西：第一是任务格式对齐，让模型知道问答、OCR、grounding、图表理解、视频问答等任务分别怎么输出；第二是粒度对齐，让局部对象、属性、数量、空间关系和文字区域能对应到语言描述；第三是行为对齐，让模型在看不清、证据不足或输入冲突时能表达不确定性，而不是编造。工程上通常混合 caption、VQA、OCR、region-level grounding、多图比较和拒答样本，并用负样本降低幻觉。面试里可以总结为：对比学习解决“看见什么大概像什么”，指令微调解决“按任务要求可靠地说什么”。

来源链接 blog.csdn.net/qq_54708219/article/details/154648350

CSDN

字节

大模型

多模态

面试

Q240 VLM 出现视觉幻觉时，应该从数据、模型结构和解码三个层面分别怎么排查？

方向 强化学习 / 对齐训练

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-01

参考回答

数据层先查图文是否错配、caption 是否过度泛化、OCR/框标注是否错误、训练集中是否存在强语言先验。例如大量“厨房里有微波炉”的样本会让模型在没有微波炉时也猜出来。模型结构层检查视觉 token 是否被过度压缩，projector 是否丢了局部细节，LLM 是否过度依赖文本 prompt；对于高分辨率、计数和空间关系任务，可能需要 tile、region token 或 grounding 分支。解码层检查 temperature、top_p、重复惩罚和系统提示，过高随机性会放大幻觉；同时可以加入 evidence-first prompt，让模型先列视觉证据再回答。评估时不能只看总准确率，要拆 OCR、计数、属性、空间关系、拒答和反事实样本。一个好的回答应说明幻觉不是单点问题，而是数据先验、视觉瓶颈和语言生成倾向共同造成的。

来源链接 blog.csdn.net/qq_54708219/article/details/154648350

CSDN

字节

大模型

多模态

面试

Q241 多模态大模型为什么需要模态对齐，图像文本对齐通常如何训练和评估？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-06-20

参考回答

模态对齐的目标是让图像、视频和文本在语义空间里能互相解释。没有对齐时，语言模型即使很强，也不知道某个视觉 token 对应的是物体、位置、文字还是动作，容易出现看图说话不准、OCR 错误和视觉幻觉。训练上常见做法包括图文对比学习、图文匹配、caption 生成、区域级 grounding、多图问答和指令微调。对齐粒度也很重要：全局图文对齐适合检索和分类，区域级对齐适合定位和细节问答，时序对齐适合视频理解。评估时不能只看一个综合 benchmark，要拆成检索召回、VQA 准确率、OCR 准确率、定位 IoU、幻觉率、多轮一致性和长尾场景表现。面试回答最好补一句：对齐不是一次性预训练结束，线上 badcase、业务数据和人工偏好会持续修正模型对视觉证据的使用方式。

来源链接 blog.csdn.net/qq_54708219/article/details/154648350

CSDN

字节

大模型

多模态

面试

Q242 RLHF、DPO、GRPO、PPO 的优化目标、训练数据和稳定性问题分别是什么？

方向 强化学习 / 对齐训练

岗位 大模型相关岗位

难度 困难

来源 牛客 2026-06-14

参考回答

PPO 和 GRPO 属于在线策略优化：PPO 用 value model/GAE 估计优势并限制更新幅度，灵活但模型多、显存高；GRPO 用同一 prompt 的组内相对奖励构造优势，可省去 value model，适合可验证推理。DPO 直接用 chosen/rejected 偏好对优化策略与参考模型的相对概率，训练简单稳定，但依赖离线偏好数据覆盖。RLHF 是更宽泛流程，通常包含 SFT、奖励模型和策略优化。共同风险包括 reward hacking、长度偏置、KL 失控和分布外泛化差。

来源链接 nowcoder.com/feed/main/detail/d9b2ff6d748c4827aba3a0227a733d0f

牛客

大模型

Q243 Reward model 如何构造偏好数据，如何处理 reward hacking、长度偏置和分布外回答？

方向 强化学习 / 对齐训练

岗位 大模型相关岗位

难度 困难

来源 牛客 2026-06-14

参考回答

奖励模型通常用同一 prompt 下的回答对训练，使 preferred 回答得分高于 rejected 回答。数据应覆盖正确性、帮助性、安全性、格式和不同长度，并保留标注分歧。为降低长度偏置，可做长度配对、分桶采样和残差校准；为防 reward hacking，要加入对抗样本、规则审计和独立测试集；分布外回答可通过不确定性估计、拒绝评分和周期性在线人审处理。奖励模型不能只看训练准确率，还要验证与真实任务通过率和人工偏好的一致性。

来源链接 nowcoder.com/feed/main/detail/d9b2ff6d748c4827aba3a0227a733d0f

牛客

大模型

Q244 对齐训练如何评估 helpfulness、harmlessness、truthfulness 和复杂任务通过率？

方向 强化学习 / 对齐训练

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-06-05

参考回答

对齐评估应拆成帮助性、安全性、真实性和任务能力。Helpfulness 看指令完成度、相关性和可执行性；harmlessness 用红队集测试违法、伤害、隐私和越权请求；truthfulness 检查事实准确、引用可靠和不确定性表达；复杂任务通过率则用代码测试、数学验证器、工具调用成功率和多步任务完成率。还需监控过度拒答、回答长度偏置、能力回退和不同语言/群体上的公平性。

来源链接 zhihu.com/search

知乎

字节

大模型

面经

Q245 大模型训练数据版本迭代时，如何记录样本来源、过滤规则和评测回归，避免新数据引入能力退化？

方向 训练框架

岗位 大模型训练工程师

难度 中等

来源 CSDN 2026-07-11

参考回答

训练数据迭代必须像代码一样做版本治理。首先要给每批样本记录来源、采集时间、授权状态、清洗规则、去重阈值、质量分、领域标签和过滤原因，保证后续能追溯“这条数据为什么进入训练集”。其次，每次数据变更都要生成数据 diff，例如新增了哪些领域、删除了哪些低质样本、重复率和长度分布如何变化，避免只看总量。训练前要跑小规模试训或 replay，观察 loss、梯度、困惑度和关键能力集表现；训练后要做回归评测，覆盖通用能力、目标领域、安全、事实性、代码/数学、多模态或业务 hard case。若新数据带来能力退化，要能回滚到上一个数据版本，并通过分桶评测定位是某个来源、某类模板化样本还是过滤规则出了问题。工程上还应把数据版本、模型 checkpoint、训练配置和评测报告绑定，形成可审计链路。

来源链接 blog.csdn.net/zhangzhentiyes/article/details/145885529

训练数据

数据治理

回归评测

质量过滤

训练框架

Q246 大模型面试复习时，为什么要把训练、推理、数据和评测拆成四条线，而不是只背模型结构？

方向 训练框架

岗位 大模型相关岗位

难度 中等

来源 B站 2026-07-07

参考回答

真实大模型岗位不只考 Transformer 结构，而是考能否把模型做出来、训稳定、部署稳、评估准。训练线关注数据配比、优化器、学习率、混合精度、并行和稳定性；推理线关注 KV cache、batch 调度、量化、吞吐、延迟和服务降级；数据线关注清洗、去重、质量分层、指令构造和安全过滤；评测线关注离线 benchmark、业务指标、误差分析和回归测试。只背模型结构容易答成概念罗列，遇到“线上延迟高怎么办”“loss spike 怎么查”“数据污染怎么防”就会断。结构化复习可以把每个问题落到瓶颈、指标、排查路径和工程取舍上，更接近面试官真实关注点。

来源链接 bilibili.com/video/BV1kaDsBNEk/

华为

训练

推理

评测

大模型面试

Q247 FlashAttention 的主要收益为什么来自减少显存读写，而不是改变 attention 的数学结果？

方向 训练框架

岗位 大模型相关岗位

难度 中等

来源 B站 2026-07-07

参考回答

标准 attention 会显式构造 $n \times n$ 注意力矩阵，虽然数学上简单，但会产生大量 HBM 读写和峰值显存。FlashAttention 的核心是 IO-aware：把 Q、K、V 分块放入 SRAM，边计算边做在线 softmax，不把完整注意力矩阵写回显存，因此减少显存访问和中间激活。它计算的仍然是精确 attention，不是稀疏近似，也不是改变 softmax 公式。收益在长序列和大 batch 下尤其明显，因为注意力矩阵规模随序列长度平方增长。FlashAttention v2/v3 进一步优化了并行划分、warp 级调度和硬件利用率。面试里要强调它降低显存和提升吞吐，但不能无限解决长上下文，因为 KV cache、prefill 成本和位置外推仍然存在。

来源链接 bilibili.com/video/BV11AbhzXE9h/

FlashAttention

Transformer

训练优化

长上下文

显存

Q248 多模态业务微调时，LoRA、视觉侧微调和全参微调应该如何选择？

方向 训练框架

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

选择微调方式要看业务数据规模、领域差异和需要改变的能力位置。LoRA 适合数据中等、目标是语言风格或任务格式适配的场景，成本低、可维护多个 adapter，但容量有限。视觉侧微调适合图像分布和预训练差异较大，例如短视频、电商图、工业缺陷、医学或遥感；只调 LLM 可能无法修正视觉特征不足。全参微调容量最大，适合领域差异很大、数据足够且要重塑模型能力的场景，但显存、训练稳定性和通用能力退化风险最高。多模态项目常见做法是先冻结视觉 encoder 训练 projector/LoRA，确认收益后再小学习率解冻部分视觉层或 LLM 高层。评估必须包含通用能力回归和目标业务 hard case。

来源链接 blog.csdn.net/trb701012/article/details/152117850

快手

LoRA

全参微调

多模态

训练成本

Q249 显存不够训练大模型时，ZeRO、张量并行、流水并行和数据并行应该如何组合？

方向 训练框架

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

选择并行策略要看瓶颈来自整模型状态、单层矩阵、模型深度还是 batch 吞吐。数据并行复制完整模型，只切 batch，简单但每卡仍保存完整参数和优化器状态。ZeRO/FSDP 进一步切分优化器状态、梯度和参数，适合解决全局状态显存过大。张量并行切单层大矩阵，适合单层参数或激活太大放不下，但需要高带宽通信。流水并行按层切模型，适合模型很深，代价是 pipeline bubble，需要 micro-batch 填充。实际训练常用数据并行 + ZeRO/FSDP 做基础，再对超大模型叠加张量并行和流水并行。调参时要同时看显存余量、通信占比、GPU 利用率、bubble 比例和全局 batch 是否影响收敛。

来源链接 blog.csdn.net/zhangzhentiyues/article/details/145909490

分布式训练

ZeRO

张量并行

流水并行

数据并行

Q250 大模型训练中出现 loss spike 时，如何区分数据异常、数值不稳定和并行通信问题？

方向 训练框架

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

定位 loss spike 要先保留触发 step 的 batch、随机种子、学习率、梯度范数、loss scale、激活统计和通信日志。数据异常通常表现为特定样本或数据源重复触发，可能有乱码、超长文本、错误标签、异常图像或污染样本；复现同一 batch 可以验证。数值不稳定常伴随梯度范数暴涨、NaN/Inf、loss scale 频繁下降，和学习率过高、FP16 溢出、归一化异常或初始化有关；可用 BF16、梯度裁剪、warmup、降低 LR 排查。并行通信问题可能表现为某些 rank loss 不一致、梯度同步异常、hang 或参数漂移，需要检查 all-reduce、ZeRO/FSDP 状态、数据切分和 checkpoint 恢复。稳妥流程是先单卡/小并行复现，再扩大到原并行配置，逐层排除。

来源链接 blog.csdn.net/zhangzhentiyues/article/details/145885374

训练稳定性

loss spike

混合精度

数据异常

梯度

Q251 DeepSpeed、LoRA 和 RLHF 分别解决训练流程中的什么问题，为什么不能放在同一层面比较？

方向 训练框架

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-07

参考回答

DeepSpeed 是训练系统层工具，主要解决大模型训练的显存、并行和吞吐问题，例如 ZeRO 切分优化器状态、梯度和参数，配合数据并行、流水并行和 offload。LoRA 是参数高效微调方法，解决下游适配成本高的问题，通过训练低秩增量矩阵减少显存和存储，同时便于多任务维护 adapter。RLHF 是对齐训练流程，解决模型输出是否符合人类偏好、安全和任务目标的问题，通常包含偏好数据、奖励模型和策略优化。三者不在同一层面：DeepSpeed 管“怎么训得动”，LoRA 管“用多少参数适配”，RLHF 管“优化什么行为”。实际项目可以组合使用，例如用 DeepSpeed/FSDP 训练基座，用 LoRA 做业务微调，再用 DPO/GRPO/RLHF 做偏好对齐。

来源链接 blog.csdn.net/libaiup/article/details/152087779

字节

DeepSpeed

LoRA

RLHF

训练框架

Q252 World Model 类 VLA 相比直接策略 VLA，多了哪些建模目标和系统收益？

方向 世界模型

岗位 世界模型 / 具身智能算法岗位

难度 困难

来源 知乎 2026-08-24

参考回答

直接策略 VLA 主要从观察和语言直接输出动作，优化目标更接近 imitation 或 policy learning。World Model 类 VLA 额外建模环境状态和未来演化，例如预测下一帧、未来 latent、对象运动、接触变化或可达状态，再把这种预测用于规划或动作生成。收益是可解释性更强，能在执行前评估候选动作后果，也更容易做仿真、反事实和失败恢复；风险是世界模型预测误差会累积，且视觉上合理的未来不一定对应物理可执行动作。面试要讲清它适合长程任务、交互规划和数据增强，但需要闭环控制校验。

来源链接 zhuanlan.zhihu.com/p/2049207405238563542

世界模型

VLA

视频预测

机器人控制

Planning

Q253 如果用视频预测作为机器人控制的中间表征，如何避免预测好看但控制不可用？

方向 世界模型

岗位 世界模型 / 具身智能算法岗位

难度 困难

来源 知乎 2026-08-24

参考回答

首先预测目标不能只追求像素好看，应加入与控制相关的状态，例如物体位姿、接触状态、可抓取区域、轨迹可达性和安全约束。其次要把预测模型放进闭环评估：给定候选动作，预测未来，再由 cost 或 value 判断是否可执行，而不是只看 FVD/PSNR。第三，训练数据要包含动作条件和失败样本，否则模型只能学被动视频外观。第四，控制接口要验证 sim-to-real 和延迟，避免预测频率低于控制需求。评估上应同时看视觉预测指标、任务成功率、碰撞率、恢复次数和真实机器人执行效果。

来源链接 zhuanlan.zhihu.com/p/2049207405238563542

世界模型

VLA

视频预测

机器人控制

Planning

Q254 自动驾驶世界模型如何让 occupancy、轨迹预测和规划动作形成可闭环评估的统一表示？

方向 世界模型 / 自动驾驶

岗位 自动驾驶世界模型算法工程师

难度 困难

来源 CSDN 2026-07-14

参考回答

世界模型如果只分别预测 occupancy 或他车轨迹，很容易变成离线感知模型；要服务规划，必须把自车动作、环境状态和未来演化统一起来。一个常见设计是在 BEV 或 latent space 中表示静态地图、动态障碍、可行驶区域和交通规则，再让模型条件化自车候选动作，预测未来 occupancy、参与者轨迹和风险代价。这样规划器可以比较不同动作造成的环境演化，而不是只看单一路径预测。关键训练信号包括真实日志的未来状态、交互场景、规则违反、碰撞/near miss 和人类接管片段。评估也要闭环：同一个世界模型接到规划器里，观察碰撞率、舒适性、通行效率、接管率和长尾场景通过率，而不是只看 ADE、FDE 或 IoU。工程风险是模型可能学到相关性而非因果，例如默认他车总会让行；所以需要反事实数据、仿真扰动和不确定性输出，让规划器知道哪些预测不可靠。

来源链接 so.csdn.net/so/search

世界模型

自动驾驶

BEV

occupancy

闭环规划

Q255 机器人世界模型训练中，仿真数据、合成视频和真实遥操作数据应该如何配比和校准？

方向 世界模型 / 具身智能

岗位 机器人世界模型算法工程师

难度 困难

来源 GitHub 2026-07-13

参考回答

这题的核心是数据源各自解决不同问题。真实遥操作数据提供真实传感器噪声、机器人动力学、接触细节和人类策略，是模型可信落地的基准；仿真数据提供可控场景、稀有失败样本和安全边界探索；合成视频可以扩展外观、物体和场景多样性，但不一定满足真实动力学。配比不能固定拍脑袋，通常先用大规模仿真/合成数据做预训练，再用真实遥操作数据做对齐和微调，最后用真实失败样本回流修正。校准上要做视觉域随机化、相机噪声建模、动力学参数随机化、接触模型校准和真实小样本验证。数据筛选时要看任务相关性，不是合成数据越多越好；如果合成视频缺少动作-状态因果，可能提升视觉表征但伤害控制。评估应分离视觉泛化、动力学预测、动作成功率和 sim-to-real gap，并用真实机器人闭环测试做最终判断。

来源链接 github.com/search

NVIDIA

世界模型

仿真

合成数据

Sim-to-Real

Q256 MoE 中专家路由如何做负载均衡和专家容量控制，为什么会出现专家塌缩？

方向 MoE / GRPO / 大模型训练

岗位 大模型算法岗

难度 困难

来源 小红书 2026-06-23

参考回答

MoE 的核心是用 router/gate 为每个 token 选择少量专家计算，从而用较低计算量扩展参数规模。负载均衡要解决的是“所有 token 都挤到少数专家”的问题，常见做法包括 top-k 路由、router auxiliary loss、专家容量因子 capacity factor、token dropping 或 rerouting、router z-loss、噪声路由和分组路由。容量控制本质是在吞吐、显存和质量之间取舍：容量太小会丢 token 或把 token 分给次优专家，质量下降；容量太大会增加 padding、通信和显存浪费。专家塌缩通常来自三类原因：第一，router 初期偏置导致马太效应，热门专家越训练越强；第二，训练数据分布不均，让某些专家长期收到更容易优化的样本；第三，辅助损失权重、学习率或 top-k 设置不合理，使路由器只追求主损失而忽略均衡。面试回答时要强调 MoE 不只是模型结构问题，也是分布式系统问题，因为跨卡专家并行会引入 all-to-all 通信，负载不均会直接拖慢训练吞吐。

来源链接 xiaohongshu.com/explore/6a0033fc000000003601d12a

小红书

美团

大模型

面经

MoE

GRPO

大模型训练

强化学习

Q257 GRPO 相比 PPO 为什么可以省去价值模型，适合哪些大模型推理训练场景？

方向 MoE / GRPO / 大模型训练

岗位 大模型算法岗

难度 困难

来源 小红书 2026-06-23

参考回答

PPO 通常需要 policy model、reference model、reward model 和 value model。value model 用来估计状态价值，帮助计算 advantage，但这会带来额外显存、训练不稳定和价值估计误差。GRPO 的思路是对同一个 prompt 采样一组回答，用组内 reward 的相对均值或标准差来构造 advantage，因此不再单独训练 value model。它的优势是工程更轻、显存压力更小，尤其适合数学推理、代码生成、复杂问答这类“同一问题可以采样多条候选并做相对比较”的场景。局限也要说清楚：GRPO 依赖 reward 质量和组采样多样性，如果 reward 稀疏、候选高度相似或规则奖励有漏洞，模型仍可能 reward hacking；同时它更适合可验证或可比较的推理任务，不一定适合开放式创作和主观偏好很强的场景。回答这题最好把 PPO 的 value baseline 和 GRPO 的 group-relative baseline 对比清楚，再落到显存、稳定性、采样成本和适用任务上。

来源链接 xiaohongshu.com/explore/6a0033fc000000003601d12a

小红书

美团

大模型

面经

MoE

GRPO

大模型训练

强化学习

Q258 VLA 如何把语言中的对象、部位和空间关系 grounding 到 3D 场景，并生成可执行动作？

方向 VLA / 具身智能

岗位 具身基础模型算法工程师

难度 困难

来源 GitHub 2026-07-14

参考回答

语言 grounding 到 3D 场景要分三步：先把语言里的对象、属性、部位和空间关系解析出来，例如“把左边桌上的红杯子放到水槽旁”；再把这些概念和视觉/点云中的实例、位姿、可操作部位对齐；最后把目标状态转成可执行的抓取、移动和放置动作。2D VLM 只能看到图像平面，容易在遮挡、深度和可达性上出错，所以具身系统通常需要深度、点云、相机外参和机器人本体状态。affordance 很关键：不是识别出杯子就能抓，还要知道哪里可抓、是否被遮挡、当前夹爪是否能到达。动作生成前要做碰撞检测、逆运动学和轨迹约束，必要时让 VLA 输出中间表征，如目标物体、目标位姿、抓取点和约束条件，而不是直接输出关节角。评估要覆盖语言定位准确率、3D 位姿误差、抓取成功率、空间关系满足率和遮挡场景泛化。

来源链接 github.com/search

- 智元机器人
- VLA
- 3D Grounding
- Affordance
- 具身智能

Q259 多机器人、多任务数据训练 VLA 时，如何统一动作空间并避免模型只记住机器人平台差异？

方向 VLA / 机器人基础模型

岗位 机器人基础模型算法工程师

难度 困难

来源 GitHub 2026-07-13

参考回答

多机器人数据的难点是动作空间、相机视角、末端执行器和动力学都不同。如果直接混训，模型可能学到平台 ID，而不是任务策略。统一动作空间有几种做法：用末端笛卡尔位姿增量表示动作，弱化不同关节结构；用离散 action token 表示高层动作意图；或者保留机器人本体状态和平台 embedding，让模型知道当前可执行能力。数据组织上要把任务语言、视觉观测、本体状态、动作和成功标记对齐，并保证不同平台上有足够相似任务，方便模型学习共享策略。训练时可以先学通用视觉语言表征，再做机器人动作微调；也可以用 action normalization 和 robot-aware adapter 缓解平台差异。评估必须做跨平台和跨物体测试，例如训练见过 A 机械臂开抽屉，测试 B 机械臂开相似抽屉。关键风险是负迁移：某个平台的动作尺度或控制延迟会污染其他平台，所以要做分平台指标和失败案例分析。

来源链接 github.com/search

- Google
- VLA
- 机器人基础模型
- 多任务数据
- 泛化

Q260 灵巧手抓取透明、柔软或易滑物体时，如何融合视觉和触觉判断接触状态？

方向 具身智能 / 灵巧操作

岗位 机器人感知与控制算法工程师

难度 困难

来源 牛客 2026-07-15

参考回答

透明、柔软和易滑物体会让单纯视觉很不可靠：透明物体边界弱，柔软物体形变大，易滑物体抓住后也可能缓慢滑移。因此接触状态估计要融合视觉、触觉、力矩、电流和末端位姿。视觉负责提供初始物体位置、形状和候选抓取点；触觉或力觉负责判断是否接触、接触面积是否足够、压力分布是否均匀；关节电流和末端位姿变化可以辅助判断夹爪是否空抓或物体是否移动。模型上可以做多模态时序分类，输出未接触、稳定接触、滑移、挤压过大、抓取失败等状态。控制上发现滑移时可以增大法向力、调整手指姿态或重新抓取；发现过度挤压时要减小夹持力，避免损坏物体。数据采集要覆盖不同材质、光照、速度和抓取角度，并标注接触事件和失败原因。评估指标除了抓取成功率，还要看滑移检测延迟、误报率、物体损伤率和跨材质泛化。

来源链接 nowcoder.com/search

优必选

灵巧手

触觉

抓取

具身智能

Q261 机器人导航中，ROS 时间戳如何对齐，相机/激光雷达/里程计不同步会带来什么问题？

方向 机器人导航 / 具身智能

岗位 机器人导航算法工程师

难度 困难

来源 牛客 2026-07-24

参考回答

ROS 时间戳对齐是多传感器融合的基础。相机、激光雷达、IMU、轮速计和里程计如果时间不同步，同一个物体会被投影到错误位置，导致建图重影、定位漂移、障碍物位置错误和控制滞后。软件上可以用 `message_filters` 做 `approximate time` 或 `exact time` 同步，用 `tf2` 根据时间戳查询对应坐标变换；硬件上更可靠的是 PTP、触发线或统一时钟源。对于运动机器人，还要做时间补偿：激光雷达一帧扫描期间机器人在移动，需要 `deskew`；相机曝光和 IMU 高频数据也要插值对齐。工程排查时看各 topic 的 `header.stamp`、系统时间、延迟分布、`tf buffer` 是否过期，以及外参是否和时间同步一起校准。评估指标包括重投影误差、点云地图重影程度、定位漂移、路径跟踪误差和动态障碍误检率。面试里要强调：空间外参和时间同步必须一起看，只校外参不校时间会留下隐性误差。

来源链接 nowcoder.com/enterprise/679/interview

优必选

ROS

导航

时间同步

路径规划

Q262 A*、DWA、TEB 和 MPC 在机器人导航中分别解决什么问题，如何组合使用？

方向 机器人导航 / 运动规划

岗位 机器人导航算法工程师

难度 困难

来源 牛客 2026-07-24

参考回答

A* 通常用于全局路径规划，在栅格地图上搜索从起点到终点的可行路径，优点是可解释、稳定，缺点是只考虑地图代价，不直接处理机器人动力学。DWA 是局部规划方法，在速度空间采样，选择短时间内不碰撞且更接近目标的速度命令，实时性好，但容易受局部极小值影响。TEB 把轨迹表示成带时间间隔的弹性带，同时优化路径形状、时间、障碍距离和运动学约束，适合差速/全向底盘局部避障。MPC 则显式考虑动力学模型和约束，在预测窗口里优化控制序列，适合高速、强约束或需要平滑控制的场景，但计算成本和建模要求更高。实际系统常用 A* 做全局路径，DWA/TEB/MPC 做局部规划和避障，再由底层控制器跟踪速度或轨迹。评估看路径长度、到达率、碰撞率、重规划频率、控制平滑度和动态障碍场景表现。

来源链接 nowcoder.com/enterprise/679/interview

A*

DWA

TEB

MPC

机器人导航

Q263 人形机器人同时做行走和上肢操作时，如何处理重心、接触约束和任务优先级？

方向 具身智能 / 人形机器人

岗位 人形机器人算法工程师

难度 困难

来源 牛客 2026-07-15

参考回答

这题考的是全身控制思路。人形机器人行走时需要保持动态平衡，上肢操作又会改变质心和角动量，因此不能把腿部步态和手臂轨迹完全独立规划。通常会建立全身动力学模型，把足底接触、摩擦锥、关节限位、质心位置和零力矩点等约束统一考虑。任务优先级上，安全和平衡最高，其次是足端接触稳定，再是手部操作精度和姿态舒适性。如果上肢抓取导致身体前倾，控制器需要通过腰部、腿部和足底力矩补偿；如果目标不可达，高层应重新规划站位，而不是强行伸手。工程实现可以用 MPC 规划质心和接触序列，用 QP/WBC 求解关节力矩或速度，再用视觉/力觉反馈修正。评估指标包括跌倒率、足底滑移、质心偏移、抓取成功率、接触力峰值、能耗和扰动恢复时间。回答要强调：具身任务不是单一轨迹跟踪，而是在多约束下做任务优先级优化。

来源链接 nowcoder.com/search

傅利叶智能

人形机器人

全身控制

步态

具身智能

Q264 机械臂连续控制任务中，为什么很多抓取项目会选择 SAC，而不是 DDPG 或 PPO？

方向 机器人控制 / 强化学习

岗位 机器人强化学习算法工程师

难度 困难

来源 牛客 2026-07-24

参考回答

SAC 适合机械臂连续控制，主要因为它是 off-policy 最大熵强化学习，样本效率高且探索更充分。机械臂抓取的动作空间通常是连续的末端位姿、关节速度或力控制，确定性策略如 DDPG 容易探索不足、对超参和噪声敏感，训练时容易陷入局部最优。PPO 稳定但 on-policy 样本效率低，在真实机器人或高保真仿真中采样成本高。SAC 通过最大化奖励和策略熵，让策略在高回报动作附近保持一定随机性，有利于发现不同抓取姿态和绕障路径。工程上 SAC 常用于仿真训练或离线数据增强，真机部署前要加动作平滑、碰撞约束和安全边界。回答时还要讲限制：SAC 需要合理奖励函数，稀疏奖励下仍然困难；仿真训练策略迁移到真机需要域随机化和真实数据校准。指标包括成功率、样本效率、训练稳定性、动作平滑度、碰撞率和 sim-to-real gap。

来源链接 nowcoder.com/discuss/866386013608763392

SAC

PPO

DDPG

机械臂抓取

强化学习

Q265 机器人执行失败后，如何把失败原因诊断、恢复策略选择和数据回流做成闭环？

方向 VLA / 机器人数据闭环

岗位 具身智能算法工程师

难度 困难

来源 知乎 2026-07-13

参考回答

机器人失败不能只记录“失败”，要拆成可学习的原因。常见失败包括感知定位错误、抓取点不可达、夹爪打滑、碰撞风险、动作超时、目标状态变化和语言理解错误。系统上可以在每个子目标后做状态校验：目标是否出现、位姿是否正确、接触力是否稳定、动作是否越界。如果失败，先做诊断分类，再选择恢复策略：重新感知、换抓取点、调整力控、退回安全位姿、重新规划路径或人工接管。数据回流要保存失败前后的多模态观测、动作、控制信号、诊断标签和人工修正轨迹，形成 hard negative 和纠错样本。训练时可以用这些样本做失败预测、策略修正和偏好学习，让模型学会什么时候不该继续执行。评估指标包括失败诊断准确率、自动恢复成功率、二次失败率、人工接管率和回流样本带来的成功率提升。面试回答要强调闭环：发现失败、解释失败、恢复失败、学习失败。

来源链接 [zhihu.com/search](https://www.zhihu.com/search)

具身智能

VLA

失败恢复

数据闭环

主动学习

Q266 移动机器人在动态环境中执行视觉导航时，如何处理定位漂移、动态障碍和控制延迟？

方向 具身智能 / 机器人控制

岗位 机器人算法工程师

难度 困难

来源 牛客 2026-07-14

参考回答

动态环境视觉导航要把定位、感知、规划和控制放在闭环里看。定位漂移通常来自纹理不足、光照变化、快速运动和动态物体干扰，需要用视觉里程计、IMU、轮速/腿部里程计和回环检测融合，必要时剔除动态特征点。动态障碍不能只在静态地图里规划，要做实时检测、轨迹预测和局部避障；对行人、车辆、宠物这类非静态目标，需要估计速度和意图。控制延迟会让规划轨迹和真实状态错位，因此要做时间戳同步、状态预测和控制补偿，例如用当前速度外推机器人位姿，再把轨迹下发给低层控制。工程上常用全局规划保证可达性，局部规划或 MPC 保证实时避障和动力学约束。评估时不能只看路径长度，要看定位误差、碰撞率、急停次数、重规划频率、目标到达率、平均速度和在人群中的舒适性。核心答案是：先让状态估计可信，再让规划考虑动态，再让控制补偿延迟。

来源链接 nowcoder.com/search

宇树科技

机器人控制

视觉定位

闭环控制

具身智能

Q267 模仿学习和强化学习在具身任务中各有什么优劣，实际系统里如何组合使用？

方向 具身智能 / 强化学习

岗位 具身智能强化学习算法工程师

难度 困难

来源 CSDN 2026-07-23

参考回答

模仿学习把专家轨迹当监督信号，优点是样本效率高、训练稳定、适合真实机器人数据昂贵的场景；缺点是容易协变量偏移，测试时一旦偏离专家分布，误差会逐步累积，而且上限受专家策略限制。强化学习通过试错最大化奖励，优点是能优化长期回报和发现更优策略，适合底层控制、恢复策略和仿真中可大量采样的任务；缺点是奖励设计难、探索成本高、真机安全风险大。实际系统通常先用遥操作数据做行为克隆或 diffusion policy 预训练，让策略获得基本能力；再在仿真或安全约束环境中用 RL 微调，提高鲁棒性和恢复能力；最后用真机失败样本做离线 RL、偏好学习或小步在线更新。关键是不要在真实机器人上无约束探索，要加入安全过滤器、动作边界、碰撞检测和人工接管。评估要看成功率、恢复率、探索成本、硬件损伤风险和长尾场景表现。

来源链接 blog.csdn.net/ZHHHHH15/article/details/160808758

模仿学习

强化学习

离线RL

安全探索

具身智能

Q268 如何解决 Sim-to-Real 鸿沟，视觉随机化、动力学随机化、系统辨识和真实数据微调分别解决什么问题？

方向 具身智能 / Sim-to-Real

岗位 具身智能算法工程师

难度 困难

来源 CSDN 2026-07-23

参考回答

Sim-to-Real 的本质是仿真分布和真实世界分布不一致，差异来自视觉外观、传感器噪声、摩擦、质量、接触、延迟和控制器响应。视觉随机化解决的是外观域偏移，比如纹理、光照、背景、相机视角和噪声，让模型不要过拟合仿真画面。动力学随机化解决物理参数不准的问题，比如摩擦系数、质量、阻尼、关节延迟和接触弹性，让策略对真实硬件误差更鲁棒。系统辨识是反过来测真实机器人和环境参数，再把仿真调得更像真实世界。真实数据微调负责最后一公里，把真实遥操作、真机失败和人工接管样本回流到模型。工程上常见流程是仿真大规模预训练、真实少量对齐、真机闭环评估、失败样本回流。指标要看仿真成功率、真机成功率、gap 大小、碰撞率、恢复成功率和跨物体/跨场景泛化。面试里要强调：只靠域随机化不够，必须把真实数据闭环接进去。

来源链接 blog.csdn.net/ZHHHHH15/article/details/160808758

Sim-to-Real

域随机化

系统辨识

仿真

具身智能

Q269 具身世界模型如何评估长程任务，为什么需要反事实仿真而不是只看一步预测误差？

方向 世界模型 / 具身智能

岗位 机器人世界模型算法工程师

难度 困难

来源 GitHub 2026-07-25

参考回答

长程具身任务里，一步预测误差低不代表策略可用，因为小误差会在多步交互中累积，而且机器人动作会改变未来状态。世界模型要服务决策，就必须评估在不同动作条件下环境如何演化。反事实仿真的价值在于：同一初始状态下，比较不同候选动作会导致什么后果，例如绕左侧是否碰撞、提前闭合夹爪是否滑落、换抓取点是否更稳。训练上可以用真实轨迹学习状态转移，用仿真扩展危险和稀有场景，用失败回流修正模型盲区。评估应从 open-loop 和 closed-loop 两层做：open-loop 看视觉重建、occupancy、物体位姿和接触状态预测；closed-loop 看任务成功率、碰撞率、恢复率、规划收益和长尾场景通过率。还要输出不确定性，告诉规划器哪些预测不可靠。面试回答的关键是：世界模型不是视频生成器，而是能被策略查询、比较和验证的环境动态模型。

来源链接 github.com/WinstonJQ/embodied-interview-qa

世界模型

反事实仿真

长程任务

闭环评估

具身智能

Q270 视频事件理解中，如何判断事件开始、结束和状态变化，而不是只做整段分类？

方向 视频理解 / 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-07-03

参考回答

整段分类只能回答视频大概是什么，无法解释事件在什么时候发生。事件理解需要把视频切成时间片段，预测每个片段的动作、主体、对象和状态，并回归开始结束边界。状态变化尤其重要，比如杯子从桌上到手里、门从关到开，这类变化要求模型比较事件前后帧。训练数据最好包含动作前、动作中、动作后三类片段，并标注边界和状态。评估时用边界误差、时间交并比、状态问答准确率和跨片段一致性共同判断。

来源链接 zhuanlan.zhihu.com/p/1933187361329611269

腾讯 视频理解 / 多模态大模型 面经 大模型

Q271 端侧 MobileVLM 如何在低算力设备上兼顾视觉理解效果、内存占用和响应延迟？

方向 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 掘金 2026-07-08

参考回答

端侧 MobileVLM 的关键是把视觉和语言两部分都做轻量化。视觉侧可以使用更小的 encoder、低分辨率输入、局部重要区域裁剪和 token 压缩，避免把大量 patch token 送进 LLM。语言侧需要选择小参数模型，并配合 INT8/INT4 量化、KV cache 管理、算子融合和推理引擎优化。为了不明显损失效果，训练时通常用大模型蒸馏小模型，把大 VLM 的答案、推理过程或中间视觉语义迁移到端侧模型；同时保留 OCR、小目标等 hard case 的高质量样本。部署时要分阶段测量图像预处理、vision encoder、prefill、decode 的延迟，不能只看总耗时。实际产品还会设置任务分级：简单识别本地完成，复杂推理转云端或降级处理。

来源链接 juejin.cn/post/7319663384097275942

美团

MobileVLM

端侧部署

量化

视觉压缩

Q272 端侧多模态模型部署时，视觉编码、语言推理和缓存复用分别如何降成本？

方向 推理部署 / 多模态大模型

岗位 大模型相关岗位

难度 中等

来源 小红书 2026-07-03

参考回答

端侧部署要分别压缩视觉侧、语言侧和系统调度。视觉编码可以降低输入分辨率、按任务选择切图数量、缓存重复图片特征，或使用轻量视觉编码器。语言推理侧可采用低比特量化、结构剪枝、小模型蒸馏和短回答约束，减少显存和延迟。缓存复用适合固定系统提示、重复图片或多轮对话中的相同上下文。还要把预处理、编码和生成流水线化，避免 CPU/GPU/NPU 互相等待。评估时不能只看模型准确率，还要看首字延迟、峰值内存、功耗、发热和离线可用性。

来源链接 xiaohongshu.com/explore/69e5b4a70000000020038bbb

华为

推理部署 / 多模态大模型

面经

大模型

Q273 长上下文推理中，位置外推、注意力稀释和证据检索分别会带来什么问题？

方向 推理优化 / 大模型基础

岗位 大模型相关岗位

难度 中等

来源 CSDN 2026-07-03

参考回答

长上下文不是把长度参数调大就结束。位置外推会让模型在训练长度之外的位置关系不稳定，需要缩放策略和长文本继续训练来适配。注意力稀释指关键信息被大量无关 token 淹没，模型可能找不到真正证据。证据检索则决定哪些片段进入上下文，如果召回错了，再强的模型也会答错。工程上通常结合分块索引、重排序、摘要记忆和引用定位，让模型先找到证据再回答。评估时要看 needle-in-a-haystack、跨段推理、引用准确率和长上下文下的延迟成本。

来源链接 blog.csdn.net/weixin_45264425/article/details/157210711

Qwen

推理优化 / 大模型基础

面经

大模型

Q274 推理模型蒸馏时，应该蒸馏最终答案、推理过程还是偏好排序，三者有什么差异？

方向 训练框架 / 推理优化

岗位 大模型相关岗位

难度 中等

来源 知乎 2026-07-03

参考回答

只蒸馏最终答案成本低，但学生模型学不到中间分解方式，遇到新题容易泛化差。蒸馏推理过程能教模型如何拆题、验证和回溯，适合数学、代码和复杂问答，但要过滤错误或冗长推理链。蒸馏偏好排序关注哪个回答更好，可用于训练选择能力或偏好模型，但不直接提供完整解题路径。实践中常把三者组合：用高质量过程样本做监督，用最终答案保证简洁正确，再用偏好数据约束风格和可靠性。评估要分别看正确率、推理长度、鲁棒性和错误自检能力。

来源链接 zhuanlan.zhihu.com/p/1974870853121508975

- DeepSeek
- 训练框架 / 推理优化
- 面经
- 大模型

Q275 车端多传感器数据如何做时间对齐、空间标定和异常样本回流，支撑闭环训练？

方向 自动驾驶 / 世界模型

岗位 VLM/VLA 算法实习生

难度 中等

来源 小红书 2026-07-02

参考回答

车端数据闭环要先保证数据本身可对齐、可复现、可追踪。时间对齐上，每路相机、雷达、定位、车控和规划输出都要带统一时钟时间戳；不同频率的数据不能简单按最近帧拼接，而要记录最大时间差，并对车辆运动做插值或补偿。空间标定上，需要维护相机内参、各传感器到车体坐标系的外参，以及外参漂移监控；车辆行驶时还要考虑滚动快门、震动和同步误差。异常样本回流通常来自接管、急刹、低置信度、预测分歧、规则触发和用户反馈，再经过聚类去重、风险分级和人工复核，进入标注和训练集。闭环训练不能只把新数据堆进去，还要做版本管理：记录数据版本、标注版本、模型版本和评测场景版本。最后通过离线回放、可交互仿真和小流量线上验证确认新模型是否真的降低接管率和风险，而不是只提高单帧指标。

来源链接 xiaohongshu.com/explore/6a4486d500000000170285f1

小鹏

自动驾驶

多传感器数据

数据闭环

VLA

Q276 VLA 动作生成中，CVAE、Diffusion Policy 和 Flow Matching 分别适合什么场景？

方向 VLA / 动作生成

岗位 VLA动作生成算法工程师

难度 困难

来源 与非网 2026-07-20

参考回答

三者都在解决动作多峰分布问题，但侧重点不同。CVAE 通过潜变量建模多种可行动作，训练和采样相对简单，适合 ACT 这类 action chunk 模型；缺点是潜变量表达能力有限，复杂接触任务里可能生成平均化动作。Diffusion Policy 通过逐步去噪生成动作序列，能表达复杂多峰轨迹，适合绕障、抓取、插入等存在多种可行解的任务；缺点是采样步数多，部署时要考虑延迟，可用 DDIM、蒸馏或短步数采样优化。Flow Matching 学习从简单分布到动作分布的连续变换，推理可更高效，也适合和大规模 transformer 动作专家结合。实际选择要看任务复杂度、控制频率、延迟预算和数据规模。面试回答要落到工程指标：轨迹成功率、动作平滑度、推理耗时、对多峰动作的覆盖、真机稳定性和失败恢复能力。

来源链接 eefocus.com/article/2015453.html

- CVAE
- Diffusion Policy
- Flow Matching
- 动作生成
- VLA

Q277 面试中如何系统比较 RT-2、OpenVLA、 π 0、GR00T 和 SmolVLA 这类 VLA/机器人基础模型？

方向 VLA / 机器人基础模型

岗位 机器人基础模型算法工程师

难度 困难

来源 古月居 2026-07-21

参考回答

比较 VLA 模型不要只背论文名，要按统一维度拆。第一看输入输出：是否使用图像、语言、本体状态，输出是离散 token、连续动作还是 action chunk。第二看主干结构：RT-2 更强调把 web-scale VLM 知识迁移到机器人动作，OpenVLA 强调开放数据和通用 VLA， π 0 更强调连续动作专家和 flow matching，GR00T 更偏人形机器人通用基础模型，SmolVLA 则关注轻量化部署。第三看数据来源：互联网视觉语言数据、机器人遥操作数据、仿真数据和多机器人数据占比不同，会影响泛化和控制能力。第四看动作表示和实时性：离散 token 接 LLM 方便但精度有限，连续动作适合控制但训练难，轻量模型更适合边缘部署。第五看评估：仿真 benchmark、真机任务成功率、跨场景泛化、延迟和安全失败。回答时最好补一句：模型能力最终要落到数据闭环和真机稳定性，而不是参数规模。

来源链接 guyuehome.com/wap/detail

- RT-2
- OpenVLA
- π 0
- GR00T
- VLA

Q278 长程具身任务中，如何把语言指令拆成子目标，并把子目标稳定落到低层控制器执行？

方向 VLA / 具身智能

岗位 具身智能算法工程师

难度 困难

来源 牛客 2026-07-17

参考回答

这题要先说明层级结构：高层负责把自然语言任务拆成可验证的子目标，例如“找到杯子、抓取杯子、移动到桌面、放下杯子”；中层负责把子目标绑定到场景状态和可操作对象；低层控制器负责生成连续动作或轨迹。关键不是简单做 prompt 分解，而是每个子目标都要有可观测的完成条件，例如物体是否被抓住、位姿是否到达、接触力是否稳定。工程上通常会让 VLM/VLA 负责语义理解和动作意图，再由 motion planner、diffusion policy 或 MPC 负责短时控制。为了稳定执行，需要加入状态重估和闭环修正：每执行一个 action chunk 后重新感知，检查目标是否偏移、夹爪是否打滑、环境是否变化。失败时不能一直重试同一动作，而要区分感知失败、抓取失败、路径不可达和动力学异常，再选择重规划、换抓取点或人工接管。评估不能只看最终成功率，还要看子目标完成率、平均重试次数、碰撞率、执行时间和跨场景泛化能力。

来源链接 nowcoder.com/search

具身智能

VLA

任务规划

低层控制

长程任务

Q279 VLA 遥操作数据采集后，如何做质量控制、异常样本筛选和训练集构造？

方向 VLA / 机器人数据

岗位 机器人数据算法工程师

难度 困难

来源 牛客 2026-07-25

参考回答

遥操作数据不能采完就直接训练。首先要做完整性检查：图像、深度、本体状态、动作、语言指令、时间戳和成功标记是否齐全。其次做时间对齐和轨迹切分，把连续日志切成 episode，并标注成功、失败、中断、人工接管和环境异常。质量控制要筛掉明显坏样本，比如相机遮挡、外参错误、夹爪空抓、动作抖动、延迟过大、任务描述和实际动作不一致。异常样本不能全部删除，失败样本如果标注清楚原因，反而可以用于失败预测、恢复策略和偏好学习。训练集构造要平衡任务、物体、场景、视角和成功/失败比例，避免模型只记住某个背景或操作员习惯。还要保留 hard cases，如遮挡、反光、软物体、狭窄空间和多物体干扰。评估时看数据覆盖率、标注一致性、训练后真机成功率、失败恢复率和跨场景泛化。

来源链接 nowcoder.com/feed/main/detail/7b8f541c9bef4733a0f738d0628b1f65

遥操作

机器人数据

VLA

数据质检

具身智能

Q280 人形机器人 VLA 动作表征应该关注哪些关键点，如何兼顾语义可控、物理可行和安全约束？

方向 VLA / 人形机器人

岗位 VLA算法工程师

难度 困难

来源 CSDN 2026-07-17

参考回答

人形机器人的动作表征不能只追求模型容易输出，还必须满足物理可行和安全约束。首先要明确动作层级：高层可以是语言子目标或技能 token，中层可以是末端位姿、足端轨迹、抓取点和目标姿态，低层才是关节角、速度或力矩。其次要考虑全身动力学，人形机器人有平衡、接触、摩擦锥、关节限位和自碰撞约束，不能让 VLA 直接生成无约束关节序列。第三是动作时间尺度，长程任务适合输出 action chunk 或技能片段，短时接触控制需要更高频反馈。第四是可解释性和可干预性，最好保留目标物体、目标位姿、接触点、步态阶段等中间量，便于安全过滤和失败诊断。训练上要用遥操作、仿真、真机失败和人工接管数据覆盖多种状态。评估看任务成功率、跌倒率、碰撞率、能耗、动作平滑度和恢复能力。

来源链接 blog.csdn.net/limengshi138392/article/details/161154768

VLA

动作表征

人形机器人

动作优化

具身智能

Q281 端到端 VLA 推理频率低于机器人控制频率时，如何设计 action chunk、插值和安全控制？

方向 VLA / 具身智能

岗位 VLA 算法工程师

难度 困难

来源 牛客 2026-07-16

参考回答

VLA 通常运行在较低频率，例如 1-10Hz，而机械臂或底盘控制可能需要 50-1000Hz，所以不能让大模型直接承担所有低层伺服控制。常见做法是让 VLA 输出 action chunk，也就是未来一小段时间的动作序列或关键路点，低层控制器在高频循环里执行插值、轨迹跟踪和安全约束。chunk 不能过长，否则环境变化后动作会滞后；也不能过短，否则模型调用频繁、延迟和抖动会放大。工程上会保留一个滚动窗口：新 chunk 到来后平滑替换旧 chunk，并用观测反馈判断是否提前中止。插值层需要考虑速度、加速度、jerk 和关节限位，不能只做线性插值。安全控制通常放在模型之后，包括碰撞检测、力控阈值、急停、workspace 限制和人机距离约束。面试中可以补充指标：端到端延迟、控制频率、chunk 命中率、动作平滑度、碰撞率、急停次数和任务成功率。核心观点是 VLA 提供语义到动作的意图，低层控制保障实时性和安全边界。

来源链接 nowcoder.com/search

VLA

端到端控制

延迟

action chunk

机器人系统